

中图分类号：TP273

论文编号：1028703 18-B038

学科分类号：081101

博士学位论文

自适应动态规划研究及其在导弹 拦截制导中的应用

研究生姓名	孙景亮
学科、专业	控制理论与控制工程
研究方向	现代飞行器的先进控制理论研究
指导教师	刘春生 教授

南京航空航天大学

研究生院 自动化学院

二〇一九年三月

Nanjing University of Aeronautics and Astronautics
The Graduate School
College of Automation Engineering

Research on Adaptive Dynamic Programming and Its Applications to the Missile Interception Guidance

A Thesis in
Control Theory and Control Engineering

by

Jingliang Sun

Advised by

Prof. Chunsheng Liu

Submitted in Partial Fulfillment

of the Requirements

for the Degree of

Doctor of Philosophy

March, 2019

摘 要

作为近年来新兴起的一种近似最优控制方法, 自适应动态规划(Adaptive Dynamic Programming, ADP)技术本质上基于强化学习(Reinforcement Learning, RL)原理, 将控制理论与计算智能有机结合, 通过采用函数近似结构, 有效解决了非线性系统的最优控制/微分对策问题, 因此, ADP 技术受到国内外研究学者的广泛关注。此外, 随着航空航天技术的快速发展以及各类新型智能飞行器的不断涌现, 传统拦截制导方法已难以适应未来航空航天领域任务快速变化、多目标决策以及复杂环境下的轨迹自适应调整需求。为了提升复杂动态环境下导弹的巡航、突防、攻击等在线任务调整能力, 实现导弹全方位智能化和自主化要求, 本文将 ADP 技术与导弹制导相结合, 通过融合鲁棒控制、自适应控制、智能控制等现代先进控制方法, 将智能自主思想引入制导律的设计过程, 提出新型的自适应最优拦截制导方案。本论文研究工作丰富和发展了 ADP 理论, 并进一步为未来智能制导系统的发展提供可借鉴的理论指导和前瞻性探索经验。具体研究内容为:

(1) 考虑拦截制导系统由于导弹飞行速度和飞行高度变化引起的内部扰动以及外界干扰等不确定项影响, 研究基于微分对策的鲁棒自适应最优拦截制导问题; 通过将不确定项的上界函数引入性能指标函数中, 将原不确定系统的鲁棒控制问题转化为其标称系统的最优调节控制问题。通过改进微分对策控制策略, 从理论上保证了原系统在干扰影响下的渐近稳定性和最优性。利用 ADP 技术, 构建评价网络结构, 在线执行微分对策控制策略, 保证闭环系统的稳定性; 并将其应用于导弹拦截制导问题中, 仿真验证了该方案的有效性。

(2) 考虑导弹末制导阶段, 由于目标的大机动逃逸, 对导弹终端时间和终端状态提出一定的要求且易造成导弹过载饱和等问题, 研究输入饱和条件下基于微分对策的有限时域自适应最优拦截制导问题; 首先在性能指标函数中引入一个非二次型正定函数用来处理输入饱和问题, 从而推导出输入饱和情况下的微分对策控制策略以及相应的 Hamilton-Jacobi-Isaacs (HJI) 方程。通过构建时变评价网络, 设计评价网络权值更新律, 在线逼近时变最优代价函数, 满足终端约束条件限制。从理论上严格保证了闭环系统的稳定性以及评价网络权值估计误差信号的有界性; 并将其应用于导弹拦截制导问题中, 仿真验证了所提方法的有效性。

(3) 针对导弹在复杂战场环境下可能存在的过载饱和、终端角度约束、终端速度约束等多约束问题, 研究多约束条件下基于微分对策的自适应最优拦截制导问题; 考虑具有严格反馈形式的非线性微分对策系统, 提出前馈+反馈控制结构。首先基于 Backstepping 控制方法, 通过引入辅助动态系统和界限李雅普诺夫函数, 有效处理输入饱和、输出约束等问题, 并设计前馈控制输入, 从而将原系统的跟踪控制问题转化为等效跟踪误差动态系统的最优调节控制问题。基

于此,利用 ADP 技术构建评价网络,在线逼近最优代价函数,保证微分对策控制策略的在线执行。由于采用前馈+反馈复合控制结构,所提出的自适应最优控制方案不仅能够保证闭环系统的稳定性以及系统输出跟踪期望信号,还确保了性能指标函数的最小化。最后将所提方法应用于拦截制导问题,实现了在线自适应最优制导。

(4) 考虑拦截制导系统的高动态特性以及快速响应要求,为有效降低在线自适应最优控制方法的计算复杂度,研究基于 ADP 技术的自适应预测最优拦截制导问题;针对具有块严格反馈形式的非线性系统,结合 ADP 技术和连续时间预测控制方法,提出了离线-在线控制模式。首先基于 Backstepping 控制结构,利用 ADP 技术在线逼近虚拟控制输入,优化虚拟控制输入;接着采用连续时间预测控制方法,离线推导出实际最优控制输入解析表达式。该离线-在线控制模式不仅能够保证闭环系统的最优性,提高控制器的鲁棒性;还有效降低控制器的计算负荷。通过拦截制导仿真对比验证了该方案的有效性和优越性。

(5) 针对多枚导弹共同拦截单一机动目标情形,研究多弹分布式最优协同拦截制导问题;考虑具有严格反馈形式的输入受限非线性多智能系统,采用领导者-跟随者协同模式,提出 Backstepping+ADP 复合控制结构。首先采用指令滤波 Backstepping 控制方法,设计分布式前馈控制输入,并通过设计辅助动态系统补偿输入饱和和影响;设计神经网络逼近未知非线性函数;从而将原系统的协同跟踪控制问题转化为等效局部协同跟踪误差动态系统的分布式最优调节控制问题。在此基础上,利用 ADP 技术构建评价网络结构,在线逼近合作型最优代价函数。基于 Lyapunov 方法,从理论上保证闭环系统的稳定性以及所有跟随者一致跟踪领导者信号,并将所提方法应用于多弹协同拦截机动目标的问题,实现了多弹协同拦截制导。

(6) 考虑传统时间触发机制造成大量计算资源和能量的浪费,甚至可能导致通信信道阻塞,从而破坏系统的稳定性,研究基于事件触发机制的多弹分布式最优协同拦截制导问题;考虑仿射非线性多智能体系统,设计事件触发分布式最优控制律,并给出自适应事件触发条件,保证闭环系统的渐近稳定性。为执行事件触发自适应最优控制器,构建评价网络,在线逼近合作型最优代价函数。基于 Lyapunov 方法分析了闭环系统的稳定性,并进一步从理论上避免了事件触发机制下芝诺行为的发生。通过多弹协同拦截制导仿真,实现了多枚导弹同时攻击机动目标的任务,仿真验证了所提方法的有效性。

关键词: 自适应动态规划 (ADP), 有限时域, 多约束条件, 事件触发, 拦截制导, 协同制导

ABSTRACT

Adaptive dynamic programming (ADP) technique, as a novel approximate optimal control method in recent years, is actually derived from the reinforcement learning (RL) principle. It integrates the control theory and computational intelligence, and utilizes the function approximation structure to deal with the optimal control and differential game problem of nonlinear systems. Therefore, the ADP technique has attracted much attention for the researchers. In addition, with the rapid development of the aerospace technology, various novel intelligent aircrafts have emerged. Thus, the traditional interception guidance methods have been difficult to cope with the future aerospace requirements, such as the rapid task change, multi-objective decision and trajectory adjustable ability adaptively under the complex circumstance. In order to improve the missile's abilities of online task adjustment, such as cruise, penetration and attack, thus realizing the requirements of intelligent and autonomous guidance, in this paper, a promising adaptive optimal interception guidance scheme is developed by combining the ADP technique and missile guidance, which integrates the robust control, adaptive control and intelligent control. This adaptive optimal method brings the intelligent principle into the design of guidance law, which enriches the ADP theory. Furthermore, it will provide the referable theoretical guidance and prospective exploratory experience for the development of intelligent guidance systems in the future. The main contributions are presented as follows.

(1) Considering the effects of uncertainties of interception guidance systems, such as internal perturbation and external disturbance caused by the changes of flight velocity and flight altitude, we study the differential game-based robust adaptive optimal interception guidance problem. By introducing the upper bounded function of uncertainties into the performance index function, the robust control problem of original uncertain system is transformed into an optimal regulation control problem of its nominal system. The asymptotically stability and optimality of the original system with uncertainties can be guaranteed theoretically by modifying the differential game strategy. Then, the critic network is constructed to implement the developed differential game strategy online via ADP technique, and the stability of the closed-loop system is ensured. The effectiveness of the proposed method is verified by applying it to the missile interception guidance problem.

(2) In the terminal guidance phase, considering the large maneuvering of target for escaping, the missile's terminal time and terminal state are both required, and further the overload saturation may occur, we study the differential game-based finite-horizon adaptive optimal interception guidance

problem with input saturation. First, by introducing a nonquadratic positive functional into the performance index function, the differential game strategy with input saturation is derived, and the associated Hamilton-Jacobi-Isaacs (HJI) equation is presented. Subsequently, we construct the time-varying critic network, and then, the time-varying optimal cost function is approximated online by designing a critic network weight updating law. Meanwhile, the terminal constraints are satisfied. The stability of the closed-loop system and the boundedness of critic network weight estimation error signal are both guaranteed. The missile interception guidance problem is utilized to demonstrate the effectiveness of the proposed method.

(3) Considering the fact that missile may suffer multiple constraints under a bad battlefield environment, such as overload saturation, terminal angle constraint, terminal velocity constraint, and so on, we investigate the differential game-based adaptive optimal interception guidance problem with multiple constraints. For the nonlinear differential game systems in strict-feedback form, the feedforward+feedback control architecture is proposed. First, based on the backstepping method, the feedforward control input is given, in which the input saturation and output constraint are overcome by introducing an auxiliary dynamic system and barrier Lyapunov function, respectively. Thus, the tracking control problem of original system is converted into an optimal regulation control problem of the equivalent tracking error dynamic system. Subsequently, the critic network is built to approximate the optimal cost function online by using ADP technique, and thus implementing the proposed differential game strategy. Owing to the feedforward+feedback control architecture, the developed scheme can not only guarantee the stability of the closed-loop system, but also drive the system output track the desired reference signal. Meanwhile, the cost function is ensured to be minimized. Finally, the adaptive optimal guidance is realized by applying it to the interception guidance problem.

(4) Considering the requirements of high dynamic characteristic and fast response of interception guidance systems, to reduce the computational complexity of the online adaptive optimal control method, the adaptive predictive optimal interception guidance problem based on ADP technique is studied. For the nonlinear systems in block strict-feedback form, the offline-online control architecture is developed by combining the ADP technique and continuous-time predictive control method. First, based on the backstepping control structure, the virtual control input is approximated online via ADP technique. Subsequently, the optimal control input in an analytical form is derived offline by using the continuous-time predictive control method. The proposed offline-online control structure not only guarantees the optimality of the closed-loop system, and improves the robustness

of the controller, but also reduces the computational burden of controller effectively. The simulation of interception guidance demonstrates the effectiveness and superiority of the proposed scheme.

(5) Considering the scenario where multiple missiles intercept a single maneuvering target, we investigate the distributed optimal cooperative interception guidance problem of multi-missile systems. For the strict-feedback nonlinear multi-agent system with input saturation, based on the leader-follower mode, the backstepping+ADP compound control structure is developed. First, by utilizing the command filtered backstepping control method, the distributed feedforward control input is designed, in which the auxiliary dynamic system is designed to deal with the input saturation, and the neural network is used to approximate the unknown nonlinear function. Thus, the cooperative tracking control problem of original system is transformed into a distributed optimal regulation control problem of the equivalent local cooperative tracking error dynamic system. Then, by using the ADP technique, the critic network is constructed to approximate the cooperative cost function online. The stability of the closed-loop system is guaranteed by utilizing Lyapunov method. Furthermore, all followers are able to synchronize to the leader signal cooperatively. Finally, the developed scheme is applied to the multi-missile cooperative interception guidance problem.

(6) Considering the fact that the traditional time-triggered mechanism may consume tremendous computation resources and energy, even leads to the obstruction of communication channel, and thus destroying the system stability, we study the event-triggered distributed optimal cooperative interception guidance problem of multi-missile systems. For the affine nonlinear multi-agent systems, the event-triggered distributed optimal control law is proposed. Then, an adaptive triggering condition is given to guarantee the asymptotically stability of the closed-loop system. In order to implement the proposed controller, the critic network is built to approximate the cooperative optimal cost function online. By using Lyapunov method, the stability of the closed-loop system is analyzed. Furthermore, the infamous Zeno behavior is avoided theoretically. By applying the proposed scheme into the multi-missile interception guidance system, the missiles are able to attack the target simultaneously, which verifies its effectiveness.

Key Words: Adaptive dynamic programming (ADP), finite-time, multiple constraints, event-triggered, interception guidance, cooperative guidance

目 录

第一章 绪论	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状分析.....	4
1.2.1 自适应动态规划研究现状.....	4
1.2.2 自适应动态规划技术在航空航天领域的研究现状	11
1.3 本文研究内容及章节安排.....	12
第二章 基于微分对策的鲁棒自适应最优拦截制导	15
2.1 引言	15
2.2 问题描述	15
2.3 鲁棒微分对策控制策略设计.....	17
2.4 自适应最优控制器设计.....	20
2.5 稳定性分析	22
2.6 导弹拦截制导应用.....	26
2.6.1 导弹-目标拦截制导模型建立	26
2.6.2 制导原则.....	27
2.6.3 非线性微分对策系统.....	28
2.7 仿真验证	28
2.8 本章小结	31
第三章 输入饱和条件下的有限时域微分对策拦截制导	32
3.1 引言	32
3.2 问题描述	32
3.3 微分对策控制策略在线执行.....	34
3.4 稳定性分析	37
3.5 仿真验证	42
3.5.1 拦截制导模型变换.....	43
3.5.2 仿真结果.....	43
3.6 本章小结	45
第四章 多约束条件下基于微分对策的自适应最优拦截制导	47
4.1 引言	47
4.2 问题描述	47

4.3 前馈控制输入设计	49
4.4 反馈最优控制输入设计	52
4.5 稳定性分析	55
4.6 仿真验证	58
4.7 本章小结	61
第五章 基于 ADP 技术的自适应预测最优拦截制导	62
5.1 引言	62
5.2 问题描述	62
5.3 虚拟控制输入的设计	64
5.3.1 最优虚拟控制输入设计	64
5.3.2 虚拟控制输入的实现	64
5.3.3 评价网络稳定性分析	66
5.4 实际控制输入设计	68
5.5 仿真验证	69
5.6 本章小结	75
第六章 基于 ADP 技术的多弹分布式最优协同拦截制导	77
6.1 引言	77
6.2 预备知识及问题描述	77
6.2.1 图论	77
6.2.2 问题描述	78
6.3 分布式前馈控制输入设计	78
6.4 分布式最优反馈控制输入设计	83
6.4.1 分布式最优控制设计	83
6.4.2 分布式最优控制的实现	84
6.5 稳定性分析	86
6.6 多导弹协同拦截制导应用	89
6.7 仿真验证	92
6.8 本章小结	96
第七章 基于事件触发机制的多弹分布式最优协同拦截制导	97
7.1 引言	97
7.2 问题描述	97
7.3 事件触发分布式最优控制律设计	98

7.4 事件触发分布式最优控制律实现.....	100
7.5 稳定性分析	102
7.6 最小驻留时间分析.....	106
7.7 仿真验证	107
7.7.1 多弹协同拦截制导应用.....	107
7.7.2 数值仿真.....	108
7.8 本章小结	112
第八章 总结与展望	113
8.1 主要工作总结	113
8.2 后续工作展望	114
参考文献	115
致 谢	130
在学期间的研究成果及发表的学术论文.....	131

图清单

图 1.1 “宙斯盾”反导示意图.....	2
图 1.2 陆基中段反导示意图.....	2
图 1.3 拦截制导示意图.....	2
图 1.4 协同制导示意图.....	2
图 1.5 本文主要研究内容及章节安排框图.....	12
图 2.1 导弹-目标相对运动示意图	27
图 2.2 鲁棒微分对策下弹-目拦截轨迹和相对距离	29
图 2.3 鲁棒微分对策下导弹视线角速率和相对速率	29
图 2.4 鲁棒微分对策下导弹和目标侧向加速度	30
图 2.5 鲁棒微分对策下评价网络权值和残余误差	30
图 2.6 鲁棒微分对策下弹-目拦截轨迹和相对距离（目标正弦机动）	30
图 2.7 鲁棒微分对策下导弹视线角速率和相对速率（目标正弦机动）	31
图 2.8 鲁棒微分对策下导弹侧向加速度（目标正弦机动）	31
图 3.1 有限时域饱和和微分对策弹-目拦截轨迹和相对距离.....	44
图 3.2 有限时域饱和和微分对策导弹视线角速率和相对速率	44
图 3.3 有限时域饱和和微分对策控制输入和侧向加速度	44
图 3.4 有限时域饱和和微分对策评价网络权值	45
图 3.5 有限时域饱和和微分对策弹-目拦截轨迹和控制输入（存在量测噪声）	45
图 4.1 多约束条件下自适应最优控制结构图	49
图 4.2 多约束条件下弹-目拦截轨迹和相对距离	59
图 4.3 多约束条件下导弹视线角速率和相对速率	59
图 4.4 多约束条件下导弹视线角和侧向加速度	60
图 4.5 多约束条件下评价网络权值和残余误差	60
图 4.6 多约束条件下弹-目拦截轨迹和相对距离（目标正弦机动）	60
图 4.7 多约束条件下导弹视线角速率和相对速率（目标正弦机动）	61
图 4.8 多约束条件下导弹视线角和侧向加速度（目标正弦机动）	61
图 5.1 自适应预测最优制导轨迹和侧向加速度（目标阶跃机动）	71
图 5.2 自适应预测最优制导下导弹视线角速率和相对速率（目标阶跃机动）	71
图 5.3 自适应预测最优制导下评价网络权值和导弹控制能量（目标阶跃机动）	71
图 5.4 自适应预测最优制导轨迹和导弹侧向加速度（目标正弦机动）	72

图 5.5 自适应预测最优制导下导弹视线角速率和相对速率（目标正弦机动）	72
图 5.6 自适应预测最优制导下评价网络权值和导弹控制能量（目标正弦机动）	72
图 5.7 自适应预测最优制导轨迹和导弹侧向加速度（目标方波机动）	73
图 5.8 自适应预测最优制导下导弹视线角速率和相对速率（目标方波机动）	73
图 5.9 自适应预测最优制导下评价网络权值和导弹控制能量（目标方波机动）	73
图 5.10 自适应预测最优制导轨迹和导弹侧向加速度（不同预测时间）	75
图 5.11 自适应预测最优制导轨迹和导弹侧向加速度（时变预测时间）	75
图 6.1 分布式自适应最优控制结构图.....	86
图 6.2 多弹协同拦截制导示意图.....	90
图 6.3 各导弹通信拓扑图.....	92
图 6.4 多弹协同拦截制导轨迹和相对距离（目标不机动）	93
图 6.5 各导弹视线角速率和相对速率（目标不机动）	93
图 6.6 各导弹视线角和碰撞角（目标不机动）	94
图 6.7 各导弹侧向加速度（目标不机动）	94
图 6.8 自适应参数 $\hat{\theta}_{i,2}$ （目标不机动）	94
图 6.9 多弹协同拦截制导轨迹和相对距离（目标常值机动）	95
图 6.10 各导弹视线角速率和相对速率（目标常值机动）	95
图 6.11 各导弹视线角和碰撞角（目标常值机动）	95
图 6.12 各导弹侧向加速度（目标常值机动）	96
图 6.13 自适应参数 $\hat{\theta}_{i,2}$ （目标常值机动）	96
图 7.1 事件触发分布式最优控制结构图.....	102
图 7.2 事件触发机制下多弹通信拓扑图.....	108
图 7.3 事件触发机制下多弹协同拦截轨迹和侧向加速度（目标阶跃机动）	109
图 7.4 事件触发机制下相对距离和相对速率（目标阶跃机动）	110
图 7.5 事件触发条件和评价网络权值范数（目标阶跃机动）	110
图 7.6 事件触发时刻（目标阶跃机动）	110
图 7.7 事件触发机制下多弹协同拦截轨迹和侧向加速度（目标正弦机动）	111
图 7.8 事件触发机制下相对距离以及相对速率（目标正弦机动）	111
图 7.9 事件触发机制条件和评价网络权值范数（目标正弦机动）	112

表清单

表 5.1 不同目标机动下各制导方法脱靶量对比..... 74

表 5.2 存在量测噪声情况下各制导方法脱靶量对比..... 74

表 7.1 目标阶跃机动下的制导性能..... 110

表 7.2 目标正弦机动下的制导性能..... 112

注释表

$\mathbb{R}$	实数域	M	导弹
$\mathbb{R}^n$	n 维实向量	T	目标
$\mathbb{R}^{n \times m}$	$n \times m$ 维实数矩阵	V_M, V_T	导弹和目标的速率
$\ \xi\ $	向量 ξ 的欧式范数	α, β	导弹和目标的航迹角
$\ A\ $	矩阵 A 的 2 范数	θ	视线角
M^T	矩阵 M 的转置	$\sigma = \dot{\theta}$	视线角速率
$P > 0$	矩阵 P 正定	u_M, v_T	导弹和目标的输入
$L_2[0, \infty)$	在 $[0, \infty)$ 上平方可积的连续函数空间	r	弹-目相对距离
$\lambda_{\min}(A)$	矩阵 A 的最小特征值	$V_r = \dot{r}$	弹-目相对速率
$\lambda_{\max}(A)$	矩阵 A 的最大特征值	a_M, a_T	导弹和目标的侧向加速度
x^*	变量 x 的最优值	τ_M, τ_T	自动驾驶仪时间常数

缩略词

缩略词	英文全称	中文名称
ADP	Adaptive Dynamic Programming	自适应动态规划
RADP	Robust Adaptive Dynamic Programming	鲁棒自适应动态规划
RL	Reinforcement Learning	强化学习
DP	Dynamic Programming	动态规划
PI	Policy Iteration	策略迭代
VI	Value Iteration	值迭代
HJB	Hamilton-Jacobi-Bellman	哈密顿-雅可比-贝尔曼
HJI	Hamilton-Jacobi-Isaacs	哈密顿-雅可比-艾萨克斯
DSC	Dynamic Surface Control	动态面控制
PN	Proportional Navigation	比例导引
NN	Neural Network	神经网络
BLF	Barrier Lyapunov Function	界限李雅普诺夫函数
MIMO	Multiple-Input and Multiple-Output	多输入多输出
PE	Persistence of Excitation	持续激励
UUB	Uniformly Ultimately Bounded	最终一致有界

第一章 绪论

1.1 研究背景及意义

自从第二次世界大战中，德国“V-2”导弹问世以来，导弹作为一种强威慑与大威力精确制导武器，逐渐开始出现在近现代战场中，并开始发挥其主导作用。特别是随着现代军事技术的不断发展，使得导弹拥有了射程远、威力大、精度高、速度快等特点，改变了传统陆海空作战的时空观念，从而改变了现代战争模式，让世界各国认识到导弹在现代战争以及国防建设等方面的重要作用 and 巨大潜力。因此导弹已经成为各国进行国防建设、军事变革以及战略储备的优选目标^[1]。在现代局部战争中，导弹始终扮演着“首当其冲，先发制人”的重要角色^[1]，已经发挥出无可替代的巨大作用，并成为把握战场先机，影响战争态势的重要攻防武器装备之一，给现代战争赋予了新的思想，带来了全新的作战理念。在当今信息化大背景下，各国的武器发展战略思想已经由传统以“强”制胜，转变为现在以“精”制胜，并最终发展为以“智”制胜的高度信息化、自主化和智能化的战略指导思想。进一步发展新型精确制导武器，提升导弹的制导性能，使之能够最大限度地服务于现代化战争，必将成为当今乃至未来国防建设以及信息化战争中至关重要的环节。

另一方面，面对精确制导武器带来的巨大挑战和威胁，空中防御能力的强弱无疑将对战争态势产生重要的影响，甚至直接左右战场的胜负。正所谓，有矛必有盾，可以说精确制导技术和空中防御技术是一对相互依存、相互制约的矛盾。例如，海湾战争中，“爱国者”2反战术弹道导弹成功拦截“飞毛腿”导弹，这是导弹制导技术与拦截制导技术的首次空中交锋，也是精确制导武器与强劲“克星”之间的首次攻防对决，这一成功案例让人们看到了导弹拦截制导技术的巨大潜力和应用前景。因此发展先进的导弹拦截制导系统不仅能够有效遏制精确制导武器带来的威胁和挑战，极大地提升空中防御能力，而且对我国国防安全建设等方面均具有重要的战略意义。此后导弹拦截制导技术便引起世界各军事大国的高度重视，并成为各国国防武器研究的重要任务之一。经过近几十年的快速发展，导弹拦截制导技术得到了长足的发展，开始不断装备部队，并投入使用，为国家和地区和平发展、国防建设做出了重要的贡献。其中最具代表性的当属美国部署的“宙斯盾”反导系统（如图 1.1）、“陆基中段防御”系统（如图 1.2）、“爱国者”反导系统、“萨德”反导系统以及俄罗斯的 S-400、S-500 防空反导系统。我国反导计划起步于上世纪六十年代，经过多年不断的探索和技术储备，取得了突破性的进展，并分别于 2010 年和 2013 年进行了两次反导试验并取得成功，成为继美国和俄罗斯之后世界上第三个掌握路基中段反导技术的国家。但相比美俄“三位一体”、空天防御一体化的导弹防御系统，我国反导技术研究与应用尚处于试验、起步阶段，还未形成全方位、立体化的反导拦截系统，形

势仍不容乐观。



图 1.1 “宙斯盾”反导示意图




图 1.2 陆基中段反导示意图

传统的导弹拦截技术主要是针对地面移动目标、有人驾驶飞行器等速度较慢的目标。采用传统的制导律（如比例导引）即可成功拦截，保证拦截制导精度^[2]。然而随着现代军事技术的快速发展，战术弹道导弹、高速智能巡航导弹、无人驾驶飞行器等新型目标不断涌现。它们不仅具备速度快、机动能力强、结构强度高特点，而且还具有根据不断获取的信息，更新和调整机动策略的能力，这些因素导致传统拦截器的拦截制导精度已不能满足要求，甚至可能会出现由于拦截器法向过载饱和而引起脱靶等现象，对传统拦截制导方式以及制导系统的稳定性和鲁棒性均带来了巨大的挑战。于是如何提升拦截制导系统的拦截能力，增大拦截概率，对进一步发展我国国防建设、实现武器装备的现代化具有重要的意义。通常情况下，提升导弹拦截能力的主要途径有以下两种形式：一种是通过设计更为先进、自主的拦截制导律（如图 1.3），提高制导系统的稳定性和鲁棒性，保证导弹对高速、大机动突防目标的有效拦截；另一种方式是通过多枚导弹协同拦截制导（如图 1.4），通过信息共享、战术协同等方式，实现多层次、全方位饱和拦截，提升导弹的整体拦截能力。



图 1.3 拦截制导示意图



图 1.4 协同制导示意图

然而，不论采取何种拦截制导方式，拦截制导律正如一个人的大脑，在整个拦截制导过程中都起着举足轻重的作用。据有关资料报道，导弹命中精度每提高一倍就相当于战斗部提高八倍的杀伤效果，由此可见提高导弹制导精度是非常重要的。此外，为了保证对机动目标的精确、高效打击，制导律在攻击末端往往对脱靶量、攻击角、攻击时间等变量有一定约束要求。另外

考虑到快速机动的新型目标也必然会采取主动规避的方式躲避拦截，甚至有可能使用各种干扰手段（如伪装、隐蔽、欺骗等）试图躲避拦截^[3]，从而达到突防的目的，这不仅对拦截器制导系统的稳定性与鲁棒性提出了更高的要求，也给拦截制导律的设计增加了难度。基于此种考虑，通过融合智能控制、机器学习以及现代控制理论的诸多先进方法，发展一种新型的智能拦截制导系统对提升我国空中防御力量，加强国防现代化建设具有十分重要的战略意义。所谓智能拦截制导系统就是使拦截器能够根据目标的机动信息，实时在线地自主学习调整拦截制导律，以应对复杂环境下的各种突发情况，从而达到高效、精准拦截的系统。

最优控制理论从上世纪五十年代被提出来以后，由于其不仅能够考虑导弹-目标的动力学问题，而且可以考虑制导过程起点或终点的约束条件^[4]，如终端脱靶量最小、最短时间、最小控制能量等特殊要求，根据给定的不同性能指标推导出最优制导律，于是很快就在航空航天领域获得广泛应用，并成功应用于导弹制导律的设计中。然而最优制导律的形式与性能指标、控制约束、终端约束、对目标加速度信息有效性的假设以及导弹的动力学系统等密切相关，虽然在一定的假设条件下能给出具体的解析表达式，但通常涉及求解矩阵微分方程的两点边值问题。如果考虑导弹-目标的非线性动态特性，则最优制导律的推导转化为非线性偏微分方程，Hamilton-Jacobi-Bellman (HJB)方程的求解。进一步考虑到导弹拦截制导过程中可能出现的过载饱和、碰撞角约束、弹着时间约束等复杂约束以及外界干扰等不确定因素的影响，则该 HJB 方程的求解问题变得更加困难，从而在一定程度上制约了其在拦截制导系统中的应用。

再者，微分对策作为控制论与对策论的重要分支，是研究双方或多方最优控制的理论。它是一种解决冲突对抗或竞争问题的有效工具和科学依据，并能够根据具体的对抗或冲突问题进行建模分析^[5]。而导弹拦截制导问题就是一类典型的零和微分对策问题。这是因为在末制导过程中，机动目标和拦截弹都是独立控制的，他们都在各自寻求相应代价函数的最大化或最小化。拦截弹试图通过调整策略使脱靶量最小化，而目标试图调整策略逃避拦截，使脱靶量最大化，如此便形成了一种典型的零和微分对策问题。与最优制导相比，微分对策制导不需要机动目标未来的信息，而只需要目标当前的机动加速度信息，理论上对任何可实现的机动目标而言是鲁棒的，于是微分对策制导被广泛应用于各种不同的军事对抗问题中。但是与最优制导问题类似，在复杂动态环境下面对非线性拦截制导系统，微分对策问题的设计往往转化为非线性偏微分方程，Hamilton-Jacobi-Isaacs (HJI) 方程的求解问题。考虑到此类偏微分方程求解的困难性，现有微分对策制导方法大多基于线性化模型设计，从而造成了一定的保守性。特别是面对高速、大机动目标，基于线性化模型设计的微分对策制导方法往往不能够奏效，甚至导致脱靶。因此，提出一种能够在线学习的最优制导律或微分对策制导律，不仅能够有效解决最优制导系统的设计问题，还能为一般非线性系统的最优控制问题提供设计思路。

自适应动态规划 (Adaptive Dynamic Programming, ADP) 技术是近年来最优控制领域新兴起

的一种近似最优控制方法,已经逐渐成为最优控制领域的研究热点^[6]。由于 ADP 理论融合了强化学习(Reinforcement Learning, RL)、动态规划(Dynamic Programming, DP)以及智能控制等方法,利用函数近似结构来近似 HJB 方程的解,从而能够有效地解决非线性系统的最优控制问题。它是一种依托于现代控制理论和计算智能理论的新型智能控制理论与方法^[7]。ADP 技术的基本结构是执行器-评价器结构;执行器模块通过和环境交互产生决策或控制,评价器模块通过评价函数来判断系统性能的优劣来调整控制策略。由于其表现出的诸多优点和巨大潜力,ADP 技术已经得到了广泛的关注与研究并取得了一些代表性的成果^[6-9]。但现在大部分研究成果均倾向于 ADP 算法理论的研究以及在工业、电力系统领域的应用,而在航空航天领域,相关研究成果并不多见,特别是基于 ADP 技术的拦截制导问题的研究至今鲜见。

基于上述考虑,本课题将 ADP 技术与导弹拦截制导问题相结合,旨在发展一种新型自适应最优制导方案,将自主智能思想引入制导律的设计过程,使导弹能够根据目标的机动信息实时在线学习调整制导律,达到独立自主、智能作战的要求,从而保证导弹拦截制导的精确化、灵巧化和智能化。作为一种全新的智能优化在线制导方法,本项目对自适应最优制导的研究将会为未来智能化武器的发展提供理论参考和前瞻性探索经验,有助于丰富和完善 ADP 理论体系,拓宽 ADP 的应用范围;同时对飞行器攻防对抗,弹道导弹突防等方面也具有重要的意义。

1.2 国内外研究现状分析

1.2.1 自适应动态规划研究现状

自适应动态规划思想由 Werbos 在上世纪八十年代首次提出^[10],其基本思想就是利用一个函数近似结构来估计代价函数,从而避免了传统动态规划计算“维数灾”问题,为高维复杂非线性系统的最优控制提供了一个便捷、有效的解决方法。鉴于其在处理高维复杂非线性系统最优控制领域的优势,ADP 技术的研究得到广大学者的青睐,并取得了一系列相关成果,由此也产生了一些同义名词,如自适应评价设计(Adaptive Critic Design)^[11-13]、近似动态规划(Approximate Dynamic Programming)^[14-16]、神经元动态规划(Neuro-Dynamic Programming)^[17]、强化学习(Reinforcement Learning)^[18-20]等。为此,在 2006 年召开的“2006 NSF Workshop and Outreach Tutorials on Approximate Dynamic Programming”研讨会上,与会人员一致建议将这种方法统称为 Adaptive/Approximate Dynamic programming。此后,IEEE 计算智能协会于 2008 年专门成立 ADP 与 RL 技术委员会,我国自动化学会也相继成立了自适应动态规划与强化学习专业委员会,并获得相关领域专家一致认可,标志着 ADP 成为一个重要的研究领域。经过几十年的发展,特别是近十年的研究,ADP 理论研究日趋成熟,并取得了丰硕的研究成果,在国际上已经出版数本专著^[21-24]以及多篇综述性文章^[6-9; 17; 25-27]。其理论研究主要涉及稳定性分析、收敛性证明以及在各类控制问题中的应用。可以根据不同的标准进行分类。按照其算法迭代方式主要分为策略迭

代法(Policy Iteration, PI)和值迭代法(Value Iteration, VI) (统称迭代 ADP 算法); 按照其算法执行方式可以分为离线迭代算法和在线自适应算法。考虑到本文主要研究基于 ADP 技术的在线自适应最优控制问题, 在接下来的分析中将着重梳理基于 ADP 技术的在线自适应算法。

发展 ADP 技术的在线自适应算法主要是考虑到离线迭代方法不能够保证在系统结构发生变化或者外界环境影响下闭环系统的稳定性, 从而降低了控制器的鲁棒性。近年来, 国内外相关研究人员热衷于研究 ADP 技术的在线自适应算法。其中 Frank L. Lewis 教授及其团队多年来一直致力于 ADP 算法的研究, 并取得了丰硕的研究成果^[28-30]。在文献[28]中, Vrabie 等针对连续线性系统, 提出了基于策略迭代思想的最优控制律。该方法通过策略评估和策略提高两步骤的不断交替迭代, 最终保证迭代策略收敛于最优控制策略, 实现了闭环系统的最优性, 同时也放松了最优控制对系统动态信息的依赖性。随后他们将其相关理论拓展到非线性系统的最优控制问题中^[29]。在文献[30]中, Vamvoudakis 等针对非线性系统的最优控制问题, 提出了执行-评价网络控制结构, 利用神经网络对非线性函数的逼近能力, 分别逼近最优代价函数和最优控制律; 为了保证执行网络和评价网络同步在线更新, 分别设计了自适应权值更新律, 并保证了闭环系统的稳定性。东北大学张化光教授及其团队近年来在 ADP 领域也取得了丰硕的研究成果。其研究成果主要针对仿射系统^[31]、非仿射系统^[32]、时滞系统^[33]以及非线性奇异摄动系统^[34]等开展研究, 针对非线性系统中的时滞、饱和、干扰等问题, 提出了一整套基于 ADP 技术的最优控制方法, 为 ADP 技术的发展作出了重要的贡献。中科院刘德荣教授及其团队在 ADP 领域也进行了深入的研究, 形成了一系列重要成果。其中王鼎老师近年来主要针对连续非线性系统的最优控制问题, 提出并发展了基于鲁棒自适应评价机制的在线自学习最优控制算法, 解决了非线性系统受干扰、输入饱和以及模型未知等问题^[35-38]。魏庆来老师主要研究了迭代 ADP 算法的收敛性和稳定性问题, 提出了全局迭代 ADP 算法和局部迭代 ADP 算法, 并将其部分研究成果应用于工业控制领域^[39-43]。纽约大学 Jiang 教授及其团队将 ADP 技术与小增益定理相结合, 提出了鲁棒自适应动态规划(Robust Adaptive Dynamic Programming, RADP)方法, 该方法针对完全未知动态的线性系统, 通过利用系统输入输出数据, 实现了基于数据驱动的鲁棒最优控制问题^[44], 并将其推广到模型完全未知的非线性系统的最优控制问题中^[45-48]。辽宁工业大学佟绍成教授及其团队将 Backstepping 控制方法与 ADP 技术相结合, 研究了严格反馈非线性系统的自适应最优跟踪控制问题以及容错控制问题, 并取得了一定的研究成果^[49-53]。

上述研究成果主要是针对不同的控制问题开展研究, 而在稳定性控制方面, 有关 ADP 技术的在线自适应算法主要还是采用 Lyapunov 稳定性分析方法, 保证闭环系统的稳定性。目前 ADP 理论成果中, 主要涉及镇定调节控制、输入饱和约束控制、跟踪控制、鲁棒控制、微分对策控制、事件触发控制以及多智能体协同控制等问题。接下来本文将重点从以下几个方面进行分类详述。

1) 鲁棒 ADP 控制

鲁棒 ADP 控制主要是考虑控制系统在内部扰动、外界干扰以及模型未知等不确定因素影响下, 利用 ADP 技术实现系统的鲁棒最优控制。鲁棒 ADP 控制一直都是相关科研工作者关注的重点, 当然也取得了很多研究成果。在文献[35]中, 针对非线性系统存在内部干扰问题, 通过修改性能指标函数, 将干扰界值函数引入性能指标函数中, 从而将存在干扰情况下的非线性系统的鲁棒最优控制问题转化为等效的标称系统的最优调节控制问题。通过设计改进型的最优控制律, 既保证了原闭环系统在干扰情况下的渐近稳定性, 也实现了闭环系统的最优性。随后, 作者将其理论成果拓展到未知非线性系统的最优控制问题中, 利用在线输入输出数据设计神经网络辨识器, 在线辨识系统模型, 实现未知非线性系统的鲁棒最优控制^[54]。文献[36; 55]进一步研究了非线性系统存在不匹配干扰时的鲁棒最优控制问题。文献[37; 56]研究了非线性系统的鲁棒跟踪最优控制问题, 文中将参考动态系统与原系统进行增广, 从而将原系统的最优跟踪控制问题转化为增广系统的最优调节控制问题; 通过设计自适应评价网络, 在线逼近最优代价函数, 实现非线性系统的自适应最优控制。此外为了有效处理不匹配干扰问题, 文献[57; 58]引入伪逆方法, 对不匹配干扰进行分解, 从而将原系统的鲁棒最优控制问题转化为等效辅助系统的最优控制问题。但可以看出上述鲁棒 ADP 控制方法都是基于问题转化的思想, 即通过修改标称系统的性能指标函数, 将干扰相关项引入最优控制性能指标函数中, 从而将原系统的鲁棒最优控制问题转化为等效系统的最优调节控制问题, 基于此, 通过利用 ADP 技术构建评价网络, 实现鲁棒自适应最优控制。但如果非线性系统存在与状态无关的外部干扰, 则上述方法不再适用。为解决此类问题, 文献[13]在执行网络的设计中引入鲁棒项, 有效补偿了由神经网络逼近误差以及外界干扰造成的影响, 进一步放松了对干扰界值已知的假设条件, 保证了闭环系统的稳定性。此外, 借鉴现代控制理论相关方法, 文献[59]提出了基于执行-评价网络结构的积分滑模控制方法, 通过将非线性干扰观测器、积分滑模控制和 ADP 技术相结合, 有效处理了未知外界干扰存在情况下的非线性系统的最优控制问题。文献[60]考虑了饱和非线性系统在匹配干扰和不匹配干扰同时存在情况下的最优控制问题, 将 ADP 技术与滑模控制方法相结合, 提出了最优保性能滑模控制方法。文献[61]通过设计干扰补偿控制器, 提出了基于离线执行-评价网络结构的最优控制方法。

然而值得注意的是, 上述鲁棒最优控制方法虽然能够有效处理匹配型干扰以及不匹配干扰问题, 但这些方法对系统动态信息的要求较为严格。而在工程实际中往往由于所考虑的系统太复杂, 导致被控系统的动态信息难以得到, 在这种情况下, 上述基于模型的控制方法已不再适用。为此提出不依赖于系统模型的最优控制方法, 就具有重要的理论意义和工程应用价值。文献[62-64]通过增加辨识网络对系统进行在线辨识, 基于逼近的系统模型, 利用 ADP 技术设计最优控制律, 实现未知非线性系统的最优控制。文献[65; 66]利用强化学习思想, 提出了基于数据

驱动的逼近策略迭代方法,通过构建执行-评价网络离线执行控制策略。此外,纽约大学 Jiang 教授及其团队针对模型未知问题,将 ADP 技术与小增益定理相结合,提出了 RADP 控制算法,通过对输入输出数据的处理,实现了线性 and 非线性系统的最优控制,并保证了闭环系统的全局渐近稳定性^[44-46]。但可以发现,上述基于 ADP 技术的最优控制问题都是针对无穷域最优控制问题,而在实际工程应用中,人们往往会对终端时间和终端状态有一定的要求,从而保证闭环系统的快速性和鲁棒性。考虑到有限时域 ADP 控制问题研究成果还很少,理论尚不成熟,但也取得了初步的成果。接下来有必要简单梳理一下有限时域 ADP 控制相关成果。

2) 有限时域 ADP 控制

有限时域 ADP 控制问题主要考虑到大部分 ADP 相关成果均在无穷域范围内求解最优控制,而在实际系统中往往要求终端时间约束、终端状态约束等要求,从而获得更好的系统性能和鲁棒性。为此研究人员开始关注在有穷域内的 ADP 控制研究,即有限时域 ADP 控制,并取得了初步的研究成果。文献[67]分析了离散系统的有限时域迭代 ADP 控制问题,并通过引入 ε 界值的概念,能够保证性能指标函数在有限时域内收敛于 ε 界值内。文献[68]借鉴文献[67]中 ε 界值的设计理念,利用启发式动态规划技术,研究了离散非线性系统的有限时域最优跟踪控制问题。另外有学者提出了解决有限时域 ADP 控制问题的另外一种思路,即通过构建时变神经网络结构,逼近有限时域最优控制中时变的最优代价函数。例如在文献[69]中,通过在评价网络中引入剩余时间的概念,设计由时不变权值向量和时变基函数组成的时变评价网络结构,实现对时变目标函数的逼近,提出了有限时域自适应评价控制结构,解决了离散非线性系统的有限时域最优控制问题。Zhao 在其博士学位论文^[70]中重点研究了线性系统和非线性系统的有限时域 ADP 控制问题,通过将 Q-learning 算法和构建时变评价网络结构相结合,解决了未知线性系统中有限时域最优控制问题;针对非线性系统,主要通过构建时变评价网络,并设计自适应权值更新律,实现非线性系统有限时域 ADP 控制。文献[71-74]通过将剩余时间变量引入神经网络基函数中,设计了时变神经网络,通过设计评价网络权值更新律,最小化估计权值误差和终端约束估计误差。文献[75]研究了多个移动机器人有限时域自适应最优编队控制问题;构建由常数权值和时变基函数组成的神经网络结构,在线求解时变代价函数,同时满足终端时刻约束。文献[76]考虑了存在饱和和约束条件下的未知非线性系统的有限时域 H_∞ 控制问题,利用 ADP 技术提出了执行-评价-干扰网络控制结构;为求解时变的 HJI 方程,设计了由常数权值和时变基函数组成的神经网络,自适应在线逼近最优解并满足了终端约束条件。与前述设计时变神经网络结构不同,文献[77]设计了由时变权值和时不变基函数组成的时变神经网络,研究了不确定非线性系统的有限时域最优保性能控制。不过可以看出,连续非线性系统的有限时域最优控制理论并不成熟,还有很多问题亟待解决,如输入饱和问题、多约束问题以及鲁棒控制问题等,而且针对非线性系统的有限时域微分对策问题的研究成果也很少,需要更加深入的研究。

3) 输入饱和条件下的 ADP 控制

执行器饱和现象广泛存在于实际物理系统中。在设计控制器时，必须要将其考虑在内，避免饱和和执行器饱和现象发生。这主要是因为执行器饱和问题可能直接降低闭环系统的控制性能，甚至导致闭环系统不稳定。关于输入饱和条件下的 ADP 控制问题，一直都备受相关科研工作者的青睐。Abu-khalaf 等较早开始利用策略迭代思想研究输入饱和条件下的近似最优控制问题^[78]；为有效处理输入饱和问题，将一个非二次型泛函引入性能指标函数中，从而将输入饱和条件下的最优控制问题转化为输入自由的最优控制问题，并将其推广至输入饱和条件下的非线性微分对策问题^[79]。基于这一思想，文献[80]针对非线性离散系统，提出输入饱和条件下的迭代 ADP 控制方法。文献[81; 82]研究了输入饱和条件下仿射非线性系统的最优控制问题，通过构建评价网络结构，在线逼近 HJB 方程的解，实现了饱和和非线性系统的自适应最优控制。Modares 采用积分强化学习思想，研究了非线性系统输入饱和条件下的最优跟踪控制问题^[83]，该算法不要求系统全部信息已知；并进一步利用经验重复利用技术，放松了学习过程中信号要求的持续激励条件^[84]。文献[85]考虑了输入饱和问题和不确定性干扰项，提出了针对非线性系统的基于 ADP 技术的鲁棒最优控制方法，并保证了闭环系统信号的最终一致有界性。文献[86]通过充分使用历史数据，实现了与经验重复利用技术一样的效果，放松了对信号持续激励的要求；进一步通过在控制器中设计一个鲁棒控制项，补偿了由于神经网络逼近误差造成的影响，最终保证了闭环系统的渐近稳定性。值得注意的是，上述研究方法大多基于同一思想，即在性能指标函数中引入一个非二次型泛函，从而将输入饱和条件下的最优控制问题转化为输入无约束的最优控制问题，然后利用 ADP 技术设计最优控制器。但该方法只能处理输入饱和和界值对称的情况，而对非对称性输入饱和问题则不再适用。而且该方法还仅限于处理常值饱和问题，对动态约束情况下的 ADP 控制研究还没有展开，特别系统输出、状态等变量受约束的情况并没有考虑。为解决上述问题，文献[87]利用 ADP 技术，研究了系统状态受约束的最优控制问题，通过引入适当的松弛变量，将原系统的状态受约束最优控制问题转化为增广系统的状态不受约束最优控制问题；随后，他们继续研究了非仿射非线性系统存在状态不等式约束条件下的 ADP 控制问题^[88]，以及跟踪误差约束条件下的 ADP 控制问题^[89]。但针对状态、输出等约束条件下的 ADP 控制相关成果依然很少，理论尚不成熟。因此，面对实际工程应用需求，考虑输入、输出、状态等多约束条件，研究多约束条件下的 ADP 控制问题具有重要的理论意义和潜在的应用前景。

4) 基于 ADP 的微分对策问题

微分对策作为一种广义的最优控制，是研究双方或多方最优控制的理论。由于非线性系统的微分对策问题同样面临求解复杂非线性 HJI 方程的问题，ADP 技术也被认为是求解微分对策纳什均衡解的一种有效、便捷的方法。因此基于 ADP 技术的微分对策问题受到大家的关注并取得了一些成果。在文献[90]中将迭代 ADP 技术应用于非线性系统的零和微分对策问题中，通过

迭代方式求解微分对策鞍点；文中还讨论了鞍点不存在情况下微分对策控制策略的选取原则。此后，作者还研究了基于 ADP 技术的非零和微分对策问题^[91]。文献[92]提出了执行-评价-干扰网络，分别用于逼近控制输入、最优代价函数以及干扰输入，通过设计神经网络权值更新律实现了非线性微分对策的同步在线 ADP 控制。文献[93]在文献[92]的基础上，考虑了输入饱和条件下的非线性微分对策问题，通过将非二次型泛函引入微分对策性能指标函数中，有效解决了输入饱和问题；采用 ADP 技术构建了三个神经网络分别在线更新控制输入、最优代价函数以及干扰输入，实现了输入饱和条件下的自适应微分对策控制。针对完全未知的非线性系统，文献[94]通过设计神经网络辨识器重构系统；利用 ADP 技术设计执行-评价-干扰网络，实现非线性系统非零和微分对策问题。进一步，基于数据驱动的微分对策问题^[95-97]以及基于积分强化学习思想的微分对策问题^[98]均得到分析研究，从而放松了对系统模型的依赖。文献[99]进一步将平方和技术与策略迭代方法相结合，将求解 HJI 方程的问题转化为存在不等式约束的优化问题，从而避免了 HJI 方程的求解。从上述分析可以看出，将 ADP 技术应用于微分对策问题的研究刚刚起步，相关成果还很少，还有很多需要研究的问题，如有限时域微分对策问题、多约束条件下的微分对策问题、鲁棒微分对策问题等等，有必要对其进行深入的研究。

5) 基于事件触发机制的 ADP 控制

事件触发控制主要是针对传统的时间触发控制而言的。传统的控制器大多基于时间触发机制，即控制器主要是依赖于采样时间进行周期性的更新。这样的控制方式不仅会造成大量计算资源和通信资源的浪费，也可能由于系统通信宽带和信道的阻塞造成系统的不稳定。而事件触发控制主要是通过事件来实现控制器的更新；只有当连续两次采样信号的差值超过一定阈值，事件才会被触发，此时控制器更新一次；在事件不发生期间，控制器便不更新，保证原来的状态，这样就可以极大地减少控制器的更新次数，从而节约计算资源。因此，近年来基于事件触发机制的 ADP 控制开始获得关注。文献[100-102]研究了事件触发机制下非线性系统的 H_∞ 控制问题；分别设计了基于事件触发机制的最优控制策略和基于时间触发机制的干扰控制策略，利用 ADP 技术构建评价网络结构，在线逼近事件触发机制下的 HJI 方程的解，并给出了自适应事件触发条件。随后在事件触发机制下，非线性系统的鲁棒最优控制^[103]，保性能最优控制^[104]以及混合数据-事件触发的 H_∞ 控制问题^[105]得以研究。文献[106]考虑了未知非线性系统，通过构建神经网络结构对系统进行重构，提出了基于事件触发机制的鲁棒 ADP 控制方法。文献[107; 108]考虑了非线性系统存在不匹配干扰情况下的事件触发 ADP 控制问题。但值得注意的是，上述基于事件触发机制的 ADP 控制方法中，神经网络权值更新律的设计仍然是基于时间触发形式的。换言之，上述成果中只是针对控制器的设计采用事件触发形式，而其他设计部分依旧采用传统的时间触发机制，这就不可避免地具有一定的保守性。基于这一考虑，文献[109-111]分别针对离散和连续非线性系统，在执行-评价网络结构下，研究了事件触发机制的 ADP 控制问题，设

计了基于事件触发机制的最优控制律以及基于事件触发机制的神经网络权值更新律，并保证了闭环系统的稳定性，从而更大程度地节约了计算资源。文献[112]研究了非线性系统基于事件触发机制的最优跟踪控制问题，通过将原系统与跟踪参考系统进行增广，将原系统的跟踪控制问题转化为增广系统的调节控制问题，最后利用 ADP 技术，设计了基于事件触发机制的神经网络权值更新律。可上述研究成果都是基于单个非线性系统设计，并不能完全反映出事件触发机制节约通信资源以及降低通信宽带和信道阻塞等优点，而将事件触发机制的 ADP 控制方法应用于多智能体系统的研究中具有重要理论意义和应用前景。文献[113-115]将其应用于非线性互联系统，提出了基于事件触发机制的分布式最优控制方法，将各个互联系统整理为一个系统形式，然后利用事件触发机制的 ADP 方法设计控制器，但互联系统与多智能体系统存在本质的区别，相关研究成果并不能直接推广至非线性多智能体的分布式最优控制。可以说，将基于事件触发机制的 ADP 技术应用于多智能体系统，研究基于事件触发机制的分布式最优控制问题依然是一个全新的课题，有待去探索研究。

6) 基于 ADP 的多智能体协同控制

将 ADP 技术应用于多智能体系统的研究刚刚起步，但也取得了一定的成果。Vamvoudakis 等针对线性系统分析了多智能体微分对策问题，文中将强化学习、几何图论以及微分对策理论相结合，通过定义“交互式纳什均衡解”的概念，提出了一种合作策略迭代算法^[116]。文献[117]进一步分析了线性离散多智能体系统的合作型微分对策问题，并提出基于强化学习的合作型在线值迭代算法。魏庆来等将迭代 ADP 算法拓展到非线性异构多智能系统中，通过利用合作策略迭代算法，提出了最优分布式一致性控制方法^[118]，并将其应用于多电池最优协同管理中^[119]。文献[120]进一步将模糊控制与 ADP 控制相结合，研究了非线性多智能体系统的基于领导者-跟随者模式的最优协同控制问题，并通过构建单一评价网络，设计评价网络权值更新律，实现了在线分布式最优系统控制。文献[121]利用策略迭代思想研究了线性多智能体系统的零和微分对策问题，提出了在线分布式最优跟踪控制方法。Luy 将 ADP 技术与 Backstepping 控制方法相结合，利用微分对策理论，研究了具有严格反馈形式的非线性多智能体系统的分布式合作 H_∞ 最优跟踪控制问题，并取得了一些研究成果^[122-125]。针对模型未知的多智能体系统，文献[126]构建了执行-评价-辨识网络结构，通过模糊逻辑系统代替传统的神经网络结构，研究了多智能体的分布式协同编队控制问题。文献[127]基于数据驱动的强化学习方法，通过利用当前和过去的数提出基于数据驱动的 ADP 方法，避免了传统方法中模型辨识过程。最后通过构建执行-评价网络结构，在线执行算法。文献[128]针对模型未知非线性多智能体系统，通过引入额外的补偿器与原系统进行增广，有效避免了 ADP 算法对模型信息已知的要求，最终基于策略迭代思想，实现了分布式在线策略迭代控制。另外，杨永亮老师在其博士论文中也对多智能体系统模型未知情况下的 ADP 控制问题进行了较为深入的研究^[129]。尽管 ADP 技术在多智能体系统的中应用

已经取得一定的成果,但仍然存在很多问题,如输入饱和条件下的多智能体系统的分布式 ADP 控制问题、通信拓扑网络结构变化情况下的分布式 ADP 控制、基于事件触发机制的分布式 ADP 控制等等,这些问题的研究将进一步地丰富和发展 ADP 理论;对 ADP 技术在工程实际问题中的应用推广也具有重要的意义。

1.2.2 自适应动态规划技术在航空航天领域的研究现状

ADP 技术的独特结构使得它在解决复杂非线性系统的控制问题中表现出巨大的潜力和优势。近年来,ADP 技术已被成功应用于电子系统^[40; 130-133]、智能交通控制领域^[26]以及工业控制领域^[41; 43]。但如何将 ADP 技术与航空航天应用相结合,用来解决具有强耦合、复杂非线性以及高动态特性的飞行器的控制问题一直是一个比较棘手的问题。相关研究成果也很少,特别是在导弹制导领域的公开成果并不多见。下面就已有研究成果进行简单的梳理:

早在 1994 年, Balakrishnan 就已经采用 ADP 设计思想,通过分别设计执行网络和评价网络来逼近最优控制中动态规划方程的解,并通过飞行器最优控制问题进行数值验证^[134]。文献[135]针对复杂直升机系统的控制问题,采用神经元动态规划思想,提出了不依赖于模型的在线学习控制器。并通过在不同飞行条件下的数值仿真,验证了该方法的鲁棒性。在文献[136]中,作者针对 AH-64 “阿帕奇”武装直升机的跟踪控制问题,设计了基于神经元动态规划的跟踪控制器。Ferrari 等针对六自由度飞行器,基于自适应评价结构,设计了一种离线-在线相结合的控制方式^[137],该控制器首先通过离线方式来训练控制器,接着采用自适应评价网络在线优化性能指标函数。文献[138]将强化学习与自适应动态逆控制相结合,并用 Q-learning 方法取代了传统执行-评价网络结构,提出了变形翼无人飞行器的自适应强化学习控制方法。在文献[139]中,逼近动态规划技术被应用于六自由度四旋翼飞行器的控制问题中,有效解决了飞行器存在多种干扰以及模型不确定项等问题。同样地,针对无人直升机系统,文献[140]在飞行器外环控制中,提出了基于 ADP 技术的输出反馈最优跟踪控制器,保证了飞行器的跟踪性能。文献[141]针对复杂飞行控制系统,提出基于增量式 ADP 的输出反馈控制方法,利用系统输入输出信息重构系统状态。文献[142]针对高超声速飞行器的最优跟踪控制问题,通过将 ADP 技术与滑模控制方法相结合,提出了基于数据驱动的辅助控制方法。

另外,ADP 技术在导弹制导控制领域的研究成果虽然很少,但依旧取得了初步的研究成果。例如,文献[143]利用自适应评价设计思想,针对导弹的线性化模型,设计了基于神经网络结构的导弹制导律。在文献[144]中,作者研究了在导弹防御问题中资源的分配问题,利用神经元动态规划思想逼近剩余代价函数,从而保证防御资源分配的最优性。文献[145]利用自适应评价思想,研究了导弹在最小飞行马赫数受限情况下的最小时间转弯问题,通过构建两个自适应评价网络求解了约束条件下的优化问题。文献[146]将自适应评价技术应用于导弹自动驾驶仪的设计中,文中通过在线调节参数,避免了传统方法中对参数的试错调试,有效缩短了在线参数学习

时间，保证了闭环系统的跟踪性能和稳定性。文献[147]直接将强化学习技术应用于寻的导弹制导律的设计，研究表明基于强化学习的制导律相比于比例导引和最优制导方法均表现出更好的性能。

从以上分析可以看出，ADP 技术在航空航天领域的研究成果并不多见，特别是在导弹制导方面的研究更是鲜有涉及。而且上述研究成果中，大多数基于 ADP 技术的制导控制方法主要是建立在对制导律或控制律的不断离线训练与学习的基础上，该方法缺少严格的稳定性证明，普适性比较差，从而不可避免地降低了制导系统的鲁棒性。因此，有必要深入研究基于 ADP 技术的在线自适应最优制导问题，将现代控制理论中自适应的思想与 ADP/RL 技术相结合，发展一种智能的自适应最优制导方法。该研究不仅可以解决制导律在线优化设计的技术难题，而且对未来智能化武器的发展也具有重要的理论价值和潜在的应用前景。

1.3 本文研究内容及章节安排

本文以导弹拦截制导为背景，以具有在线自学习功能的 ADP 技术为基础，在最优控制/微分对策理论框架下，结合自适应控制、鲁棒控制、智能控制等现代控制方法，开展基于 ADP 技术的一对一拦截制导以及多弹协同拦截制导研究。本文研究内容及章节安排如图 1.5 所示。




图 1.5 本文主要研究内容及章节安排框图

具体研究内容如下:

第一章首先阐述了研究 ADP 技术以及在导弹拦截制导中应用的背景和意义;然后介绍和分析了 ADP 技术的国内外研究现状,以及 ADP 技术在航空航天领域的研究成果。

第二章主要针对拦截制导系统存在内部扰动、外界干扰的情况下,研究基于微分对策的鲁棒自适应最优拦截制导问题;提出改进型的鲁棒微分对策控制策略,保证了闭环系统的鲁棒性和最优性;通过构建评价网络结构,在线逼近最优代价函数,保证闭环系统的稳定性;通过拦截制导系统验证了所提方法的有效性。

第三章主要考虑拦截制导过程中终端状态约束、终端时间约束以及可能出现的过载饱和现象,研究输入饱和条件下基于微分对策的有限时域自适应最优拦截制导问题;通过在性能指标函数中引入一个非二次型泛函有效处理输入饱和问题,并推导出输入饱和条件下的有限时域微分对策控制策略;接着构建时变评价网络结构,设计评价网络权值更新律,在线逼近时变最优代价函数以及终端约束条件,保证闭环系统的稳定性;并在导弹拦截制导非线性系统中进行仿真验证。

第四章主要针对拦截制导系统可能存在输入饱和、输出约束等问题,研究多约束条件下基于微分对策的自适应最优拦截制导问题;本章主要考虑具有严格反馈形式的非线性系统,结合 Backstepping 控制方法和 ADP 技术,提出前馈+反馈形式的复合控制结构;在前馈设计中,基于 Backstepping 控制方法,有效处理了输入饱和以及输出约束问题;在反馈设计中,基于 ADP 技术构建评价网络,在线执行微分对策控制策略,从而保证了闭环系统的稳定性以及跟踪方式的最优性;

第五章主要考虑 ADP 技术在高非线性系统中计算复杂度的问题,研究基于 ADP 技术的自适应预测最优拦截制导问题;针对具有块严格反馈形式的非线性系统,在 Backstepping 控制结构下,利用 ADP 技术在线设计自适应最优虚拟控制输入;采用连续时间预测控制方法,离线给出了实际最优控制输入的解析表达式;这种基于离线-在线控制结构,不仅有效降低了 ADP 技术的计算复杂度,也提高了复合控制器的鲁棒性。通过仿真对比验证表明了本章所提方法的优越性。

第六章主要针对多弹协同拦截机动目标的情形,研究基于 ADP 技术的多弹分布式自适应最优协同拦截制导问题;首先,将该协同制导问题描述成一类具有严格反馈形式的非线性多智能体系统的协同控制问题;采用“领弹-从弹”协同方式,基于图论知识和一致性理论,结合指令滤波 Backstepping 控制方法和 ADP 技术,提出前馈+反馈控制结构;通过设计分布式前馈控制输入保证所有从弹一致收敛于领弹信号;然后,利用 ADP 技术,设计分布式反馈最优控制输入,保证协同跟踪方式的最优性。最后,将该理论应用于多弹协同拦截制导问题中,验证了该方法的有效性。

第七章主要考虑多弹协同拦截制导过程中计算资源和通讯资源的浪费问题, 研究基于事件触发机制的多弹分布式自适应最优协同拦截制导问题; 将该问题描述为一类非线性多智能系统的分布式最优协同控制问题; 设计基于事件触发的分布式最优控制律以及自适应事件触发条件, 保证了闭环系统的渐近稳定性; 利用 ADP 技术构建评价网络结构, 在线逼近合作型最优代价函数, 并给出可执行的自适应事件触发条件, 从理论上保证闭环系统的稳定性, 避免了芝诺行为。将该方法应用于多弹协同拦截制导问题, 实现了多弹同时攻击机动目标的任务。

第八章对本文主要工作进行总结分析; 并针对本文存在的问题和不足, 对后续工作进行了展望。

第二章 基于微分对策的鲁棒自适应最优拦截制导

2.1 引言

在导弹拦截制导过程中, 导弹方试图通过调节自身制导律, 实现零控脱靶量的最小化, 从而击中目标; 而目标方往往会进行大机动规避, 试图使零控脱靶量最大化, 顺利逃脱。这种动态博弈过程可描述为一种典型的二人零和微分对策问题。另外考虑到导弹在其飞行空域内的飞行高度和飞行速度都在不断变化, 导致系统结构参数和控制参数发生变化, 并最终改变系统的动态特性。此外系统未建模部分以及外界干扰的作用也将严重影响制导系统的性能, 甚至破坏系统的稳定性, 从这一点来讲, 研究基于不确定微分对策的导弹拦截制导问题具有重要的意义, 但针对复杂非线性微分对策问题, 其相应的 Hamilton-Jacobi-Isaacs (HJI) 方程的求解问题限制了它的发展。

自适应动态规划(Adaptive Dynamic Programming, ADP)技术自提出以来, 也被广泛应用于零和微分对策问题, 用于求解相应 HJI 方程的解, 并取得了一些成果^[92; 93; 148-150], 但针对存在不确定项的鲁棒微分对策问题的研究成果并不多见。其中文献[151]也主要是针对线性系统, 基于策略迭代思想, 研究了系统存在匹配型干扰情况下的鲁棒微分对策问题, 而对于非线性系统的鲁棒微分对策问题的研究并没有涉及。为此, 本章将以拦截制导为应用背景, 研究非线性系统的鲁棒微分对策问题; 通过利用 ADP 技术, 提出基于微分对策的鲁棒自适应最优控制方案, 该方案有助于提高导弹拦截制导系统的鲁棒性, 实现在线自适应最优拦截制导。

2.2 问题描述

考虑如下具有不确定项的连续仿射非线性系统

$$\dot{x}(t) = f(x) + g(x)(\bar{u}(t) + \bar{d}(x)) + k(x)(\bar{v}(t) + \bar{b}(x)) \quad (2.1)$$

其中, $x(t) \in \mathbb{R}^n$ 表示系统状态向量; $\bar{u}(t) \in \mathbb{R}^m, \bar{v}(t) \in \mathbb{R}^k$ 分别表示微分对策双方各自的控制输入向量。 $f(x), g(x)$ 和 $k(x)$ 均为连续可微函数; $\bar{d}(x)$ 和 $\bar{b}(x)$ 为未知非线性不确定项, 满足 $\bar{d}(0) = 0, \bar{b}(0) = 0$; 另外假设该系统可控, 即存在一个容许控制能够保证闭环系统渐近稳定, 使得系统在该控制器作用下, 能够使系统状态从初始状态转移到平衡状态。需要指出的是, 为方便起见, 在后续表述中, 有时会省略时间变量 t 。如果没有特别说明, 则它们表示相同的含义, 例如 $x = x(\cdot), \bar{u} = \bar{u}(\cdot), \bar{v} = \bar{v}(\cdot)$ 等。

首先为方便控制器的设计, 针对系统(2.1), 给出如下假设:

假设 2.1: 非线性函数 $f(x)$ 在包含原点的集合 Ω_x 上局部 Lipschitz 连续且满足 $f(0) = 0$ 。控制矩阵 $g(x)$ 和 $k(x)$ 均为有界函数。即存在正常数 g_m, g_M ($0 < g_m < g_M$) 和 k_m, k_M ($0 < k_m < k_M$) 使得不等式

$g_m < \|g(x)\| < g_M$ 和 $k_m < \|k(x)\| < k_M$ 成立。

本节设计控制器的主要目的就是找到一组微分对策控制策略 $(\bar{u}(x), \bar{v}(x))$ ，确保系统(2.1)在不确定项 $\bar{d}(x)$ 和 $\bar{b}(x)$ 的影响下渐近收敛。

为有效补偿上述不确定项的影响，首先考虑系统(2.1)的标称系统

$$\dot{x}(t) = f(x) + g(x)u(t) + k(x)v(t) \quad (2.2)$$

其中， $u(t)$ 和 $v(t)$ 分别表示标称系统双方各自的控制输入。

对系统不确定项 $\bar{d}(x)$ 和 $\bar{b}(x)$ 作出如下假设：

假设 2.2: 存在两个对称正定矩阵 $R_1 \in \mathbb{R}^{m \times m}$, $R_2 \in \mathbb{R}^{k \times k}$ ，满足 $d(x) = R_1^{-1} \bar{d}(x)$, $b(x) = R_2^{-1} \bar{b}(x)$ ，其中， $d(x) \in \mathbb{R}^k$ 和 $b(x) \in \mathbb{R}^m$ 均为有界函数，即存在两个已知的界值函数 $d_M(x)$ 和 $b_M(x)$ ，满足不等式 $\|d(x)\| \leq d_M(x)$, $\|b(x)\| \leq b_M(x)$ 且 $d_M(0) = b_M(0) = 0$ 。

基于假设 2.2，考虑标称系统(2.2)，定义如下性能指标函数：

$$V(x) = \int_0^\infty \{Q(x) + u^T(t)R_1u(t) - v^T(t)R_2v(t)\} dt \quad (2.3)$$

其中， $Q(x) = d_M^2(x) + cb_M^2(x) + x^T Q_1 x$ ， Q_1 表示对称正定矩阵， $c > 1$ 是需要设计的参数，它的选取直接影响对系统收敛性的分析。

注释 2.1: $Q(x)$ 的设计不仅包含了对系统状态的刻画，还反映了对系统不确定项的描述。由 $Q(x)$ 的定义式以及假设 2.2 可知，对于 $\forall x \neq 0$, $Q(x) > 0$ 。由极大极小值原理可得，通过寻找微分对策控制策略 $(u^*(x), v^*(x))$ ，实现性能指标函数的最小化，不仅可以保证闭环系统的状态能够收敛于很小的领域内，也实现了对不确定项影响的最小化，从而达到了干扰抑制的效果。

接下来考虑标称系统(2.2)，定义哈密顿函数为

$$H(x, u, \nabla V(x)) = Q(x) + u^T(t)R_1u(t) - v^T(t)R_2v(t) + (\nabla V(x))^T (f(x) + g(x)u(t) + k(x)v(t)) \quad (2.4)$$

其中， $\nabla V(x)$ 表示性能指标函数 $V(x)$ 对状态 x 的偏导数，即 $\nabla V(x) = \partial V(x) / \partial x$ 。

基于 Nash-Pontryagin 极大极小值原理，纳什均衡解 $(u^*(x), v^*(x))$ 存在的必要条件就是使得哈密顿函数(2.4)满足下列不等式

$$H(x, u^*, v, \nabla V^*(x)) \leq H(x, u^*, v^*, \nabla V^*(x)) \leq H(x, u, v^*, \nabla V^*(x)) \quad (2.5)$$

式中最优代价函数 $V^*(x)$ 满足下列关系

$$V^*(x) = \max_{v(t)} \min_{u(t)} \int_0^\infty \{Q(x) + u^T(t)R_1u(t) - v^T(t)R_2v(t)\} dt \quad (2.6)$$

且 $V^*(0) = 0$ 。

因此可通过求解如下 Hamilton-Jacobi-Isaacs (HJI) 方程获得最优代价函数 $V^*(x)$ ：

$$0 = \max_{v(t)} \min_{u(t)} H(x, u(t), v(t), \nabla V^*(x)) \quad (2.7)$$

这里假设 HJI 方程(2.7)的解存在且唯一^[152]。由必要条件 $\partial H(\cdot) / \partial u = 0$ 和 $\partial H(\cdot) / \partial v = 0$ 可得，微分对策控制策略为

$$\begin{cases} u^*(x) = -\frac{1}{2}R_1^{-1}g^T(x)\nabla V^*(x) \\ v^*(x) = \frac{1}{2}R_2^{-1}k^T(x)\nabla V^*(x) \end{cases} \quad (2.8)$$

将式(2.8)代入式(2.7)，整理可得相应的 HJI 方程为

$$\begin{aligned} 0 = & Q(x) + (\nabla V^*(x))^T f(x) - \frac{1}{4}(\nabla V^*(x))^T g(x)R_1^{-1}g^T(x)\nabla V^*(x) \\ & + \frac{1}{4}(\nabla V^*(x))^T k(x)R_2^{-1}k^T(x)\nabla V^*(x) \end{aligned} \quad (2.9)$$

需要注意的是，微分对策控制策略(2.8)主要是针对标称系统(2.2)设计，它不能保证原系统在不确定项 $\bar{d}(x)$ 和 $\bar{b}(x)$ 的影响下渐近稳定。基于此，本章将设计一种鲁棒微分对策控制策略，保证闭环系统的稳定性，提高控制器的鲁棒性。

注释 2.2：根据文献[79; 92; 153]可知，微分对策控制策略(2.8)满足不等式(2.5)。平衡点 $(u^*(x), v^*(x))$ 称为系统(2.2)的纳什均衡解（鞍点）。因此，相应的 HJI 方程(2.9)一定存在一个局部的非负正定解 $V^*(x) \geq 0, V(0) = 0$ 使得闭环系统局部渐近稳定。

2.3 鲁棒微分对策控制策略设计

针对原系统(2.1)，为有效补偿不确定项 $\bar{d}(x)$ 和 $\bar{b}(x)$ 的影响，受文献[35]启发，通过改进式(2.8)，提出鲁棒微分对策控制策略如下：

$$\begin{aligned} \bar{u}(x) &= -\frac{\varepsilon_1}{2}R_1^{-1}g^T(x)\nabla V^*(x) \\ \bar{v}(x) &= \frac{1}{2\varepsilon_2}R_2^{-1}k^T(x)\nabla V^*(x) \end{aligned} \quad (2.10)$$

其中， $\varepsilon_1 > 1$ 和 $\varepsilon_2 > 1$ 均为需要设计的反馈增益。

基于设计的鲁棒微分对策控制策略(2.10)，可以得出如下结论：

引理 2.1：针对标称系统(2.2)，如果设计反馈增益 ε_1 和 ε_2 满足 $\varepsilon_1 \geq \frac{1}{2}, \varepsilon_2 \geq 2$ ，则鲁棒微分对策控制策略(2.10)能够保证闭环系统渐近稳定。

证明：考虑到最优代价函数 $V^*(x) \geq 0$ 满足式(2.6)，可以保证对于 $\forall x \neq 0, V^*(x) > 0$ 。因此，基于文献[92; 93]，将最优代价函数 $V^*(x)$ 作为 Lyapunov 候选函数。对 $V^*(x)$ 求导可得

$$\begin{aligned} \dot{V}^*(x) &= (\nabla V^*(x))^T (f(x) + g(x)\bar{u}(x) + k(x)\bar{v}(x)) \\ &= -Q(x) + \frac{1}{4}(\nabla V^*(x))^T g(x)R_1^{-1}g^T(x)\nabla V^*(x) - \frac{1}{4}(\nabla V^*(x))^T k(x)R_2^{-1}k^T(x)\nabla V^*(x) \\ &\quad - \frac{\varepsilon_1}{2}(\nabla V^*(x))^T g(x)R_1^{-1}g^T(x)\nabla V^*(x) + \frac{1}{2\varepsilon_2}(\nabla V^*(x))^T k(x)R_2^{-1}k^T(x)\nabla V^*(x) \\ &= -Q(x) - \frac{1}{2}\left(\varepsilon_1 - \frac{1}{2}\right)\left\|R_1^{-\frac{1}{2}}g^T(x)\nabla V^*(x)\right\|^2 - \frac{1}{2}\left(\frac{1}{2} - \frac{1}{\varepsilon_2}\right)\left\|R_2^{-\frac{1}{2}}k^T(x)\nabla V^*(x)\right\|^2 \end{aligned} \quad (2.11)$$

由式(2.11)可以得出，对于 $\forall x \neq 0$ ，只要保证 $\varepsilon_1 \geq \frac{1}{2}, \varepsilon_2 \geq 2$ ，则有 $\dot{V}^*(x) < 0$ 。由 Lyapunov 稳定性理论可知，设计的鲁棒微分对策控制策略能够保证闭环系统的渐近稳定性。

定理 2.1: 针对原不确定系统(2.1), 总是存在两个反馈增益系数 $\varepsilon_1 \geq 1$ 和 $\varepsilon_2 \geq \frac{2c}{c-1}$, 式中 $c > 1$ 已在式(2.3)中定义, 使得原系统在该鲁棒微分对策控制策略(2.10)作用下渐近稳定。

证明: 选取 Lyapunov 函数为 $\bar{L}(t) = V^*(x)$ 。对其求导, 可得

$$\dot{\bar{L}}(t) = (\nabla V^*(x))^T (f(x) + g(x)(\bar{u}(t) + \bar{d}(x)) + k(x)(\bar{v}(t) + \bar{b}(x))) \quad (2.12)$$

结合式(2.9)-(2.10), 将其代入整理, 式(2.12)可变为

$$\begin{aligned} \dot{\bar{L}}(t) = & -Q(x) - \frac{1}{2} \left(\varepsilon_1 - \frac{1}{2} \right) \left\| (\nabla V^*(x))^T g(x) R_1^{-\frac{1}{2}} \right\|^2 - \frac{1}{2} \left(\frac{1}{2} - \frac{1}{\varepsilon_2} \right) \left\| (\nabla V^*(x))^T k(x) R_2^{-\frac{1}{2}} \right\|^2 \\ & + (\nabla V^*(x))^T g(x) \bar{d}(x) + (\nabla V^*(x))^T k(x) \bar{b}(x) \\ \leq & -x^T Q_1 x - \left\{ \frac{1}{2} \left(\varepsilon_1 - \frac{1}{2} \right) \left\| (\nabla V^*(x))^T g(x) R_1^{-\frac{1}{2}} \right\|^2 + \frac{1}{2} \left(\frac{1}{2} - \frac{1}{\varepsilon_2} \right) \left\| (\nabla V^*(x))^T k(x) R_2^{-\frac{1}{2}} \right\|^2 \right. \\ & \left. - \left\| (\nabla V^*(x))^T g(x) R_1^{-\frac{1}{2}} \right\| d_M(x) - \left\| (\nabla V^*(x))^T k(x) R_2^{-\frac{1}{2}} \right\| b_M(x) + d_M^2(x) + c b_M^2(x) \right\} \end{aligned} \quad (2.13)$$

通过重新定义变量 $\xi = \left[d_M(x), b_M(x), \left\| (\nabla V^*(x))^T g(x) R_1^{-\frac{1}{2}} \right\|, \left\| (\nabla V^*(x))^T k(x) R_2^{-\frac{1}{2}} \right\| \right]^T$, 并对式(2.13)整理, 可得如下形式:

$$\dot{\bar{L}}(t) \leq -x^T Q_1 x - \xi^T \Theta \xi \quad (2.14)$$

其中,

$$\Theta = \begin{bmatrix} 1 & 0 & -\frac{1}{2} & 0 \\ 0 & c & 0 & -\frac{1}{2} \\ -\frac{1}{2} & 0 & \frac{1}{2} \left(\varepsilon_1 - \frac{1}{2} \right) & 0 \\ 0 & -\frac{1}{2} & 0 & \frac{1}{2} \left(\frac{1}{2} - \frac{1}{\varepsilon_2} \right) \end{bmatrix}$$

由式(2.14)可以得出, 当反馈增益满足 $\varepsilon_1 \geq 1, \varepsilon_2 \geq \frac{2c}{c-1}$ 时, 可保证对称矩阵 $\Theta > 0$, 从而使得 $\dot{\bar{L}}(t) < 0$ 。根据 Lyapunov 稳定性理论, 闭环系统的渐近稳定性得以保证。

从引理 2.1 和定理 2.1 可得, 提出的鲁棒微分对策控制策略(2.10)能够确保不确定系统(2.1)的鲁棒性。接着将分析它的最优性。

首先针对不确定系统(2.1), 定义如下性能指标函数:

$$\bar{V}(x) = \int_0^\infty \left\{ \bar{Q}(x) + \frac{1}{\varepsilon_1} \bar{u}(t) R_1 \bar{u}(t) - \varepsilon_2 \bar{v}(t) R_2 \bar{v}(t) \right\} dt \quad (2.15)$$

其中,

$$\begin{aligned} \bar{Q}(x) = & d_M^2(x) + c b_M^2(x) + x^T Q_1 x - (\nabla V^*(x))^T g(x) \bar{d}(x) - (\nabla V^*(x))^T k(x) \bar{b}(x) \\ & + \frac{1}{4} (\varepsilon_1 - 1) (\nabla V^*(x))^T g(x) R_1^{-1} g^T(x) \nabla V^*(x) + \frac{1}{4} \left(1 - \frac{1}{\varepsilon_2} \right) (\nabla V^*(x))^T k(x) R_2^{-1} k^T(x) \nabla V^*(x) \end{aligned} \quad (2.16)$$

基于式(2.15)-(2.16), 可以得出以下结论:

引理 2.2: 存在两个反馈增益 ε_1 和 ε_2 满足 $\varepsilon_1 \geq 2, \varepsilon_2 \geq \frac{c}{c-1}$, 式中 $c > 1$, 使得 $\bar{Q}(x)$ 正定。

证明：在式(2.16)的右端加上和减去 $\frac{1}{\varepsilon_1-1}d^T(x)d(x)$ 和 $\frac{\varepsilon_2}{\varepsilon_2-1}b^T(x)b(x)$ ，经整理可得

$$\begin{aligned}\bar{Q}(x) = & Q(x) - (\nabla V^*(x))^T g(x) \bar{d}(x) - (\nabla V^*(x))^T k(x) \bar{b}(x) \\ & + \frac{1}{4(\varepsilon_1-1)} [(\varepsilon_1-1)^2 (\nabla V^*(x))^T g(x) R_1^{-1} g^T(x) \nabla V^*(x) + 4d^T(x)d(x)] \\ & + \frac{\varepsilon_2}{4(\varepsilon_2-1)} \left[\left(1 - \frac{1}{\varepsilon_2}\right)^2 (\nabla V^*(x))^T k(x) R_2^{-1} k^T(x) \nabla V^*(x) + 4b^T(x)b(x) \right] \\ & - \frac{1}{\varepsilon_1-1} d^T(x)d(x) - \frac{\varepsilon_2}{\varepsilon_2-1} b^T(x)b(x)\end{aligned}\quad (2.17)$$

考虑关系式 $d(x) = R_1^{\frac{1}{2}} \bar{d}(x)$, $b(x) = R_2^{\frac{1}{2}} \bar{b}(x)$ 和 $Q(x) = d_M^2(x) + cb_M^2(x) + x^T Q_1 x$ ，式(2.17)可表示为

$$\begin{aligned}\bar{Q}(x) = & d_M^2(x) + cb_M^2(x) + x^T Q_1 x - \frac{1}{\varepsilon_1-1} d^T(x)d(x) - \frac{\varepsilon_2}{\varepsilon_2-1} b^T(x)b(x) \\ & + \frac{1}{4(\varepsilon_1-1)} \left\| (\varepsilon_1-1)(\nabla V^*(x))^T g(x) R_1^{-\frac{1}{2}} - 2d^T(x) \right\|^2 \\ & + \frac{\varepsilon_2}{4(\varepsilon_2-1)} \left\| \left(1 - \frac{1}{\varepsilon_2}\right) (\nabla V^*(x))^T k(x) R_2^{-\frac{1}{2}} - 2b^T(x) \right\|^2\end{aligned}\quad (2.18)$$

考虑到非线性项 $d(x)$ 和 $b(x)$ 满足 $\|d(x)\| \leq d_M(x)$, $\|b(x)\| \leq b_M(x)$ 且反馈增益满足 $\varepsilon_1 \geq 2$, $\varepsilon_2 \geq \frac{c}{c-1}$ ，可以进一步将式(2.18)表述为

$$\begin{aligned}\bar{Q}(x) \geq & x^T Q_1 x + d_M^2(x) + cb_M^2(x) - \frac{1}{\varepsilon_1-1} d^T(x)d(x) - \frac{\varepsilon_2}{\varepsilon_2-1} b^T(x)b(x) \\ \geq & x^T Q_1 x + \frac{\varepsilon_1-2}{\varepsilon_1-1} d_M^2(x) + \frac{(c-1)\varepsilon_2-c}{\varepsilon_2-1} b_M^2(x)\end{aligned}\quad (2.19)$$

从上式中，可以得出只要反馈增益满足 $\varepsilon_1 \geq 2$, $\varepsilon_2 \geq \frac{c}{c-1}$ ，则函数 $\bar{Q}(x)$ 是正定的。

定理 2.2: 针对不确定系统(2.1)以及代价函数(2.15)，总是存在一组反馈增益 $\varepsilon_1 \geq 2$ 和 $\varepsilon_2 \geq \frac{2c}{c-1}$ ，使得鲁棒微分对策控制策略(2.10)是一组渐近稳定的纳什均衡解。

证明：针对不确定系统(2.1)以及性能指标函数(2.15)，定义哈密顿函数如下：

$$\begin{aligned}H(x, \bar{u}(x), \bar{v}(x), \nabla \bar{V}(x)) = & \bar{Q}(x) + \frac{1}{\varepsilon_1} \bar{u}(t) R_1 u(t) - \varepsilon_2 \bar{v}(t) R_2 v(t) \\ & + (\nabla V^*(x))^T (f(x) + g(x)(\bar{u}(t) + \bar{d}(x)) + k(x)(\bar{v}(t) + \bar{b}(x)))\end{aligned}\quad (2.20)$$

将 $\bar{V}(x)$ 替换为 $V^*(x)$ 并将式(2.16)代入式(2.20)，化简可得

$$\begin{aligned}H(x, \bar{u}(x), \bar{v}(x), \nabla V^*(x)) = & d_M^2(x) + cb_M^2(x) + x^T Q_1 x + (\nabla V^*(x))^T f(x) + (\nabla J^*(x))^T g(x) \bar{u}(t) \\ & + (\nabla V^*(x))^T k(x) \bar{v}(t) + \frac{1}{4} (\varepsilon_1-1) (\nabla V^*(x))^T g(x) R_1^{-1} g^T(x) \nabla V^*(x) \\ & + \frac{1}{4} \left(1 - \frac{1}{\varepsilon_2}\right) (\nabla V^*(x))^T k(x) R_2^{-1} k^T(x) \nabla V^*(x) + \frac{1}{\varepsilon_1} \bar{u}(t) R_1 \bar{u}(t) - \varepsilon_2 \bar{v}(t) R_2 \bar{v}(t)\end{aligned}\quad (2.21)$$

考虑式(2.9)并把式(2.10)代入式(2.21)，整理可得 $H(x, \bar{u}(x), \bar{v}(x), \nabla V^*(x)) = 0$ 。这时 $V^*(x)$ 被认为是针对不确定系统(2.1)的相应 HJI 方程的解。换言之，所设计的鲁棒微分对策控制策略在性能指标函数(2.15)中是最优的。

综上所述, 可得出这样的结论: 针对不确定系统(2.1), 只要设计反馈增益 ε_1 和 ε_2 满足 $\varepsilon_1 \geq 2, \varepsilon_2 \geq \frac{2c}{c-1}$, 就可以保证所设计的鲁棒微分对策控制策略(2.10)是鲁棒最优的。

由式(2.10)可以看出, 控制器的执行需要获得最优代价函数 $V^*(x)$, 这就不可避免地需要求解非线性 HJI 方程(2.9)。但该 HJI 方程属于非线性偏微分方程, 很难获得其解析解形式。为解决这一问题, 在下一节中将利用 ADP 技术构建评价网络, 在线逼近最优代价函数。

2.4 自适应最优控制器设计

在设计控制器之前, 基于文献[36; 75; 85], 给出如下假设:

假设 2.3: 针对标称系统(2.2)以及微分对策控制策略(2.8), 存在一个有效的连续可微的 Lyapunov 函数 $J_s(x)$, 满足 $\dot{J}_s(x) = (\nabla J_s(x))^T (f(x) + g(x)u^* + k(x)v^*) < 0$, 其中, $\nabla J_s(x)$ 表示 $J_s(x)$ 对状态 x 的偏导数; 则必定存在一个正定矩阵 $\Lambda(x)$ 使得如下等式成立:

$$(\nabla J_s(x))^T (f(x) + g(x)u^* + k(x)v^*) = -(\nabla J_s(x))^T \Lambda(x) \nabla J_s(x)。$$

如果定义 $\lambda_{\min}(\Lambda(x))$ 和 $\lambda_{\max}(\Lambda(x))$ 分别为矩阵 $\Lambda(x)$ 的最小特征值和最大特征值, 则可进一步得到 $\lambda_{\min}(\Lambda(x)) \|\nabla J_s(x)\|^2 \leq (\nabla J_s(x))^T \Lambda(x) \nabla J_s(x) \leq \lambda_{\max}(\Lambda(x)) \|\nabla J_s(x)\|^2$ 。

注释 2.3: 通常假设闭环系统在最优控制策略作用下存在上界, 且其上界与状态相关的函数。考虑到函数 $\nabla J_s(x)$ 为状态 x 的函数, 不失一般性, 可以假设 $\|f(x) + g(x)u^* + k(x)v^*\| \leq \eta \|\nabla J_s(x)\|$, 式中 $\eta > 0$ 为常数。进一步可得关系 $\|(\nabla J_s(x))^T (f(x) + g(x)u^* + k(x)v^*)\| \leq \eta \|\nabla J_s(x)\|^2$ 。考虑到有效的 Lyapunov 函数 $J_s(x)$ 满足 $\dot{J}_s(x) = (\nabla J_s(x))^T (f(x) + g(x)u^* + k(x)v^*) < 0$, 不难发现假设 2.3 是合理的。通常情况下, 在控制器的实现过程中将 $J_s(x)$ 选为多项式形式, 如 $J_s(x) = 0.5x^T x$ 。

为了执行鲁棒微分对策控制策略, 利用神经网络非线性逼近能力, 构建评价网络对最优代价函数进行逼近, 具体可表述为

$$V^*(x) = W_c^T \sigma(x) + \varepsilon(x) \quad (2.22)$$

其中, $W_c \in \mathbb{R}^L$ 表示神经网络理想权值向量, $\sigma(x) \in \mathbb{R}^L$ 表示激励函数, 而 $\varepsilon(x)$ 则表示神经网络逼近误差, L 表示隐含层的神经元个数。

最优代价函数 $V^*(x)$ 对状态 x 的偏导数为

$$\nabla V^*(x) = (\nabla \sigma(x))^T W_c + \nabla \varepsilon(x) \quad (2.23)$$

其中, $\nabla \sigma(x), \nabla \varepsilon(x)$ 分别表示变量 $\sigma(x)$ 和 $\varepsilon(x)$ 对状态 x 的偏导数。

将式(2.23)代入微分对策控制策略, 则式(2.8)可描述为

$$\begin{cases} u^*(x) = -\frac{1}{2} R_1^{-1} g^T(x) ((\nabla \sigma(x))^T W_c + \nabla \varepsilon(x)) \\ v^*(x) = \frac{1}{2} R_2^{-1} k^T(x) ((\nabla \sigma(x))^T W_c + \nabla \varepsilon(x)) \end{cases} \quad (2.24)$$

将式(2.24)代入式(2.10)经化简整理, 相应的 HJI 方程可表示为

$$\begin{aligned}
0 = & Q(x) + W_c^T \nabla \sigma(x) f(x) - \frac{1}{4} W_c^T \nabla \sigma(x) g(x) R_1^{-1} g^T(x) (\nabla \sigma(x))^T W_c \\
& + \frac{1}{4} W_c^T \nabla \sigma(x) k(x) R_2^{-1} k^T(x) (\nabla \sigma(x))^T W_c + \delta_{HII}
\end{aligned} \quad (2.25)$$

式中 δ_{HII} 表示由神经网络逼近误差引起的残余误差，具体表达式如下：

$$\begin{aligned}
\delta_{HII} = & (\nabla \varepsilon(x))^T \left(f(x) + g(x)u^* + k(x)v^* \right) + \frac{1}{4} (\nabla \varepsilon(x))^T g(x) R_1^{-1} g^T(x) \nabla \varepsilon(x) \\
& - \frac{1}{4} (\nabla \varepsilon(x))^T k(x) R_2^{-1} k^T(x) \nabla \varepsilon(x)
\end{aligned} \quad (2.26)$$

考虑到神经网络理想权值一般情况下都是未知的，微分对策控制策略(2.24)还不能够执行。基于此，可以利用神经网络输出估计理想权值，达到逼近最优代价函数的目的，具体表达式为：

$$\hat{V}(x) = \hat{W}_c^T \sigma(x) \quad (2.27)$$

其中， $\hat{W}_c$ 表示理想权值向量 W_c 的估计值。

类似地，将式(2.27)对状态 x 求偏导数可得

$$\nabla \hat{V}(x) = (\nabla \sigma(x))^T \hat{W}_c \quad (2.28)$$

于是可以得到估计的微分对策控制策略为

$$\begin{cases} \hat{u}(x) = -\frac{1}{2} R_1^{-1} g^T(x) (\nabla \sigma(x))^T \hat{W}_c \\ \hat{v}(x) = \frac{1}{2} R_2^{-1} k^T(x) (\nabla \sigma(x))^T \hat{W}_c \end{cases} \quad (2.29)$$

将式(2.29)代入哈密顿函数(2.4)，可得估计的哈密顿函数为

$$\begin{aligned}
H(x, \hat{W}_c, \hat{u}, \hat{v}) = & Q(x) + \hat{W}_c^T \nabla \sigma(x) f(x) - \frac{1}{4} \hat{W}_c^T \nabla \sigma(x) g(x) R_1^{-1} g^T(x) (\nabla \sigma(x))^T \hat{W}_c \\
& + \frac{1}{4} \hat{W}_c^T \nabla \sigma(x) k(x) R_2^{-1} k^T(x) (\nabla \sigma(x))^T \hat{W}_c \triangleq e_c
\end{aligned} \quad (2.30)$$

对比式(2.25)和式(2.30)不难发现，由于评价网络估计权值 $\hat{W}_c$ 与理想权值 W_c 之间的误差，造成了系统哈密顿函数 $H(x, W_c, u^*, v^*)$ 和 $H(x, \hat{W}_c, \hat{u}, \hat{v})$ 的不一致。此时需要对评价网络权值 $\hat{W}_c$ 进行调整，保证估计权值收敛于理想权值，即 $\hat{W}_c \rightarrow W_c$ ，从而确保估计的哈密顿函数最小化，即 $H(x, \hat{W}_c, \hat{u}, \hat{v}) \rightarrow 0$ 。

为了保证估计的评价网络权值 $\hat{W}_c$ 收敛于理想权值 W_c ，先设计一个目标函数如下：

$$E_c = \frac{1}{2} e_c^T e_c \quad (2.31)$$

基于梯度下降法，可以设计评价网络权值更新律，保证所选择的的目标函数 $E_c = 0.5 e_c^T e_c$ 最小化，达到最小化 $H(x, \hat{W}_c, \hat{u}, \hat{v})$ 的目的。但基于梯度下降法设计的权值更新律很难保证闭环系统在学习过程中信号的有界性。基于这种考虑，受文献[152]启发，本章设计如下评价网络权值更新律：

$$\begin{aligned}\dot{\hat{W}}_c = & -\alpha_c \left(\frac{\partial E_c}{\partial \hat{W}_c} \right) + \frac{1}{2} \alpha_s \Sigma(x, \hat{u}, \hat{v}) \nabla \sigma(x) g(x) R_1^{-1} g^T(x) \nabla J_s(x) \\ & - \frac{1}{2} \alpha_s \Sigma(x, \hat{u}, \hat{v}) \nabla \sigma(x) k(x) R_2^{-1} k^T(x) \nabla J_s(x)\end{aligned}\quad (2.32)$$

其中, $\alpha_c > 0$ 表示评价网络的学习率, $\alpha_s > 0$ 为调节参数; $J_s(x)$ 为选择的满足假设 2.3 的 Lyapunov 函数, $\Sigma(x, \hat{u}, \hat{v})$ 定义如下:

$$\Sigma(x, \hat{u}, \hat{v}) = \begin{cases} 0, & \text{if } \dot{J}_s(x) = (\nabla J_s(x))^T (f(x) + g(x)\hat{u} + k(x)\hat{v}) < 0, \\ 1, & \text{else.} \end{cases}\quad (2.33)$$

注释 2.4: 在评价网络权值更新律(2.32)中, 第一项是基于梯度下降法设计的, 主要用于最小化 $H(x, \hat{W}_c, \hat{u}, \hat{v})$; 第二项和第三项是附加项, 主要用于保证在学习过程中, 闭环系统信号的有界性。由 $\Sigma(x, \hat{u}, \hat{v})$ 的定义可以看出, 当闭环系统稳定时, 这两项不起任何作用; 但当闭环系统不稳定时, 这两个附加项才被激活, 确保闭环系统信号的有界。这两个附加项具体的推导过程如下:

针对标称系统(2.2), 选择 Lyapunov 函数 $J_s(x)$, 在微分对策控制策略(2.29)作用下, 对其求导可得

$$\Theta = (\nabla J_s(x))^T \left(f(x) - \frac{1}{2} g(x) R_1^{-1} g^T(x) (\nabla \sigma(x))^T \hat{W}_c + \frac{1}{2} k(x) R_2^{-1} k^T(x) (\nabla \sigma(x))^T \hat{W}_c \right)\quad (2.34)$$

如果闭环系统稳定, 易得 $\Theta \leq 0$; 相反, 如果闭环系统不稳定, 则 $\Theta > 0$ 。为了维持系统的稳定性, 基于梯度下降法, 设计附加项如下:

$$-\frac{\partial \Theta}{\partial \hat{W}_c} = \frac{1}{2} \nabla \sigma_c(x) g(x) R_1^{-1} g^T(x) \nabla J_s(x) - \frac{1}{2} \nabla \sigma_c(x) k(x) R_2^{-1} k^T(x) \nabla J_s(x)\quad (2.35)$$

接着, 定义评价网络权值估计误差为 $\tilde{W}_c = W_c - \hat{W}_c$ 。根据式(2.25)和式(2.30), 可以得到评价网络权值估计误差动态系统为:

$$\begin{aligned}\dot{\tilde{W}}_c = & \alpha_c \left\{ -\tilde{W}_c^T \nabla \sigma(x) f(x) - \frac{1}{4} \tilde{W}_c^T A \tilde{W}_c + \frac{1}{2} \tilde{W}_c^T A W_c + \frac{1}{4} \tilde{W}_c^T B \tilde{W}_c - \frac{1}{2} \tilde{W}_c^T B W_c - \delta_{HII} \right\} \\ & \times \left\{ -\frac{1}{2} A W_c + \nabla \sigma(x) f(x) + \frac{1}{2} A \tilde{W}_c + \frac{1}{2} B W_c - \frac{1}{2} B \tilde{W}_c \right\} \\ & - \frac{1}{2} \alpha_s \Sigma(x, \hat{u}, \hat{v}) \tilde{W}_c^T \nabla \sigma(x) g(x) R_1^{-1} g^T(x) \nabla J_s(x) \\ & + \frac{1}{2} \alpha_s \Sigma(x, \hat{u}, \hat{v}) \tilde{W}_c^T \nabla \sigma(x) k(x) R_2^{-1} k^T(x) \nabla J_s(x)\end{aligned}\quad (2.36)$$

其中, $A = \nabla \sigma(x) g(x) R_1^{-1} g^T(x) (\nabla \sigma(x))^T$, $B = \nabla \sigma(x) k(x) R_2^{-1} k^T(x) (\nabla \sigma(x))^T$ 。

2.5 稳定性分析

在稳定性分析之前, 针对构建的评价网络给出如下基本假设:

假设 2.4: 评价网络理想权值 W_c 存在上界, 即存在一个正常数 W_M , 使得不等式 $\|W_c\| \leq W_M$ 成立; 另外, 在紧集 $\Omega_x \in \mathbb{R}^n$ 内, 对于任意的 $x \in \Omega_x$, 评价网络激励函数 $\sigma(x)$ 、逼近误差 $\varepsilon(x)$ 以及相应的偏导数 $\nabla \sigma(x), \nabla \varepsilon(x)$ 都有界, 即存在正常数 $b_\phi, b_\varepsilon, b_\varepsilon$ 和 b_{ε_x} , 使得不等式 $\|\sigma(x)\| < b_\phi, \|\varepsilon(x)\| < b_\varepsilon, \|\nabla \sigma_c(x)\| < b_{\phi_x}$ 和 $\|\nabla \varepsilon_c(x)\| < b_{\varepsilon_x}$ 成立。

定理 2.3: 考虑标称系统(2.2)以及给定的性能指标函数(2.3), 在上述基本假设成立的前提下, 如果设计微分对策控制策略如式(2.29)所示, 且采用如式(2.32)所示的评价网络权值更新律, 则可保证评价网络权值估计误差 $\tilde{W}_c$ 是最终一致有界(Uniformly Ultimately Bounded, UUB)的。

证明: 选择 Lyapunov 函数为

$$L = \frac{1}{2\alpha_c} \tilde{W}_c^T \tilde{W}_c + \frac{\alpha_s}{2\alpha_c} J_s(x) \quad (2.37)$$

对 Lyapunov 函数(2.37)求导可得

$$\dot{L} = \frac{1}{\alpha_c} \tilde{W}_c^T \dot{\tilde{W}}_c + \frac{\alpha_s}{2\alpha_c} (\nabla J_s(x))^T \dot{x} \quad (2.38)$$

将权值估计误差动态系统(2.36)代入式(2.38), 化简整理可得

$$\begin{aligned} \dot{L} = & \left(-\tilde{W}_c^T \nabla \sigma(x) f(x) - \frac{1}{4} \tilde{W}_c^T A \tilde{W}_c + \frac{1}{2} \tilde{W}_c^T A W_c + \frac{1}{4} \tilde{W}_c^T B \tilde{W}_c - \frac{1}{2} \tilde{W}_c^T B W_c - \delta_{HII} \right) \\ & \times \left(\tilde{W}_c^T \nabla \sigma_c(x) f(x) - \frac{1}{2} \tilde{W}_c^T A W_c + \frac{1}{2} \tilde{W}_c^T A \tilde{W}_c + \frac{1}{2} \tilde{W}_c^T B W_c - \frac{1}{2} \tilde{W}_c^T B \tilde{W}_c \right) \\ & + \frac{\alpha_s}{2\alpha_c} (\nabla J_s(x))^T \dot{x} - \frac{\alpha_s}{2\alpha_c} \Sigma(x, \hat{u}, \hat{v}) \tilde{W}_c^T \nabla \sigma(x) g(x) R_1^{-1} g^T(x) \nabla J_s(x) \\ & + \frac{\alpha_s}{2\alpha_c} \Sigma(x, \hat{u}, \hat{v}) \tilde{W}_c^T \nabla \sigma(x) k(x) R_2^{-1} k^T(x) \nabla J_s(x) \end{aligned} \quad (2.39)$$

基于假设 2.1 和假设 2.4, 可以分析得出, A 和 B 均为有界信号, 即存在正常数 $\lambda_{1m}, \lambda_{2m}$ 和 $\lambda_{1M}, \lambda_{2M}$, 满足不等式条件 $\lambda_{1m} \leq \|A\| \leq \lambda_{1M}$, $\lambda_{2m} \leq \|B\| \leq \lambda_{2M}$ 。另外, 经分析可进一步假设不等式 $\|\nabla \sigma(x) f(x)\| \leq \lambda_3$, $\|A W_c\| \leq \lambda_4$, $\|B W_c\| \leq \lambda_5$ 和 $\|\delta_{HII}\| \leq \lambda_6$ 成立, 式中 $\lambda_3, \lambda_4, \lambda_5$ 和 λ_6 均为正常数。

根据以下不等式关系

$$\begin{aligned} ab &= \frac{1}{2} \left(-\left(\phi_1 a - \frac{b}{\phi_1} \right)^2 + \phi_1^2 a^2 + \frac{b^2}{\phi_1^2} \right) \leq \frac{1}{2} \left(\phi_1^2 a^2 + \frac{b^2}{\phi_1^2} \right) \\ -ab &= -\frac{1}{2} \left(\left(\phi_2 a - \frac{b}{\phi_2} \right)^2 + \phi_2^2 a^2 + \frac{b^2}{\phi_2^2} \right) \leq \frac{1}{2} \left(\phi_2^2 a^2 + \frac{b^2}{\phi_2^2} \right) \end{aligned} \quad (2.40)$$

式中 ϕ_1 和 ϕ_2 均为非零常数。通过简单的数学运算, 式(2.39)可变换为

$$\begin{aligned} \dot{L} \leq & -\lambda_8 \|\tilde{W}_c\|^4 + \lambda_9 \|\tilde{W}_c\|^2 + \lambda_6^2 + \frac{\alpha_s}{2\alpha_c} (\nabla J_s(x))^T \dot{x} \\ & - \frac{\alpha_s}{2\alpha_c} \Sigma(x, \hat{u}, \hat{v}) \tilde{W}_c^T \nabla \sigma(x) g(x) R_1^{-1} g^T(x) \nabla J_s(x) \\ & + \frac{\alpha_s}{2\alpha_c} \Sigma(x, \hat{u}, \hat{v}) \tilde{W}_c^T \nabla \sigma(x) k(x) R_2^{-1} k^T(x) \nabla J_s(x) \end{aligned} \quad (2.41)$$

其中,

$$\begin{aligned} \lambda_8 &= \left(\frac{1}{8} - \frac{7}{16} \phi_2^2 \right) \lambda_{1m}^2 + \left(\frac{1}{8} - \frac{1}{16} \phi_2^2 \right) \lambda_{2m}^2 - \frac{1}{4} \phi_1^2 \lambda_{1m}^2 - \frac{7}{16} \phi_1^2 \lambda_{2m}^2 - \frac{1}{4} \lambda_{1m} \lambda_{2m} \\ \lambda_9 &= \left(\frac{5}{2} + \frac{3}{8\phi_1^2} + \frac{7}{16\phi_2^2} \right) \lambda_3^2 + \left(\frac{3}{2} + \frac{3}{16\phi_1^2} \right) \lambda_4^2 + \left(\frac{5}{4} + \frac{3}{16\phi_1^2} + \frac{3}{16\phi_2^2} \right) \lambda_5^2 - \frac{1}{4} \lambda_3 \lambda_{2m} - \frac{1}{2} \lambda_{1m} \lambda_6 + \frac{1}{2} \lambda_{2m} \lambda_6 \end{aligned}$$

考虑到 $\Sigma(x, \hat{u}, \hat{v})$ 的定义式(2.33), 接下来将分两种情形讨论。

情形 1: $\Sigma(x, \hat{u}, \hat{v}) = 0$ 。在这种情况下, 很明显 $(\nabla J_s(x))^T \dot{x} < 0$ 。因此可以找到一个正常数 λ_7 , 使得不等式 $0 < \lambda_7 \|\nabla J_s(x)\| \leq -(\nabla J_s(x))^T \dot{x}$ 成立^[35]。于是式(2.41)可简化为

$$\dot{L} \leq -\lambda_8 \|\tilde{W}_c\|^4 + \lambda_9 \|\tilde{W}_c\|^2 + \lambda_6^2 - \frac{\alpha_s}{2\alpha_c} \lambda_7 \|\nabla J_s(x)\| \quad (2.42)$$

分析式(2.42)可知, 当下列不等式成立时, 可保证 $\dot{L} < 0$ 。

$$\|\tilde{W}_c\| \geq \sqrt{\frac{\lambda_9 + \sqrt{\lambda_9^2 + 4\lambda_8\lambda_6^2}}{2\lambda_8}} \triangleq A_1 \quad (2.43)$$

情形 2: $\Sigma(x, \hat{u}, \hat{v}) = 1$ 。这种情况意味着在评价网络学习过程中闭环系统不稳定, 式(2.32)中的两个附加项开始起作用, 维持系统的稳定状态。此时需要对式(2.41)进行变换。通过在式(2.41)右端同时加上和减去以下两项

$$\begin{aligned} & \frac{\alpha_s}{2\alpha_c} (\nabla J_s(x))^T (g(x)R_1^{-1}g^T(x)((\nabla \sigma(x))^T W_c + \nabla \varepsilon(x))) \\ & \frac{\alpha_s}{2\alpha_c} (\nabla J_s(x))^T (k(x)R_2^{-1}k^T(x)((\nabla \sigma(x))^T W_c + \nabla \varepsilon(x))) \end{aligned}$$

整理可得

$$\begin{aligned} \dot{L} \leq & -\lambda_8 \|\tilde{W}_c\|^4 + \lambda_9 \|\tilde{W}_c\|^2 + \lambda_6^2 + \frac{\alpha_s}{2\alpha_c} (\nabla J_s(x))^T (f(x) + g(x)u^* + k(x)v^*) \\ & + \frac{\alpha_s}{2\alpha_c} (\nabla J_s(x))^T D_1 \nabla \varepsilon_c(x) - \frac{\alpha_s}{2\alpha_c} (\nabla J_s(x))^T D_2 \nabla \varepsilon_c(x) \end{aligned} \quad (2.44)$$

其中, $D_1 = g(x)R_1^{-1}g^T(x) > 0$ 和 $D_2 = k(x)R_2^{-1}k^T(x) > 0$ 均为有界信号, 即存在正常数 D_{1m}, D_{2m} 和 D_{1M}, D_{2M} , 使得不等式 $D_{1m} \leq \|D_1\| \leq D_{1M}, D_{2m} \leq \|D_2\| \leq D_{2M}$ 成立。

基于假设 2.3, 考虑不等式 $\lambda_{\min}(\Lambda(x)) \|\nabla J_s(x)\|^2 \leq (\nabla J_s(x))^T \Lambda(x) \nabla J_s(x) \leq \lambda_{\max}(\Lambda(x)) \|\nabla J_s(x)\|^2$, 式(2.44)可简化为

$$\dot{L} \leq -\lambda_8 \|\tilde{W}_c\|^4 + \lambda_9 \|\tilde{W}_c\|^2 + \lambda_6^2 - \lambda_{10} \|\nabla J_s(x)\|^2 + \lambda_{11} \|\nabla J_s(x)\| \quad (2.45)$$

其中, $\lambda_{10} = \frac{\alpha_s}{2\alpha_c} \lambda_{\max}(\Lambda(x)), \lambda_{11} = \frac{\alpha_s}{2\alpha_c} (D_{1M} + D_{2M}) b_{\varepsilon_x}$ 。

从式(2.45)容易得出, 当评价网络权值估计误差 $\tilde{W}_c$ 满足下列不等式关系时, 可保证 $\dot{L} < 0$ 。

$$\|\tilde{W}_c\| \geq \sqrt{\frac{\lambda_9}{2\lambda_8} + \sqrt{\frac{\lambda_9^2}{4\lambda_8^2} + \frac{\lambda_6^2}{\lambda_8} + \frac{\lambda_{11}^2}{4\lambda_8\lambda_{10}}}} \triangleq A_2 \quad (2.46)$$

结合上述两种情形可得出如下结论: 如果评价网络权值估计误差 $\tilde{W}_c$ 满足不等式关系 $\|\tilde{W}_c\| > \max(A_1, A_2)$, 即可保证 $\dot{L} < 0$ 。根据 Lyapunov 稳定性定理^[153], 评价网络权值估计误差信号是最终一致有界(UUB)的。证毕

定理 2.4: 考虑标称系统(2.2)以及性能指标函数(2.3), 在假设 2.1-2.4 成立的前提下, 如果设计微分对策控制策略如式(2.29)所示, 评价网络权值更新律设计为式(2.32), 则可保证闭环系统最终一致有界稳定。

证明：将最优代价函数 $V^*(x)$ 选取为 Lyapunov 函数。对其求导得

$$\dot{V}^*(x) = (\nabla V^*(x))^T f(x) + (\nabla V^*(x))^T g(x) \hat{u}(x) + (\nabla V^*(x))^T k(x) \hat{v}(x) \quad (2.47)$$

根据式(2.8)和式(2.9)，可以得出

$$\begin{aligned} (\nabla V^*(x))^T f(x) &= -Q(x) - (\nabla V^*(x))^T g(x) u^*(x) - (\nabla V^*(x))^T k(x) v^*(x) \\ &\quad - u^{*T}(x) R_1 u^*(x) + v^{*T}(x) R_2 v^*(x) \end{aligned} \quad (2.48)$$

将式(2.48)代入式(2.47)，整理可得

$$\begin{aligned} \dot{V}^*(x) &= (\nabla V^*(x))^T g(x) (\hat{u}(x) - u^*(x)) + (\nabla V^*(x))^T k(x) (\hat{v}(x) - v^*(x)) \\ &\quad - Q(x) - u^{*T}(x) R_1 u^*(x) + v^{*T}(x) R_2 v^*(x) \end{aligned} \quad (2.49)$$

考虑关系式 $Q(x) = d_M^2(x) + c b_M^2(x) + x^T Q_1 x$ ，式(2.49)表述为

$$\begin{aligned} \dot{V}^*(x) &\leq (\nabla V^*(x))^T g(x) (\hat{u}(x) - u^*(x)) + (\nabla V^*(x))^T k(x) (\hat{v}(x) - v^*(x)) \\ &\quad - x^T Q_1 x - u^{*T}(x) R_1 u^*(x) + v^{*T}(x) R_2 v^*(x) \end{aligned} \quad (2.50)$$

根据微分对策控制策略(2.24)，可得如下两个关系式：

$$u^{*T}(x) R_1 u^*(x) = \frac{1}{4} W_c^T A W_c + \frac{1}{2} W_c^T \nabla \sigma(x) D_1 \nabla \varepsilon(x) + \frac{1}{4} (\nabla \varepsilon(x))^T D_1 \nabla \varepsilon(x) \quad (2.51)$$

$$v^{*T}(x) R_2 v^*(x) = \frac{1}{4} W_c^T B W_c + \frac{1}{2} W_c^T \nabla \sigma(x) D_2 \nabla \varepsilon(x) + \frac{1}{4} (\nabla \varepsilon_c(x))^T D_2 \nabla \varepsilon(x) \quad (2.52)$$

考虑假设 2.1-2.4，下列不等式关系可成立：

$$\|u^{*T}(x) R_1 u^*(x)\| \leq \frac{1}{4} \lambda_{1M} W_M^2 + \frac{1}{2} W_M D_{1M} b_{\phi_x} b_{\varepsilon_x} + \frac{1}{4} D_{1M} b_{\varepsilon_x}^2 \quad (2.53)$$

$$\|v^{*T}(x) R_2 v^*(x)\| \leq \frac{1}{4} \lambda_{2M} W_M^2 + \frac{1}{2} W_M D_{2M} b_{\phi_x} b_{\varepsilon_x} + \frac{1}{4} D_{2M} b_{\varepsilon_x}^2 \quad (2.54)$$

另一方面，结合式(2.24)和式(2.29)，经整理化简可得

$$\hat{u}(x) - u^*(x) = -\frac{1}{2} R_1^{-1} g^T(x) (\nabla \sigma(x))^T \tilde{W}_c + \frac{1}{2} R_1^{-1} g^T(x) \nabla \varepsilon(x) \quad (2.55)$$

$$\hat{v}(x) - v^*(x) = \frac{1}{2} R_2^{-1} k^T(x) (\nabla \sigma(x))^T \tilde{W}_c - \frac{1}{2} R_2^{-1} k^T(x) \nabla \varepsilon(x) \quad (2.56)$$

对式(2.55)和式(2.56)等号两边分别取范数整理可得

$$\|\hat{u}(x) - u^*(x)\| \leq \frac{1}{2} R_1^{-1} g_M b_{\phi_x} \|\tilde{W}_c\| + \frac{1}{2} R_1^{-1} g_M b_{\varepsilon_x} \quad (2.57)$$

$$\|\hat{v}(x) - v^*(x)\| \leq \frac{1}{2} R_2^{-1} k_M b_{\phi_x} \|\tilde{W}_c\| + \frac{1}{2} R_2^{-1} k_M b_{\varepsilon_x} \quad (2.58)$$

进一步基于定理 2.3 可知，评价网络权值估计误差最终一致有界，即 $\|\tilde{W}_c\| > \max(A_1, A_2)$ 。如果定义 $\Gamma = \max(A_1, A_2)$ ，则式(2.57)和式(2.58)可进一步简化为

$$\|\hat{u}(x) - u^*(x)\| \leq \frac{1}{2} R_1^{-1} g_M b_{\phi_x} \Gamma + \frac{1}{2} R_1^{-1} g_M b_{\varepsilon_x} \quad (2.59)$$

$$\|\hat{v}(x) - v^*(x)\| \leq \frac{1}{2} R_2^{-1} k_M b_{\phi_x} \Gamma + \frac{1}{2} R_2^{-1} k_M b_{\varepsilon_x} \quad (2.60)$$

将式(2.53)、式(2.54)、式(2.59)和式(2.60)分别代入式(2.50)可得

$$\dot{V}^*(x) \leq -\lambda_{\min}(Q_1) \|x\|^2 + \Lambda \quad (2.61)$$

其中， $\lambda_{\min}(Q_1)$ 表示矩阵 Q_1 的最小特征值；另外，

$$\Lambda = \frac{1}{2}(\Gamma+1)(R_1^{-1}(g_M b_{\phi_x})^2 + R_2^{-1}(k_M b_{\phi_x})^2) + \frac{1}{4}W_M^2(\lambda_{1M} + \lambda_{2M}) + \frac{1}{2}W_M(D_{1M} + D_{2M})b_{\phi_x} b_{\varepsilon_x} + \frac{1}{4}(D_{1M} + D_{2M})b_{\varepsilon_x}^2$$

从式(2.61)中可以清楚得出, 系统状态信号只要满足下列不等式关系

$$\Omega_x = \left\{ x : \|x\| \geq \sqrt{\frac{\Lambda}{\lambda_{\min}(Q_1)}} \right\} \quad (2.62)$$

即可保证 $\dot{V}^*(x) < 0$ 。证毕

注释 2.5: 从式(2.62)可以看出, 紧集 Ω_x 的大小可以通过选择 $\lambda_{\min}(Q_1)$ 来调节。如果选择比较大的 $\lambda_{\min}(Q_1)$, 便可以获得较小的收敛域。另外, 还可以通过增加神经元个数, 减小评价网络逼近误差。从理论上讲, 如果选择神经元个数 $L \rightarrow \infty$ 时, 可以保证逼近误差 $\varepsilon(x) \rightarrow 0$ 且 $\nabla \varepsilon(x) \rightarrow 0$ 。也就是说, 可选择足够多的神经元个数保证足够小的界值 Λ 。

2.6 导弹拦截制导应用

为了验证所设计的鲁棒微分对策控制策略的有效性, 本节将上述理论应用于导弹拦截制导中。在此过程中, 导弹试图拦截机动目标, 而目标却试图成功逃逸, 于是构成了动态博弈的双方, 它们旨在寻找一组使得双方都满意的纳什均衡解。为此, 首先建立弹-目拦截制导模型, 通过分析制导原则, 建立如式(2.1)所示的非线性微分对策控制系统。最后将本章提出的鲁棒微分对策控制策略应用于该拦截制导系统, 实现基于微分对策的鲁棒自适应最优拦截制导。

2.6.1 导弹-目标拦截制导模型建立

考虑二维平面内的导弹-目标相对运动关系, 如图 2.1 所示, 将导弹和目标均视为质点, 其中, M 表示导弹, T 表示目标; V_M, V_T 分别表示导弹和目标各自的速度; α, β 表示它们的航迹角; θ 为视线角, 把视线角 θ 对时间的导数描述为视线角速率, 表示为 $\dot{\theta} = \sigma$; 导弹和目标在垂直于各自速度方向的法向控制输入分别用 u_M 和 v_T 表示; r 为导弹与目标之间的相对距离, r 对时间的导数描述为弹-目相对速率, 表示为 $\dot{r} = V_r$ 。

假设在末制导阶段, 导弹和目标的飞行速度均保持不变。则可建立如下导弹-目标相对运动关系:

$$\begin{aligned} V_r = \dot{r} &= V_T \cos(\beta - \theta) - V_M \cos(\alpha - \theta) \\ \sigma = \dot{\theta} &= (V_T \sin(\beta - \theta) - V_M \sin(\alpha - \theta))/r \\ \dot{\alpha} &= u_M/V_M \\ \dot{\beta} &= v_T/V_T \end{aligned} \quad (2.63)$$




图 2.1 导弹-目标相对运动示意图

另外，为方便起见，不妨假设导弹与目标的自动驾驶仪系统均为一阶系统，具体表述为：
导弹质心运动方程：

$$\begin{aligned}\dot{x}_M &= V_M \cos \alpha \\ \dot{y}_M &= V_M \sin \alpha \\ \dot{\alpha} &= a_M / V_M \\ \dot{a}_M &= (u_M - a_M) / \tau_M\end{aligned}\quad (2.64)$$

式中 (x_M, y_M) 表示导弹质心在二维平面内的位置坐标； a_M 表示侧向加速度； τ_M 为自动驾驶仪时间常数，假设为 $\tau_M = 0.1$ 。

目标质心运动方程：

$$\begin{aligned}\dot{x}_T &= V_T \cos \beta \\ \dot{y}_T &= V_T \sin \beta \\ \dot{\beta} &= a_T / V_T \\ \dot{a}_T &= (v_T - a_T) / \tau_T\end{aligned}\quad (2.65)$$

式中 (x_T, y_T) 表示目标质心在二维平面内的位置坐标信息； a_T 表示目标的侧向加速度； τ_T 为自动驾驶仪时间常数，假设为 $\tau_T = 0.1$ 。

2.6.2 制导原则

在拦截制导过程中，为了保证能够成功拦截目标，导弹方会通过选择控制策略最小化零控脱靶量，而目标方通常会调整自己的策略最大化零控脱靶量，试图逃逸。为了在拦截制导过程中对导弹制导性能进行定性分析，给出如下零控脱靶量^[154]的定义。

定义 2.1 (零控脱靶量)：零控脱靶量是指当导弹和目标都不再发生机动时，它们之间的最小距离，表示为 $r_{miss}(t)$ ，具体表达式如下：

$$r_{miss}(t) = \frac{r^2 \sigma}{\sqrt{V_r^2 + r^2 \sigma^2}} \quad (2.66)$$

从式(2.66)可以得出，要保证零控脱靶量为零，需要调节视线角速率 σ 为零；与此同时，还

必须保证导弹与目标之间的相对速率 V_r 小于零。总之，可以分析得出，保证导弹成功拦截目标，即 $r \rightarrow 0$ ，需要满足以下两个条件：

$$\sigma \rightarrow 0, V_r < 0 \quad (2.67)$$

2.6.3 非线性微分对策系统

基于上述分析可知，通过设计控制输入保证变量 σ 收敛于零，即可实现拦截。因此选择系统状态变量为 $x = \sigma$ ，对其求导整理后可得，拦截制导系统状态方程为：

$$\dot{x} = -\frac{2V_r}{r}x - \frac{\cos(\alpha - \theta)}{r}u_M + \frac{\cos(\beta - \theta)}{r}v_T \quad (2.68)$$

如果定义 $f(x) = -2V_r x/r$ ， $g(x) = -\cos(\alpha - \theta)/r$ ， $k(x) = \cos(\beta - \theta)/r$ 以及控制输入 $u = u_M$ ， $v = v_T$ ，则式(2.68)可描述为如式(2.2)所示的非线性微分对策系统

$$\dot{x} = f(x) + g(x)u + k(x)v \quad (2.69)$$

从式(2.68)可以看出，如果弹目相对距离 $r \rightarrow 0$ ，则非线性项 $f(x)$ 、 $g(x)$ 和 $k(x)$ 都趋于无穷大，此时拦截制导系统(2.69)已被破坏，所设计的制导律不再适用。然而需要注意的是，在末制导过程中，由于受到导弹导引头、接收机过载等物理因素的限制^[155]，往往存在一个最小作用距离 r_0 。一旦导弹与目标之间的相对距离 r 小于或等于最小作用距离 r_0 ，即 $r \leq r_0$ ，则制导过程结束，此时导弹和目标均靠自身的惯性完成最后的制导任务。

另外，观察式(2.68)不难发现，当 $|(\alpha - \theta)| = \pi/2$ ， $|(\beta - \theta)| = \pi/2$ 时，控制矩阵 $g(x)$ 和 $k(x)$ 均等于零，此时系统不可控。因此可归纳出拦截制导律的可行域为

$$\Phi = \{x : |(\alpha - \theta)| \neq \pi/2, |(\beta - \theta)| \neq \pi/2, r \neq 0, V_r < 0\} \quad (2.70)$$

考虑拦截制导系统由于飞行过程中系统结构参数和控制参数变化引起的动态不确定性以及系统未建模动态等特性，如果进一步假设此类不确定项满足匹配原则，则可将存在不确定项的拦截制导模型描述为如式(2.1)所示系统

$$\begin{aligned} \dot{x} &= f(x) + g(x)(u + \bar{d}(x)) + k(x)(v + \bar{b}(x)) \\ &= -\frac{2V_r}{r}x - \frac{\cos(\alpha - \theta)}{r}(u + \bar{d}(x)) + \frac{\cos(\beta - \theta)}{r}(v + \bar{b}(x)) \end{aligned} \quad (2.71)$$

其中， $\bar{d}(x)$ 和 $\bar{b}(x)$ 表示系统不确定项。

2.7 仿真验证

在末制导阶段，考虑导弹和目标的速度恒定，假设为 $V_M = 600$ m/s, $V_T = 400$ m/s；拦截制导系统中导弹和目标的初始位置坐标分别为 $(x_M, y_M) = (0, 0)$ 和 $(x_T, y_T) = (2500, 0)$ ；进一步，假设拦截制导系统存在的不确定项分别为 $\bar{d}(x) = \delta_1 x \cos(\delta_2 x + \delta_3 x^2)$ 和 $\bar{b}(x) = \delta_4 x \sin(x)$ ，式中 $\delta_1 \in [-10, 10]$, $\delta_2 \in [-25, 25]$, $\delta_3 \in [-15, 15]$, $\delta_4 \in [-1, 1]$ 均为未知的随机参数。

情形 1: $v_T = \hat{v}(x)$

在这种情况下，假设机动目标输入就是最大化性能指标函数(2.3)的信号 $\hat{v}(x)$ ，其中 $\hat{v}(x)$ 如

式(2.29)定义。此时微分对策制导律描述的是机动目标影响最坏情况下导弹选择的最优制导律。

假设导弹初始航迹角选为 $\alpha_0 = 30^\circ$ ，目标初始航迹角为 $\beta_0 = 125^\circ$ ；选择反馈增益为 $\varepsilon_1 = 115$ 和 $\varepsilon_2 = 10$ ，设计参数 $c = 36$ ；另外，设计 $Q_1 = 200, R_1 = 0.1, R_2 = 0.1$ ；评价网络激励函数选取为 $\sigma(x) = [x, x^2, x^3, x^4]^T$ ，初始权值向量为 $\hat{W}_c(0) = [50, 50, 50, 50]^T$ ，评价网络学习率 $\alpha_c = 0.07$ ， $\alpha_s = 10$ 。此外，Lyapunov 函数 $J_s(x)$ 选取为 $J_s(x) = 0.5x^2$ 。

仿真结果如图 2.2-图 2.5 所示。图 2.2 给出了拦截制系统存在不确定时，导弹-目标拦截轨迹以及相对距离变化曲线；图 2.2(a)表明在所设计的鲁棒微分对策控制策略下，导弹能够在可接受的零控脱靶量条件下成功拦截目标，其中弹-目相对距离如图 2.2(b)所示，从最初的 2500m 逐渐减小到小于 0.5m 的脱靶量范围内，描述了导弹不断接近目标的过程。图 2.3 分别给出了拦截过程中的视线角速率变化曲线和弹-目相对速率变化曲线。可以看到，在拦截制导的大部分时间内，视线角速率始终保持在零附近，直到制导最后时刻，而且导弹与目标的相对速率始终小于零。仿真结果满足式(2.67)描述的拦截条件，即 $\sigma \rightarrow 0, V_r < 0$ ，可以保证导弹能够成功拦截机动目标。




图 2.2(a) 导弹-目标拦截轨迹




图 2.2(b) 导弹-目标相对距离

图 2.2 鲁棒微分对策下弹-目拦截轨迹和相对距离




图 2.3(a) 导弹视线角速率




图 2.3(b) 导弹-目标相对速率

图 2.3 鲁棒微分对策下导弹视线角速率和相对速率

另外，导弹和目标的侧向加速度曲线如图 2.4 所示，从中可以看出，导弹侧向加速度在大部分制导时间内均保持在较合理的范围内，直至制导最后时刻呈现出发散的特性，这主要是由于制导过程中动力学方程发生变化造成的。图 2.5 分别给出了评价网络权值更新过程和残余误差曲线，进一步表明了评价网络权值估计误差向量的有界性。




图 2.4(a) 导弹侧向加速度

图 2.4(b) 目标侧向加速度

图 2.4 鲁棒微分对策下导弹和目标侧向加速度




图 2.5(a) 评价网络权值

图 2.5(b) 残余误差

图 2.5 鲁棒微分对策下评价网络权值和残余误差

情形 2: $v_t = 100 \sin(t) \text{ m/s}^2$

为进一步验证所设计的微分对策拦截制导律在其他形式目标机动情况下的鲁棒性, 选择目标机动为幅值等于 $10g$ 的正弦机动形式; 在这种情况下, 目标机动形式相对于性能指标函数(2.3)而言并不是最坏情况。从理论上讲, 本章给出的最优拦截制导律仍然能够成功拦截该机动目标。

此时, 假设导弹初始航迹角为 $\alpha_0 = 30^\circ$, 目标初始航迹角为 $\beta_0 = 60^\circ$; 反馈增益选取为 $\varepsilon_1 = 200$ 和 $\varepsilon_2 = 5$, 设计参数 $c = 35$; $R_1 = 0.25$, $R_2 = 100$, $\alpha_c = 0.4$, $\alpha_s = 20$; 其他参数与情形 1 相同。具体仿真结果如图 2.6-图 2.8 所示, 从中可以看出, 在目标正弦机动下, 所设计的最优拦截制导律同样能够在容许的脱靶量范围内成功拦截目标, 如图 2.6 所示; 从图 2.7 可以看出, 视线角速率 σ 以及导弹与目标之间的相对速率 v_r 均满足拦截条件(2.67), 这进一步表明该制导方案的有效性。




图 2.6(a) 导弹-目标拦截轨迹

图 2.6(b) 导弹-目标相对距离

图 2.6 鲁棒微分对策下弹-目拦截轨迹和相对距离 (目标正弦机动)




图 2.7(a) 导弹视线角速率




图 2.7(b) 导弹-目标相对速率

图 2.7 鲁棒微分对策下导弹视线角速率和相对速率（目标正弦机动）




图 2.8 鲁棒微分对策下导弹侧向加速度（目标正弦机动）

需要指出的是，从上述两种情形的仿真结果中可以看出，在制导最后时刻，制导系统的信号都表现为发散特性。这主要是因为，在制导末端，随着弹-目相对距离的减小，制导系统(2.68)中的动态特性发生变化。特别地，当 $r \rightarrow 0$ 时，正如前所述，非线性项 $f(x)$, $g(x)$ 和 $k(x)$ 都趋于无穷大。这导致该拦截制导系统状态发散，所设计的制导律已不再适用。因此仿真曲线中出现的这种发散现象属于拦截制导系统末端必然发生的情况。

2.8 本章小结

本章主要考虑导弹拦截制导系统存在的内部扰动、未建模动态等不确定性问题，将该问题抽象为一类不确定非线性微分对策控制问题，加以分析研究。为了补偿不确定项的影响，通过修改性能指标函数，进一步改进微分对策控制策略，从而提出了鲁棒微分对策控制策略，并且严格证明了所提方法的鲁棒性和最优性。为了能够在线执行该鲁棒微分对策控制策略，构建了评价网络结构，通过设计评价网络权值更新律，在线逼近最优代价函数，从而达到自适应最优控制的目的，并从理论上保证了评价网络权值估计误差信号的有界性以及闭环系统的稳定性。最后，将本章提出的鲁棒微分对策控制策略应用于导弹拦截制导过程，解决了鲁棒自适应最优制导问题。但本章研究内容并没有考虑拦截制导过程中导弹过载饱和问题。在接下来的章节中将予以考虑，并加以解决。

第三章 输入饱和条件下的有限时域微分对策拦截制导

3.1 引言

在导弹末制导过程中，目标通常会改变既定轨迹进行大机动逃逸，从而使得导弹必须能够在尽可能短的时间内进行攻击；同时，对终端脱靶量、终端时间以及终端状态等变量均有一定的约束要求。因此在末制导段，需要有强抗目标机动能力且能够在综合考虑各种终端约束条件的高精度制导律，保证拦截制导过程的实现。此外，在拦截大机动目标时，由于目标的大幅度机动、导弹自身的不确定性以及外界的干扰因素等原因可能会造成制导系统的舵机饱和以及过载饱和问题。而一旦发生这类情况，就有可能使系统动态品质变坏，甚至破坏系统的稳定性。因此在设计制导律时充分考虑系统输入饱和特性将有利于提高拦截制导系统的鲁棒性。

然而，针对拦截制导系统表现出的非线性特性，研究输入饱和条件下的有限时域微分对策拦截制导问题通常会涉及 Hamilton-Jacobi-Isaacs (HJI) 方程的求解问题，给制导律的设计带来了极大的挑战。虽然 ADP 技术已被用于求解微分对策问题中 HJI 方程的解，但现有大部分研究成果都集中于无穷域最优控制问题的研究。只有极少数的文献^[71, 73-76]研究基于 ADP 技术的有限时域最优控制问题，却没有考虑输入饱和问题的影响。而将 ADP 技术应用于有限时域微分对策问题的研究更是鲜有涉及。基于此，本章考虑系统存在饱和约束条件下的有限时域微分对策问题，进一步拓宽 ADP 技术的应用范围，丰富和发展微分对策理论体系。

3.2 问题描述

考虑如下连续仿射非线性系统

$$\dot{x} = f(x) + g(x)u(t) + k(x)v(t) \quad (3.1)$$

其中， $x \in \mathbb{R}^n$ 为系统状态， $u(t) \in \mathbb{R}^m$ 和 $v(t) \in \mathbb{R}^k$ 分别表示博弈双方各自的控制输入向量； $f(x) \in \mathbb{R}^n, g(x) \in \mathbb{R}^{n \times m}, k(x) \in \mathbb{R}^{n \times k}$ 均为已知的连续非线性函数；不失一般性，假设非线性函数 $f(x), g(x)$ 和 $k(x)$ 均为局部 Lipschitz 连续且满足 $f(0) = 0$ 。

此外，本章考虑系统控制输入向量 $u(t)$ 受限，即 $u(t)$ 的每一个分量均满足如下不等式：

$$|u_i(t)| \leq \lambda, \quad i = 1, \dots, m \quad (3.2)$$

其中， $\lambda > 0$ 表示控制输入界值。

为了便于后续分析，先给出如下假设条件：

假设 3.1：控制输入矩阵函数 $g(x)$ 和 $k(x)$ 均有上界，即存在两个正常数 g_M 和 k_M ，对于 $\forall x$ ，使得不等式 $\|g(x)\| \leq g_M$ 和 $\|k(x)\| \leq k_M$ 成立。

定义有限时域性能指标函数如下：

$$V(x, t) = \psi(x(t_f), t_f) + \int_t^{t_f} r(x, u, v) dt \quad (3.3)$$

其中, $\psi(\cdot)$ 表示终端状态约束, $r(x, u, v) = Q(x, t) + U(u) - v^T R_2 v$ 表示从时刻 t 到 t_f 期间对状态和输入的刻画; $Q(x, t) \geq 0$ 表示半正定函数, $U(u)$ 表示一个非二次型泛函, R_2 为正定对称矩阵。

本章主要目的就是寻找一组微分对策控制策略 $(u^*(x), v^*(x))$, 使得控制输入 $u^*(x)$ 能够最小化性能指标函数(3.3), 而控制输入 $v^*(x)$ 能够最大化性能指标函数(3.3), 同时保证闭环系统满足给定的终端约束条件。

为有效处理输入饱和问题, 借鉴文献[78; 84; 85]中的设计思想, 引入一个非二次型泛函

$$U(u) = 2\lambda \int_0^u \phi^{-T}(v/\lambda) R_1 dv \quad (3.4)$$

其中, $v \in \mathbb{R}^m, \phi \in \mathbb{R}^m, \phi(v) = [\phi(v_1) \dots \phi(v_m)]^T, \phi^{-1}(u) = [\phi^{-1}(u_1) \dots \phi^{-1}(u_m)]^T$, $\phi(\cdot)$ 表示一一映射的有界 $C^p(p \geq 1)$ 类函数且满足条件 $|\phi(\cdot)| \leq 1$ 和 $\phi(0) = 0$; 另外, $\phi(\cdot)$ 属于单调奇函数且它的一阶导数有界; 另外, 为方便起见, $R_1 = \text{diag}(r_1, \dots, r_m) > 0$ 选为正定对角矩阵。

不失一般性, 选择双曲正切函数 $\phi(\cdot) = \tanh(\cdot)$, 则式(3.4)可表述为

$$U(u) = 2 \int_0^u (\lambda \tanh^{-1}(v/\lambda))^T R_1 dv \quad (3.5)$$

对式(3.5)求积分, 经运算整理可得

$$U(u) = 2 \int_0^u (\lambda \tanh^{-1}(v/\lambda))^T R_1 dv = 2\lambda (\tanh^{-1}(u/\lambda))^T R_1 u + \lambda^2 \bar{R}_1 \ln(\bar{\mathbf{1}} - (u/\lambda)^2) \quad (3.6)$$

其中, $\bar{\mathbf{1}} = [1, \dots, 1]^T \in \mathbb{R}^m$ 表示元素全为 1 的列向量; $\bar{R}_1 = [r_1, \dots, r_m] \in \mathbb{R}^{1 \times m}$ 表示行向量。

结合有限时域性能指标函数(3.3), 定义系统(3.1)的哈密顿函数为

$$H(x, u, v) = \nabla V_t + Q(x, t) + 2 \int_0^u (\lambda \tanh^{-1}(v/\lambda))^T R_1 dv - v^T R_2 v + (\nabla V(x, t))^T (f(x) + g(x)u + k(x)v) \quad (3.7)$$

其中, $\nabla V_t = \frac{\partial V(x, t)}{\partial t}$, $\nabla V(x, t) = \frac{\partial V(x, t)}{\partial x}$ 。

注释 3.1: 从式(3.7)可以看出, 在有穷域微分对策问题中, 由于 V_t 的存在使得 $V(x, t)$ 表现为时变特性。而在无穷域微分对策问题中, $V_t = 0$, 故不存在上述问题。

根据 Nash-Pontryagin 极大极小值原理, 纳什均衡解 $(u^*(x), v^*(x))$ 存在的必要条件是

$$H(x, u^*, v, V^*(x, t)) \leq H(x, u^*, v^*, V^*(x, t)) \leq H(x, u, v^*, V^*(x, t)) \quad (3.8)$$

式中最优代价函数 $V^*(x, t)$ 满足下列关系:

$$V^*(x, t) = \max_v \min_u \left\{ \psi(x(t_f), t_f) + \int_t^{t_f} \left(Q(x, t) + 2 \int_0^u (\lambda \tanh^{-1}(v/\lambda))^T R_1 dv - v^T R_2 v \right) dt \right\} \quad (3.9)$$

且 $V^*(0, 0) = 0$ 。

因此可通过求解下列 HJI 方程得到最优代价函数 $V^*(x, t)$

$$0 = \max_v \min_u H(x, u, v, V^*(x, t)) \quad (3.10)$$

假设式(3.10)的解存在且唯一。利用最优控制必要条件 $\frac{\partial H(x, u, v)}{\partial u} = 0, \frac{\partial H(x, u, v)}{\partial v} = 0$, 可推导得到输入饱和条件下的微分对策控制策略为

$$\begin{cases} u^*(x) = -\lambda \tanh(D^*) \\ v^*(x) = \frac{1}{2} R_2^{-1} k^T(x) \nabla V^*(x, t) \end{cases} \quad (3.11)$$

其中, $D^* = \frac{1}{2\lambda} R_1^{-1} g^T(x) \nabla V^*(x, t)$ 。

将式(3.11)代入式(3.6), 化简整理可得

$$U(u^*) = (\nabla V^*(x, t))^T g(x) \lambda \tanh(D^*) + \lambda^2 \bar{R}_1 \ln(\bar{1} - \tanh^2(D^*)) \quad (3.12)$$

将式(3.11)和式(3.12)代入式(3.7), 整理可得输入受限条件下的 HJI 方程为

$$\begin{aligned} H(x, u^*, v^*) = & \nabla V_t^* + Q(x, t) + (\nabla V^*(x, t))^T f(x) \\ & + \lambda^2 \bar{R}_1 \ln(\bar{1} - \tanh^2(D^*)) + \frac{1}{4} (\nabla V^*(x, t))^T k(x) R_2^{-1} k^T(x) (\nabla V^*(x, t))^T = 0 \end{aligned} \quad (3.13)$$

可以看出, 微分对策控制策略(3.11)的实现需要求解 HJI 方程(3.13)。但该 HJI 方程属于非线性偏微分方程, 难以获得其解析解形式。为解决这一问题, 本章将利用 ADP 技术, 在线逼近最优代价函数。

3.3 微分对策控制策略在线执行

为方便控制器设计, 先给出如下假设:

假设 3.2^[75]: 考虑系统(3.1)以及性能指标函数(3.3), 在微分对策控制策略(3.11)作用下, 存在一个连续可微的 Lyapunov 候选函数 $J_s(x)$ 使得不等式 $\dot{J}_s(x) = (\nabla J_s(x))^T (f(x) + g(x)u^* + k(x)v^*) < 0$ 成立, 式中 $\nabla J_s(x)$ 表示 $J_s(x)$ 对状态 x 的偏导数; 那么一定存在一个正定函数 $\Lambda(x) \in \mathbb{R}^{n \times n}$, 使得不等式 $(\nabla J_s(x))^T (f(x) + g(x)u^* + k(x)v^*) < -(\nabla J_s(x))^T \Lambda(x) \nabla J_s(x)$ 成立。

本节考虑到有限时域微分对策中, 最优代价函数 $V^*(x, t)$ 表现出时变特性, 传统神经网络结构对时变非线性函数的逼近能力有限, 而且还必须考虑终端状态约束问题, 从而保证闭环系统的性能。基于这样的考虑, 我们将设计基于剩余时间的时变评价网络, 在线逼近最优代价函数 $V^*(x, t)$ 。受文献[75]启发, 在时变评价网络中本章仍然采用常值评价网络权值, 但激励函数选取为与剩余时间相关的时变函数。基于此, 时变的最优代价函数 $V^*(x, t)$ 可表述为

$$V^*(x, t) = W_c^T \sigma(x, t_f - t) + \varepsilon(x, t) \quad (3.14)$$

其中, $W_c \in \mathbb{R}^L$ 表示评价网络理想权值向量, $\sigma(x, t_f - t) \in \mathbb{R}^L$ 为所选择的的时变激励函数, $\varepsilon(x, t)$ 表示逼近误差, L 为隐含层神经元个数。

终端约束可表示为

$$V^*(x, t_f) = W_c^T \sigma(x(t_f), 0) + \varepsilon(x, t_f) \quad (3.15)$$

分别求 $V^*(x, t)$ 对状态 x 和时间 t 的偏导数可得

$$\begin{aligned} \nabla V^*(x, t) &= (\nabla_x \sigma(x, t_f - t))^T W_c + \nabla_x \varepsilon(x, t) \\ \nabla V_t^* &= (\nabla_t \sigma(x, t_f - t))^T W_c + \nabla_t \varepsilon(x, t) \end{aligned} \quad (3.16)$$

其中, $\nabla_x \sigma(x, t_f - t) = \frac{\partial \sigma_c(x, t_f - t)}{\partial x}$, $\nabla_x \varepsilon(x, t) = \frac{\partial \varepsilon(x, t)}{\partial x}$, $\nabla_t \sigma(x, t_f - t) = \frac{\partial \sigma_c(x, t_f - t)}{\partial t}$, $\nabla_t \varepsilon(x, t) = \frac{\partial \varepsilon(x, t)}{\partial t}$ 。

将式(3.16)代入微分对策控制策略(3.11)可得

$$\begin{cases} u^*(x) = -\lambda \tanh\left(\frac{1}{2\lambda} R_1^{-1} g^T(x) (\nabla_x \sigma(x, t_f - t))^T W_c\right) + \varepsilon_{u^*} \\ v^*(x) = \frac{1}{2} R_2^{-1} k^T(x) (\nabla_x \sigma(x, t_f - t))^T W_c + \varepsilon_{v^*} \end{cases} \quad (3.17)$$

其中, $\varepsilon_{u^*} = -\frac{1}{2}[\bar{1} - \tanh^2(\xi)] \bar{R}_1 g^T(x) \nabla_x \varepsilon(x, t)$, $\varepsilon_{v^*} = \frac{1}{2} R_2^{-1} k^T(x) \nabla_x \varepsilon(x, t)$, $\xi \in \mathbb{R}^m$ 在 $\frac{1}{2\lambda} R_1^{-1} g^T(x) (\nabla_x \sigma(x, t_f - t))^T W_c$ 和 $\frac{1}{2\lambda} R_1^{-1} g^T(x) ((\nabla_x \sigma(x, t_f - t))^T W_c + \nabla_x \varepsilon(x, t))$ 之间选取。

将式(3.17)代入式(3.13), 则 HJI 方程可描述为

$$\begin{aligned} H(x, W_c, u^*, v^*) &= W_c^T \nabla_t \sigma(x, t_f - t) + Q(x, t) + W_c^T \nabla_x \sigma(x, t_f - t) f(x) + \lambda^2 \bar{R}_1 \ln(\bar{1} - \tanh^2(D)) \\ &\quad + \frac{1}{4} W_c^T \nabla_x \sigma(x, t_f - t) k(x) R_2^{-1} k^T(x) (\nabla_x \sigma(x, t_f - t))^T W_c + \delta_{HJI} = 0 \end{aligned} \quad (3.18)$$

其中, $D = \frac{1}{2\lambda} R_1^{-1} g^T(x) (\nabla_x \sigma(x, t_f - t))^T W_c$; δ_{HJI} 是由于评价网络逼近误差引起的残余误差项, 具体

可表示为 $\delta_{HJI} = \nabla_t \varepsilon(x, t) + (\nabla_x \varepsilon(x, t))^T (f(x) + g(x)u^* + k(x)v^*) - \frac{1}{4} (\nabla_x \varepsilon(x, t))^T k(x) R_2^{-1} k^T(x) \nabla_x \varepsilon(x, t)$ 。

注释 3.2: 在文献[78]中已经证明, 随着神经元个数 L 的不断增加, 残余误差 δ_{HJI} 逐渐收敛到零。换言之, 对于任意一个正数, i.e., $\forall \varepsilon_h > 0$, 总是存在一个正数 L_h , 使得当 $L > L_h$ 时, $\|\delta_{HJI}\| \leq \varepsilon_h$ 。

考虑到评价网络理想权值向量 W_c 未知, 不能用于控制器的设计, 可考虑利用其输出估计最优代价函数, 具体表达式为

$$\hat{V}(x, t) = \hat{W}_c^T \sigma(x, t_f - t) \quad (3.19)$$

同样地, 终端状态约束变为

$$\hat{V}(x, t_f) = \hat{W}_c^T \sigma(\hat{x}(t_f), 0) \quad (3.20)$$

其中, $\hat{W}_c$ 为理想权值 W_c 的估计值, 评价网络权值估计误差向量可定义为 $\tilde{W}_c = W_c - \hat{W}_c$; $\sigma(\hat{x}(t_f), 0) \in \mathbb{R}^L$ 表示终端时刻的激励函数, $\hat{x}_{t_f}$ 为终端状态的估计值, 可通过系统动态和当前状态计算得到。

同理, 针对式(3.19), 对状态 x 和时间 t 分别求偏导数可得

$$\begin{aligned} \nabla \hat{V}(x, t) &= (\nabla_x \sigma(x, t_f - t))^T \hat{W}_c \\ \nabla \hat{V}_t(x, t) &= (\nabla_t \sigma(x, t_f - t))^T \hat{W}_c \end{aligned} \quad (3.21)$$

这样就可以得到估计的微分对策控制策略为

$$\begin{cases} \hat{u}(x) = -\lambda \tanh(\hat{D}) \\ \hat{v}(x) = \frac{1}{2} R_2^{-1} k^T(x) (\nabla_x \sigma(x, t_f - t))^T \hat{W}_c \end{cases} \quad (3.22)$$

其中, $\hat{D} = \frac{1}{2\lambda} R_1^{-1} g^T(x) (\nabla_x \sigma(x, t_f - t))^T \hat{W}_c$ 。

结合式(3.21)和式(3.22), 估计的哈密顿函数可描述为

$$\begin{aligned} H(x, \hat{W}_c, \hat{u}, \hat{v}) &= \hat{W}_c^T \nabla_t \sigma(x, t_f - t) + \hat{W}_c^T \nabla_x \sigma(x, t_f - t) (f(x) + g(x)\hat{u} + k(x)\hat{v}) \\ &\quad + Q(x, t) + 2 \int_0^{\hat{u}} (\lambda \tanh^{-1}(v/\lambda))^T R_1 dv - \hat{v}^T R_2 \hat{v} = e_c \end{aligned} \quad (3.23)$$

定义终端约束估计误差为

$$\begin{aligned} e_{t_f} &= \psi(x(t_f), t_f) - \hat{W}_c^T \sigma_c(\hat{x}(t_f), 0) \\ &= W_c^T \sigma_c(x(t_f), 0) - \hat{W}_c^T \sigma_c(\hat{x}(t_f), 0) + \varepsilon(x, t_f) \\ &= W_c^T \tilde{\sigma}_c(x(t_f), 0) + \tilde{W}_c^T \sigma_c(\hat{x}(t_f), 0) + \varepsilon(x, t_f) \end{aligned} \quad (3.24)$$

其中, $\tilde{\sigma}_c(x(t_f), 0) = \sigma_c(x(t_f), 0) - \sigma_c(\hat{x}(t_f), 0)$ 。

从式(3.23)和式(3.24)可以看出, 需要设计评价网络权值更新律, 保证估计权值 $\hat{W}_c$ 最终收敛于理想权值 W_c , 使得 $H(x, \hat{W}_c, \hat{u}, \hat{v}) \rightarrow 0$, 同时满足终端约束条件。综合考虑, 设计如下目标函数:

$$E_{total} = \frac{1}{2} e_c^T e_c + \frac{1}{2} e_{t_f}^T e_{t_f} \quad (3.25)$$

基于梯度下降法, 设计评价网络权值更新律如下:

$$\begin{aligned} \dot{\hat{W}}_c &= -\alpha_1 \frac{\bar{\beta}_1}{m_s} e_c - \alpha_1 \frac{\bar{\beta}_2}{m_t} e_{t_f} \\ &\quad + \frac{1}{2} \alpha_1 \Sigma(x, \hat{u}, \hat{v}) \nabla_x \sigma(x, t_f - t) g(x) R_1^{-1} [\bar{1} - \tanh^2(\hat{D})] \bar{R}_1 g^T(x) \nabla J_s(x) \\ &\quad - \frac{1}{2} \alpha_1 \Sigma(x, \hat{u}, \hat{v}) \nabla_x \sigma(x, t_f - t) k(x) R_2^{-1} k^T(x) \nabla J_s(x) \\ &\quad + \alpha_1 \left[\nabla_x \sigma(x, t_f - t) g(x) \lambda [\tanh(\hat{D}) - \text{sign}(\hat{D})] \frac{\bar{\beta}_1^T}{m_s} \hat{W}_c - \frac{1}{4} \frac{\bar{\beta}_1}{m_s} \hat{W}_c^T K \hat{W}_c - (Y_2 - Y_1 \bar{\beta}_1^T) \hat{W}_c \right] \end{aligned} \quad (3.26)$$

其中, $\bar{\beta}_1 = \beta_1 / (1 + \beta_1^T \beta_1)$, $m_s = 1 + \beta_1^T \beta_1$, $\beta_1 = \nabla_x \sigma(x, t_f - t) + \nabla_x \sigma(x, t_f - t) (f(x) + g(x) \hat{u} + k(x) \hat{v})$, $K = \nabla_x \sigma(x, t_f - t) k(x) R_2^{-1} k^T(x) (\nabla_x \sigma(x, t_f - t))^T$, $\beta_2 = -\sigma(\hat{x}(t_f), 0)$, $m_t = 1 + \beta_2^T \beta_2$, $\bar{\beta}_2 = \beta_2 / (1 + \beta_2^T \beta_2)$; α_1 为评价网络学习率, $J_s(x)$ 在假设 3.2 中已定义, Y_1 和 Y_2 为相应维数的设计参数; $\text{sign}(\cdot)$ 表示符号函数; $\Sigma(x, \hat{u}, \hat{v})$ 的定义如下:

$$\Sigma(x, \hat{u}, \hat{v}) = \begin{cases} 0, & \text{if } \dot{J}_s(x) = (\nabla J_s(x))^T (f(x) + g(x) \hat{u} + k(x) \hat{v}) < 0 \\ 1, & \text{else} \end{cases} \quad (3.27)$$

注释 3.3: 式(3.26)中, 第一项是基于梯度下降法得到, 主要用于最小化逼近的哈密顿函数, i.e., $H(x, \hat{W}_c, \hat{u}, \hat{v}) \rightarrow 0$; 第二项同样基于梯度下降法获得, 主要用于最小化终端约束估计误差; 第三项和第四项是附加项, 用于保证评价网络在学习过程中闭环系统信号的有界性; 最后一项主要用来保证闭环系统的稳定性。此外, 第三项和第四项的具体推导过程如下:

基于假设 3.2, 以及逼近的微分对策控制策略(3.22), 对 Lyapunov 函数 $J_s(x)$ 求导, 可得

$$\Theta = (\nabla J_s(x))^T \left(f(x) - \lambda g(x) \tanh(\hat{D}) + \frac{1}{2} k(x) R_2^{-1} k^T(x) (\nabla_x \sigma(x, t_f - t))^T \hat{W}_c \right) \quad (3.28)$$

如果闭环系统稳定, 则可以保证 $\Theta \leq 0$; 相反, 如果闭环系统不稳定, 则 $\Theta > 0$ 。为了继续维持闭环系统的稳定性, 有必要进行系统调节使得 $\Theta < 0$ 成立。基于梯度下降法得

$$\begin{aligned}
 -\frac{\partial \Theta}{\partial \hat{W}_c} &= -\frac{\partial \left[(\nabla J_s(x))^T \left(f(x) - \lambda g(x) \tanh(\hat{D}) + \frac{1}{2} k(x) R_2^{-1} k^T(x) (\nabla_x \sigma(x, t_f - t))^T \hat{W}_c \right) \right]}{\partial \hat{W}_c} \\
 &= \left(\frac{\partial \hat{D}}{\partial \hat{W}_c} \right)^T \frac{\partial \left[\lambda (\nabla J_s(x))^T g(x) \tanh(\hat{D}) \right]}{\partial \hat{D}} - \frac{1}{2} \nabla_x \sigma(x, t_f - t) k(x) R_2^{-1} k^T(x) \nabla J_s(x) \\
 &= \frac{1}{2} \nabla_x \sigma(x, t_f - t) g(x) R_1^{-1} [\bar{\mathbf{1}} - \tanh^2(\hat{D})] \bar{R}_1 g^T(x) \nabla J_s(x) - \frac{1}{2} \nabla_x \sigma(x, t_f - t) k(x) R_2^{-1} k^T(x) \nabla J_s(x)
 \end{aligned} \quad (3.29)$$

从上述分析可以看出, 式(3.26)中的第三项和第四项能够保证评价网络在学习过程中闭环系统的稳定性, 从而放松了控制器对初始稳定控制的要求。

3.4 稳定性分析

为便于后续分析, 针对评价网络给出如下假设:

假设 3.3: 评价网络理想权值 W_c 有界, 即存在一个正常数 $W_M > 0$, 使得 $\|W_c\| \leq W_M$ 成立; 此外, 在紧集 $\Omega_x \in \mathbb{R}^n$ 内, 对于任意的 $x \in \Omega_x$, 评价网络激励函数 $\sigma(x, t)$, 逼近误差 $\varepsilon(x, t)$ 以及它们的梯度项均有界, 满足不等式 $\|\sigma(x, t)\| \leq \sigma_M$, $\|\nabla \sigma(x, t)\| \leq b_\sigma$, $\|\varepsilon(x, t)\| \leq b_\varepsilon$, $\|\nabla_x \varepsilon(x, t)\| \leq b_{\varepsilon_x}$, $\|\nabla_t \varepsilon(x, t)\| \leq b_{\varepsilon_t}$, 其中, $\sigma_M, b_\sigma, b_\varepsilon, b_{\varepsilon_x}$ 和 b_{ε_t} 均为正常数。

定理 3.1: 考虑连续时间非线性微分对策系统(3.1)以及给定的有限时域性能指标函数(3.3), 在假设 3.1-假设 3.3 成立的前提下, 如果设计微分对策控制策略如式(3.22)所示, 并设计评价网络权值更新律如式(3.26)所示, 则闭环系统状态信号 $x(t)$ 以及评价网络权值估计误差信号 $\tilde{W}_c$ 均可保证最终一致有界。

证明: 选择如下 Lyapunov 函数

$$L(t) = V(x, t) + J_s(x) + \frac{1}{2} \tilde{W}_c^T \alpha_1^{-1} \tilde{W}_c \quad (3.30)$$

对式(3.30)求导可得

$$\dot{L}(t) = \dot{V}(x, t) + \dot{J}_s(x) + \tilde{W}_c^T \alpha_1^{-1} \dot{\tilde{W}}_c \quad (3.31)$$

考虑式(3.31)中的第一项

$$\begin{aligned}
 \dot{V}(x, t) &= \nabla V_t + (\nabla V(x))^T (f(x) + g(x)\hat{u} + k(x)\hat{v}) \\
 &= W_c^T \nabla_t \sigma(x, t_f - t) + W_c^T \nabla_x \sigma(x, t_f - t) f(x) \\
 &\quad - W_c^T \nabla_x \sigma(x, t_f - t) g(x) \lambda \tanh(\hat{D}) + \frac{1}{2} W_c^T K \hat{W}_c + \varepsilon_0(x, t)
 \end{aligned} \quad (3.32)$$

其中, $\varepsilon_0(x, t) = (\nabla_t \varepsilon(x, t))^T + (\nabla_x \varepsilon(x, t))^T (f(x) + g(x)\hat{u} + k(x)\hat{v})$ 。基于上述假设条件, 易得 $\varepsilon_0(x, t)$ 是一个有界信号, 即存在常数 $\varepsilon_M > 0$, 满足 $\|\varepsilon_0(x, t)\| \leq \varepsilon_M$ 。

考虑 HJI 方程(3.18), 可以得到下列等式

$$\begin{aligned}
 &W_c^T \nabla_t \sigma(x, t_f - t) + W_c^T \nabla_x \sigma(x, t_f - t) f(x) \\
 &= -Q(x, t) - U(u) + W_c^T \nabla_x \sigma(x, t_f - t) g(x) \lambda \tanh(D) - \frac{1}{4} W_c^T K W_c - \delta_{HJI}
 \end{aligned} \quad (3.33)$$

其中, $U(u) = W_c^T \nabla_x \sigma_c(x, t_f - t) g(x) \lambda \tanh(D) + \lambda^2 \bar{R}_1 \ln(\bar{\mathbf{1}} - \tanh^2(D))$ 。

将式(3.33)代入式(3.32)，化简整理可得

$$\begin{aligned}\dot{V}(x, t) &= -Q(x, t) - U(u) + W_c^T \nabla_x \sigma(x, t_f - t) g(x) \lambda \tanh(D) - \frac{1}{4} W_c^T K W_c \\ &\quad - W_c^T \nabla_x \sigma(x, t_f - t) g(x) \lambda \tanh(\hat{D}) + \frac{1}{2} W_c^T K W_c + \varepsilon_0(x, t) - \delta_{HII} \\ &= -Q(x, t) - U(u) + W_c^T \nabla_x \sigma(x, t_f - t) g(x) \lambda [\tanh(D) - \tanh(\hat{D})] \\ &\quad - \frac{1}{2} W_c^T K \tilde{W}_c + \frac{1}{4} W_c^T K W_c + \varepsilon_0(x, t) - \delta_{HII}\end{aligned}\quad (3.34)$$

进一步分析可得 $U(u)$ 是正定函数，且存在不等式关系 $[\tanh(D) - \tanh(\hat{D})] \leq 2 \cdot \bar{1}$ ；考虑到 $Q(x, t) > 0$ ，可得出这样的结论：对于 $\forall x \neq 0$ ，存在一个正定矩阵 $q > 0$ ，满足不等式关系 $x^T q x < Q(x, t)$ 。因此，式(3.34)可变换为

$$\dot{V}(x, t) \leq -x^T q x + 2\lambda W_c^T (\nabla_x \sigma(x, t_f - t)) g(x) \bar{1} - \frac{1}{2} \tilde{W}_c^T K W_c + \frac{1}{4} W_c^T K W_c + \varepsilon_v \quad (3.35)$$

其中， $\varepsilon_v = \varepsilon_0(x, t) - \delta_{HII}$ 是一个有界信号。

接下来考虑式(3.31)中的第二项，有

$$\begin{aligned}\dot{J}_s(x) &= (\nabla J_s(x))^T f(x) - (\nabla J_s(x))^T g(x) \lambda \tanh(\hat{D}) \\ &\quad + \frac{1}{2} (\nabla J_s(x))^T k(x) R_2^{-1} k^T(x) \nabla_x^T \sigma(x, t_f - t) \hat{W}_c\end{aligned}\quad (3.36)$$

最后，考虑式(3.31)中的第三项，将式(3.26)代入可得

$$\begin{aligned}\tilde{W}_c^T \alpha_1^{-1} \tilde{\dot{W}}_c &= \tilde{W}_c^T \frac{\bar{\beta}_1}{m_s} \left[Q(x, t) + U(\hat{u}) + \hat{W}_c^T \beta_1 - \frac{1}{4} \hat{W}_c^T K \hat{W}_c \right] + \tilde{W}_c^T \frac{\bar{\beta}_2}{m_t} \left[W_c^T \tilde{\sigma}(x(t_f), 0) + \tilde{W}_c^T \sigma(x(t_f), 0) + \varepsilon(x, t_f) \right] \\ &\quad - \frac{1}{2} \tilde{W}_c^T \Sigma(x, \hat{u}, \hat{v}) \nabla_x \sigma(x, t_f - t) g(x) R_1^{-1} [\bar{1} - \tanh^2(\hat{D})] \bar{R}_1 g^T(x) J_s \\ &\quad + \frac{1}{2} \tilde{W}_c^T \Sigma(x, \hat{u}, \hat{v}) \nabla_x \sigma(x, t_f - t) k(x) R_2^{-1} k^T(x) \nabla J_s(x) \\ &\quad - \tilde{W}_c^T \left[\nabla_x \sigma(x, t_f - t) g(x) \lambda [\tanh(\hat{D}) - \text{sign}(\hat{D})] \frac{\bar{\beta}_1^T}{m_s} \hat{W}_c - \frac{1}{4} \frac{\bar{\beta}_1}{m_s} \hat{W}_c^T K \hat{W}_c - (Y_2 - Y_1 \bar{\beta}_1^T) \hat{W}_c \right]\end{aligned}\quad (3.37)$$

通过将式(3.18)代入式(3.37)，进行简单的数学运算，整理后可得

$$\begin{aligned}\tilde{W}_c^T \alpha_1^{-1} \tilde{\dot{W}}_c &= \tilde{W}_c^T \frac{\bar{\beta}_1}{m_s} \left[U(\hat{u}) - U(u) - \tilde{W}_c^T \beta_1 + W_c^T \beta_1 - W_c^T \beta - \frac{1}{4} \hat{W}_c^T K \hat{W}_c + \frac{1}{4} W_c^T K W_c - \delta_{HII} \right] \\ &\quad + \tilde{W}_c^T \frac{\bar{\beta}_2}{m_t} \left[W_c^T \tilde{\sigma}(x(t_f), 0) + \tilde{W}_c^T \sigma(x(t_f), 0) + \varepsilon(x, t_f) \right] \\ &\quad - \frac{1}{2} \tilde{W}_c^T \Sigma(x, \hat{u}, \hat{v}) \nabla_x \sigma(x, t_f - t) g(x) R_1^{-1} [\bar{1} - \tanh^2(\hat{D})] \bar{R}_1 g^T(x) \nabla J_s(x) \\ &\quad + \frac{1}{2} \tilde{W}_c^T \Sigma(x, \hat{u}, \hat{v}) \nabla_x \sigma(x, t_f - t) k(x) R_2^{-1} k^T(x) \nabla J_s(x) \\ &\quad - \tilde{W}_c^T \left[\nabla_x \sigma(x, t_f - t) g(x) \lambda [\tanh(\hat{D}) - \text{sign}(\hat{D})] \frac{\bar{\beta}_1^T}{m_s} \hat{W}_c - \frac{1}{4} \frac{\bar{\beta}_1}{m_s} \hat{W}_c^T K \hat{W}_c - (Y_2 - Y_1 \bar{\beta}_1^T) \hat{W}_c \right]\end{aligned}\quad (3.38)$$

其中，

$$\begin{aligned}\beta &= \nabla_t \sigma(x, t_f - t) + \nabla_x \sigma(x, t_f - t) (f(x) + g(x)u + k(x)v) \\ &= \nabla_t \sigma(x, t_f - t) + \nabla_x \sigma(x, t_f - t) (f(x) - g(x) \lambda \tanh(D)) + \frac{1}{2} K W_c\end{aligned}\quad (3.39)$$

$$\begin{aligned}\beta_1 &= \nabla_t \sigma(x, t_f - t) + \nabla_x \sigma(x, t_f - t)(f(x) + g(x)\hat{u} + k(x)\hat{v}) \\ &= \nabla_t \sigma(x, t_f - t) + \nabla_x \sigma(x, t_f - t)(f(x) - g(x)\lambda \tanh(\hat{D})) + \frac{1}{2} K \hat{W}_c\end{aligned}\quad (3.40)$$

$$U(\hat{u}) = \hat{W}_c^T \nabla_x \sigma(x, t_f - t) g(x) \lambda \tanh(\hat{D}) + \lambda^2 \bar{R}_1 \ln(\bar{\mathbf{1}} - \tanh^2(\hat{D})) \quad (3.41)$$

基于式(3.39)和式(3.40)，可以得到

$$W_c^T \beta_1 - W_c^T \beta = W_c^T \nabla_x \sigma(x, t_f - t) g(x) \lambda [\tanh(D) - \tanh(\hat{D})] - \frac{1}{2} W_c^T K \hat{W}_c \quad (3.42)$$

另一方面，基于式(3.6)和式(3.41)， $U(\hat{u}) - U(u)$ 可简化为

$$\begin{aligned}U(\hat{u}) - U(u) &= \hat{W}_c^T \nabla_x \sigma(x, t_f - t) g(x) \lambda \tanh(\hat{D}) + \lambda^2 \bar{R}_1 \ln(\bar{\mathbf{1}} - \tanh^2(\hat{D})) \\ &\quad - W_c^T \nabla_x \sigma(x, t_f - t) g(x) \lambda \tanh(D) - \lambda^2 \bar{R}_1 \ln(\bar{\mathbf{1}} - \tanh^2(D))\end{aligned}\quad (3.43)$$

进一步考虑下列等价关系

$$\begin{aligned}\lambda^2 \bar{R}_1 \ln(\bar{\mathbf{1}} - \tanh^2(D)) &= \lambda^2 \bar{R}_1 [\ln 4 - 2D - 2\ln(1 + e^{-2D})] \\ &= \lambda^2 \bar{R}_1 [\ln 4 - 2D \text{sign}(D) + \varepsilon_D] \\ &= \lambda^2 \bar{R}_1 \ln 4 - W_c^T \nabla_x \sigma(x, t_f - t) g(x) \lambda \text{sign}(D) + \lambda^2 \bar{R}_1 \varepsilon_D\end{aligned}\quad (3.44)$$

其中， ε_D 表示逼近误差，并且很容易得到信号 ε_D 是有界的，满足 $\|\varepsilon_D\| \leq \ln 4$ 。

注释 3.4: 当 $D > 0$ 时， $\ln(1 + e^{-2D})$ 趋近于 0；而当 $D < 0$ 时， $\ln(1 + e^{-2D})$ 趋近于 $-2D$ ，因此，式(3.44)成立。

类似地，下列等式成立

$$\lambda^2 \bar{R}_1 \ln(\bar{\mathbf{1}} - \tanh^2(\hat{D})) = \lambda^2 \bar{R}_1 \ln 4 - \hat{W}_c^T \nabla_x \sigma(x, t_f - t) g(x) \lambda \text{sign}(\hat{D}) + \lambda^2 \bar{R}_1 \varepsilon_{\hat{D}} \quad (3.45)$$

其中， $\|\varepsilon_{\hat{D}}\| \leq \ln 4$ 。

将式(3.44)和式(3.45)代入式(3.43)，化简整理可得

$$\begin{aligned}U(\hat{u}) - U(u) &= \hat{W}_c^T \nabla_x \sigma(x, t_f - t) g(x) \lambda \tanh(\hat{D}) + \lambda^2 \bar{R}_1 \ln(\bar{\mathbf{1}} - \tanh^2(\hat{D})) \\ &\quad - W_c^T \nabla_x \sigma(x, t_f - t) g(x) \lambda \tanh(D) - \lambda^2 \bar{R}_1 \ln(\bar{\mathbf{1}} - \tanh^2(D)) \\ &= \hat{W}_c^T \nabla_x \sigma(x, t_f - t) g(x) \lambda \tanh(\hat{D}) - W_c^T \nabla_x \sigma(x, t_f - t) g(x) \lambda \tanh(D) \\ &\quad - W_c^T \nabla_x \sigma(x, t_f - t) g(x) \lambda [\text{sign}(\hat{D}) - \text{sign}(D)] \\ &\quad + \hat{W}_c^T \nabla_x \sigma(x, t_f - t) g(x) \lambda \text{sign}(\hat{D}) + \lambda^2 \bar{R}_1 (\varepsilon_{\hat{D}} - \varepsilon_D)\end{aligned}\quad (3.46)$$

进一步将式(3.46)代入式(3.38)，通过数学运算化简整理可得

$$\begin{aligned}\tilde{W}_c^T \alpha_1^{-1} \dot{\tilde{W}}_c &= \tilde{W}_c^T \frac{\bar{\beta}_1}{m_s} \left[-\beta_1^T \tilde{W}_c - \tilde{W}_c^T \nabla_x \sigma(x, t_f - t) g(x) \lambda [\tanh(\hat{D}) - \text{sign}(\hat{D})] \right. \\ &\quad \left. - W_c^T \nabla_x \sigma(x, t_f - t) g(x) \lambda [\text{sign}(\hat{D}) - \text{sign}(D)] + \varepsilon_j \right] - \frac{1}{4} \tilde{W}_c^T \frac{\bar{\beta}_1}{m_s} \tilde{W}_c^T K \hat{W}_c \\ &\quad + \tilde{W}_c^T \frac{\bar{\beta}_2}{m_t} \left[W_c^T \tilde{\sigma}(x(t_f), 0) + \tilde{W}_c^T \sigma(x(t_f), 0) + \varepsilon(x, t_f) \right] \\ &\quad - \frac{1}{2} \tilde{W}_c^T \Sigma(x, \hat{u}, \hat{v}) \nabla_x \sigma(x, t_f - t) g(x) R_1^{-1} [\bar{\mathbf{1}} - \tanh^2(\hat{D})] \bar{R}_1 g^T(x) \nabla J_s(x) \\ &\quad + \frac{1}{2} \tilde{W}_c^T \Sigma(x, \hat{u}, \hat{v}) \nabla_x \sigma(x, t_f - t) k(x) R_2^{-1} k^T(x) \nabla J_s(x) \\ &\quad - \tilde{W}_c^T \left[\nabla_x \sigma(x, t_f - t) g(x) \lambda [\tanh(\hat{D}) - \text{sign}(\hat{D})] \frac{\bar{\beta}_1^T}{m_s} \hat{W}_c - \frac{1}{4} \frac{\bar{\beta}_1}{m_s} \hat{W}_c^T K \hat{W}_c - (Y_2 - Y_1 \bar{\beta}_1^T) \hat{W}_c \right]\end{aligned}\quad (3.47)$$

其中， $\varepsilon_j = \lambda^2 \bar{R}_1 (\varepsilon_{\hat{D}} - \varepsilon_D) - \delta_{HII}$ 。

基于定义式 $\tilde{W}_c = W_c - \hat{W}_c$ ，进一步整理，式(3.47)可重新表示为

$$\begin{aligned} \tilde{W}_c^T \alpha_1^T \dot{\tilde{W}}_c = & -\tilde{W}_c^T \bar{\beta}_1 \bar{\beta}_1^T \tilde{W}_c - \frac{1}{2} \tilde{W}_c^T \frac{\bar{\beta}_1}{m_s} W_c^T K \tilde{W}_c + \frac{1}{4} \tilde{W}_c^T \frac{\bar{\beta}_1}{m_s} W_c^T K W_c \\ & + \tilde{W}_c^T \frac{\bar{\beta}_1}{m_s} c_1 - \tilde{W}_c^T c_2 + \tilde{W}_c^T (Y_2 - Y_1 \bar{\beta}_1^T) \hat{W}_c + \tilde{W}_c^T (\sigma(x(t_f), 0))^T \frac{\bar{\beta}_2^T}{m_t} \tilde{W}_c + \tilde{W}_c^T \frac{\bar{\beta}_2}{m_t} c_3 \\ & - \frac{1}{2} \tilde{W}_c^T \Sigma(x, \hat{u}, \hat{v}) \nabla_x \sigma(x, t_f - t) g(x) R_1^{-1} [\bar{\mathbf{1}} - \tanh^2(\hat{D})] \bar{R}_1 g^T(x) \nabla J_s(x) \\ & + \frac{1}{2} \tilde{W}_c^T \Sigma(x, \hat{u}, \hat{v}) \nabla_x \sigma(x, t_f - t) k(x) R_2^{-1} k^T(x) \nabla J_s(x) \end{aligned} \quad (3.48)$$

其中， $c_1 = W_c^T \nabla_x \sigma(x, t_f - t) g(x) \lambda [\text{sign}(D) - \text{sign}(\hat{D})] + \varepsilon_j$ ， $c_2 = \nabla_x \sigma(x, t_f - t) g(x) \lambda [\tanh(\hat{D}) - \text{sign}(\hat{D})] \frac{\bar{\beta}_1^T}{m_s} W_c$ 和 $c_3 = W_c^T \tilde{\sigma}(x(t_f), 0) + \varepsilon(x, t_f)$ 都是有界信号。

另外考虑评价网络权值估计误差定义式 $\tilde{W}_c = W_c - \hat{W}_c$ ，易得

$$\tilde{W}_c^T (Y_2 - Y_1 \bar{\beta}_1^T) \hat{W}_c = \tilde{W}_c^T Y_2 W_c - \tilde{W}_c^T Y_2 \tilde{W}_c - \tilde{W}_c^T Y_1 \bar{\beta}_1^T W_c + \tilde{W}_c^T Y_1 \bar{\beta}_1^T \tilde{W}_c \quad (3.49)$$

综上，结合式(3.35)、式(3.36)、式(3.48)和(3.49)，式(3.31)最终能够简化为

$$\begin{aligned} \dot{L}(t) \leq & -x^T q x - \tilde{W}_c^T \bar{\beta}_1 \bar{\beta}_1^T \tilde{W}_c + \tilde{W}_c^T \bar{\beta}_1 \left(Y_1 - \frac{1}{2m_s} W_c^T K \right) \tilde{W}_c - \tilde{W}_c^T \left(Y_2 - (\sigma(x(t_f), 0))^T \frac{\bar{\beta}_2^T}{m_t} \right) \tilde{W}_c \\ & + \tilde{W}_c^T \bar{\beta}_1 \left(\frac{1}{4m_s} W_c^T K W_c + \frac{c_1}{m_s} \right) + \tilde{W}_c^T \left(Y_2 W_c - c_2 - Y_1 \bar{\beta}_1^T W_c - \frac{1}{2} K W_c + \frac{\bar{\beta}_2}{m_t} c_3 \right) \\ & + 2\lambda W_c^T (\nabla_x \sigma(x, t_f - t))^T g(x) \bar{\mathbf{1}} + \frac{1}{4} W_c^T K W_c + \varepsilon_v + (\nabla J_s(x))^T (f(x) + g(x) \hat{u} + k(x) \hat{v}) \\ & - \frac{1}{2} \tilde{W}_c^T \Sigma(x, \hat{u}, \hat{v}) \nabla_x \sigma(x, t_f - t) g(x) R_1^{-1} [\bar{\mathbf{1}} - \tanh^2(\hat{D})] \bar{R}_1 g^T(x) \nabla J_s(x) \\ & + \frac{1}{2} \tilde{W}_c^T \Sigma(x, \hat{u}, \hat{v}) \nabla_x \sigma(x, t_f - t) k(x) R_2^{-1} k^T(x) \nabla J_s(x) \end{aligned} \quad (3.50)$$

定义变量 $Z = [x, \bar{\beta}_1^T \tilde{W}_c, \tilde{W}_c]^T$ ，式(3.50)可整理为

$$\begin{aligned} \dot{L}(t) \leq & (\nabla J_s(x))^T (f(x) + g(x) \hat{u} + k(x) \hat{v}) - Z^T M Z + Z^T N + d \\ & - \frac{1}{2} \tilde{W}_c^T \Sigma(x, \hat{u}, \hat{v}) \nabla_x \sigma(x, t_f - t) g(x) R_1^{-1} [\bar{\mathbf{1}} - \tanh^2(\hat{D})] \bar{R}_1 g^T(x) \nabla J_s(x) \\ & + \frac{1}{2} \tilde{W}_c^T \Sigma(x, \hat{u}, \hat{v}) \nabla_x \sigma(x, t_f - t) k(x) R_2^{-1} k^T(x) \nabla J_s(x) \end{aligned} \quad (3.51)$$

其中，

$$M = \begin{bmatrix} qI & 0 & 0 \\ 0 & I & \frac{1}{2} Y_1 - \frac{1}{4m_s} W_c^T K \\ 0 & \frac{1}{2} Y_1^T - \frac{1}{4m_s} K^T W_c & (\sigma(x(t_f), 0))^T \frac{\bar{\beta}_2^T}{m_t} - Y_2 \end{bmatrix}, \quad N = \begin{bmatrix} 0 \\ \frac{1}{4m_s} W_c^T K W_c + \frac{c_1}{m_s} \\ Y_2 W_c - c_2 - Y_1 \bar{\beta}_1^T W_c - \frac{1}{2} K W_c + \frac{\bar{\beta}_2}{m_t} c_3 \end{bmatrix}, \quad \text{以}$$

及 $d = 2\lambda W_c^T (\nabla_x \sigma(x, t_f - t))^T g(x) \bar{\mathbf{1}} + \frac{1}{4} W_c^T K W_c + \varepsilon_v$ 。

如果选择设计参数 Y_1 和 Y_2 使得 $M > 0$ ，则式(3.51)可变换为

$$\begin{aligned}\dot{L}(t) \leq & -\lambda_{\min}(M)\|Z\|^2 + \|N\|\|Z\| + d + (\nabla J_s(x))^T (f(x) + g(x)\hat{u} + k(x)\hat{v}) \\ & - \frac{1}{2} \tilde{W}_c^T \Sigma(x, \hat{u}, \hat{v}) \nabla_x \sigma(x, t_f - t) g(x) R_1^{-1} [\bar{1} - \tanh^2(\hat{D})] \bar{R}_1 g^T(x) \nabla J_s(x) \\ & + \frac{1}{2} \tilde{W}_c^T \Sigma(x, \hat{u}, \hat{v}) \nabla_x \sigma(x, t_f - t) k(x) R_2^{-1} k^T(x) \nabla J_s(x)\end{aligned}\quad (3.52)$$

其中, $\lambda_{\min}(M)$ 表示矩阵 M 的最小特征值。

根据 $\Sigma(x, \hat{u}, \hat{v})$ 的定义式(3.27), 下面将分两种情形讨论。

情形 1: $\Sigma(x, \hat{u}, \hat{v}) = 0$ 。在这种情况下, 评价网络在学习过程中闭环系统稳定, 可以得出 $(\nabla J_s(x))^T \dot{x} < 0$, 进一步有 $-(\nabla J_s(x))^T \dot{x} > 0$ 。此时考虑实数域的稠密性, 可假设存在一个正常数 $\mu > 0$, 使得不等式 $0 < \mu \|\nabla J_s(x)\| \leq -(\nabla J_s(x))^T \dot{x}$ 成立。另外, 为保证评价网络在学习过程中权值向量能够充分学习收敛至理想权值, 此处通常假设系统信号满足持续激励条件。如此, 式(3.52)可简化为

$$\begin{aligned}\dot{L}(t) \leq & (\nabla J_s(x))^T \dot{x} - \lambda_{\min}(M)\|Z\|^2 + \|N\|\|Z\| + d \\ \leq & -\mu(\nabla J_s(x))^T \dot{x} - \lambda_{\min}(M)\left(\|Z\| - \frac{1}{2} \frac{\|N\|}{\lambda_{\min}(M)}\right)^2 + \frac{1}{4} \frac{\|N\|^2}{\lambda_{\min}(M)} + d\end{aligned}\quad (3.53)$$

从式(3.53)可以清楚的看出, 只要下列不等式成立, 则可以保证 $\dot{L}(t) < 0$ 。

$$\|\nabla J_s(x)\| \geq \frac{\|N\|^2 + 4d\lambda_{\min}(M)}{4\mu\lambda_{\min}(M)}\quad (3.54)$$

或

$$\|Z\| \geq \sqrt{\frac{\|N\|^2 + 4d\lambda_{\min}(M)}{4\lambda_{\min}^2(M)}} + \frac{\|N\|}{2\lambda_{\min}(M)}\quad (3.55)$$

注释 3.5: 持续激励条件是参数自适应设计中的必要条件。可以保证自适应参数能够利用系统信息充分学习, 从而收敛至其真值。通常情况下, 可以在控制器中加入一个较小的时变噪声信号保证持续激励条件。当然也可以在自适应参数更新律设计过程中, 通过重复使用过去经验数据, 从而放松对持续激励条件的要求。需要注意的是, 在式(3.53)中, 即便持续激励条件不再满足, 也可以保证 $(\nabla J_s(x))^T \dot{x} < 0$, 从而使得式(3.52)简化为如下形式:

$$\dot{L}(t) \leq -\lambda_{\min}(M)\left(\|Z\| - \frac{1}{2} \frac{\|N\|}{\lambda_{\min}(M)}\right)^2 + \frac{1}{4} \frac{\|N\|^2}{\lambda_{\min}(M)} + d.$$

上式同样可以保证闭环系统信号的最终一致有界性, 不影响闭环系统稳定性的分析。但此时评价网络权值可能会因为学习不充分导致最终不能够收敛于理想权值。

情形 2: $\Sigma(x, \hat{u}, \hat{v}) = 1$ 。此时闭环系统不稳定, 即 $(\nabla J_s(x))^T (f(x) + g(x)\hat{u} + k(x)\hat{v}) > 0$ 。式(3.52)可变换为如下形式:

$$\begin{aligned}\dot{L}(t) \leq & (\nabla J_s(x))^T f(x) - \lambda(\nabla J_s(x))^T g(x) \left[\tanh(\hat{D}) + \frac{1}{2\lambda} [\bar{1} - \tanh^2(\hat{D})] \bar{R}_1 R_1^{-1} g^T(x) (\nabla_x \sigma(x, t_f - t))^T \tilde{W}_c \right] \\ & + \frac{1}{2} (\nabla J_s(x))^T k(x) R_2^{-1} k^T(x) (\nabla_x \sigma(x, t_f - t))^T \tilde{W}_c - \lambda_{\min}(M)\|Z\|^2 + \|N\|\|Z\| + d\end{aligned}\quad (3.56)$$

通过泰勒展开可得

$$\begin{aligned}\tanh(D) - \tanh(\hat{D}) &= \frac{\partial \tanh(\hat{D})}{\partial \hat{D}}(D - \hat{D}) + O((D - \hat{D})^2) \\ &= \frac{1}{2\lambda}[\bar{\mathbf{1}} - \tanh^2(\hat{D})]\bar{R}_1 R_1^{-1} g^T(x)(\nabla_x \sigma(x, t_f - t))^T \tilde{W}_c + O((D - \hat{D})^2)\end{aligned}\quad (3.57)$$

其中, $O((D - \hat{D})^2)$ 表示泰勒展开式中的高阶项; 显然这是一个有界信号, i.e., $\|O((D - \hat{D})^2)\| \leq d_1$, d_1 为正常数。

利用式(3.57)可知

$$\tanh(\hat{D}) + \frac{1}{2\lambda}[\bar{\mathbf{1}} - \tanh^2(D)]\bar{R}_1 R_1^{-1} g^T(x)(\nabla_x \sigma(x, t_f - t))^T \tilde{W}_c = \tanh(D) - O((D - \hat{D})^2) \quad (3.58)$$

此时, 结合式(3.17)和式(3.58), 式(3.56)可以变换为

$$\begin{aligned}\dot{L}(t) &\leq -(\nabla J_s(x))^T \left(\lambda g(x) O((D - \hat{D})^2) + g(x) \varepsilon_u^* + k(x) \varepsilon_v^* \right) \\ &\quad - \lambda_{\min}(M) \|Z\|^2 + \|N\| \|Z\| + d + (\nabla J_s(x))^T (f(x) + g(x)u^* + k(x)v^*)\end{aligned}\quad (3.59)$$

基于前述给出的假设 3.1-假设 3.4, 易得 $\lambda g(x) O((D - \hat{D})^2) + g(x) \varepsilon_u^* + k(x) \varepsilon_v^*$ 是一个有界信号, 即存在一个正常数 d_M , 满足不等式 $\|\lambda g(x) O((D - \hat{D})^2) + g(x) \varepsilon_u^* + k(x) \varepsilon_v^*\| \leq d_M$ 。此时可以将式(3.59)整理成如下完全平方形式:

$$\dot{L}(t) \leq -\lambda_{\min}(\Lambda(x)) \left(\|\nabla J_s(x)\| - \frac{d_M}{2\lambda_{\min}(\Lambda(x))} \right)^2 - \lambda_{\min}(M) \left(\|Z\| - \frac{\|N\|}{2\lambda_{\min}(M)} \right)^2 + \varsigma \quad (3.60)$$

其中, $\varsigma = \frac{d_M^2}{4\lambda_{\min}(\Lambda(x))} + \frac{\|N\|^2}{4\lambda_{\min}(M)} + d$, $\lambda_{\min}(\Lambda(x))$ 表示矩阵 $\Lambda(x)$ 的最小特征值。

从式(3.60)中可以得出这样的结论: 只要下列不等式成立, 就可以保证 $\dot{L}(t) < 0$:

$$\|\nabla J_s(x)\| \geq \sqrt{\frac{\varsigma}{\lambda_{\min}(\Lambda(x))}} + \frac{d_M}{2\lambda_{\min}(\Lambda(x))} \quad (3.61)$$

或

$$\|Z\| \geq \sqrt{\frac{\varsigma}{\lambda_{\min}(M)}} + \frac{\|N\|}{2\lambda_{\min}(M)} \quad (3.62)$$

结合以上两种情形, 基于 Lyapunov 稳定性定理, 可以得出这样的结论: 在提出的输入饱和条件下的有限时域微分对策控制策略作用下, 可以保证闭环系统状态 x 以及评价网络权值估计误差信号 $\tilde{W}_c$ 最终一致有界。

注释 3.5: 观察式(3.54)、(3.55)、式(3.61)和式(3.62), 不难发现信号 $\|\nabla J_s(x)\|$ 和 $\|Z\|$ 的界值大小都可以通过调节参数而改变。如果选择比较大的 $\lambda_{\min}(M)$ 和 $\lambda_{\min}(\Lambda(x))$, 则它们可以变得很小。此外, 如果增加神经元个数 L , i.e., $L \rightarrow \infty$, 则有 $\varepsilon(x, t) \rightarrow 0$ 和 $\nabla_x \varepsilon(x, t) \rightarrow 0$, 从而保证误差信号 $\|Z\|$ 的界值变小。

3.5 仿真验证

本节通过将提出的微分对策控制策略应用于导弹拦截机动目标的制导过程中, 解决输入饱和条件下的有限时域微分对策制导问题, 从而验证所提方案的有效性。

3.5.1 拦截制导模型变换

考虑第二章建立的拦截制导模型(2.68)，具体表达式如下：

$$\dot{\sigma} = -\frac{2V_r}{r}\sigma - \frac{\cos(\alpha - \theta)}{r}u_M + \frac{\cos(\beta - \theta)}{r}v_T \quad (3.63)$$

不难发现，在制导末端，随着弹目相对距离 $r \rightarrow 0$ ，该拦截制导运动学关系将被破坏，所提出的制导律将不再适用。为了避免这类问题的发生，本章通过对式(3.63)进行变换，构造新的拦截制导模型，保证所设计的制导律能够顺利执行。

首先，定义剩余时间为 $t_{go} = -r/\dot{r}$ 。基于此，不妨定义新的状态变量为 $x = [x_1, x_2]^T = [\theta, \sigma t_{go}]^T$ 。进一步，定义一个新变量 $\bar{t} = \ln(r(0)) - \ln(r(t))$ 。以新变量 $\bar{t}$ 为自变量对状态变量 x 求导，化简整理可得

$$\begin{aligned} \frac{dx_1}{d\bar{t}} &= x_2 \\ \frac{dx_2}{d\bar{t}} &= x_2 + x_2^3 + \frac{1}{\dot{r}}(\cos(\alpha - \theta) + x_2 \sin(\alpha - \theta))\bar{u} - \frac{1}{\dot{r}}(\cos(\beta - \theta) + x_2 \sin(\beta - \theta))\bar{v} \end{aligned} \quad (3.64)$$

其中， $\bar{u} = t_{go} u_M$ ， $\bar{v} = t_{go} v_T$ 分别表示导弹和目标新的等效控制输入。

由式(3.64)可以看出，当新变量 $\bar{t} \rightarrow \infty$ 时，弹目相对距离 $r \rightarrow 0$ 。这与控制理论中稳定性分析的思想一致。可以说，通过对拦截制导模型的变换，本节把制导问题转换为等效的控制问题来处理。

3.5.2 仿真结果

假设导弹与目标在末制导阶段，飞行速度恒定，i.e., $V_M = 600 \text{ m/s}$, $V_T = 400 \text{ m/s}$ 。自动驾驶仪时间常数选择与前面一致，i.e., $\tau_M = \tau_T = 0.1$ 。假设导弹初始坐标位置为 $(x_M, y_M) = (0, 0)$ ，目标初始坐标位置为 $(x_T, y_T) = (5000, 0)$ ；它们的初始航迹角分别设定为 $\alpha_0 = 60^\circ$ 和 $\beta_0 = 80^\circ$ 。

微分对策控制策略中，选择时间依赖的半正定函数为 $Q(x, t) = 20(x_1^2 + x_2^2 + \tau^2)$ ，式中 $\tau = t_f - t$ ， t_f 表示终端时刻，设定为 $t_f = 60\text{s}$ ；权重矩阵为 $R_1 = 8$ 和 $R_2 = 500$ ；终端约束条件可假设为 $\psi(x(t_f), t_f) = x(t_f)^T x(t_f)$ ；导弹等效控制输入饱和约束假设为 $|\bar{u}| \leq 400$ 。选择时变评价网络的激励函数为 $\sigma(x, t_f - t) = [x_1^2 \exp(-\tau), x_2^2 \exp(-\tau), x_1 x_2 \tau, x_1^4 \exp(-\tau), x_2^2 \exp(-\tau), x_1^3 x_2, x_1^2 x_2^2, x_1 x_2^3]^T$ ，初始权值设为零向量；设计参数 $Y_1 = 100 \cdot [1, 1, 1, 1, 1, 1, 1, 1]^T$, $Y_2 = 0.5I$ ，其中， I 表示相应维数的单位矩阵；评价网络学习率为 $\alpha_1 = 0.2$ ，Lyapunov 函数选取为 $J_s(x) = 0.5(x_1^2 + x_2^2)$ 。为了保证评价网络学习过程中对信号的持续激励，在制导过程前 10s 内，有必要在控制器中加入一个比较小的探索信号 $n(t) = \sin^5(t) \cos(t) + \sin^5(2t) \cos(0.2t)$ 。

仿真结果如图 3.1-图 3.4 所示。图 3.1(a)刻画了导弹拦截机动目标的轨迹曲线，从中可以比较直观地看到导弹最终能够成功拦截机动目标。图 3.1(b)给出了导弹与目标的相对距离变化曲线，可以看出在微分对策控制策略作用下，相对距离 r 从初始的 5000m 逐渐减小到容许的脱靶

量范围内,这也说明了在拦截制导过程中导弹始终在接近目标,直至最后击中成功。为了进一步从理论上验证本章拦截制导方案的拦截效果,给出了图 3.2,其中图 3.2(a)给出了拦截制导过程中弹目视线角速率变化情况。从中可以清楚看到,视线角速率 σ 在制导大部分时间段都稳定在零点附近,直至最后时刻才发散。图 3.2(b)表明了制导过程中弹目相对速率始终保持 $V_r < 0$ 。从仿真结果可以看到,视线角速率和相对速率均满足拦截条件,从而能够保证导弹最终成功拦截机动目标。此外,为了说明本章所提方法对输入受限问题处理的有效性,图 3.3(a)给出了导弹与目标的各自的控制输入曲线,从中可以看出,导弹控制输入始终被限制在饱和约束范围之内。图 3.3(b)给出了导弹与目标的侧向加速度曲线。图 3.4 描述了评价网络权值向量的更新过程,表明了该权值向量的有界性。




图 3.1(a) 导弹-目标拦截轨迹




图 3.1(b) 导弹-目标相对距离

图 3.1 有限时域饱和微分对策弹-目拦截轨迹和相对距离




图 3.2(a) 导弹视线角速率




图 3.2(b) 导弹-目标相对速率

图 3.2 有限时域饱和微分对策导弹视线角速率和相对速率




图 3.3(a) 导弹和目标各自的控制输入




图 3.3(b) 导弹和目标各自的侧向加速度

图 3.3 有限时域饱和微分对策控制输入和侧向加速度




图 3.4 有限时域饱和微分对策评价网络权值

为了进一步检验所提方法的鲁棒性，假设在拦截制导过程中，量测到的状态信号被一组大小介于 $[-0.1, 0.1]$ 的均匀分布的随机噪声污染。此时，拦截制导系统性能受到影响，制导精度有所下降，但由于本章采用 ADP 技术设计拦截制导律，能够实现拦截制导律在外界环境变化、内部参数扰动情况下的在线自学习功能，正如图 3.5 所示，导弹与目标的控制输入响应曲线均表现出振荡现象，但导弹依旧能够在提出的有限时域微分对策控制策略作用下实现拦截，并保证控制输入在约束范围之内。




图 3.5(a) 导弹-目标拦截轨迹




图 3.5(b) 导弹和目标各自的控制输入

图 3.5 有限时域饱和微分对策弹-目标拦截轨迹和控制输入（存在量测噪声）

基于以上分析可得，本章设计的微分对策控制策略不仅能够保证在有限时域内的最优拦截制导律设计问题，还可以有效避免导弹过载饱和问题，实现了输入饱和条件下的有限时域微分对策拦截制导。

3.6 本章小结

本章从拦截制导系统需要在限时域内设计优化制导律以及可能存在的过载饱和等实际工程问题出发，着重研究了非线性系统在输入饱和约束条件下的有限时域微分对策问题。通过在性能指标函数中引入非二次型泛函，有效处理了输入饱和问题，从而将输入受限的微分对策问题转化为输入自由的微分对策问题。考虑到有限时域微分对策问题中，最优代价函数表现出的时变性以及终端约束条件的限制，利用 ADP 技术，通过构建时变评价网络在线逼近时变的最优代价函数；将终端约束误差信号引入评价网络权值更新律的设计中，既保证了最优代价函数的逼

近, 也满足了终端约束条件。最后从理论上严格证明了该方案的合理性, 保证了闭环系统的稳定性。仿真结果进一步验证了该方法的有效性。但本章并没有充分考虑拦截制导系统可能存在的终端状态约束、终端时间约束以及有限时间制导等多约束问题。因此, 需要在后续的研究中进一步考虑拦截制导系统在多约束条件下的制导问题, 使之更加符合工程技术需求。

第四章 多约束条件下基于微分对策的自适应最优拦截制导

4.1 引言

随着战场环境的日益复杂，在制导过程中，为了有效提高导弹的战斗能力，通常需要考虑导弹的一些约束条件。从控制角度看，约束主要分为控制约束和状态约束。控制约束主要指导弹过载饱和、气动舵饱和等；状态约束指导弹在制导某些时刻或全部时刻，对状态变量的约束，如碰撞角度约束、碰撞时间约束等。考虑多约束条件下的微分对策制导问题能够有效提高制导系统的鲁棒性和可靠性，具有十分重要的意义。但正如前所述，拦截制导系统表现出的非线性特性，使得微分对策制导律的设计通常要求解复杂的 HJI 方程，极大地限制了该方法的应用。

虽然 ADP 技术的发展为求解非线性微分对策问题带来了机遇。但现有大部分 ADP 相关算法都是针对仿射非线性系统。但连续仿射非线性系统需要满足一定的匹配条件，即在状态空间描述中未知非线性项必须和控制输入出现在同一个方程中。考虑到很多系统不满足这样的条件，文献[158-160]开始研究具有严格反馈形式的非线性系统的自适应最优控制问题，首次将 ADP 技术引入严格反馈非线性系统中，放松了对系统匹配条件的要求。随后，辽宁工业大学佟绍成教授团队进一步研究了严格反馈非线性系统的模糊自适应最优控制问题^[49; 51; 53]。但值得注意的是，以上研究成果均为将约束问题考虑到控制器的设计中，这对于很多工程问题是不允许的。此外，基于微分对策理论，考虑严格反馈非线性系统的自适应最优控制问题并没有相关成果，还需要进一步研究。基于上述考虑，本章利用 ADP 技术，研究输入输出约束条件下的严格反馈非线性系统的自适应最优控制问题，有助于进一步拓宽 ADP 技术的应用范围，丰富和发展微分对策内涵，并为解决多约束条件下的拦截制导问题提供可行思路。

4.2 问题描述

考虑如下—类具有严格反馈形式的非线性系统

$$\begin{aligned}\dot{x}_i &= f_i(\bar{x}_i) + g_i(\bar{x}_i)x_{i+1} + k_i(\bar{x}_i)d_i, \quad i=1, \dots, n-1 \\ \dot{x}_n &= f_n(\bar{x}_n) + g_n(\bar{x}_n)u(v(t)) + k_n(\bar{x}_n)d_n \\ y &= x_1\end{aligned}\quad (4.1)$$

其中， $\bar{x}_i = [x_1, \dots, x_i]^T \in \mathbb{R}^i, i=1, 2, \dots, n$ 表示系统状态， $u(v(t)) \in \mathbb{R}$ 表示系统饱和输入； $y \in \mathbb{R}$ 为系统输出。这里假设系统输出 y 被约束在一个闭集内，i.e., $|y| \leq k_c$ ，其中 $k_c > 0$ 为输出约束界值；另外， $f_i(\bar{x}_i) \in \mathbb{R}, g_i(\bar{x}_i) \in \mathbb{R}$ 和 $k_i(\bar{x}_i) \in \mathbb{R}, i=1, 2, \dots, n$ 都为已知的连续函数； $d_i \in \mathbb{R}$ 表示未知有界干扰信号，满足 $d_i \in L_2[0, \infty)$ ；这里假设系统饱和输入 $u(v(t))$ 被描述成如下形式：

$$u(v(t)) = \text{sat}(v(t)) = \begin{cases} \text{sign}(v(t))u_{\max}, & |v(t)| \geq u_{\max} \\ v(t), & |v(t)| < u_{\max} \end{cases} \quad (4.2)$$

其中, $u_{\max}$ 表示控制输入饱和界值, $\text{sign}(\cdot)$ 为符号函数。

为有效处理输入饱和问题, 将饱和输入 $u(v(t))$ 用如下函数逼近:

$$h(v) = u_{\max} \tanh\left(\frac{v}{u_M}\right) = u_M \frac{e^{v/u_{\max}} - e^{-v/u_{\max}}}{e^{v/u_{\max}} + e^{-v/u_{\max}}} \quad (4.3)$$

这样可以得到下列等价关系

$$u(v) = \text{sat}(v) = h(v) + \Delta(v) = u_{\max} \tanh\left(\frac{v}{u_{\max}}\right) + \Delta(v) \quad (4.4)$$

其中, $\Delta(v) = \text{sat}(v) - h(v)$ 表示 $\text{sat}(v)$ 和 $h(v)$ 之间的差值。显然 $\Delta(v)$ 是一个有界信号^[161], 满足

$$|\Delta(v)| = |\text{sat}(v) - h(v)| \leq u_{\max} (1 - \tanh(1)) = \bar{d} \quad (4.5)$$

注释 4.1: 当 $0 < |v(t)| \leq u_{\max}$ 时, 随着 $|v(t)|$ 从 0 增大到 $u_{\max}$, 差值 $\Delta(v)$ 将从 0 增大到 $\bar{d}$; 相反, 当 $|v(t)| > u_M$ 时, 随着 $|v(t)|$ 从 $u_{\max}$ 到无穷大, 差值 $\Delta(v)$ 将从 $\bar{d}$ 减小到 0。

基于上述变换, 系统(4.1)可变换为

$$\begin{aligned} \dot{x}_i &= f_i(\bar{x}_i) + g_i(\bar{x}_i)x_{i+1} + k_i(\bar{x}_i)d_i, \quad i=1, \dots, n-1 \\ \dot{x}_n &= f_n(\bar{x}_n) + g_n(\bar{x}_n)h(v) + g_n(\bar{x}_n)\Delta(v) + k_n(\bar{x}_n)d_n \\ y &= x_1 \end{aligned} \quad (4.6)$$

本章的主要目的就是设计控制器 $v(t)$, 使得系统输出信号 y 能够以最优方式跟踪给定的参考信号 $y_d(t)$, 并且保证系统输出和控制输入都能在各自的约束范围内。

为了方便后续控制器设计, 不妨给出如下假设条件:

假设 4.1: 函数 $g_i(\bar{x}_i)$ 的符号已知且 $g_i(\bar{x}_i) \neq 0$; 进一步, 假设存在两个正常数 $g_{\min}^i$ 和 $g_{\max}^i$, 使得不等式 $0 < g_{\min}^i \leq |g_i(\bar{x}_i)| \leq g_{\max}^i$ 成立。

假设 4.2: 存在两个正常数 $k_{\min}^i$ 和 $k_{\max}^i$, 使得函数 $k_i(\bar{x}_i)$ 满足 $k_{\min}^i \leq |k_i(\bar{x}_i)| \leq k_{\max}^i$ 。

假设 4.3: 参考信号 $y_d(t)$ 以及它的 i 阶导数 $y_d^{(i)}(t), i=1, \dots, n$ 有界, 即 $|y_d(t)| \leq A_0 < k_c$, $|y_d^{(i)}(t)| \leq A_i$, 其中 $A_0, A_1, \dots, A_n$ 都是正整数。

注释 4.2: 前面已经知道 $\Delta(v)$ 是有界的, 基于假设 4.1, 容易得到 $g_n(\bar{x}_n)\Delta(v)$ 是有界的, 即存在一个正常数 $\mathcal{G}$, 满足 $|g_n(\bar{x}_n)\Delta(v)| \leq \mathcal{G}$ 。

本章主要将 ADP 技术应用于具有严格反馈形式的非线性系统的控制问题中, 考虑输入饱和、输出约束问题, 结合传统的 Backstepping 控制方法, 通过引入辅助动态系统以及界限 Lyapunov 函数(Barrier Lyapunov Function, BLF)方法, 提出多约束条件下的自适应最优控制方案, 其控制结构如图 4.1 所示。

其中, $k_{b1} > 0$ 表示误差项 z_1 的界值, 可通过关系式 $z_1 = y - y_d$ 确定。

对式(4.9)求导, 并将式(4.8)代入, 整理可得

$$\dot{V}_1 = \frac{z_1}{k_{b1}^2 - z_1^2} [h_1(z_1) + f_1(x_{1d}) + g_1(x_1)z_2 + g_1(x_1)x_{2d}^a + g_1(x_1)x_{2d}^* + k_1(x_1)d_1 - \dot{y}_d] \quad (4.10)$$

此时可设计前馈虚拟控制输入 x_{2d}^a 为

$$x_{2d}^a = \frac{1}{g_1(x_1)} \left[-\gamma_1 \frac{z_1}{k_{b1}^2 - z_1^2} - f_1(x_{1d}) + \dot{y}_d \right] \quad (4.11)$$

其中, $\gamma_i > 0, i = 1, 2, \dots, n$ 为设计参数。

将式(4.11)代入式(4.10), 整理可得

$$\dot{V}_1 = -\gamma_1 \frac{z_1^2}{(k_{b1}^2 - z_1^2)^2} + \frac{z_1}{k_{b1}^2 - z_1^2} [h_1(z_1) + g_1(x_1)z_2 + g_1(x_1)x_{2d}^* + k_1(x_1)d_1] \quad (4.12)$$

第2步: 通过对 z_2 求导可得

$$\dot{z}_2 = h_2(\bar{z}_2) + f_2(\bar{x}_{2d}) + g_2(\bar{x}_2)z_3 + g_2(\bar{x}_2)x_{3d}^a + g_2(\bar{x}_2)x_{3d}^* + k_2(\bar{x}_2)d_2 - \dot{x}_{2d} \quad (4.13)$$

其中, $\bar{z}_i = [z_1, \dots, z_i]^T, i = 1, \dots, n$ 。

定义如下 Lyapunov 函数

$$V_2 = V_1 + \frac{1}{2} z_2^2 \quad (4.14)$$

对式(4.14)求导可得

$$\begin{aligned} \dot{V}_2 &= \dot{V}_1 + z_2 [h_2(\bar{z}_2) + f_2(\bar{x}_{2d}) + g_2(\bar{x}_2)z_3 + g_2(\bar{x}_2)x_{3d}^a + g_2(\bar{x}_2)x_{3d}^* + k_2(\bar{x}_2)d_2 - \dot{x}_{2d}] \\ &= -\gamma_1 \frac{z_1^2}{(k_{b1}^2 - z_1^2)^2} + \frac{z_1}{k_{b1}^2 - z_1^2} [h_1(z_1) + g_1(x_1)z_2 + g_1(x_1)x_{2d}^* + k_1(x_1)d_1] \\ &\quad + z_2 [h_2(\bar{z}_2) + f_2(\bar{x}_{2d}) + g_2(\bar{x}_2)z_3 + g_2(\bar{x}_2)x_{3d}^a + g_2(\bar{x}_2)x_{3d}^* + k_2(\bar{x}_2)d_2 - \dot{x}_{2d}] \end{aligned} \quad (4.15)$$

如果设计虚拟控制输入 x_{3d}^a 为

$$x_{3d}^a = \frac{1}{g_2(\bar{x}_2)} \left[-\gamma_2 z_2 - \frac{1}{k_{b1}^2 - z_1^2} g_1(x_1)z_1 - f_2(\bar{x}_{2d}) + \dot{x}_{2d} \right] \quad (4.16)$$

并将式(4.16)代入式(4.15), 化简整理可得

$$\begin{aligned} \dot{V}_2 &= -\gamma_1 \frac{z_1^2}{(k_{b1}^2 - z_1^2)^2} - \gamma_2 z_2^2 + \frac{z_1}{k_{b1}^2 - z_1^2} [h_1(z_1) + g_1(x_1)x_{2d}^* + k_1(x_1)d_1] \\ &\quad + z_2 [h_2(\bar{z}_2) + g_2(\bar{x}_2)z_3 + g_2(\bar{x}_2)x_{3d}^* + k_2(\bar{x}_2)d_2] \end{aligned} \quad (4.17)$$

第*i*步 ($3 \leq i \leq n-1$): 以此类推, 对 z_i 求导, 有

$$\dot{z}_i = h_i(\bar{z}_i) + f_i(\bar{x}_{id}) + g_i(\bar{x}_i)z_{i+1} + g_i(\bar{x}_i)x_{(i+1)d}^a + g_i(\bar{x}_i)x_{(i+1)d}^* + k_i(\bar{x}_i)d_i - \dot{x}_{id} \quad (4.18)$$

同样选择如下 Lyapunov 函数:

$$V_i = V_{i-1} + \frac{1}{2} z_i^2 \quad (4.19)$$

对式(4.19)求导并将式(4.18)代入, 整理可得

$$\begin{aligned}
 \dot{V}_i &= \dot{V}_{i-1} + z_i [h_i(\bar{z}_i) + f_i(\bar{x}_{id}) + g_i(\bar{x}_i)z_{i+1} + g_i(\bar{x}_i)x_{(i+1)d}^a + g_i(\bar{x}_i)x_{(i+1)d}^* + k_i(\bar{x}_i)d_i - \dot{x}_{id}] \\
 &= -\gamma_1 \frac{z_1^2}{(k_{b1}^2 - z_1^2)^2} - \sum_{j=2}^{i-1} \gamma_j z_j^2 + \frac{z_1}{k_{b1}^2 - z_1^2} [h_1(z_1) + g_1(x_1)x_{2d}^* + k_1(x_1)d_1] \\
 &\quad + \sum_{j=2}^i z_j h_j(\bar{z}_j) + \sum_{j=2}^i z_j g_j(\bar{x}_j)x_{(j+1)d}^* + \sum_{j=2}^i z_j k_j(\bar{x}_j)d_j + g_{i-1}(\bar{x}_{i-1})z_{i-1}z_i \\
 &\quad + z_i [f_i(\bar{x}_{id}) + g_i(\bar{x}_i)z_{i+1} + g_i(\bar{x}_i)x_{(i+1)d}^a - \dot{x}_{id}]
 \end{aligned} \tag{4.20}$$

设计虚拟控制输入 $x_{(i+1)d}^a$ 为

$$x_{(i+1)d}^a = \frac{1}{g_i(\bar{x}_i)} [-\gamma_i z_i - g_{i-1}(\bar{x}_{i-1})z_{i-1} - f_i(\bar{x}_{id}) + \dot{x}_{id}] \tag{4.21}$$

并将式(4.21)代入式(4.20)，整理可得

$$\begin{aligned}
 \dot{V}_i &= -\gamma_1 \frac{z_1^2}{(k_{b1}^2 - z_1^2)^2} - \sum_{j=2}^i \gamma_j z_j^2 + \frac{z_1}{k_{b1}^2 - z_1^2} [h_1(z_1) + g_1(x_1)x_{2d}^* + k_1(x_1)d_1] + \sum_{j=2}^i z_j h_j(\bar{z}_j) \\
 &\quad + \sum_{j=2}^i z_j g_j(\bar{x}_j)x_{(j+1)d}^* + \sum_{j=2}^i z_j k_j(\bar{x}_j)d_j + g_i(\bar{x}_i)z_i z_{i+1}
 \end{aligned} \tag{4.22}$$

第 n 步： 基于误差动态面(4.7)，对误差变量 z_n 求导得

$$\dot{z}_n = h_n(\bar{z}_n) + f_n(\bar{x}_{nd}) + g_n(\bar{x}_n)h(v) + g_n(\bar{x}_n)\Delta(v) + k_n(\bar{x}_n)d_n - \dot{x}_{nd} - \dot{h} \tag{4.23}$$

为补偿输入饱和影响，设计辅助系统如下：

$$\dot{h} = -lh + g_n(\bar{x}_n)(h(v) - v) \tag{4.24}$$

其中， $l > 0$ 是设计参数；实际控制输入 v 有两部分构成，即 $v = v^a + v^*$ ， v^a 表示前馈实际控制输入， v^* 表示反馈最优控制输入。

将式(4.24)代入式(4.23)，可得

$$\dot{z}_n = h_n(\bar{z}_n) + f_n(\bar{x}_{nd}) + g_n(\bar{x}_n)\Delta(v) + k_n(\bar{x}_n)d_n - \dot{x}_{nd} + lh + g_n(\bar{x}_n)v^a + g_n(\bar{x}_n)v^* \tag{4.25}$$

通过选择 Lyapunov 函数

$$V_n = V_{n-1} + \frac{1}{2} z_n^2 \tag{4.26}$$

对其求导并将式(4.22)和式(4.25)代入，可以得到如下等式

$$\begin{aligned}
 \dot{V}_n &= -\gamma_1 \frac{z_1^2}{(k_{b1}^2 - z_1^2)^2} - \sum_{i=2}^{n-1} \gamma_i z_i^2 + \frac{z_1}{k_{b1}^2 - z_1^2} [h_1(z_1) + g_1(x_1)x_{2d}^* + k_1(x_1)d_1] \\
 &\quad + \sum_{i=2}^n z_i h_i(\bar{z}_i) + \sum_{i=2}^{n-1} z_i g_i(\bar{x}_i)x_{(i+1)d}^* + \sum_{i=2}^n z_i k_i(\bar{x}_i)d_i + g_{n-1}(\bar{x}_{n-1})z_{n-1}z_n \\
 &\quad + z_n [f_n(\bar{x}_{nd}) + g_n(\bar{x}_n)\Delta(v) + g_n(\bar{x}_n)v^a + g_n(\bar{x}_n)v^* + lh - \dot{x}_{nd}]
 \end{aligned} \tag{4.27}$$

基于 Young 不等式，下列关系成立：

$$z_n g_n(\bar{x}_n)\Delta(v) \leq \frac{1}{2} z_n^2 + \frac{1}{2} \mathcal{G}^2 \tag{4.28}$$

此时设计前馈实际控制输入为

$$v^a = \frac{1}{g_n(\bar{x}_n)} \left[-lh - g_{n-1}(\bar{x}_{n-1})z_{n-1} - \frac{1}{2} z_n - \gamma_n z_n - f_n(\bar{x}_{nd}) + \dot{x}_{nd} \right] \tag{4.29}$$

将式(4.28)和式(4.29)代入式(4.27)，整理可得

$$\begin{aligned} \dot{V}_n \leq & -\gamma_1 \frac{z_1^2}{(k_{b1}^2 - z_1^2)^2} - \sum_{i=2}^n \gamma_i z_i^2 + \frac{z_1}{k_{b1}^2 - z_1^2} [h_1(z_1) + g_1(x_1)x_{2d}^* + k_1(x_1)d_1] \\ & + \sum_{i=2}^n z_i h_i(\bar{z}_i) + \sum_{i=2}^{n-1} z_i g_i(\bar{x}_i)x_{(i+1)d}^* + \sum_{i=2}^n z_i k_i(\bar{x}_i)d_i + z_n g_n(\bar{x}_n)v^* + \frac{1}{2}g^2 \end{aligned} \quad (4.30)$$

经整理合并, 式(4.30)可重新表示为

$$\dot{V}_n \leq -\gamma \|Z\|^2 + \frac{1}{2}g^2 + Z^T \left(\begin{bmatrix} h_1(z_1) \\ \vdots \\ h_n(\bar{z}_n) \end{bmatrix} + \begin{bmatrix} g_1(x_1) & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & g_n(\bar{x}_n) \end{bmatrix} U^* + \begin{bmatrix} k_1(x_1) & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & k_n(\bar{x}_n) \end{bmatrix} d^* \right) \quad (4.31)$$

其中, $z_{11} = \frac{z_1}{k_{b1}^2 - z_1^2}$, $Z = [z_{11}, z_2, \dots, z_n]^T$, $\gamma = \min(\gamma_i | 1 \leq i \leq n)$; 另外, 控制器 $U = [x_{2d}, \dots, x_{nd}, v]^T$ 描述为 $U = U^a + U^*$, 式中 $U^a = [x_{2d}^a, \dots, x_{nd}^a, v^a]^T$ 为已经设计的前馈控制输入, $U^* = [x_{2d}^*, \dots, x_{nd}^*, v^*]^T$ 为需要设计的反馈最优控制输入; 干扰项 $d^* = [d_1, \dots, d_n]^T$ 也需要在接下来的反馈最优设计中在线估计。

从式(4.31)中不难发现, 在控制器 $U = U^a + U^*$ 结构中, 如果 $U^* = 0$, 则前馈控制输入 U^a 不能保证闭环系统的稳定性。因此需要设计反馈最优控制输入 U^* , 保证下列等效仿射非线性系统的稳定性, 从而使得整个系统的闭环稳定性得以保证

$$\dot{Z} = \begin{bmatrix} h_1(z_1) \\ \vdots \\ h_n(\bar{z}_n) \end{bmatrix} + \begin{bmatrix} g_1(x_1) & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & g_n(\bar{x}_n) \end{bmatrix} U^* + \begin{bmatrix} k_1(x_1) & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & k_n(\bar{x}_n) \end{bmatrix} d^* \quad (4.32)$$

4.4 反馈最优控制输入设计

将式(4.32)变换为如下形式:

$$\dot{Z} = H(Z) + G(X)U + K(X)d \quad (4.33)$$

其中, $H(Z) = [h_1(z_1), \dots, h_n(\bar{z}_n)]^T$, $G(X) = \text{diag}[g_1(x_1), \dots, g_n(\bar{x}_n)]^T$, $K(X) = \text{diag}[k_1(x_1), \dots, k_n(\bar{x}_n)]^T$, $X = [x_1, \dots, x_n]^T$ 。

如果把干扰项 d 看作是外界干扰输入, 则针对仿射非线性系统(4.33)的最优控制问题即可描述为容许控制输入 U 和外界干扰 d 之间的一种零和微分对策问题。本节主要目的就是寻找一组微分对策控制策略 (U^*, d^*) , 即纳什均衡解, 保证控制输入 U^* 能够最小化给定的性能指标函数, 而干扰输入 d^* 能够最大化该性能指标函数。

定义性能指标函数为

$$V(Z) = \int_0^\infty \{Q(Z) + U^T R_1 U - d^T R_2 d\} d\tau \quad (4.34)$$

其中, $Q(Z) \in \mathbb{R}$ 表示半正定函数, $R_1 = R_1^T$ 和 $R_2 = R_2^T$ 均为正定对称矩阵。

基于性能指标函数(4.34), 定义哈密顿函数为

$$H(Z, U, d) = Q(Z) + U^T R_1 U - d^T R_2 d + (\nabla V(Z))^T (H(Z) + G(X)U + K(X)d) \quad (4.35)$$

其中, $\nabla V(Z)$ 表示 $V(Z)$ 对 Z 的偏导数, i.e., $\nabla V(Z) = \partial V(Z) / \partial Z$ 。

基于以上分析可知, 最优代价函数 $V^*(Z)$ 可通过求解如下微分对策问题得到:

$$V^*(Z) = \min_U \max_d \int_0^\infty \{Q(Z) + U^T R_1 U - d^T R_2 d\} d\tau \quad (4.36)$$

进一步假设微分对策控制策略 (U^*, d^*) 存在且唯一, 则 (U^*, d^*) 一定满足必要条件

$$H(Z, U^*, d) \leq H(Z, U^*, d^*) \leq H(Z, U, d^*) \quad (4.37)$$

由最优控制解存在的必要条件^[152]可得, 微分对策控制策略为

$$\begin{cases} U^* = -\frac{1}{2} R_1^{-1} G^T(X) \nabla V^*(Z) \\ d^* = \frac{1}{2} R_2^{-1} K^T(X) \nabla V^*(Z) \end{cases} \quad (4.38)$$

将式(4.38)代入哈密顿函数(4.35), 其相应的 HJI 方程可表述为

$$\begin{aligned} Q(Z) + (\nabla V^*(Z))^T H(Z) - \frac{1}{4} (\nabla V^*(Z))^T G(X) R_1^{-1} G^T(X) \nabla V^*(Z) \\ + \frac{1}{4} (\nabla V^*(Z))^T K(X) R_2^{-1} K^T(X) \nabla V^*(Z) = 0 \end{aligned} \quad (4.39)$$

且满足 $V^*(0) = 0$ 。

从微分对策控制策略(4.38)可以看出, 该策略的执行取决于最优代价函数 $V^*(Z)$ 的信息, 而 $V^*(Z)$ 的获得则需要求解相应的 HJI 方程(4.39)。但可以看出, 该 HJI 方程属于非线性偏微分方程, 一般情况很难获得其解析解形式。基于此, 本章利用 ADP 技术在线逼近最优代价函数 $V^*(Z)$, 保证微分对策控制策略(4.38)的执行。

为方便后续设计, 首先给出如下假设条件:

假设 4.4: 考虑仿射非线性系统(4.33)以及给定的性能指标函数(4.34), 在微分对策控制策略(4.38)作用下, 通常可以假设存在一个连续可微径向无界的 Lyapunov 函数 $J_s(Z)$, 使得不等式 $\dot{J}_s(Z) = (\nabla J_s(Z))^T (H(Z) + G(X)U^* + K(X)d^*) < 0$ 成立, 其中, $\nabla J_s(Z)$ 表示 $J_s(Z)$ 对 Z 的偏导数。此时可以确定存在一个正定函数 $\Lambda(Z)$ 满足 $\forall Z \neq 0, \Lambda(Z) > 0$ 且 $Z = 0 \Rightarrow \Lambda(Z) = 0$, 使得下列不等式成立:

$$(\nabla J_s(Z))^T (H(Z) + G(X)U^* + K(X)d^*) < -(\nabla J_s(Z))^T \Lambda(Z) \nabla J_s(Z) \quad (4.40)$$

另外, 假设在微分对策控制策略作用下闭环系统是有界的且界值函数为关于变量 Z 的表达式^[158-160], 即

$$\|H(Z) + G(X)U^* + K(X)d^*\| \leq c\sqrt{\|Z\|} \quad (4.41)$$

其中, $c > 0$ 为正常数。

利用神经网络对非线性函数的逼近能力, 构造评价网络结构对最优代价函数 $V^*(Z)$ 进行在线逼近, 具体表达式为

$$V^*(Z) = W_c^T \sigma(Z) + \varepsilon(Z) \quad (4.42)$$

其中, $W_c \in \mathbb{R}^L$ 表示评价网络理想权值向量; $\sigma(Z) \in \mathbb{R}^L$ 为激励函数; $\varepsilon(Z)$ 表示逼近误差。

对式(4.42)求偏导, 有

$$\nabla V^*(Z) = (\nabla \sigma(Z))^T W_c + \nabla \varepsilon(Z) \quad (4.43)$$

其中, $\nabla \sigma(Z)$ 表示激励函数 $\sigma(Z)$ 对变量 Z 的偏导数, i.e., $\nabla \sigma(Z) = \partial \sigma(Z) / \partial Z$ 。

将式(4.43)代入式(4.38)和式(4.39), 微分对策控制策略可重新表示为

$$\begin{cases} U^* = -\frac{1}{2} R_1^{-1} G^T(X) ((\nabla \sigma(Z))^T W_c + \nabla \varepsilon(Z)) \\ d^* = \frac{1}{2} R_2^{-1} K^T(X) ((\nabla \sigma(Z))^T W_c + \nabla \varepsilon(Z)) \end{cases} \quad (4.44)$$

相应的 HJI 方程为

$$Q(Z) + W_c^T \nabla \sigma(Z) H(Z) - \frac{1}{4} W_c^T \nabla \sigma(Z) (D_1 - D_2) (\nabla \sigma(Z))^T W_c + \delta_{HJI} = 0 \quad (4.45)$$

其中, $D_1 = G(X) R_1^{-1} G^T(X)$ 和 $D_2 = K(X) R_2^{-1} K^T(X)$ 均为有界信号, 即存在正常数 $D_{1\min}, D_{1\max}, D_{2\min}$ 和 $D_{2\max}$, 满足 $D_{1\min} \leq \|D_1\| \leq D_{1\max}$ 和 $D_{2\min} \leq \|D_2\| \leq D_{2\max}$; 由评价网络逼近误差造成的残余误差 δ_{HJI} 可表示为

$$\begin{aligned} \delta_{HJI} &= (\nabla \varepsilon(Z))^T H(Z) - \frac{1}{4} (\nabla \varepsilon(Z))^T (D_1 - D_2) \nabla \varepsilon(Z) - \frac{1}{2} W_c^T \nabla \sigma(Z) (D_1 - D_2) \nabla \varepsilon_c(Z) \\ &= (\nabla \varepsilon(Z))^T (H(Z) + G(X) U^* + K(X) d^*) + \frac{1}{4} (\nabla \varepsilon(Z))^T (D_1 - D_2) \nabla \varepsilon(Z) \end{aligned} \quad (4.46)$$

考虑到评价网络理想权值向量未知, 评价网络输出信号将被用于估计理想权值, 具体表示为

$$\hat{V}(Z) = \hat{W}_c^T \sigma(Z) \quad (4.47)$$

其中, $\hat{W}_c$ 为理想权值 W_c 的估计值。

同样地, 对式(4.47)求偏导可得

$$\nabla \hat{V}(Z) = (\nabla \sigma(Z))^T \hat{W}_c \quad (4.48)$$

将其代入式(4.38), 可以得到估计的微分对策控制策略为

$$\begin{cases} \hat{U} = -\frac{1}{2} R_1^{-1} G^T(X) ((\nabla \sigma(Z))^T \hat{W}_c) \\ \hat{d} = \frac{1}{2} R_2^{-1} K^T(X) ((\nabla \sigma(Z))^T \hat{W}_c) \end{cases} \quad (4.49)$$

其相应的 HJI 方程(4.45)可变为

$$H(Z, \hat{U}, \hat{d}) = Q(Z) + \hat{W}_c^T \nabla \sigma(Z) H(Z) - \frac{1}{4} \hat{W}_c^T \nabla \sigma(Z) (D_1 - D_2) (\nabla \sigma(Z))^T \hat{W}_c \stackrel{\Delta}{=} e_c \quad (4.50)$$

考虑到 $H(Z, U^*, d^*) = 0$, 需要设计评价网络权值更新律, 保证估计权值 $\hat{W}_c$ 收敛于理想权值 W_c , 从而使得哈密顿函数 $H(Z, \hat{U}, \hat{d}) \rightarrow 0$ 。为此, 定义如下二次型目标函数:

$$E_c = \frac{1}{2} e_c^T e_c \quad (4.51)$$

基于梯度下降法, 虽然可以设计出评价网络权值更新律。但梯度下降法设计的更新律仅仅是为了最小化目标函数 E_c , 而并不能保证闭环系统学习过程中信号的有界性。为此, 基于假设

4.4, 本节设计如下评价网络权值更新律:

$$\begin{aligned} \dot{\hat{W}}_c = & -\frac{\alpha_c \phi}{m_s^2} e_c + \frac{\alpha_c}{2} \Sigma(Z, \hat{U}, \hat{d}) \nabla \sigma(Z) (D_1 - D_2) \nabla J_s(Z) \\ & - \alpha_c \left[-\frac{1}{4} \frac{\phi}{m_s^2} \hat{W}_c^T \nabla \sigma(Z) (D_1 - D_2) (\nabla \sigma(Z))^T \hat{W}_c + (F_2 \hat{W}_c - F_1 \phi^T \hat{W}_c) \right] \end{aligned} \quad (4.52)$$

其中, $\phi = \nabla \sigma(Z)(H(Z) + G(X)\hat{U} + K(X)\hat{d})$, $\alpha_c > 0$ 表示评价网络学习率, $m_s = (1 + \phi^T \phi)$, $\varphi = \phi/m_s$; F_1 和 F_2 是需要设计的相应维数的调节参数; $J_s(Z)$ 在假设 4.4 中已定义; $\Sigma(Z, \hat{U}, \hat{d})$ 定义如下:

$$\Sigma(Z, \hat{U}, \hat{d}) = \begin{cases} 0, & \text{if } j(Z) = (\nabla J(Z))^T (H(Z) + G(X)\hat{U} + K(X)\hat{d}) < 0, \\ 1, & \text{else.} \end{cases} \quad (4.53)$$

如果定义评价网络权值估计误差为 $\tilde{W}_c = W_c - \hat{W}_c$, 由式(4.45)可知

$$Q(Z) = -W_c^T \nabla \sigma(Z) H(Z) + \frac{1}{4} W_c^T \nabla \sigma(Z) (D_1 - D_2) (\nabla \sigma(Z))^T W_c - \delta_{HJ} \quad (4.54)$$

结合式(4.50)、式(4.52)和式(4.54), 经化简整理, 可得评价网络权值估计误差动态可表述为

$$\begin{aligned} \dot{\tilde{W}}_c = & \frac{\alpha_c \phi}{m_s^2} \left[-\phi^T \tilde{W}_c + \frac{1}{4} \tilde{W}_c^T \nabla \sigma(Z) (D_1 - D_2) (\nabla \sigma(Z))^T \tilde{W}_c - \delta_{HJ} \right] \\ & - \frac{\alpha_c}{2} \Sigma(Z, \hat{U}, \hat{d}) \nabla \sigma(Z) (D_1 - D_2) \nabla J_s(Z) \\ & + \alpha_c \left[-\frac{1}{4} \frac{\phi}{m_s^2} \hat{W}_c^T \nabla \sigma(Z) (D_1 - D_2) (\nabla \sigma(Z))^T \hat{W}_c + (F_2 \hat{W}_c - F_1 \phi^T \hat{W}_c) \right] \end{aligned} \quad (4.55)$$

需要注意的是, 式(4.55)将用于后续评价网络权值估计误差收敛性分析。

4.5 稳定性分析

本节将给出严格的系统稳定性分析, 在此之前, 针对评价网络作出如下普遍性假设:

假设 4.5: 评价网络理想权值向量 W_c 有界, 即存在一个正常数 W_{cM} , 满足 $\|W_c\| \leq W_{cM}$; 另外, 在紧集 $\Omega_z \in \mathbb{R}^n$ 内, 对于任意的 $Z \in \Omega_z$, 评价网络激励函数 $\sigma(Z)$, 逼近误差 $\varepsilon(Z)$ 以及梯度项 $\nabla \sigma(Z)$ 和 $\nabla \varepsilon(Z)$ 均有界, 满足 $\|\sigma(Z)\| \leq \sigma_M$, $\|\varepsilon(Z)\| \leq \varepsilon_M$, $\|\nabla \sigma(Z)\| \leq b_\sigma$ 和 $\|\nabla \varepsilon(Z)\| \leq b_M$, 其中, $\sigma_M, \varepsilon_M, b_\sigma$ 和 b_M 均为正常数; 此外, 易得残余误差项 δ_{HJ} 也是有界的, 满足不等式 $\|\delta_{HJ}\| \leq \delta_{HM}$, 式中 δ_{HM} 表示正常数。

基于上述分析与设计, 给出如下定理:

定理 4.1: 针对输入输出约束的具有严格反馈形式的非线性系统(4.1), 设计前馈控制输入如式(4.11)、式(4.21)和式(4.29)所示, 并且辅助系统设计为如式(4.24)所示; 进一步, 反馈微分对策控制策略设计为式(4.49), 评价网络权值更新律为式(4.52)。那么在假设 4.1-假设 4.5 成立的前提下可通过参数选择, 不仅能够保证闭环系统所有信号最终一致有界(UUB), 还能够确保系统输出以最优方式跟踪给定的参考信号; 同时系统输出信号均保持在各自的约束范围之内。

证明: 选择 Lyapunov 函数为

$$V_{HH} = \frac{1}{2} \log \left(\frac{k_{b1}^2}{k_{b1}^2 - z_1^2} \right) + \frac{1}{2} \sum_{i=2}^n z_i^2 + \frac{1}{2} \tilde{W}_c^T \alpha_c^{-1} \tilde{W}_c + J_s(Z) \quad (4.56)$$

对 V_{HH} 求导可得

$$\dot{V}_{HH} = \frac{z_1 \dot{z}_1}{k_{b1}^2 - z_1^2} + \sum_{i=2}^n z_i \dot{z}_i + \tilde{W}_c^T \alpha_c^{-1} \dot{\tilde{W}}_c + (\nabla J_s(Z))^T \dot{Z} \quad (4.57)$$

将式(4.31)代入上式, 整理得

$$\dot{V}_{HH} = -\gamma \|Z\|^2 + \frac{1}{2} g^2 + Z^T (H(Z) + G(X)U^* + K(X)d^*) + \tilde{W}_c^T \alpha_c^{-1} \dot{\tilde{W}}_c + (\nabla J_s(Z))^T \dot{Z} \quad (4.58)$$

基于评价网络权值估计误差动态(4.55), 下式成立

$$\begin{aligned} \tilde{W}_c^T \alpha_c^{-1} \dot{\tilde{W}}_c &= \tilde{W}_c^T \frac{\phi}{m_s} (-\phi^T \tilde{W}_c - \delta_{HH}) + \frac{1}{4} \tilde{W}_c^T \frac{\phi}{m_s} \tilde{W}_c^T \nabla \sigma(Z) (D_1 - D_2) (\nabla \sigma(Z))^T \tilde{W}_c \\ &\quad - \frac{1}{4} \tilde{W}_c^T \frac{\phi}{m_s} \hat{W}_c^T \nabla \sigma(Z) (D_1 - D_2) (\nabla \sigma(Z))^T \hat{W}_c + \tilde{W}_c^T (F_2 \hat{W}_c - F_1 \phi^T \hat{W}_c) \\ &\quad - \frac{1}{2} \tilde{W}_c^T \Sigma(Z, \hat{U}, \hat{d}) \nabla \sigma(Z) (D_1 - D_2) \nabla J_s(Z) \end{aligned} \quad (4.59)$$

进一步, 基于权值估计误差定义式 $\tilde{W}_c = W_c - \hat{W}_c$, 消去式(4.59)中的 $\hat{W}_c$ 整理可得

$$\begin{aligned} \tilde{W}_c^T \alpha_c^{-1} \dot{\tilde{W}}_c &= \tilde{W}_c^T \frac{\phi}{m_s} (-\phi^T \tilde{W}_c - \delta_{HH}) + \frac{1}{2} \tilde{W}_c^T \frac{\phi}{m_s} W_c^T \nabla \sigma(Z) (D_1 - D_2) (\nabla \sigma(Z))^T \tilde{W}_c \\ &\quad - \frac{1}{4} \tilde{W}_c^T \frac{\phi}{m_s} W_c^T \nabla \sigma(Z) (D_1 - D_2) (\nabla \sigma(Z))^T W_c + \tilde{W}_c^T (F_2 \hat{W}_c - F_1 \phi^T \hat{W}_c) \\ &\quad - \frac{1}{2} \tilde{W}_c^T \Sigma(Z, \hat{U}, \hat{d}) \nabla \sigma(Z) (D_1 - D_2) \nabla J_s(Z) \end{aligned} \quad (4.60)$$

此外可以将 $\tilde{W}_c^T (F_2 \hat{W}_c - F_1 \phi^T \hat{W}_c)$ 作如下变换:

$$\tilde{W}_c^T (F_2 \hat{W}_c - F_1 \phi^T \hat{W}_c) = \tilde{W}_c^T F_2 W_c - \tilde{W}_c^T F_2 \tilde{W}_c - \tilde{W}_c^T F_1 \phi^T W_c + \tilde{W}_c^T F_1 \phi^T \tilde{W}_c \quad (4.61)$$

基于以上变换, 定义变量 $Y = [\phi^T \tilde{W}_c, \tilde{W}_c]^T$, 则式(4.60)可整理为

$$\tilde{W}_c^T \alpha_c^{-1} \dot{\tilde{W}}_c = -Y^T M Y + Y^T N - \frac{1}{2} \tilde{W}_c^T \Sigma(Z, \hat{U}, \hat{d}) \nabla \sigma(Z) (D_1 - D_2) \nabla J_s(Z) \quad (4.62)$$

其中,

$$M = \begin{bmatrix} I & -\frac{1}{2} F_1^T \\ -\frac{1}{2} F_1 & F_2 - \frac{1}{2} \frac{\phi}{m_s} W_c^T \nabla \sigma(Z) (D_1 - D_2) (\nabla \sigma(Z))^T \end{bmatrix}, \quad N = \begin{bmatrix} -\frac{\delta_{HH}}{m_s} \\ \left(F_2 - F_1 \phi^T - \frac{1}{4} \frac{\phi}{m_s} W_c^T \nabla \sigma(Z) (D_1 - D_2) (\nabla \sigma(Z))^T \right) W_c \end{bmatrix}.$$

将式(4.62)代入式(4.58), 并通过选择设计参数 F_1 和 F_2 保证矩阵 $M > 0$, 则式(4.58)可重新表述为

$$\begin{aligned} \dot{V}_{HH} &\leq -\gamma \|Z\|^2 + \frac{1}{2} g^2 + Z^T (H(Z) + G(X)U^* + K(X)d^*) + (\nabla J_s(Z))^T \dot{Z} \\ &\quad - \lambda_{\min}(M) \|Y\|^2 + \|N\| \|Y\| - \frac{1}{2} \tilde{W}_c^T \Sigma(Z, \hat{U}, \hat{d}) \nabla \sigma(Z) (D_1 - D_2) \nabla J_s(Z) \end{aligned} \quad (4.63)$$

其中, $\lambda_{\min}(M)$ 表示矩阵 M 的最小特征值。

考虑不等式关系(4.41), 式(4.63)可变换为

$$\begin{aligned} \dot{V}_{HJI} \leq & -\left(\gamma - \frac{1}{2}\right)\|Z\|^2 + \frac{c^2}{2}\|Z\| + \frac{1}{2}\mathcal{G}^2 - \lambda_{\min}(M)\|Y\|^2 + \|N\|\|Y\| \\ & - \frac{1}{2}\tilde{W}_c^T \Sigma(Z, \hat{U}, \hat{d}) \nabla \sigma(Z)(D_1 - D_2) \nabla J_s(Z) + (\nabla J_s(Z))^T \dot{Z} \end{aligned} \quad (4.64)$$

根据 $\Sigma(Z, \hat{U}, \hat{d})$ 的定义式(4.53), 在下面的分析中, 将分两种情况进行讨论。

情形 1: $\Sigma(Z, \hat{U}, \hat{d}) = 0$ 。此时在评价网络学习过程中闭环系统稳定, 不等式 $(\nabla J_s(Z))^T \dot{Z} < 0$ 成立。为保证评价网络在学习过程中, 权值能够通过自适应更新律充分学习, 从而收敛至理想权值, 此处通常假设系统信号满足持续激励条件, 则存在一个正常数 μ 满足 $0 < \mu < \|Z\|$, 使得不等式 $(\nabla J_s(Z))^T \dot{Z} \leq -\mu\|\nabla J_s(Z)\| < 0$ 成立。此时, 式(4.64)可简化为

$$\dot{V}_{HJI} \leq -\left(\gamma - \frac{1}{2}\right)\|Z\|^2 + \frac{c^2}{2}\|Z\| + \frac{1}{2}\mathcal{G}^2 - \lambda_{\min}(M)\|Y\|^2 + \|N\|\|Y\| - \mu\|\nabla J_s(Z)\| \quad (4.65)$$

从式(4.65)可的, 为保证系统稳定性, 需要选择参数 γ 满足 $\gamma > \frac{1}{2}$ 。通过对式(4.65)整理可得

$$\dot{V}_{HJI} \leq -\mu\|\nabla J_s(Z)\| - \left(\gamma - \frac{1}{2}\right)\left(\|Z\| - \frac{c^2}{2(2\gamma-1)}\right)^2 - \lambda_{\min}(M)\left(\|Y\| - \frac{\|N\|}{2\lambda_{\min}(M)}\right)^2 + \lambda_1 \quad (4.66)$$

其中, $\lambda_1 = \frac{1}{2}\mathcal{G}^2 + \frac{c^4}{8(2\gamma-1)} + \frac{\|N\|^2}{4\lambda_{\min}(M)}$ 。

分析式(4.66), 可以确定只要下列不等式关系成立, 即可保证 $\dot{V}_{HJI} < 0$

$$\|\nabla J_s(Z)\| \geq \frac{\lambda_1}{\mu} = A_1 \quad (4.67)$$

或

$$\|Z\| \geq \sqrt{\frac{2\lambda_1}{2\gamma-1}} + \frac{c^2}{2(2\gamma-1)} = B_1 \quad (4.68)$$

或

$$\|Y\| \geq \sqrt{\frac{\lambda_1}{\lambda_{\min}(M)}} + \frac{\|N\|}{2\lambda_{\min}(M)} = C_1 \quad (4.69)$$

情形 2: $\Sigma(Z, \hat{U}, \hat{d}) = 1$ 。这种情况下, 在评价网络学习过程中, 闭环系统信号的有界性不能保证, 不等式 $(\nabla J_s(Z))^T \dot{Z} \geq 0$ 成立。此时, 式(4.64)可变换为

$$\begin{aligned} \dot{V}_{HJI} \leq & -\left(\gamma - \frac{1}{2}\right)\|Z\|^2 + \frac{c^2}{2}\|Z\| + \frac{1}{2}\mathcal{G}^2 - \lambda_{\min}(M)\|Y\|^2 + \|N\|\|Y\| \\ & - \frac{1}{2}\tilde{W}_c^T \nabla \sigma(Z)(D_1 - D_2) \nabla J_s(Z) + (\nabla J_s(Z))^T \dot{Z} \end{aligned} \quad (4.70)$$

由微分对策控制策略(4.44)以及其估计形式(4.49), 可知

$$\begin{cases} U^* - \hat{U} = -\frac{1}{2}R_1^{-1}G^T(X)((\nabla \sigma(Z))^T \tilde{W}_c + \nabla \varepsilon(Z)) \\ d^* - \hat{d} = \frac{1}{2}R_2^{-1}K^T(X)((\nabla \sigma(Z))^T \tilde{W}_c + \nabla \varepsilon(Z)) \end{cases} \quad (4.71)$$

基于式(4.71), 式(4.70)可进一步变换为

$$\begin{aligned} \dot{V}_{HII} \leq & -\left(\gamma - \frac{1}{2}\right)\|Z\|^2 + \frac{c^2}{2}\|Z\| + (\nabla J_s(Z))^T (H(Z) + G(X)U^* + K(X)d^*) \\ & - \lambda_{\min}(M)\|Y\|^2 + \|N\|\|Y\| + \frac{1}{2}(\nabla J_s(Z))^T (D_1 - D_2)\nabla \varepsilon(Z) + \frac{1}{2}\mathcal{G}^2 \end{aligned} \quad (4.72)$$

基于假设 4.4-假设 4.5 可知, 信号 D_1, D_2 和 $\nabla \varepsilon(Z)$ 是有界的, 则式(4.72)可整理为如下形式:

$$\begin{aligned} \dot{V}_{HII} \leq & -\lambda_{\min}(\Lambda(Z))\left(\|\nabla J_s(Z)\| - \frac{b_M(D_{1\max} - D_{2\min})}{4\lambda_{\min}(\Lambda(Z))}\right)^2 - \left(\gamma - \frac{1}{2}\right)\left(\|Z\| - \frac{c^2}{2(2\gamma-1)}\right)^2 \\ & - \lambda_{\min}(M)\left(\|Y\| - \frac{\|N\|}{2\lambda_{\min}(M)}\right)^2 + \lambda_2 \end{aligned} \quad (4.73)$$

其中, $\lambda_2 = \frac{1}{2}\mathcal{G}^2 + \frac{c^4}{8(2\gamma-1)} + \frac{\|N\|^2}{4\lambda_{\min}(M)} + \frac{b_M^2(D_{1\max} - D_{2\min})^2}{16\lambda_{\min}(\Lambda(Z))}$ 。

从式(4.73)可以得出, 保证 $\dot{V}_{HII} < 0$ 需要满足下列不等式条件:

$$\|\nabla J_s(Z)\| \geq \sqrt{\frac{\lambda_2}{\lambda_{\min}(\Lambda(Z))}} + \frac{b_M(D_{1\max} - D_{2\min})}{4\lambda_{\min}(\Lambda(Z))} = A_2 \quad (4.74)$$

或

$$\|Z\| \geq \sqrt{\frac{2\lambda_2}{2\gamma-1}} + \frac{c^2}{2(2\gamma-1)} = B_2 \quad (4.75)$$

或

$$\|Y\| \geq \sqrt{\frac{\lambda_2}{\lambda_{\min}(M)}} + \frac{\|N\|}{2\lambda_{\min}(M)} = C_2 \quad (4.76)$$

综上所述, 可以得出这样的结论: 只要不等式 $\|\nabla J_s(Z)\| \geq \max(A_1, A_2)$ 或 $\|Z\| \geq \max(B_1, B_2)$, 或 $\|Y\| \geq \max(C_1, C_2)$ 成立, 即可使得 $\dot{V}_{HII} < 0$, 从而保证闭环系统信号的最终一致有界性。

4.6 仿真验证

本节将考虑第二章建立的拦截制导系统, 验证本章提出的控制方案的有效性。首先, 对拦截制导系统做适当的变形, 选择状态变量为 $x_1 = \theta, x_2 = \sigma$, 则拦截制导系统可描述为如式(4.1)所示的具有严格反馈形式的非线性系统, 具体表达式为

$$\begin{aligned} \dot{x}_1 &= x_2 \\ \dot{x}_2 &= -\frac{2V_r}{r}x_2 - \frac{\cos(\alpha - \theta)}{r}u_M + \frac{\cos(\beta - \theta)}{r}v_T \end{aligned} \quad (4.77)$$

基于式(4.77), 本节假设在末制导阶段, 导弹与目标的飞行速度恒定, 假设为 $V_M = 600 \text{ m/s}$, $V_T = 400 \text{ m/s}$ 。自动驾驶仪时间常数为 $\tau_M = \tau_T = 0.1$ 。导弹和目标的初始航迹角可设为 $\alpha_0 = \pi/6 \text{ rad}$ 和 $\beta_0 = \pi/6 \text{ rad}$; 初始位置坐标信息假设为 $(x_M, y_M) = (0, 0)$ 和 $(x_T, y_T) = (2500, 0)$; 期望视线角设定为 $\theta_d = 0 \text{ rad}$; 进一步, 假设视线角约束为 $|\theta| \leq 1 \text{ rad}$; 导弹侧向加速度饱和约束为 $|u_M| \leq 100 \text{ m/s}^2$ 。

本节选择控制器参数如下: 前馈控制输入部分 $\gamma_1 = 2, \gamma_2 = 20, k_{b1} = 1$; 辅助系统中 $h(0) = 0$, $l = 10$; 微分对策控制策略中, 将评价网络激励函数选取为双曲正切函数形式, 具体表示为

$\sigma(Z) = [\tanh(0.1z_{11}), \tanh(z_2), \tanh(2z_{11}z_2), \tanh(0.5z_{11}^2), \tanh(10z_2^2)]^T$, 初始权值向量设定为零向量; 选择 $Q(Z) = z_{11}^2 + z_2^2$, $R_1 = R_2 = I_2$, 学习率为 $\alpha_c = 0.4$, 调节参数 $F_1 = 200 \cdot [1, 1, 1, 1, 1]^T$, $F_2 = 20I$; $J(Z) = 0.5(z_{11}^2 + z_2^2)$; 此外, 在评价网络学习过程中, 为维持信号的持续激励, 从而保证系统能够充分学习, 在控制器执行的前 4s 内加入一个比较小的噪声探索信号, 具体表达式为 $n(t) = 0.1\sin^5(t)\cos(t) + 0.05\sin^5(2t)\cos(0.2t)$ 。

情形 1: $v_r = \hat{d}$

在这种情形下, 假设目标机动就是如式(4.49)给出的估计干扰输入, 即 $v_r = \hat{d}$ 。

仿真结果如图 4.2-图 4.5 所示, 其中, 图 4.2(a) 给出了导弹拦截机动目标的轨迹图, 可以直观地看到, 导弹最终可以成功拦截机动目标。相应地, 图 4.2(b) 给出了导弹与目标之间的相对距离, 从中可以发现, 在平行导引原则下, 导弹始终朝着目标方向前进, 从最初的 2500m 逐渐减小到小于 0.1m 的脱靶量范围内。为了更好地说明所提方案的有效性, 给出了拦截制导过程中视线角速率和相对速率变化曲线, 如图 4.3 所示, 视线角速率曲线从最初非零状态调整并保持在零附近, 即 $\sigma \rightarrow 0$, 这可以保证导弹始终朝着目标飞行; 相对速率曲线在整个拦截制导过程中都保持负值, 说明导弹能够始终接近目标。可以看到, 保证导弹成功拦截机动目标的必要条件 $\sigma \rightarrow 0$, $V_r < 0$ 都被满足, 这进一步说明了本章所提算法的有效性。




图 4.2(a) 导弹-目标拦截轨迹




图 4.2(b) 导弹-目标相对距离

图 4.2 多约束条件下弹-目拦截轨迹和相对距离




图 4.3(a) 导弹视线角速率




图 4.3(b) 导弹-目标相对速率

图 4.3 多约束条件下导弹视线角速率和相对速率

另外, 图 4.4(a)给出了视线角变化曲线, 可以清楚地看到视线角始终保持在给定的约束范围之内; 图 4.4(b)刻画了导弹侧向加速度变化曲线, 从中可以看出, 在拦截制导过程中导弹侧

向加速度发生饱和现象, 但通过辅助系统的设计, 导弹侧向加速度始终被限定在给定输入约束内 $|u_M| \leq 100 \text{ m/s}^2$, 同时还可以保证导弹成功拦截目标。另外, 为了验证评价网络权值估计误差信号的有界性, 给出了图 4.5, 从中可以看出, 评价网络权值通过大约 5s 的学习后, 收敛于稳定值; 同时残余误差减小到零。




图 4.4(a) 导弹视线角




图 4.4(b) 导弹侧向加速度

图 4.4 多约束条件下导弹视线角和侧向加速度




图 4.5(a) 评价网络权值




图 4.5(b) 残余误差

图 4.5 多约束条件下评价网络权值和残余误差

情形 2: $v_r = 50 \sin(t) \text{ m/s}^2$

本章微分对策拦截制导策略主要描述的是在目标机动最坏情况下, 导弹最优拦截制导律的设计过程。为了进一步验证该微分对策拦截制导律的鲁棒性, 选择目标机动形式为幅值为 $5g$ 的正弦波, 即 $v_r = 50 \sin(t) \text{ m/s}^2$ 。在这种情况下, 目标机动并不是最坏的情形。从理论上讲, 本章提出的最优拦截制导律对它具有很强的鲁棒性。具体仿真结果如图 4.6-图 4.8 所示, 可以看出即使目标机动形式改变, 导弹始终能够在输入输出约束条件下成功拦截目标。




图 4.6(a) 导弹-目标拦截轨迹




图 4.6(b) 导弹-目标相对距离

图 4.6 多约束条件下弹-目拦截轨迹和相对距离 (目标正弦机动)




图 4.7(a) 导弹视线角速率




图 4.7(b) 导弹-目标相对速率

图 4.7 多约束条件下导弹视线角速率和相对速率（目标正弦机动）




图 4.8(a) 导弹视线角




图 4.8(b) 导弹侧向加速度

图 4.8 多约束条件下导弹视线角和侧向加速度（目标正弦机动）

值得注意的是，在以上仿真结果中可以发现，在导弹拦截机动目标最后时刻，闭环系统信号表现出发散特性。这主要是由于随着相对距离 $r \rightarrow 0$ ，拦截制导系统(4.77)已经被破坏，所设计的制导律已不再适用。基于这种考虑，在实际工程中往往会预先设定一个最小脱靶距离 r_0 ，当相对距离 $r \leq r_0$ 时，就可以认为导弹已经成功击中目标，此时制导过程结束，这样就避免了仿真结果中出现的发散现象。

4.7 本章小结

本章主要从拦截制导过程中输入饱和、输出受限等问题出发，研究输入输出约束条件下的一类具有严格反馈形式的非线性系统的零和微分对策问题。通过将 ADP 技术与 Backstepping 控制方法相结合，解决了严格反馈系统的自适应最优跟踪控制问题，拓宽了 ADP 技术的适用范围。首先借助 Backstepping 控制方法，将严格反馈系统的跟踪控制问题转化为具有仿射非线性形式的等效跟踪误差动态系统的最优调节控制问题。在前馈控制中，通过引入辅助系统和界限 Lyapunov 函数有效处理了输入输出约束问题。随后基于微分对策理论，实现了非线性系统的最优控制问题。利用 ADP 技术，通过构建评价网络在线逼近相应 HJI 方程的解，实现微分对策控制策略的在线逼近，最终实现了多约束条件下的自适应最优控制；理论研究成果通过拦截制导系统验证了它有效性，为发展多约束条件下的自适应最优拦截制导方案提供了可借鉴的思路。

第五章 基于ADP技术的自适应预测最优拦截制导

5.1 引言

在前面章节中,主要以导弹拦截制导为背景,利用 ADP 技术研究了非线性系统的自适应最优控制问题,并将其应用于导弹拦截制导律的设计;通过构建评价网络结构,设计评价网络权重更新律,在线逼近最优代价函数,从而保证所设计控制器的执行。可以说前述内容着重强调了算法的可执行性以及闭环系统的稳定性。近年来,虽然 ADP 技术得到了长足的发展,并取得了丰硕的研究成果。但它依旧面临很多具有挑战性的问题,其中计算复杂度问题便值得进一步考虑的问题。目前,ADP 技术主要应用于维数较低的连续非线性系统。其主要原因就是针对高维复杂系统,在传统的 actor-critic 结构下,设计的在线持续更新的控制器计算复杂度过高,对计算机处理能力提出较高要求。这种情况下,提出一种新型 ADP 算法在保证闭环系统稳定性基础上还能够降低控制器的计算复杂度,对于 ADP 技术应用于高维复杂非线性系统具有重要的理论意义。

预测控制作为最优控制的一个分支,由于它能够通过离线计算得到最优控制解析表达式,得到很多科研工作者的青睐。其中,连续时间预测控制方法自提出以来^[162],就受到很大的关注,并在航空航天领域取得了很多研究成果^[163-165]。但连续时间预测控制得到最优解析表达式属于离线计算方式,它需要提前知道系统精确模型以确保闭环系统性能。但在实际工程应用中系统模型一般难以精确已知,从而降低了连续时间预测控制器的鲁棒性。另外,针对高维复杂非线性系统,连续时间预测控制方法往往会由于维数过高而难以得到其解析解形式。基于此,本章将 ADP 技术与连续时间预测控制方法相结合,采用离线-在线控制结构,一方面通过给出最优控制解析表达式降低 ADP 算法的计算复杂度;另一方面,通过在线自适应调整方式保证闭环系统的鲁棒性,从而实现非线性系统的自适应预测最优控制。

5.2 问题描述

考虑如下具有块严格反馈形式的 MIMO 连续非线性系统

$$\begin{cases} \dot{x}_1 = f_1(x_1) + g_1(x_1)x_2 \\ \dot{x}_2 = f_2(x_1, x_2) + g_2(x_1, x_2)u \end{cases} \quad (5.1)$$

其中, $x_1 \in \mathbb{R}^{n_1}, x_2 \in \mathbb{R}^{n_2}$ 表示系统状态, $u(t) \in \mathbb{R}^m$ 为控制输入; $f_1(x_1) \in \mathbb{R}^{n_1}$ 和 $f_2(x_1, x_2) \in \mathbb{R}^{n_2}$ 均为连续非线性函数, $g_1(x_1) \in \mathbb{R}^{n_1 \times n_2}, g_2(x_1, x_2) \in \mathbb{R}^{n_2 \times m}$ 表示控制输入函数;

将式(5.1)表示为状态空间形式,表示为

$$\dot{x} = f(x) + g(x)u \quad (5.2)$$

其中, $x = [x_1^T, x_2^T]^T \in \mathbb{R}^{n_1+n_2}$, $f(x) = \begin{bmatrix} f_1(x_1) + g_1(x_1)x_2 \\ f_2(x_1, x_2) \end{bmatrix} \in \mathbb{R}^{n_1+n_2}$, $g(x) = \begin{bmatrix} 0 \\ g_2(x_1, x_2) \end{bmatrix} \in \mathbb{R}^{(n_1+n_2) \times m}$; 此外, 假设 $f(x) + g(x)u$ 在包含原点的局部范围内 Lipschitz 连续且系统(5.2)可控。

注释 5.1: 为了能够清晰明了地表达自适应预测最优控制方法的设计步骤, 本章考虑的系统(5.1)在形式上只包含 2 个严格反馈块。本质上, 针对更加一般的具有 n 个严格反馈块的非线性系统, 设计思想与本章方法类似。

为了方便控制器的设计, 首先给出如下假设:

假设 5.1: 非线性函数 $g_i(\cdot) \neq 0, i=1, 2$, 并且存在两个正常数 $g_{\min}^i$ 和 $g_{\max}^i$ 满足 $g_{\min}^i \leq \|g_i(\cdot)\| \leq g_{\max}^i$ 。

基于系统(5.1)的严格反馈形式以及 Backstepping 设计思想, 定义如下误差动态面:

$$\begin{cases} z_1 = x_1 \\ z_2 = x_2 - \bar{v}_2 \end{cases} \quad (5.3)$$

其中, $\bar{v}_2$ 表示将虚拟控制量 v_2 通过如下一阶低通滤波器后的输出:

$$\tau \dot{\bar{v}}_2 + \bar{v}_2 = v_2 \quad (5.4)$$

其中, τ 为时间常数。

基于误差动态面(5.3), 原系统(5.1)可变换为

$$\begin{cases} \dot{z}_1 = f_1(z_1) + g_1(z_1)(z_2 + \eta_2 + v_2) \\ \dot{z}_2 = f_z(z_1, z_2, v_2) + g_z(z_1, z_2, v_2)u \\ -\tau \dot{\bar{v}}_2 = \eta_2 \end{cases} \quad (5.5)$$

其中, $\eta_2 = \bar{v}_2 - v_2$, $f_z(z_1, z_2, v_2) = f_2(z_1, z_2 + \bar{v}_2) - \dot{\bar{v}}_2$, $g_z(z_1, z_2, v_2) = g_2(z_1, z_2 + \bar{v}_2)$ 。

针对式(5.5), 本章主要目的就是设计虚拟控制 v_2 和实际控制输入 u , 使得系统动态误差 $z_1 = 0$ 。然而, 如果使用传统 Backstepping 控制方法, 就需要在每一步中针对子系统选择 Lyapunov 函数, 从而设计出稳定的控制器。但可以发现, 由于每一个子系统的状态和输入都属于高维的, 一般情况下很难设计出合理的 Lyapunov 函数。基于这种考虑, 可以得出这样的结论: 设计虚拟控制 v_2 和实际控制输入 u 的关键就在于寻找其相对应子系统的 Lyapunov 函数 $V_1(z_1)$ 和 $V_2(z_2)$ 。此外不难发现, 在传统 Backstepping 设计方法中, Lyapunov 函数的选择主要是保证闭环系统的稳定性, 但忽略了对系统最优性能的考虑。换言之, Backstepping 设计方法中, 对虚拟控制输入和实际控制输入的优化不仅能够保证闭环系统的稳定性, 还可以实现对给定性能指标函数的优化。

考虑到 ADP 技术能够通过构建评价网络在线逼近最优代价函数, 即最优 Lyapunov 函数; 而连续时间预测控制方法能够给出最优控制解析表达式, 有效降低 ADP 方法的计算复杂度, 本章将利用结合 ADP 技术和连续时间预测控制分别设计虚拟控制 v_2 和实际控制输入 u , 从而保证闭环系统的稳定性和最优性。

5.3 虚拟控制输入的设计

本节中, ADP 技术将被用于求解最优虚拟控制输入, 实现虚拟控制输入的最优化。

5.3.1 最优虚拟控制输入设计

针对 z_1 子系统, 如果选择足够小的时间常数 τ , 就可以把状态 x_2 当做虚拟控制量 v_2 来处理。此时 z_1 子系统可描述为

$$\dot{z}_1 = f_1(z_1) + g_1(z_1)v_2 \quad (5.6)$$

本节主要目的就是设计虚拟控制量 v_2 使得 z_1 子系统能够保持稳定, 同时最小化如下性能指标函数:

$$V_1(z_1) = \int_0^{\infty} \{Q_1(z_1(\tau)) + v_2(\tau)^T R_1 v_2(\tau)\} d\tau \quad (5.7)$$

其中, $Q_1(z_1)$ 是连续可微的半正定函数, $R_1 > 0$ 表示正定对称矩阵。

定义如下哈密顿函数:

$$H(z_1, v_2, \nabla V_{z_1}) = Q_1(z_1) + v_2^T R_1 v_2 + (\nabla V(z_1))^T (f_1(z_1) + g_1(z_1)v_2) \quad (5.8)$$

其中, $\nabla V(z_1)$ 表示 $V(z_1)$ 对 z_1 的偏导数。

由 Bellman 最优性原理可得, 最优代价函数 $V_1^*(z_1)$ 一定满足下列关系:

$$0 = \min_{v_2} H(z_1, v_2, \nabla V^*(z_1)) \quad (5.9)$$

如果假设等式(5.9)的最优解存在且唯一, 则根据最优解存在的必要条件 $\frac{\partial H(\cdot)}{\partial v_2} = 0$ 可得, 最优虚拟控制表达式为

$$v_2^* = -\frac{1}{2} R_1^{-1} g_1^T(z_1) \nabla V^*(z_1) \quad (5.10)$$

将式(5.10)代入式(5.9), 可得相应的 HJB 方程表达式为

$$Q_1(z_1) + (\nabla V^*(z_1))^T f_1(z_1) - \frac{1}{4} (\nabla V^*(z_1))^T g_1(z_1) R_1^{-1} g_1^T(z_1) \nabla V^*(z_1) = 0 \quad (5.11)$$

由式(5.10)和式(5.11)可知, 最优虚拟控制量 v_2^* 的设计取决于相应 HJB 方程(5.11)的求解。正如前述几章一样, 该 HJB 方程属于非线性偏微分方程, 一般情况下很难得到它的解析解形式。与前面章节类似, 下面将利用 ADP 技术, 通过构建评价网络在线逼近最优代价函数 $V^*(z_1)$, 完成最优虚拟控制量 v_2^* 的设计。

5.3.2 虚拟控制输入的实现

在构建评价网络之前给出如下假设, 便于后续稳定性分析。

假设 5.2: 针对 z_1 子系统(5.6)以及给定的性能指标函数(5.7), 在最优控制(5.10)作用下, 存在一个连续可微径向无界的 Lyapunov 函数 $J_s(z_1)$ 满足 $\dot{J}_s(z_1) = (\nabla J_s(z_1))^T (f_1(z_1) + g_1(z_1)v_2^*) < 0$ 。那么一定存在一个正定矩阵 $\Lambda(z_1)$ 使得等式 $(\nabla J_s(z_1))^T (f_1(z_1) + g_1(z_1)v_2^*) = -(\nabla J_s(z_1))^T \Lambda(z_1) \nabla J_s(z_1)$ 成立。

利用神经网络对连续非线性函数的逼近能力, 可以通过构建评价网络实现对最优代价函数

的逼近，具体表示为：

$$V_1^*(z_1) = W_c^T \sigma(z_1) + \varepsilon(z_1) \quad (5.12)$$

其中， $W_c \in \mathbb{R}^L$ 表示评价网络理想权值向量， $\sigma(z_1) \in \mathbb{R}^L$ 为所选择的激励函数，而 $\varepsilon(z_1)$ 则表示逼近误差。

对式(5.12)求偏导，可以得到

$$\nabla V^*(z_1) = (\nabla \sigma(z_1))^T W_c + \nabla \varepsilon(z_1) \quad (5.13)$$

其中， $\nabla \sigma(z_1) = \frac{\partial \sigma(z_1)}{\partial z_1}$, $\nabla \varepsilon(z_1) = \frac{\partial \varepsilon(z_1)}{\partial z_1}$ 。

将式(5.13)代入式(5.10)，最优虚拟控制可重新表示为

$$v_2^* = -\frac{1}{2} R_1^{-1} g_1^T(z_1) ((\nabla \sigma(z_1))^T W_c + \nabla \varepsilon(z_1)) \quad (5.14)$$

同样地，HJB 方程可表示为

$$Q_1(z_1) + W_c^T \nabla \sigma(z_1) f_1(z_1) - \frac{1}{4} W_c^T D(z_1) W_c + \delta_{HJB} = 0 \quad (5.15)$$

其中， $D(z_1) = \nabla \sigma(z_1) g_1(z_1) R_1^{-1} g_1^T(z_1) (\nabla \sigma(z_1))^T$ ；由逼近误差造成的残余误差项为

$$\begin{aligned} \delta_{HJB} = & (\nabla \varepsilon(z_1))^T f_1(z_1) - \frac{1}{4} (\nabla \varepsilon(z_1))^T g_1(z_1) R_1^{-1} g_1^T(z_1) \nabla \varepsilon(z_1) \\ & - \frac{1}{2} (\nabla \varepsilon(z_1))^T g_1(z_1) R_1^{-1} g_1^T(z_1) ((\nabla \sigma(z_1))^T W_c) \end{aligned} \quad (5.16)$$

但由于评价网络理想权值 W_c 未知，式(5.14)仍然不能用于控制器的实现。因此需要利用评价网络的输出逼近最优代价函数，具体表达式为

$$\hat{V}_1(z_1) = \hat{W}_c^T \sigma(z_1) \quad (5.17)$$

同样对式(5.17)求偏导可得

$$\nabla \hat{V}_1(z_1) = (\nabla \sigma(z_1))^T \hat{W}_c \quad (5.18)$$

其中， $\hat{W}_c$ 表示理想权值 W_c 的估计值；评价网络权值估计误差可定义为 $\tilde{W}_c = W_c - \hat{W}_c$ 。

基于式(5.17)，可以得到估计的最优虚拟控制输入为

$$\hat{v}_2 = -\frac{1}{2} R_1^{-1} g_1^T(z_1) (\nabla \sigma(z_1))^T \hat{W}_c \quad (5.19)$$

相应地估计的 HJB 方程可表示为

$$H(z_1, \hat{v}_2, \hat{W}_c) = Q_1(z_1) + \hat{W}_c^T \nabla \sigma(z_1) f_1(z_1) - \frac{1}{4} \hat{W}_c^T D(z_1) \hat{W}_c \stackrel{\Delta}{=} e_c \quad (5.20)$$

结合式(5.15)、式(5.18)和式(5.20)， e_c 可进一步表示成与权值估计误差 $\tilde{W}_c$ 相关的表达式

$$e_c = -\tilde{W}_c^T \nabla \sigma(z_1) f_1(z_1) - \frac{1}{4} \tilde{W}_c^T D(z_1) \tilde{W}_c + \frac{1}{2} \tilde{W}_c^T D(z_1) W_c - \delta_{HJB} \quad (5.21)$$

由式(5.21)可以看出，只要保证权值估计误差 $\tilde{W}_c \rightarrow 0$ ，即 $\hat{W}_c \rightarrow W_c$ ，则哈密顿函数 $H(z_1, \hat{v}_2, \hat{W}_c) \rightarrow 0$ 。为达到这一目的，需要设计 $\hat{W}_c$ 的权值更新律保证以下目标函数最小化，从而使得 e_c 最小化：

$$E_c = \frac{1}{2} e_c^T e_c \quad (5.22)$$

基于梯度下降法, 在考虑系统稳定性以及学习过程中信号有界性的前提下, 设计如下评价网络权值更新律:

$$\begin{aligned} \dot{\hat{W}}_c = & -\frac{\alpha_c \phi}{m_s^2} e_c + \frac{\alpha_c}{2} \nabla \sigma(z_1) g_1(z_1) R_1^{-1} g_1^T(z_1) \nabla J_s(z_1) \\ & + \alpha_c \left[\frac{1}{4} \frac{\phi}{m_s^2} \hat{W}_c^T D(z_1) \hat{W}_c - (F_2 \hat{W}_c - F_1 \phi^T \hat{W}_c) \right] \end{aligned} \quad (5.23)$$

其中, $\phi = \nabla \sigma(z_1)(f_1(z_1) + g_1(z_1)\hat{v}_2)$, $\alpha_c > 0$ 表示评价网络学习率, $m_s = (1 + \phi^T \phi)$ 主要用于闭环系统稳定性分析且 $\varphi = \phi/m_s$; F_1 和 F_2 是需要设计的调节参数, $J_s(z_1)$ 已在假设 5.2 中定义。

基于式(5.21)和式(5.23), 通过简单的数学变换, 可以得到评价网络权值估计误差动态为

$$\begin{aligned} \dot{\tilde{W}}_c = & \frac{\alpha_c \phi}{m_s^2} \left[-\phi^T \tilde{W}_c + \frac{1}{4} \tilde{W}_c^T D(z_1) \tilde{W}_c - \delta_{HJB} \right] - \frac{\alpha_c}{2} \nabla \sigma(z_1) g_1(z_1) R_1^{-1} g_1^T(z_1) \nabla J_s(z_1) \\ & - \alpha_c \left[\frac{1}{4} \frac{\phi}{m_s^2} \hat{W}_c^T D(z_1) \hat{W}_c - (F_2 \hat{W}_c - F_1 \phi^T \hat{W}_c) \right] \end{aligned} \quad (5.24)$$

基于式(5.24), 在下一节中将分析评价网络权值估计误差信号 $\tilde{W}_c$ 的有界性, 确保在所设计的更新律(5.23)作用下估计权值 $\hat{W}_c$ 最终可以有界收敛于理想权值 W_c 。

5.3.3 评价网络稳定性分析

在稳定性分析之前, 针对评价网络给出如下假设:

假设 5.3: 评价网络理想权值 W_c 有界, i.e., $\|W_c\| \leq W_M$, 其中, W_M 为正常数; 此外, 在紧集 $\Omega_{z_1} \in \mathbb{R}^n$ 内, 对于任意的 $z_1 \in \Omega_{z_1}$, 激励函数 $\sigma(z_1)$ 、逼近误差 $\varepsilon(z_1)$ 以及它们的偏导数 $\nabla \sigma(z_1)$ 和 $\nabla \varepsilon(z_1)$ 都是有界信号, 即存在正常数 $\sigma_M, \zeta_M, \varepsilon_M$ 和 b_{cm} , 满足不等式 $\|\sigma(z_1)\| < \sigma_M, \|\varepsilon(z_1)\| \leq \varepsilon_M, \|\nabla \sigma(z_1)\| < \zeta_M$ 和 $\|\nabla \varepsilon(z_1)\| \leq b_{cm}$; 另外, 残余误差信号 δ_{HJB} 也是有界的, 满足 $\|\delta_{HJB}\| \leq \delta_{HM}$, 式中 δ_{HM} 为正常数。

定理 5.1: 针对 z_1 子系统(5.6)以及性能指标函数(5.7), 设计最优虚拟控制输入如式(5.19)所示, 并且设计评价网络权值更新律如式(5.23)所示。在假设 5.1-假设 5.3 成立的前提下, 可以保证评价网络权值估计误差信号 $\tilde{W}_c$ 是最终一致有界的。

证明: 选择如下 Lyapunov 函数

$$L_1(z_1) = \frac{1}{2} \tilde{W}_c^T \alpha_c^{-1} \tilde{W}_c + J_s(z_1) \quad (5.25)$$

对式(5.25)求导可得

$$\dot{L}_1(z_1) = \tilde{W}_c^T \alpha_c^{-1} \dot{\tilde{W}}_c + (\nabla J_s(z_1))^T \dot{z}_1 \quad (5.26)$$

首先考虑第一项, 将式(5.24)代入整理可得

$$\begin{aligned} \tilde{W}_c^T \alpha_c^{-1} \dot{\tilde{W}}_c = & \tilde{W}_c^T \frac{\phi}{m_s^2} \left\{ -\phi^T \tilde{W}_c + \frac{1}{4} \tilde{W}_c^T D(z_1) \tilde{W}_c - \delta_{HJB} \right\} - \frac{1}{2} \tilde{W}_c^T \nabla \sigma(z_1) g_1(z_1) R_1^{-1} g_1^T(z_1) \nabla J_s(z_1) \\ & - \tilde{W}_c^T \left[\frac{1}{4} \frac{\phi}{m_s^2} \hat{W}_c^T D(z_1) \hat{W}_c - (F_2 \hat{W}_c - F_1 \phi^T \hat{W}_c) \right] \end{aligned} \quad (5.27)$$

通过等式关系 $\tilde{W}_c = W_c - \hat{W}_c$ ，对式(5.27)进行数学变换，整理可得

$$\begin{aligned} \tilde{W}_c^T \alpha_c^{-1} \dot{\tilde{W}}_c &= \tilde{W}_c^T \frac{\phi}{m_s^2} (-\phi^T \tilde{W}_c - \delta_{HJB}) + \frac{1}{2} \tilde{W}_c^T \frac{\phi}{m_s^2} W_c^T D(z_1) \tilde{W}_c \\ &\quad - \frac{1}{4} \tilde{W}_c^T \frac{\phi}{m_s^2} W_c^T D(z_1) W_c + \tilde{W}_c^T (F_2 \hat{W}_c - F_1 \phi^T \hat{W}_c) \\ &\quad - \frac{1}{2} \tilde{W}_c^T \nabla \sigma(z_1) g_1(z_1) R_1^{-1} g_1^T(z_1) \nabla J_s(z_1) \end{aligned} \quad (5.28)$$

另外，下列等式关系成立

$$\tilde{W}_c^T (F_2 \hat{W}_c - F_1 \phi^T \hat{W}_c) = \tilde{W}_c^T F_2 W_c - \tilde{W}_c^T F_2 \tilde{W}_c - \tilde{W}_c^T F_1 \phi^T W_c + \tilde{W}_c^T F_1 \phi^T \tilde{W}_c \quad (5.29)$$

定义变量 $X = [\phi^T \tilde{W}_c, \tilde{W}_c]^T$ ，式(5.28)可整理为

$$\tilde{W}_c^T \alpha_c^{-1} \dot{\tilde{W}}_c = -X^T M X + X^T N - \frac{1}{2} \tilde{W}_c^T \nabla \sigma(z_1) g_1(z_1) R_1^{-1} g_1^T(z_1) \nabla J_s(z_1) \quad (5.30)$$

其中，

$$M = \begin{bmatrix} I & -\frac{1}{2} F_1^T \\ -\frac{1}{2} F_1 & F_2 - \frac{1}{2} \frac{\phi}{m_s^2} W_c^T D(z_1) \end{bmatrix}, \quad N = \begin{bmatrix} \frac{\delta_{HJB}}{m_s} \\ \left(F_2 - F_1 \phi^T - \frac{1}{4} \frac{\phi}{m_s^2} W_c^T D(z_1) \right) W_c \end{bmatrix}.$$

观察式(5.30)，可以通过选择设计参数 F_1 和 F_2 使得矩阵 $M > 0$ ，则下列不等式成立

$$\tilde{W}_c^T \alpha_c^{-1} \dot{\tilde{W}}_c \leq -\lambda_{\min}(M) \|X\|^2 + \|N\| \|X\| - \frac{1}{2} \tilde{W}_c^T \nabla \sigma(z_1) g_1(z_1) R_1^{-1} g_1^T(z_1) \nabla J_s(z_1) \quad (5.31)$$

其中， $\lambda_{\min}(M)$ 表示矩阵 M 的最小特征值。

结合式(5.31)，式(5.26)可变换为

$$\begin{aligned} \dot{L}_1(z_1) &\leq -X^T M X + X^T N - \frac{1}{2} \tilde{W}_c^T \nabla \sigma(z_1) g_1(z_1) R_1^{-1} g_1^T(z_1) \nabla J_s(z_1) \\ &\quad + (\nabla J_s(z_1))^T (f_1(z_1) + g_1(z_1) \hat{v}_2) \end{aligned} \quad (5.32)$$

通过最优虚拟控制输入(5.14)和逼近的虚拟控制输入(5.19)得

$$v_2^* - \hat{v}_2 = -\frac{1}{2} R_1^{-1} g_1^T(z_1) ((\nabla \sigma(z_1))^T \tilde{W}_c + \nabla \varepsilon(z_1)) \quad (5.33)$$

基于式(5.33)，可将式(5.32)变换为如下形式：

$$\begin{aligned} \dot{L}_1(z_1) &\leq (\nabla J_s(z_1))^T (f_1(z_1) + g_1(z_1) v_2^*) - \lambda_{\min}(M) \|X\|^2 + \|N\| \|X\| \\ &\quad + \frac{1}{2} (\nabla \varepsilon(z_1))^T g_1(x) R_1^{-1} g_1^T(z_1) \nabla J_s(z_1) \end{aligned} \quad (5.34)$$

考虑假设 5.1 和假设 5.3，可得 $\|g_1(x) R_1^{-1} g_1^T(z_1)\| < \kappa$ ，式中 κ 为正常数。进一步考虑假设 5.2，式(5.34)可表示为

$$\dot{L}_1(z_1) \leq -\lambda_{\min}(\Lambda) \|\nabla J_s(z_1)\|^2 - \lambda_{\min}(M) \|X\|^2 + \|N\| \|X\| + \frac{1}{2} b_{cM} \kappa \|\nabla J_s(z_1)\| \quad (5.35)$$

通过不等式(5.35)可以知，只要下列不等式成立，则可保证 $\dot{L}_1(z_1) < 0$ ：

$$\|\nabla J_s(z_1)\| > \sqrt{\frac{\|N\|^2}{4\lambda_{\min}(M)\lambda_{\min}(\Lambda)} + \frac{b_{cM}^2 \kappa^2}{16\lambda_{\min}^2(\Lambda)}} + \frac{b_{cM} \kappa}{4\lambda_{\min}(\Lambda)} \quad (5.36)$$

或

$$\|X\| > \sqrt{\frac{\|N\|^2}{4\lambda_{\min}^2(M)} + \frac{b_{CM}^2 \kappa^2}{16\lambda_{\min}(\Lambda)\lambda_{\min}(M)}} + \frac{\|N\|}{2\lambda_{\min}(M)} \quad (5.37)$$

由 Lyapunov 稳定性定理可得, 评价网络权值估计误差信号 $\tilde{W}_c$ 是最终一致有界的。

5.4 实际控制输入设计

基于上一节设计, z_1 子系统的虚拟控制输入 v_2 已经获得。本节需要考虑 z_2 子系统, 设计实际控制输入 v 。由于 ADP 技术在线逼近最优代价函数, 会给计算机带来很大的计算负担, 引入连续时间预测控制方法, 采用离线方式给出最优控制解析表达式, 降低计算复杂度。

这里考虑如下 z_2 子系统

$$\begin{cases} \dot{z}_2 = f_z(z_1, z_2, v_2) + g_z(z_1, z_2, v_2)u \\ y(t) = h(z_2) = z_2 \end{cases} \quad (5.38)$$

其中, $y \in \mathbb{R}^n$ 表示 z_2 子系统的输出信号。此时假设系统(5.38)中, 输出对输入的相对度为 r 。

本节的主要目的就是: 在下列给定的性能指标函数下, 设计一个近似最优控制器 $u(t)$, 保证闭环系统的稳定性:

$$\begin{aligned} & \min J(t) \\ & \text{s. t. } \dot{z}_2 = f_z(z_1, z_2, v_2) + g_z(z_1, z_2, v_2)u \\ & \quad y(t) = h(z_2) \end{aligned} \quad (5.39)$$

其中, $J(t)$ 表示性能指标函数, 具体表达式为

$$J(t) = \frac{1}{2}[y(t+\delta)]^T Q_2[y(t+\delta)] + \frac{1}{2}u^T(t+\delta)R_2u(t+\delta) \quad (5.40)$$

其中, $Q_2 \geq 0 \in \mathbb{R}^{n_2 \times n_2}$ 和 $R_2 \geq 0 \in \mathbb{R}^{m \times m}$ 均为半正定函数, $\delta > 0$ 表示预测时间。

通过对系统在 $t+\delta$ 时刻的输出信号 $y(t+\delta)$ 和控制输入 $u(t+\delta)$ 泰勒展开, 可以得到

$$\begin{cases} y(t+\delta) \approx y(t) + \delta \dot{y}(t) + \frac{\delta^2}{2!} \ddot{y}(t) + \cdots + \frac{\delta^r}{r!} y^{(r)}(t) \\ u(t+\delta) \approx u(t) \end{cases} \quad (5.41)$$

通过 Lie 导数相关概念^[166], 可以计算得到 $y(t)$ 的各阶导数

$$\begin{cases} \dot{y}(t) = \frac{\partial(h(z_2))}{\partial z_2} \dot{z}_2 = L_{f_z} h(z_2) \\ y^{(r-1)}(t) = L_{f_z}^{r-1} h(z_2) \\ y^{(r)}(t) = L_{f_z}^r h(z_2) + \frac{\partial L_{f_z}^{r-1} h(z_2)}{\partial z_2} g_z(z_2)u(t) \\ \quad = L_{f_z}^r h(z_2) + L_{g_z} L_{f_z}^{r-1} h(z_2)u(t) \end{cases} \quad (5.42)$$

定义 $w(\delta) = \left[1, \delta, \dots, \frac{\delta^{r-1}}{(r-1)!}, \frac{\delta^r}{r!}\right]^T$ 和 $Y(t) = [y(t), \dot{y}(t), \dots, y^{(r-1)}(t), y^{(r)}(t)]$, 则 $y(t+\delta)$ 可表示为

$$y(t+\delta) \approx Y(t)w(\delta) + \frac{\delta^r}{r!} L_{g_z} L_{f_z}^{r-1} h(z_2)u(t) \quad (5.43)$$

接着把式(5.43)代入性能指标函数(5.40), 整理可得

$$\begin{aligned}
J(t) &\approx \frac{1}{2} \left[Y(t)w(\delta) + \frac{\delta^r}{r!} L_{g_z} L_{f_z}^{r-1} h(z_2) u(t) \right]^T Q_2 \left[Y(t)w(\delta) + \frac{\delta^r}{r!} L_{g_z} L_{f_z}^{r-1} h(z_2) u(t) \right] + \frac{1}{2} u^T(t) R_2 u(t) \\
&= \frac{1}{2} w^T(\delta) Y^T(t) Q_2 Y(t) w(\delta) + \frac{\delta^r}{r!} w^T(\delta) Y^T(t) Q_2 L_{g_z} L_{f_z}^{r-1} h(z_2) u(t) \\
&\quad + \frac{1}{2} \frac{\delta^{2r}}{(r!)^2} u^T(t) (L_{g_z} L_{f_z}^{r-1} h(z_2))^T Q_2 L_{g_z} L_{f_z}^{r-1} h(z_2) u(t) + \frac{1}{2} u^T(t) R_2 u(t)
\end{aligned} \quad (5.44)$$

基于最优控制解存在的必要条件 $\frac{\partial J(t)}{\partial u(t)} = 0$ ，可得 z_2 子系统最优控制解析表达式为

$$u(t) = - \left(R_2 + \kappa \left(L_{g_z} L_{f_z}^{r-1} h(z_2) \right)^T Q_2 L_{g_z} L_{f_z}^{r-1} h(z_2) \right)^{-1} \left(L_{g_z} L_{f_z}^{r-1} h(z_2) \right)^T Q_2 Y(t) v \quad (5.45)$$

其中， $\kappa = \frac{\delta^{2r}}{(r!)^2}$ ， $v = \frac{\delta^r}{r!} w(\delta)$ 。

注释 5.2: 从最优控制解析表达式(5.45)可以看出，当系统输出为 $y = z_2$ ，相对度为 $r=1$ 时，最优控制(5.45)可简化为 $u(t) = -(R_2 + \delta^2 g_z^T Q_2 g_z)^{-1} g_z^T Q_2 (z_2 + \delta f_z) \delta$ 。从中可以看出最优控制 $u(t)$ 的大小可以通过参数 Q_2, R_2 和 δ 的选择来调节。如果进一步选择 $R_2 = 0$ ，则最优控制可简化为 $u(t) = -g_z^{-1} \left[\frac{1}{\delta} z_2 + f_z \right]$ 。值得注意的是，在 Backstepping 控制方法中，当选择设计参数 $k_2 = \frac{1}{\delta}$ 时，与该控制器结构具有相同的表达式。因此可以得出这样的结论：本章提出的预测最优控制方法不仅能够保证闭环系统的最优性，还可以表现出 Backstepping 设计方法的优越性。

基于上述分析，得出如下主要定理：

定理 5.2: 针对系统(5.1)，在假设条件成立的前提下，选择足够小的时间常数 τ ，此时如果设计虚拟控制输入 v_2 为(5.19)，评价网络权值更新律为(5.23)；在性能指标(5.40)约束下，设计实际控制输入为(5.45)，那么通过选择设计参数可以保证闭环系统所有信号都是最终一致有界的。

证明：首先，基于定理 5.1，评价网络权值估计误差信号 $\tilde{w}_c$ 是有界的，从而使得虚拟控制输入(5.19)能够保证 z_1 子系统闭环稳定。接着需要重点分析在最优控制输入(5.45)作用下， z_2 子系统的稳定性。根据文献[163]的分析，可以知道对于非线性广义预测控制方法，闭环系统稳定性与系统的相对度和控制阶数有关。文献[163]已经证明，当系统相对度与控制阶数的差值小于 4 时，在非线性广义预测控制作用下闭环系统始终稳定。感兴趣的读者可参考文献[13]。

注释 5.3: 本章通过将 ADP 技术与连续时间预测控制相结合，提出了离线-在线复合控制模式；一方面给出最优控制解析解形式，有效降低了控制器计算复杂度；另一方面通过利用 ADP 技术在线学习的优点，降低了连续时间预测控制对系统模型的依赖，有效提高了控制器的鲁棒性。

5.5 仿真验证

为验证所提方案的有效性，本节将设计的控制器应用于导弹拦截制导系统中。考虑前述几章建立的拦截制导系统

$$\begin{aligned}
\dot{x}_1 &= x_2 \\
\dot{x}_2 &= -\frac{2V_r}{r} x_2 - \frac{\cos(\alpha - \theta)}{r} u_M + \frac{\cos(\beta - \theta)}{r} v_T
\end{aligned} \quad (5.46)$$

针对导弹拦截机动目标的过程，不妨先作出一些合理的假设。

假设 5.4: 导弹和目标的控制输入均有界，即 $|u_M| \leq u_{\max}$ 和 $|v_T| \leq v_{\max}$ ，式中 $u_{\max}$ 和 $v_{\max}$ 表示界值。另外，假设机动目标的飞行速度 v_T 有界，即存在一个正常数 $v_{T\max}$ ，满足 $|v_T| \leq v_{T\max}$ 。

在本节中，假设导弹与目标的飞行速度分别为 $V_M = 600 \text{ m/s}$ 和 $V_T = 400 \text{ m/s}$ ，自动驾驶仪时间常数为 $\tau_M = \tau_T = 0.1$ ；导弹与目标的初始航迹角假设为 $\alpha_0 = \pi/6 \text{ rad}$ 和 $\beta_0 = \pi/3 \text{ rad}$ 。导弹初始位置坐标设定为 $(x_M, y_M) = (0, 0)$ ，目标初始位置坐标设定为 $(x_T, y_T) = (2500, 0)$ 。

在虚拟控制输入中，选择评价网络激励函数为 $\sigma(z_1) = [z_1, z_1^2, z_1^4]^T$ ，初始权值设定为零向量；选择 $Q_1(z_1) = 0.01z_1^2$ 和 $R_1 = 0.1$ ；调节参数设计为 $F_1 = 20 \cdot [1, 1, 1]^T$ 和 $F_2 = 2I$ ，式中 I 表示相应维数的单位矩阵；学习率 $\alpha_c = 0.5$ ，Lyapunov 函数选为 $J_s(z_1) = 0.5z_1^2$ ；一阶低通滤波器中时间常数为 $\tau = 0.01$ ；为保证评价网络学习过程中信号满足持续激励条件，在控制器开始学习的前 2s 内加入一个较小的有界探索信号 $n(t) = 0.1\sin^5(t)\cos(t) + 0.05\sin^5(2t)\cos(0.2t)$ 。

而在实际最优控制输入中，选择预测时间为 $\delta = 15$ ，矩阵为 $Q_2 = 1000$ 和 $R_2 = 0.005$ 。另外，考虑实际拦截制导过程中，导弹往往会受到过载饱和等物理约束，为此在本节中假设导弹的输入约束为 $|u_M| \leq 200 \text{ m/s}^2$ 。在控制器的执行过程中，为防止执行器饱和，对导弹饱和控制输入作如下处理：

$$u_s = \text{sat}(u_M) \quad (5.47)$$

其中，饱和输入 $\text{sat}(u_M)$ 表示为

$$\text{sat}(u_M) = \begin{cases} \text{sign}(u_M)u_{\max}, & |u_M| \geq u_{\max} \\ u_M, & |u_M| < u_{\max} \end{cases}$$

其中， $u_{\max}$ 表示导弹输入 u_M 的界值， $\text{sign}(\cdot)$ 为符号函数。

接下来，我们将针对目标在不同机动性情形，通过与动态面(Dynamic Surface Control, DSC)制导方法以及传统的比例导引(Proportional Navigation, PN)方法进行仿真对比，验证本章所提自适应预测最优制导方法的有效性。

情形 1：目标以阶跃形式机动

在此情形下，假设目标以幅值为 $5g$ ，即 $a_T = 5g$ ，的阶跃形式的机动躲避导弹的拦截。仿真结果如图 5.1-图 5.3 所示，其中，图 5.1(a)给出了在不同制导律作用下，导弹拦截机动目标的轨迹曲线；从中可以清晰地表明所有制导律均可保证导弹成功拦截目标。图 5.1(b)给出了在不同制导律作用下导弹的侧向加速度曲线。可以看出本章提出的自适应预测制导方法与 PN 制导方法表现出相似的性能，但 DSC 制导方法需要更大的控制能量。图 5.2 给出了不同制导方法作用下导弹视线角速率和相对速率变化曲线。图 5.3(a)刻画了自适应预测最优制导方法中评价网络权值变化曲线；从中可以看出，评价网络权值经过一段时间的学习最终收敛于理想值。图 5.3(b)给出了三种制导方法下控制能量 $\|u_M\|^2$ 的变化曲线；可以看到，DSC 制导方法所需控制能量远远

大于其他两种制导方法。




图 5.1(a) 导弹-目标拦截轨迹




图 5.1(b) 导弹侧向加速度

图 5.1 自适应预测最优制导轨迹和侧向加速度（目标阶跃机动）




图 5.2(a) 导弹视线角速率




图 5.2(b) 导弹-目标相对速率

图 5.2 自适应预测最优制导下导弹视线角速率和相对速率（目标阶跃机动）




图 5.3(a) 评价网络权值




图 5.3(b) 导弹控制能量

图 5.3 自适应预测最优制导下评价网络权值和导弹控制能量（目标阶跃机动）

此外，表 5.1 中给出了各制导方法作用下导弹拦截机动目标的最小脱靶量。从表 5.1 中可以看到，DSC 制导精度要高于本章提出的自适应预测最优制导和 PN 制导。但从控制能量中可以看出，DSC 所需控制能量远大于其他两种制导方法。也就是说，DSC 制导方法需要以消耗更多的能量来换取更高的制导精度。另一方面，自适应预测最优制导精度虽然低于 DSC 制导精度，但制导性能相当。尤其是自适应预测最优制导方法在控制能量方面明显优于 DSC 制导。而自适应预测制导与 PN 制导相比，在控制能量相当的情况下能够表现出较好的制导精度。可以这样认为，本章提出的自适应预测制导方法能够以较小的控制能量取得较高的制导精度，这从侧面体现了最优控制主要思想，验证了该方法的有效性。

情形 2: 目标以正弦形式机动

在此情形下, 假设机动目标的侧向加速度为 $a_T = 100\sin(t + 0.1) \text{ m/s}^2$ 。仿真结果如图 5.4-图 5.6 所示, 从脱靶量角度看, DSC 制导方法优于其他两种制导方法, 具体脱靶量信息如表 5.1 所示。但从图 5.6(b)中可以明显看到, DSC 制导方法所需的控制能量远远大于其他两种制导方法, 而且出现了输入饱和问题, 并由此表现出振荡现象, 这也正是 DSC 制导方法本身固有的缺陷, 即由于控制输入过大而导致系统响应出现振荡现象。而自适应预测最优制导方法在脱靶量方面优于 PN 制导, 但在控制输入、弹道特性等其他性能方面却与 PN 制导方法表现出极其相似的特性。




图 5.4(a) 导弹-目标拦截轨迹




图 5.4(b) 导弹侧向加速度

图 5.4 自适应预测最优制导轨迹和导弹侧向加速度 (目标正弦机动)




图 5.5(a) 导弹视线角速率




图 5.5(b) 导弹-目标相对速率

图 5.5 自适应预测最优制导下导弹视线角速率和相对速率 (目标正弦机动)




图 5.6(a) 评价网络权值




图 5.6(b) 导弹控制能量

图 5.6 自适应预测最优制导下评价网络权值和导弹控制能量 (目标正弦机动)

情形 3: 目标以方波形式机动

在此情形下, 目标以幅值为 $10g$, 周期为 $5s$ 的方波形式机动试图躲避拦截。仿真结果如图 5.7-图 5.9 所示。制导精度如表 5.1 所示, 与前两种情形类似, DSC 制导精度 ($\approx 0.032 m$) 与自适应预测最优制导精度 ($\approx 0.016 m$) 基本相当, 但高于 PN 制导精度 ($\approx 1.72 m$), 但 DSC 制导方法所需控制能量远大于其他两种制导方法。而在弹道特性方面, 自适应预测最优制导与 PN 制导类似, 具有相似的弹道特性, 且控制能量相当, 但自适应预测最优制导在制导精度方面却优于 PN 制导。这进一步表明了本章提出的自适应预测最优制导方法能够以最小的控制代价获得最好的控制效果, 从而说明该方法的优越性。




图 5.7(a) 导弹-目标拦截轨迹




图 5.7(b) 导弹侧向加速度

图 5.7 自适应预测最优制导轨迹和导弹侧向加速度 (目标方波机动)




图 5.8(a) 导弹视线角速率




图 5.8(b) 导弹-目标相对速率

图 5.8 自适应预测最优制导下导弹视线角速率和相对速率 (目标方波机动)




图 5.9(a) 评价网路权值




图 5.9(b) 导弹控制能量

图 5.9 自适应预测最优制导下评价网络权值和导弹控制能量 (目标方波机动)

表 5.1 不同目标机动下各制导方法脱靶量对比

	目标机动		
	常值	正弦波	方波
本文制导方法	0.097	0.758	0.032
DSC 制导方法	0.015	0.014	0.016
PN 制导方法	1.93	1.41	1.72

从以上仿真结果可以看出,在不同目标机动下 DSC 制导精度均优于本章所提自适应预测最优制导精度。这主要是因为自适应预测最优制导中采用 ADP 技术在线更新策略,利用评价网络逼近最优代价函数,这就存在一定的学习训练时间,从而导致制导律精度有所下降;但自适应预测最优制导在控制能量上与 DSC 制导方法相比,表现出优势明显。

为了进一步验证自适应预测最优制导方法的性能,考虑系统状态信息在获取过程中存在量测噪声的情况。假设拦截制导过程中,导弹视线角速率 σ 被均值为 0, 方差为 0.1 rad/s 的高斯白噪声污染,此时系统制导性能会因为测量信息的不精确而下降。同样考虑目标不同机动下,分析三种制导方法的优越性。经仿真分析,各制导方法在不同目标机动情形下的脱靶量信息如表 5.2 所示:

表 5.2 存在量测噪声情况下各制导方法脱靶量对比

	目标机动		
	常值	正弦波	方波
本文制导方法	1.00	0.78	0.71
DSC 制导方法	16.54	22.57	37.51
PN 制导方法	69.88	5.54	61.26

表 5.2 清楚地表明,存在量测噪声情况下,本章所提自适应预测最优制导方法在制导精度上明显优于其他两种制导方法,而 DSC 制导方法和 PN 制导方法的鲁棒性明显降低。特别是,DSC 制导方法在三种不同目标机动情形下,均没有表现出很好的制导性能,这主要是因为 DSC 制导方法对模型依赖性比较强,不具备自学习功能,导致该制导方法鲁棒性较差,而本章提出的自适应预测最优制导方案,由于采用了离线-在线控制模式,可以通过在线自学习的方式适应外部环境变化,调整控制参数,从而提高了制导系统的鲁棒性。总之,从表 5.2 的仿真结果可以看出,本章提出的自适应预测最优制导方法不仅能够保证系统的最优性,还可以提高制导系统鲁棒性,表现出一定的优越性。

接着,继续讨论不同预测时间下导弹的制导性能。从式(5.45)可以看出,预测时间 δ 实质上充当着控制增益的角色。它的大小不会破坏系统的稳定性,而仅仅是影响闭环系统的收敛速率。为了验证这一性能,假设目标做正弦机动,即 $a_T = 100\sin(t + 0.1) \text{ m/s}^2$,此时选择不同预测时间 $\delta = 0.6, 2, 10$ 。仿真结果如图 5.10 所示。




图 5.10(a) 导弹-目标拦截轨迹

图 5.10(b) 导弹侧向加速度

图 5.10 自适应预测最优制导轨迹和导弹侧向加速度（不同预测时间）

从仿真结果可以看出，选择的预测时间越小，拦截制导系统的收敛速率越快，即导弹拦截机动目标的时间更短；但选择越小的预测时间所需的控制能量会越大，这也恰恰是控制器设计中控制增益的作用效果。

另外，随着导弹越来越接近目标，机动目标试图主动规避。此时导弹需要更快的反应速度和更大的机动能力。此时希望预测时间 δ 能够随着导弹与目标的相对距离逐渐减小，从而保证导弹制导性能。为此，可以将预测时间 δ 选取为一个时变指数衰减的变量，即 $\delta = 20e^{-0.5t}$ 。仿真结果如图 5.11 所示，从中可以看出导弹能够成功拦截机动目标，这进一步验证了本章所提算法的有效性。




图 5.11(a) 导弹-目标拦截轨迹

图 5.11(b) 导弹侧向加速度

图 5.11 自适应预测最优制导轨迹和导弹侧向加速度（时变预测时间）

5.6 本章小结

本章通过将 ADP 技术与连续时间预测控制方法相结合，针对 MIMO 非线性块严格反馈系统，提出了一种基于离线-在线控制结构的自适应预测最优控制方法。一方面，通过采用连续时间预测控制方法给出最优控制解析表达式，有效降低了控制器的计算复杂度；另一方面，利用 ADP 技术，通过构建评价网络，在线逼近虚拟控制输入，保证了所设计虚拟控制输入的最优性；优化了传统 Backstepping 控制方法中虚拟控制输入的设计过程。基于离线-在线控制结构，本章所提出的自适应预测最优控制方法不仅能够保证闭环系统的稳定性和最优性，还表现出良好的鲁棒性。最后将所提方法应用于导弹拦截机动目标的制导过程中。通过对不同机动目标情形下，

与其他制导方法进行仿真对比,表明了本章所提自适应预测最优控制方法的有效性。但该方法仍然要求全部的系统动态信息,这在一定程度上限制了它的应用范围。因此,如何充分利用 ADP 技术自学习特点,研究系统模型未知情况下的自适应预测最优控制方法具有重要的意义,值得以后进一步的研究。

第六章 基于ADP技术的多弹分布式最优协同拦截制导

6.1 引言

随着航空航天技术的快速发展,现代各类高速、智能、大机动目标不断出现。它们通常会采取主动规避的策略,甚至使用各种干扰手段(如伪装、隐蔽、欺骗等)试图躲避拦截,从而达到突防的目的,这就给传统拦截制导方式带来了巨大的挑战,因此多弹协同拦截制导方法得到很多科研工作者的青睐。多弹协同拦截制导通常采用多枚导弹从不同方位共同拦截或攻击目标,不仅能够有效提高导弹突防和攻击能力,同时也更加符合现代信息化战争思想中协同作战的理念。另外,多枚导弹之间通过数据链实现信息共享,战术协同,可以形成全方位、零死角的对空防御体系,有效提高拦截制导系统的稳定性和鲁棒性。

近年来,多导弹协同制导问题得到了持续的关注并取得了一些研究成果^[167-169]。从理论角度看,多弹协同制导问题实质上属于多智能体一致性问题范畴。因此利用多智能系统的分布式一致性理论研究多弹协同制导问题具有很大的发展潜力和应用前景^[170-172]。自适应动态规划(ADP)技术作为一种新兴起近似最优控制方法,融合了机器学习、智能控制以及最优控制等现代控制方法,是一种具有计算智能的控制方法。基于此,本章将ADP技术应用于多导弹协同拦截制导问题,发展一种具有在线学习功能的自主智能的分布式自适应最优制导方法,这不仅有助于提高拦截制导系统的制导性能,还可以拓宽ADP技术在多智能系统中的控制问题,对丰富和发展ADP算法具有重要的意义。

6.2 预备知识及问题描述

6.2.1 图论

假设图 $G=(\mathcal{V}, \mathcal{E})$ 表示 N 个智能体组成的多智能体系统之间的通信拓扑结构,其中, $\mathcal{V}=\{1, 2, \dots, N\}$ 表示图 G 的节点集合,即 N 个智能体的集合; $\mathcal{E}=\{(i, j): i, j \in \mathcal{V}\} \subseteq \mathcal{V} \times \mathcal{V}$ 为边集,表示各智能体之间信息传输通道。如果 $(i, j) \in \mathcal{E}$,则表明智能体 j 是智能体 i 的邻域智能体,并且智能体 i 能够接收到智能体 j 的信息;反之亦然。进一步把智能体 i 的所有邻域智能体的集合表示为 $N_i=\{j \in \mathcal{V}: (i, j) \in \mathcal{E}\}$;如果对于任意两个节点有 $(i, j) \in \mathcal{E}$ 时,存在 $(j, i) \in \mathcal{E}$,那么图 G 就称为无向图;否则,图 G 称为有向图。图 G 的邻接矩阵定义为 $\mathcal{A}=[a_{ij}] \in \mathbb{R}^{N \times N}$,其中矩阵元素 a_{ij} 定义如下:如果 $(i, j) \in \mathcal{E}$,则元素 $a_{ij}=1$;否则, $a_{ij}=0$ 。 $\mathcal{D}=\text{diag}[d_1, \dots, d_N]$ 表示图 G 的入度矩阵,其中, $d_i=\sum_{j \in N_i} a_{ij}$ 。本章假设图 G 为强联通的有向图且 $a_{ii}=0$,即在图 G 中任意两个节点之间总存在一条有向路径且图 G 没有自环。定义图 G 的拉普拉斯矩阵(Laplacian matrix)为 $\mathcal{L}=\mathcal{D}-\mathcal{A}$ 。

另外,智能体 i 与领导者之间的连接矩阵定义为 $\mathcal{B}=\text{diag}[b_1, \dots, b_N]$,式中如果智能体 i 能够

接收到领导者信息，则 $b_i = 1$ ；否则， $b_i = 0$ 。

6.2.2 问题描述

考虑一类由 N 个跟随者和一个领导者组成的具有输入饱和约束的不确定非线性多智能体系统，其中第 i 智能体可表示为如下具有严格反馈形式的非线性系统：

$$\begin{cases} \dot{x}_{i,q} = f_{i,q}(\bar{x}_{i,q}) + g_{i,q}(\bar{x}_{i,q})x_{i,q+1}, & q=1, 2, \dots, n_i-1 \\ \dot{x}_{i,n_i} = f_{i,n_i}(\bar{x}_{i,n_i}) + g_{i,n_i}(\bar{x}_{i,n_i})u_i(v_i) \\ y_i = x_{i,1}, & i=1, 2, \dots, N \end{cases} \quad (6.1)$$

其中， $\bar{x}_{i,q} = [x_{i,1}, \dots, x_{i,q}]^T \in \mathbb{R}^q$ 表示第 i 个跟随者的状态， $u_i(v_i) \in \mathbb{R}$ 为饱和控制输入， $y_i \in \mathbb{R}$ 表示系统输出； $f_{i,q}(\bar{x}_{i,q}) \in \mathbb{R}$ 是未知的非线性光滑函数且满足 $f_{i,q}(0) = 0$ ； $g_{i,q}(\bar{x}_{i,q}) \in \mathbb{R}$ 表示已知的非线性函数。本章中假设饱和输入 $u_i(v_i)$ 满足以下关系：

$$u_i(v_i) = \begin{cases} -u_{i,L} & \text{if } v_i \leq -u_{i,L} \\ v_i & \text{if } -u_{i,L} < v_i < u_{i,H} \\ u_{i,H} & \text{if } v_i \geq u_{i,H} \end{cases} \quad (6.2)$$

其中， $u_{i,L}$ 和 $u_{i,H}$ 分别表示饱和控制输入 $u_i(v_i)$ 的上下界， v_i 为需要设计的控制输入指令。

本章主要目的就是设计分布式自适应最优控制输入 v_i ，保证闭环系统所有信号都是有界的；同时所有跟随者的输出 $y_i, i=1, \dots, N$ 都能够以最优方式一致跟随领导者信号 $r(t)$ ；并保证控制输入能够在给定的饱和约束范围内。

基于此，为方便后续设计，首先针对系统(6.1)给出如下假设和引理：

假设 6.1 ^[122]：存在两个正常数 $g_{\min}^{i,q}$ 和 $g_{\max}^{i,q}$ ，使得非线性函数 $g_{i,q}(\cdot)$ 满足 $g_{\min}^{i,q} \leq |g_{i,q}(\cdot)| \leq g_{\max}^{i,q}$ 。

假设 6.2 ^[173]：领导者信号 $r(t) \in \mathbb{R}$ 以及它的一阶导数 $\dot{r}(t) \in \mathbb{R}$ 都是连续的；并且只要满足条件 $b_i \neq 0, i=1, 2, \dots, N$ ，则智能体 i 就可以得到领导者信息。

引理 6.1 ^[174]：如果光滑非线性函数 $f(x)$ 在紧集 Ω 内是连续的，则一定存在一个神经网络结构，使得对于任意的常数 $\varepsilon > 0$ ，都有

$$\sup_{x \in \Omega} |f(x) - \theta^T \phi(x)| \leq \varepsilon \quad (6.3)$$

其中， θ 表示神经网络理想权值， $\phi(x)$ 为激励函数。

6.3 分布式前馈控制输入设计

本节中，利用指令滤波 Backstepping 控制方法，通过设计分布式前馈控制输入，将原非线性多智能体系统的分布式跟踪控制问题转化为等效局部一致跟踪误差动态的分布式最优调节控制问题。

定义如下局部邻域误差动态面：

$$\begin{cases} z_{i,1} = \sum_{j=1}^N a_{i,j}(y_i - y_j) + b_i(y_i - r) \\ z_{i,q} = x_{i,q} - \bar{\alpha}_{i,q}, \quad q = 2, \dots, n_i - 1 \\ z_{i,n_i} = x_{i,n_i} - \bar{\alpha}_{i,n_i} - \chi_i^*, \\ i = 1, 2, \dots, N \end{cases} \quad (6.4)$$

其中, $\bar{\alpha}_{i,q}$ 为分布式虚拟控制输入 $x_{i,qd}$ 通过一阶指令滤波器之后的输出信号; 而虚拟控制输入 $x_{i,qd}$ 定义为 $x_{i,qd} = x_{i,qd}^a + x_{i,qd}^*$, $x_{i,qd}^a$ 表示分布式自适应前馈虚拟控制输入, 前馈实际控制输入 v_i^a 将会在最后一步设计中出现; $x_{i,qd}^*$ 表示分布式自适应最优反馈控制输入。

一阶指令滤波器设计为

$$\tau_{i,q} \dot{\bar{\alpha}}_{i,q} + \bar{\alpha}_{i,q} = x_{i,qd}, \quad \bar{\alpha}_{i,q}(0) = x_{i,qd}(0) \quad (6.5)$$

其中, $\tau_{i,q}$ 为滤波器时间常数。

接下来, 将通过 n_i 步设计分布式前馈控制输入, 具体步骤为:

第 1 步: 基于局部邻域误差动态面(6.4), 对误差信号 $z_{i,1}$ 求导, 整理可得

$$\begin{aligned} \dot{z}_{i,1} &= \sum_{j=1}^N a_{i,j}(\dot{y}_i - \dot{y}_j) + b_i(\dot{y}_i - \dot{r}) \\ &= (b_i + d_i)[\Gamma_{i,1}(Z_{i,1}) + g_{i,1}(x_{i,1})x_{i,2}] - \sum_{j \in \mathbb{N}_i} a_{i,j}g_{j,1}(x_{j,1})x_{j,2} - b_i\dot{r} \end{aligned} \quad (6.6)$$

其中, $\Gamma_{i,1}(Z_{i,1}) = f_{i,1}(x_{i,1}) - \frac{1}{b_i + d_i} \sum_{j \in \mathbb{N}_i} a_{i,j} f_{j,1}(x_{j,1})$, $Z_{i,1} = [x_{i,1}, x_{j,1}]^T, j \in \mathbb{N}_i$ 。

基于系统表达式(6.1), 式(6.6)可进一步变换为

$$\begin{aligned} \dot{z}_{i,1} &= (b_i + d_i)[h_{i,1}(Z_{i,1}) + \Gamma_{i,1}(Z_{i,1,d}) + g_{i,1}(x_{i,1})(z_{i,2} + \bar{\alpha}_{i,2} - x_{i,2d} + x_{i,2d})] \\ &\quad - \sum_{j \in \mathbb{N}_i} a_{i,j}g_{j,1}(x_{j,1})x_{j,2} - b_i\dot{r} \end{aligned} \quad (6.7)$$

其中, $h_{i,1}(Z_{i,1}) = \Gamma_{i,1}(Z_{i,1}) - \Gamma_{i,1}(Z_{i,1,d})$, $Z_{i,1,d} = [x_{i,1d}, x_{j,1d}]^T, j \in \mathbb{N}_i$, $x_{i,1d} = r(t)$ 。

由于非线性函数 $f_{i,q}(\bar{x}_{i,q}), q = 1, 2, \dots, n_i$ 未知, 导致 $\Gamma_{i,1}(Z_{i,1,d})$ 也是未知的。为此, 本章采用神经网络对非线性函数 $\Gamma_{i,1}(Z_{i,1,d})$ 进行逼近, 具体表示为

$$\Gamma_{i,1}(Z_{i,1,d}) = \theta_{i,q}^T S_{i,q}(Z_{i,qd}) + \delta_{i,q}(Z_{i,qd}), \quad q = 1, 2, \dots, n_i \quad (6.8)$$

其中, $\theta_{i,q}$ 表示神经网络理想权值向量, $S_{i,q}(Z_{i,qd})$ 为激励函数, $\delta_{i,q}(Z_{i,qd})$ 表示神经网络逼近误差; 易得, $\delta_{i,q}(Z_{i,qd})$ 是一个有界信号, 即存在一个正常数 $\varepsilon_{i,q}$, 使得 $|\delta_{i,q}(Z_{i,qd})| \leq \varepsilon_{i,q}$ 成立。

为了补偿虚拟控制输入 $x_{i,2d}$ 通过一阶指令滤波器后造成的滤波误差 $\bar{\alpha}_{i,2} - x_{i,2d}$, 引入补偿信号 $\xi_{i,1}$, 设计补偿动态系统为

$$\dot{\xi}_{i,1} = -k_{i,1}\xi_{i,1} + (b_i + d_i)g_{i,1}(x_{i,1})(\bar{\alpha}_{i,2} - x_{i,2d} + \xi_{i,2}), \quad \xi_{i,1}(0) = 0 \quad (6.9)$$

其中, $k_{i,1} > 0$ 为设计参数。

定义补偿跟踪误差为

$$\bar{z}_{i,1} = z_{i,1} - \xi_{i,1}, \quad \bar{z}_{i,2} = z_{i,2} - \xi_{i,2} \quad (6.10)$$

对 $\bar{z}_{i,1}$ 求导, 结合式(6.7)和式(6.9), 可以得到

$$\begin{aligned} \dot{\bar{z}}_{i,1} = & (b_i + d_i) [h_{i,1}(Z_{i,1}) + \Gamma_{i,1}(Z_{i,1d}) + g_{i,1}(x_{i,1})(\bar{z}_{i,2} + x_{i,2d}^a + x_{i,2d}^*)] \\ & + k_{i,1}\xi_{i,1} - \sum_{j \in \mathbb{N}_i} a_{i,j} g_{j,1}(x_{j,1}) x_{j,2} - b_i \dot{r} \end{aligned} \quad (6.11)$$

选择 Lyapunov 函数为

$$V_1 = \sum_{i=1}^N \left(\frac{1}{2} \bar{z}_{i,1}^2 + \frac{1}{2\gamma_{i,1}} \tilde{\theta}_{i,1}^T \tilde{\theta}_{i,1} \right) \quad (6.12)$$

其中, $\gamma_{i,1} > 0$ 为设计参数。

通过对式(6.12)求导, 并将式(6.11)代入, 整理得

$$\begin{aligned} \dot{V}_1 = & \sum_{i=1}^N \left(\bar{z}_{i,1} \dot{\bar{z}}_{i,1} + \frac{1}{\gamma_{i,1}} \tilde{\theta}_{i,1}^T \dot{\tilde{\theta}}_{i,1} \right) \\ = & \sum_{i=1}^N \left\{ \bar{z}_{i,1} [(b_i + d_i)(h_{i,1}(Z_{i,1}) + \Gamma_{i,1}(Z_{i,1d}) + g_{i,1}(x_{i,1})(\bar{z}_{i,2} + x_{i,2d}^a + x_{i,2d}^*)) \right. \\ & \left. + k_{i,1}\xi_{i,1} - \sum_{j \in \mathbb{N}_i} a_{i,j} g_{j,1}(x_{j,1}) x_{j,2} - b_i \dot{r}] + \frac{1}{\gamma_{i,1}} \tilde{\theta}_{i,1}^T \dot{\tilde{\theta}}_{i,1} \right\} \end{aligned} \quad (6.13)$$

基于神经网络逼近非线性函数的表达式(6.8), 并利用 Young 不等式, 可知

$$\bar{z}_{i,1} \Gamma_{i,1}(Z_{i,1d}) \leq \bar{z}_{i,1} \hat{\theta}_{i,1}^T S_{i,1}(Z_{i,1d}) + \bar{z}_{i,1} \tilde{\theta}_{i,1}^T S_{i,1}(Z_{i,1d}) + \frac{1}{2} \bar{z}_{i,1}^2 + \frac{1}{2} \varepsilon_{i,1}^2 \quad (6.14)$$

其中, $\hat{\theta}_{i,q}$ 表示神经网络理想权值 $\theta_{i,q}$ 的估计值, 且定义权值估计误差为 $\tilde{\theta}_{i,q} = \theta_{i,q} - \hat{\theta}_{i,q}$ 。

此时, 设计前馈虚拟控制输入 $x_{i,2d}^a$ 以及神经网络权值自适应调节律 $\dot{\hat{\theta}}_{i,1}$ 为

$$x_{i,2d}^a = \frac{1}{(b_i + d_i)g_{i,1}(x_{i,1})} \left(-k_{i,1}\bar{z}_{i,1} + \sum_{j \in \mathbb{N}_i} a_{i,j} g_{j,1}(x_{j,1}) x_{j,2} + b_i \dot{r} \right) - \frac{1}{g_{i,1}(x_{i,1})} \left(\frac{1}{2} \bar{z}_{i,1} + \hat{\theta}_{i,1}^T S_{i,1}(Z_{i,1d}) \right) \quad (6.15)$$

$$\dot{\hat{\theta}}_{i,1} = (b_i + d_i) \gamma_{i,1} \bar{z}_{i,1} S_{i,1}(Z_{i,1d}) - \eta_{i,1} \hat{\theta}_{i,1} \quad (6.16)$$

其中, $\eta_{i,1} > 0$ 为设计参数。

将式(6.14)-式(6.16)代入式(6.13), 化简整理可得、

$$\begin{aligned} \dot{V}_1 \leq & \sum_{i=1}^N \left\{ -k_{i,1} \bar{z}_{i,1}^2 + (b_i + d_i) g_{i,1}(x_{i,1}) \bar{z}_{i,1} \bar{z}_{i,2} + \bar{z}_{i,1} [h_{i,1}(Z_{i,1}) + g_{i,1}(x_{i,1}) x_{i,2d}^*] \right. \\ & \left. + \frac{1}{2} (b_i + d_i) \varepsilon_{i,1}^2 + \frac{\eta_{i,1}}{\gamma_{i,1}} \tilde{\theta}_{i,1}^T \hat{\theta}_{i,1} \right\} \end{aligned} \quad (6.17)$$

第 q 步 ($2 \leq q \leq n_i - 1$): 对误差变量 $z_{i,q}$ 求导, 有

$$\begin{aligned} \dot{z}_{i,q} = & f_{i,q}(\bar{x}_{i,q}) + g_{i,q}(\bar{x}_{i,q}) x_{i,q+1} - \dot{\bar{\alpha}}_{i,q} \\ = & h_{i,q}(Z_{i,q}) + \Gamma_{i,q}(Z_{i,qd}) + g_{i,q}(\bar{x}_{i,q})(z_{i,q+1} + \bar{\alpha}_{i,q+1} - x_{i,(q+1)d} + x_{i,(q+1)d}^*) - \dot{\bar{\alpha}}_{i,q} \end{aligned} \quad (6.18)$$

其中, $h_{i,q}(Z_{i,q}) = f_{i,q}(Z_{i,q}) - \Gamma_{i,q}(Z_{i,qd})$, $\Gamma_{i,q}(Z_{i,q}) = f_{i,q}(\bar{x}_{i,q})$ 以及 $Z_{i,q} = \bar{x}_{i,q}$ 。

同样引入补偿信号 $\xi_{i,q}$ 来补偿滤波误差 $\bar{\alpha}_{i,q+1} - x_{i,(q+1)d}$ 的影响, 设计补偿动态系统为

$$\dot{\xi}_{i,q} = -k_{i,q} \xi_{i,q} + g_{i,q}(\bar{x}_{i,q})(\bar{\alpha}_{i,q+1} - x_{i,(q+1)d} + \xi_{i,q+1}), \quad \xi_{i,q}(0) = 0 \quad (6.19)$$

其中, $k_{i,q} > 0$ 为需要设计的参数。

通过补偿信号 $\xi_{i,q}$ 可以定义补偿跟踪误差如下:

$$\bar{z}_{i,q} = z_{i,q} - \xi_{i,q}, \quad \bar{z}_{i,q+1} = z_{i,q+1} - \xi_{i,q+1} \quad (6.20)$$

基于式(6.18)和式(6.19), 对 $\bar{z}_{i,q}$ 求导可得

$$\dot{\bar{z}}_{i,q} = h_{i,q}(Z_{i,q}) + \Gamma_{i,q}(Z_{i,qd}) + g_{i,q}(\bar{x}_{i,q})(\bar{z}_{i,q+1} + x_{i,(q+1)d}^a + x_{i,(q+1)d}^* + k_{i,q}\xi_{i,q} - \dot{\bar{\alpha}}_{i,q}) \quad (6.21)$$

选择 Lyapunov 函数为

$$V_q = V_{q-1} + \sum_{i=1}^N \left(\frac{1}{2} \bar{z}_{i,q}^2 + \frac{1}{2\gamma_{i,q}} \tilde{\theta}_{i,q}^T \tilde{\theta}_{i,q} \right) \quad (6.22)$$

其中, $\gamma_{i,q} > 0$ 表示设计参数。

对 V_q 求导, 整理可得

$$\begin{aligned} \dot{V}_q = \dot{V}_{q-1} + \sum_{i=1}^N \left\{ \bar{z}_{i,q} [h_{i,q}(Z_{i,q}) + \Gamma_{i,q}(Z_{i,qd}) + k_{i,q}\xi_{i,q} - \dot{\bar{\alpha}}_{i,q} \right. \\ \left. + g_{i,q}(\bar{x}_{i,q})(\bar{z}_{i,q+1} + x_{i,(q+1)d}^a + x_{i,(q+1)d}^*)] + \frac{1}{\gamma_{i,q}} \tilde{\theta}_{i,q}^T \dot{\tilde{\theta}}_{i,q} \right\} \end{aligned} \quad (6.23)$$

利用神经网络逼近未知非线性函数 $\Gamma_{i,q}(Z_{i,qd})$, 并再次利用 Young 不等式, 可得

$$\bar{z}_{i,q} \Gamma_{i,q}(Z_{i,qd}) \leq \bar{z}_{i,q} \hat{\theta}_{i,q}^T S_{i,q}(Z_{i,qd}) + \bar{z}_{i,q} \tilde{\theta}_{i,q}^T S_{i,q}(Z_{i,qd}) + \frac{1}{2} \bar{z}_{i,q}^2 + \frac{1}{2} \varepsilon_{i,q}^2 \quad (6.24)$$

此时设计前馈虚拟控制输入 $x_{i,(q+1)d}^a$ 以及神经网络权值自适应调节律 $\dot{\hat{\theta}}_{i,q}$ 为

$$x_{i,(q+1)d}^a = \frac{1}{g_{i,q}(\bar{x}_{i,q})} \left[-k_{i,q} \bar{z}_{i,q} - \frac{1}{2} \bar{z}_{i,q} - g_{i,q-1}(\bar{x}_{i,q-1}) \bar{z}_{i,q-1} - \hat{\theta}_{i,q}^T S_{i,q}(Z_{i,qd}) + \dot{\bar{\alpha}}_{i,q} \right] \quad (6.25)$$

$$\dot{\hat{\theta}}_{i,q} = \gamma_{i,q} \bar{z}_{i,q} S_{i,q}(Z_{i,qd}) - \eta_{i,q} \hat{\theta}_{i,q} \quad (6.26)$$

其中, $\eta_{i,q} > 0$ 为设计参数。

将式(6.24)-式(6.26)代入式(6.23), 化简整理后可以得到如下不等式关系:

$$\begin{aligned} \dot{V}_q \leq \sum_{i=1}^N \left\{ -\sum_{j=1}^q k_{i,j} \bar{z}_{i,j}^2 + \sum_{j=1}^q \bar{z}_{i,j} h_{i,j}(Z_{i,j}) + (b_i + d_i) \bar{z}_{i,1} g_{i,1}(x_{i,1}) x_{i,2d}^* + \sum_{j=2}^q \bar{z}_{i,j} g_{i,j}(\bar{x}_{i,j}) x_{i,(j+1)d}^* \right. \\ \left. + g_{i,q}(\bar{x}_{i,q}) \bar{z}_{i,q} \bar{z}_{i,q+1} + \frac{1}{2} (b_i + d_i) \varepsilon_{i,1}^2 + \frac{1}{2} \sum_{j=2}^q \varepsilon_{i,j}^2 + \sum_{j=1}^q \frac{\eta_{i,j}}{\gamma_{i,j}} \tilde{\theta}_{i,j}^T \dot{\tilde{\theta}}_{i,j} \right\} \end{aligned} \quad (6.27)$$

第 n_i 步: 基于式(6.4), 对误差信号 z_{i,n_i} 求导可得

$$\begin{aligned} \dot{z}_{i,n_i} = \dot{x}_{i,n_i} - \dot{\bar{\alpha}}_{i,n_i} - \dot{\chi}_i \\ = h_{i,n_i}(Z_{i,n_i}) + \Gamma_{i,n_i}(Z_{i,n_id}) + g_{i,n_i}(\bar{x}_{i,n_i}) u_i(v_i) - \dot{\bar{\alpha}}_{i,n_i} - \dot{\chi}_i \end{aligned} \quad (6.28)$$

其中, $h_{i,n_i}(Z_{i,n_i}) = \Gamma_{i,n_i}(Z_{i,n_i}) - \Gamma_{i,n_i}(Z_{i,n_id})$, $\Gamma_{i,n_i}(Z_{i,n_i}) = f_{i,n_i}(\bar{x}_{i,n_i})$, $Z_{i,n_i} = \bar{x}_{i,n_i}$ 。

为了补偿第 i 个智能体中, 输入饱和带来的影响, 设计辅助动态系统为

$$\dot{\chi}_i = -k_{i,n_i} \chi_i + g_{i,n_i}(\bar{x}_{i,n_i}) (u_i(v_i) - v_i) \quad (6.29)$$

其中, $k_{i,n_i} > 0$ 为设计参数。

考虑到在这一步设计中, 实际前馈控制输入将会出现且不存在滤波误差。为了与前面设计部分保持一致, 引入补偿信号 ξ_{i,n_i} , 并定义补偿动态系统以及补偿跟踪误差信号分别为

$$\dot{\xi}_{i,n_i} = -k_{i,n_i} \xi_{i,n_i}, \quad \bar{z}_{i,n_i} = z_{i,n_i} - \xi_{i,n_i} \quad (6.30)$$

对误差信号 $\bar{z}_{i,n_i}$ 求导可得

$$\dot{\bar{z}}_{i,n_i} = h_{i,n_i}(Z_{i,n_i}) + \Gamma_{i,n_i}(Z_{i,n_i d}) + g_{i,n_i}(\bar{x}_{i,n_i})(v_i^a + v_i^*) + k_{i,n_i} \chi_i - \dot{\bar{\alpha}}_{i,n_i} + k_{i,n_i} \xi_{i,n_i} \quad (6.31)$$

定义如下 Lyapunov 函数

$$V = V_{n_i-1} + \sum_{i=1}^N \left(\frac{1}{2} \bar{z}_{i,n_i}^2 + \frac{1}{2\gamma_{i,n_i}} \tilde{\theta}_{i,n_i}^T \tilde{\theta}_{i,n_i} \right) \quad (6.32)$$

其中, $\gamma_{i,n_i} > 0$ 为设计参数。

通过对 V 求导, 并将式(6.31)代入, 化简整理可得

$$\begin{aligned} \dot{V} = \dot{V}_{n_i-1} + \sum_{i=1}^N \left\{ \bar{z}_{i,n_i} \left[h_{i,n_i}(Z_{i,n_i}) + \Gamma_{i,n_i}(Z_{i,n_i d}) + g_{i,n_i}(\bar{x}_{i,n_i})(v_i^a + v_i^*) \right. \right. \\ \left. \left. + k_{i,n_i} \chi_i - \dot{\bar{\alpha}}_{i,n_i} + k_{i,n_i} \xi_{i,n_i} \right] + \frac{1}{\gamma_{i,n_i}} \tilde{\theta}_{i,n_i}^T \dot{\tilde{\theta}}_{i,n_i} \right\} \end{aligned} \quad (6.33)$$

与前面几步骤类似, 利用神经网络逼近未知非线性函数 $\Gamma_{i,n_i}(Z_{i,n_i d})$, 并利用 Young 不等式进行变换, 可得

$$\bar{z}_{i,n_i} \Gamma_{i,n_i}(Z_{i,n_i d}) \leq \bar{z}_{i,n_i} \hat{\theta}_{i,n_i}^T S_{i,n_i}(Z_{i,n_i d}) + \bar{z}_{i,n_i} \tilde{\theta}_{i,n_i}^T S_{i,n_i}(Z_{i,n_i d}) + \frac{1}{2} \bar{z}_{i,n_i}^2 + \frac{1}{2} \varepsilon_{i,n_i}^2 \quad (6.34)$$

此时, 我们设计前馈实际控制输入 v_i^a 以及神经网络权值自适应调节律 $\dot{\hat{\theta}}_{i,n_i}$ 如下:

$$v_i^a = \frac{1}{g_{i,n_i}(\bar{x}_{i,n_i})} \left[-k_{i,n_i} z_{i,n_i} - \frac{1}{2} \bar{z}_{i,n_i} - k_{i,n_i} \chi_i - g_{i,n_i-1}(\bar{x}_{i,n_i-1}) \bar{z}_{i,n_i-1} - \hat{\theta}_{i,n_i}^T S_{i,n_i}(Z_{i,n_i d}) + \dot{\bar{\alpha}}_{i,n_i} \right] \quad (6.35)$$

$$\dot{\hat{\theta}}_{i,n_i} = \gamma_{i,n_i} \bar{z}_{i,n_i} S_{i,n_i}(Z_{i,n_i d}) - \eta_{i,n_i} \hat{\theta}_{i,n_i} \quad (6.36)$$

其中, $\eta_{i,n_i} > 0$ 为需要设计的参数。

将式(6.34)-式(6.36)代入式(6.33), 化简整理可得

$$\begin{aligned} \dot{V} \leq \sum_{i=1}^N \left\{ -\sum_{j=1}^{n_i} k_{i,j} \bar{z}_{i,j}^2 + \sum_{j=1}^{n_i} \bar{z}_{i,j} h_{i,j}(Z_{i,j}) + (b_i + d_i) \bar{z}_{i,1} g_{i,1}(x_{i,1}) x_{i,2d}^* + \sum_{j=2}^{n_i-1} \bar{z}_{i,j} g_{i,j}(\bar{x}_{i,j}) x_{i,(j+1)d}^* \right. \\ \left. + \bar{z}_{i,n_i} g_{i,n_i}(\bar{x}_{i,n_i}) v_i^* + \frac{1}{2} (b_i + d_i) \varepsilon_{i,1}^2 + \frac{1}{2} \sum_{j=2}^{n_i} \varepsilon_{i,j}^2 + \sum_{j=1}^{n_i} \frac{\eta_{i,j}}{\gamma_{i,j}} \tilde{\theta}_{i,j}^T \dot{\tilde{\theta}}_{i,j} \right\} \end{aligned} \quad (6.37)$$

考虑到不等式 $\tilde{\theta}_{i,q}^T \dot{\tilde{\theta}}_{i,q} \leq -\frac{1}{2} \|\tilde{\theta}_{i,q}\|^2 + \frac{1}{2} \|\theta_{i,q}\|^2$ 成立, 如果进一步定义变量 $k_i = \min\{k_{i,q} | 1 \leq q \leq n_i\}$ 以及

$\beta_{ii} = \frac{1}{2} (b_i + d_i) \varepsilon_{i,1}^2 + \frac{1}{2} \sum_{j=2}^{n_i} \varepsilon_{i,j}^2$, 那么, 式(6.37)可重新变换为

$$\begin{aligned} \dot{V} \leq \sum_{i=1}^N \left\{ -k_i \|Z_i\|^2 - \frac{1}{2} r_i \|\tilde{\theta}_i\|^2 + \frac{1}{2} r_i' \|\theta_i\|^2 + \beta_{ii} \right. \\ \left. + Z_i^T \left(\begin{bmatrix} h_{i,1}(Z_{i,1}) \\ \vdots \\ h_{i,n_i}(Z_{i,n_i}) \end{bmatrix} + \begin{bmatrix} (b_i + d_i) g_{i,1}(x_{i,1}) & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & g_{i,n_i}(\bar{x}_{i,n_i}) \end{bmatrix} U_i^* \right) \right\} \end{aligned} \quad (6.38)$$

其中, $Z_i = [\bar{z}_{i,1}, \bar{z}_{i,2}, \dots, \bar{z}_{i,n_i}]^T$, $U_i^* = [x_{i,2d}^*, \dots, x_{i,n_i d}^*, v_i^*]^T$, $\theta_i = [\theta_{i,1}, \dots, \theta_{i,n_i}]^T$, $\tilde{\theta}_i = [\tilde{\theta}_{i,1}, \dots, \tilde{\theta}_{i,n_i}]^T$, 参数 r_i 和 r_i' 分

别定义为 $r_i = \min\left\{\frac{\eta_{i,q}}{\gamma_{i,q}} | 1 \leq q \leq n_i\right\}$ 和 $r_i' = \max\left\{\frac{\eta_{i,q}}{\gamma_{i,q}} | 1 \leq q \leq n_i\right\}$ 。

正如前面描述的一样,本章分布式自适应最优控制器 U_i 主要由两部分组成,即 $U_i = U_i^a + U_i^*$, 其中, 分布式前馈控制输入 $U_i^a = [x_{i,2d}^a, \dots, x_{i,n_d}^a, v_i^a]^T$ 已经设计, 正如式(6.15)、式(6.25)和式(6.35)所示; 从不等式(6.38)可以看出, 如果分布式反馈最优控制输入 $U_i^* = [x_{i,2d}^*, \dots, x_{i,n_d}^*, v_i^*]^T = 0$, 则由于跟踪误差项 $h_{i,q}(Z_{i,q})$, $q=1, 2, \dots, n_i$ 的存在导致闭环系统不稳定。因此需要设计 U_i^* 保证如下协同跟踪误差动态系统能够保持稳定, 从而保证整个闭环系统的稳定性:

$$\dot{Z}_i = \begin{bmatrix} h_{i,1}(Z_{i,1}) \\ \vdots \\ h_{i,n_i}(Z_{i,n_i}) \end{bmatrix} + \begin{bmatrix} (b_i + d_i)g_{i,1}(x_{i,1}) & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & g_{i,n_i}(\bar{x}_{i,n_i}) \end{bmatrix} U_i^* \quad (6.39)$$

6.4 分布式最优反馈控制输入设计

6.4.1 分布式最优控制设计

基于式(6.39), 考虑如下协同跟踪误差动态系统

$$\dot{Z}_i = \bar{H}_i(Z_i) + G_i(X_i)U_i \quad (6.40)$$

其中, $X_i = [x_{i,1}, \dots, x_{i,n_i}]^T$, $\bar{H}_i(Z_i) = [h_{i,1}(Z_{i,1}), \dots, h_{i,n_i}(Z_{i,n_i})]^T$, $G_i(X_i) = \text{diag}[(b_i + d_i)g_{i,1}(x_{i,1}), \dots, g_{i,n_i}(\bar{x}_{i,n_i})]$ 。

本节的主要目的就是设计分布式最优反馈控制输入 U_i^* , 保证误差信号 Z_i 收敛于零附近的小邻域内; 同时还必须最小化下列局部合作型性能指标函数:

$$J_i = \int_0^\infty \left(Q_i(Z_i(\tau)) + U_i^T R_{ii} U_i + \sum_{j \in N_i} U_j^T R_{ij} U_j \right) d\tau \quad (6.41)$$

其中, $Q_i(Z_i) \geq 0$ 为半正定函数, $R_{ii} = R_{ii}^T > 0$ 和 $R_{ij} = R_{ij}^T \geq 0$ 均为对称矩阵。

基于合作型性能指标函数(6.41), 定义哈密顿函数为

$$H(Z_i, U_i, U_j, \nabla J_i(Z_i)) = Q_i(Z_i) + U_i^T R_{ii} U_i + \sum_{j \in N_i} U_j^T R_{ij} U_j + (\nabla J_i(Z_i))^T (\bar{H}_i(Z_i) + G_i(X_i)U_i) \quad (6.42)$$

其中, $\nabla J_i(Z_i)$ 表示 $J_i(Z_i)$ 对变量 Z_i 的偏导数, i.e., $\nabla J_i(Z_i) = \partial J_i(Z_i) / \partial Z_i$ 。

基于 Belleman 最优理论, 可知局部合作型最优代价函数 $J_i^*(Z_i)$ 满足下列耦合 HJB 方程

$$\min_{U_i} H(Z_i, U_i, U_j, \nabla J_i^*(Z_i)) = 0 \quad (6.43)$$

如果假设耦合 HJB 方程(6.43)的最优解 U_i^* 存在且唯一, 则根据最优解存在的必要条件 $\partial H(\cdot) / \partial U_i = 0$ 可得, 分布式最优控制 U_i^* 的表达式为

$$U_i^* = -\frac{1}{2} R_{ii}^{-1} G_i^T(X_i) \nabla J_i^*(Z_i) \quad (6.44)$$

将式(6.44)代入式(6.42), 可得相应的耦合 HJB 方程为

$$\begin{aligned} Q_i(Z_i) + (\nabla J_i^*(Z_i))^T \bar{H}_i(Z_i) - \frac{1}{4} (\nabla J_i^*(Z_i))^T G_i(X_i) R_{ii}^{-1} G_i^T(X_i) \nabla J_i^*(Z_i) \\ + \frac{1}{4} \sum_{j \in N_i} (\nabla J_j^*(Z_j))^T G_j(X_j) R_{jj}^{-1} G_j^T(X_j) \nabla J_j^*(Z_j) = 0 \end{aligned} \quad (6.45)$$

并且满足 $J_i^*(0) = 0$ 。

可以看出, 分布式最优控制输入(6.44)的实现依赖于耦合 HJB 方程(6.45)的求解。然而该 HJB 方程不仅包含第 i 个智能体自身的信息, 而且还涉及它的邻域智能体的相关信息, 属于耦合非线性偏微分方程, 一般情况下很难得到该耦合 HJB 方程的解析解。基于此, 本章将利用 ADP 技术, 在线逼近该 HJB 方程的近似最优解, 从而实现分布式近似最优控制。

6.4.2 分布式最优控制的实现

在设计分布式自适最优控制之前, 先给出下列假设。

假设 6.3 ^[37]: 考虑协同跟踪误差动态系统(6.40)以及局部合作性能指标函数(6.41), 在分布式最优控制输入(6.44)作用下, 假设存在一个连续可微径向无界的 Lyapunov 函数 $J_{si}(Z_i)$, 使得不等式关系 $\dot{J}_{si}(Z_i) = (\nabla J_{si}(Z_i))^T (\bar{H}_i(Z_i) + G_i(X_i)U_i^*) < 0$ 成立, 其中, $\nabla J_{si}(Z_i)$ 表示 $J_{si}(Z_i)$ 对变量 Z_i 的偏导数。那么, 一定存在一个正定矩阵 $\Lambda_i(Z_i)$ 满足 $\forall Z_i \neq 0, \Lambda_i(Z_i) > 0$ 且 $Z_i = 0 \Rightarrow \Lambda_i(Z_i) = 0$, 使得不等式关系 $(\nabla J_{si}(Z_i))^T (\bar{H}_i(Z_i) + G_i(X_i)U_i^*) < -(\nabla J_{si}(Z_i))^T \Lambda_i(Z_i) \nabla J_{si}(Z_i)$ 成立。

注释 6.1: 首先需要说明的是, 假设 6.3 已经出现在很多相关文献中, 如^[37; 53; 175]。接下来简单分析一下它的合理性。通常可以假设协同跟踪误差动态系统(6.40)在分布式最优控制输入(6.44)作用下其闭环系统是有界的, 且界值可表示为变量 Z_i 的函数。不失一般性, 可假设不等式 $\|\bar{H}_i(Z_i) + G_i(X_i)U_i^*\| \leq \eta_i \|\nabla J_{si}(Z_i)\|$, 其中, $\eta_i > 0$ 为常数。进一步, 可以得到不等式 $\|(\nabla J_{si}(Z_i))^T (\bar{H}_i(Z_i) + G_i(X_i)U_i^*)\| \leq \eta_i \|\nabla J_{si}(Z_i)\|^2$ 成立。考虑到在 Lyapunov 函数 $J_{si}(Z_i)$ 的作用下, 存在不等式关系 $\dot{J}_{si}(Z_i) = (\nabla J_{si}(Z_i))^T (\bar{H}_i(Z_i) + G_i(X_i)U_i^*) < 0$, 于是很容易得出假设 6.3 是合理的。一般情况下, 可以通过选择二次多项式形式的 $J_{si}(Z_i)$ 满足上述条件。

接下来, 利用神经网络对连续非线性函数的逼近能力, 通过构建评价网络实现对局部最优代价函数 $J_i^*(Z_i)$ 的逼近。具体表达式为

$$J_i^*(Z_i) = W_{ci}^T \sigma_i(Z_i) + \varepsilon_i(Z_i) \quad (6.46)$$

其中, $W_{ci} \in \mathbb{R}^L$ 表示评价网络理想权值, $\sigma_i(Z_i) \in \mathbb{R}^L$ 为激励函数, $\varepsilon_i(Z_i)$ 表示逼近误差, L 为隐含层神经元个数。

通过对式(6.46)求变量 Z_i 的偏导数, 可得

$$\nabla J_i^*(Z_i) = (\nabla \sigma_i(Z_i))^T W_{ci} + \nabla \varepsilon_i(Z_i) \quad (6.47)$$

其中, $\nabla \sigma_i(Z_i)$ 表示 $\sigma_i(Z_i)$ 对变量 Z_i 的偏导数, i.e., $\nabla \sigma_i(Z_i) = \partial \sigma_i(Z_i) / \partial Z_i$ 。

将式(6.47)代入式(6.44), 分布式最优控制输入表达式可变换为

$$U_i^* = -\frac{1}{2} R_{ii}^{-1} G_i^T(X_i) ((\nabla \sigma_i(Z_i))^T W_{ci} + \nabla \varepsilon_i(Z_i)) \quad (6.48)$$

相应的耦合 HJB 方程可表示为

$$\begin{aligned} H_i(Z_i, W_{ci}) = & Q_i(Z_i) + W_{ci}^T \nabla \sigma_i(Z_i) \bar{H}_i(Z_i) - \frac{1}{4} W_{ci}^T \nabla \sigma_i(Z_i) G_i(X_i) R_{ii}^{-1} G_i^T(X_i) (\nabla \sigma_i(Z_i))^T W_{ci} \\ & + \frac{1}{4} \sum_{j \in N_i} W_{cj}^T \nabla \sigma_j(Z_j) G_j(X_j) R_{jj}^{-1} R_{ij} R_{jj}^{-1} G_j^T(X_j) (\nabla \sigma_j(Z_j))^T W_{cj} + \delta_{HJB_i} = 0 \end{aligned} \quad (6.49)$$

其中, 由评价网络逼近误差造成的残余误差项 δ_{HJB_i} 可表示为

$$\begin{aligned} \delta_{HJB_i} = & (\nabla \varepsilon_i(Z_i))^T (\bar{H}_i(Z_i) + G_i(X_i)U_i^*) + \frac{1}{4} (\nabla \varepsilon_i(Z_i))^T G_i(X_i)R_{ii}^{-1}G_i^T(X_i)\nabla \varepsilon_i(Z_i) \\ & + \sum_{j \in \mathbb{N}_i} \left[\frac{1}{4} (\nabla \varepsilon_i(Z_i))^T G_j(X_j)R_{jj}^{-1}R_{ij}R_{jj}^{-1}G_j^T(X_j)\nabla \varepsilon_j(Z_j) \right. \\ & \left. + \frac{1}{2} W_j^T \nabla \sigma_j(Z_j)G_j(X_j)R_{jj}^{-1}R_{ij}R_{jj}^{-1}G_j^T(X_j)\nabla \varepsilon_j(Z_j) \right] \end{aligned} \quad (6.50)$$

考虑到一般情况下, 评价网络理想权值 W_{ci} 是未知的, 导致分布式最优控制输入(6.48)仍然不能够用于执行, 因此可以利用评价网络输出估计局局部最优代价函数

$$\hat{J}_i(Z_i) = \hat{W}_{ci}^T \sigma_i(Z_i) \quad (6.51)$$

其中, $\hat{W}_{ci}$ 是理想权值 W_{ci} 的估计值。

基于式(6.51), 可得估计的分布式最优控制输入为

$$\hat{U}_i = -\frac{1}{2} R_{ii}^{-1} G_i^T(X_i) (\nabla \sigma_i(Z_i))^T \hat{W}_{ci} \quad (6.52)$$

同样地, 估计的哈密顿函数可表示为

$$\begin{aligned} H_i(Z_i, \hat{W}_{ci}) = & Q_i(Z_i) + \hat{W}_{ci}^T \nabla \sigma_i(Z_i) \bar{H}_i(Z_i) - \frac{1}{4} \hat{W}_{ci}^T \nabla \sigma_i(Z_i) G_i(X_i) R_{ii}^{-1} G_i^T(X_i) (\nabla \sigma_i(Z_i))^T \hat{W}_{ci} \\ & + \frac{1}{4} \sum_{j \in \mathbb{N}_i} \hat{W}_{cj}^T \nabla \sigma_j(Z_j) G_j(X_j) R_{jj}^{-1} R_{ij} R_{jj}^{-1} G_j^T(X_j) (\nabla \sigma_j(Z_j))^T \hat{W}_{cj} = e_{ci} \end{aligned} \quad (6.53)$$

观察式(6.49)和式(6.53), 可以发现, 造成式(6.53)不等于零的主要原因就是评价网络估计权值 $\hat{W}_{ci}$ 与理想权值 W_{ci} 不相等。为了调节 $\hat{W}_{ci}$ 使得 $\hat{W}_{ci} \rightarrow W_{ci}$, 从而保证 $H_i(Z_i, \hat{W}_{ci}) \rightarrow 0$, 需要对评价网络估计权值 $\hat{W}_{ci}$ 设计自适应更新律最小化误差信号 e_{ci} 。为此, 首先设计如下目标函数:

$$E_{ci} = \frac{1}{2} e_{ci}^T e_{ci} \quad (6.54)$$

基于梯度下降法以及假设 6.3, 设计如下评价网络权值更新律:

$$\begin{aligned} \dot{\hat{W}}_{ci} = & -\frac{\alpha_i \phi_i}{m_{si}^2} e_{ci} + \frac{\alpha_i}{2} \nabla \sigma_i(Z_i) G_i(X_i) R_{ii}^{-1} G_i^T(X_i) \nabla J_{si}(Z_i) \\ & + \alpha_i \left[\frac{1}{4} \frac{\phi_i}{m_{si}^2} \hat{W}_{ci}^T M_{li} \hat{W}_{ci} - \sum_{j \in \mathbb{N}_i} \frac{1}{4} \frac{\phi_i}{m_{si}^2} \hat{W}_{cj}^T M_{2j} \hat{W}_{cj} - (F_{2i} \hat{W}_{ci} - F_{li} \phi_i^T \hat{W}_{ci}) \right] \end{aligned} \quad (6.55)$$

其中, $\alpha_i > 0$ 为评价网络学习率, $\phi_i = \nabla \sigma_i(Z_i) (\bar{H}_i(Z_i) + G_i(X_i) \hat{U}_i) \in \mathbb{R}^L$, $m_{si} = 1 + \phi_i^T \phi_i$, $\phi_i = \phi_i / m_{si}$; 此外, $M_{li} = \nabla \sigma_i(Z_i) G_i(X_i) R_{ii}^{-1} G_i^T(X_i) (\nabla \sigma_i(Z_i))^T$, $M_{2j} = \nabla \sigma_j(Z_j) G_j(X_j) R_{jj}^{-1} R_{ij} R_{jj}^{-1} G_j^T(X_j) (\nabla \sigma_j(Z_j))^T$; F_{li} 和 F_{2i} 为需要设计的调节参数; $J_{si}(Z_i)$ 在假设 6.3 中已经定义。

注释 6.2: 从式(6.55)中可以看出, 评价网络权值更新律主要包含三项。第一项是基于梯度下降法设计的, 主要用于最小化目标函数 E_{ci} ; 第二项是基于假设 6.3 设计的, 主要为了保证评价网络在学习过程中闭环系统信号的有界性; 第三项是为了保证闭环系统稳定性而设计的附件项。从第三项中可以看到, 第 i 个智能体的控制输入信号中包含了它所有邻域智能体的控制输入信号。换言之, 只有邻域智能体的行为会影响第 i 个智能体的稳定性, 而其他智能体不会对它有

任何影响。

定义评价网络权值估计误差为 $\tilde{W}_{ci} = W_{ci} - \hat{W}_{ci}$ 。基于式(6.49)、式(6.53)和式(6.55)，经化简整理，可得评价网络权值估计误差动态为

$$\begin{aligned} \dot{\tilde{W}}_{ci} = & -\alpha_i \phi_i \phi_i^T \tilde{W}_{ci} + \frac{\alpha_i \phi_i}{m_{si}^2} \left[\frac{1}{4} \tilde{W}_{ci}^T M_{li} \tilde{W}_{ci} - \sum_{j \in N_{li}} \left(\frac{1}{2} W_{cj}^T M_{2j} \tilde{W}_{cj} - \frac{1}{4} \tilde{W}_{cj}^T M_{2j} \tilde{W}_{cj} \right) - \delta_{HJBi} \right] \\ & - \frac{\alpha_i}{2} \nabla \sigma_i(Z_i) G_i(X_i) R_{ii}^{-1} G_i^T(X_i) \nabla J_{si}(Z_i) \\ & - \alpha_i \left[\frac{1}{4} \frac{\phi_i}{m_{si}^2} \hat{W}_{ci}^T M_{li} \hat{W}_{ci} - \sum_{j \in N_{li}} \frac{1}{4} \frac{\phi_j}{m_{sj}^2} \hat{W}_{cj}^T M_{2j} \hat{W}_{cj} - (F_{2i} \hat{W}_{ci} - F_{li} \phi_i^T \hat{W}_{ci}) \right] \end{aligned} \quad (6.56)$$

基于前面的设计，本章所提分布式自适应最优协同控制方法的控制结构图如图 6.1 所示。




图 6.1 分布式自适应最优控制结构图

从图 6.1 中，可以了解到本章结合指令滤波 Backstepping 控制方法和 ADP 技术，提出的前馈+反馈复合控制结构的主要思想以及相关设计参数的关系，从而可以更加清楚地明白该方案解决具有严格反馈非线性多智能体系统的自适应最优控制问题的思想。

6.5 稳定性分析

为方便后续稳定性分析，针对设计的评价网络，给出如下合理假设。

假设 6.4: 对第 i 个智能体，评价网络理想权值 W_{ci} 是有界的，即存在一个正常数 W_{Mi} ，使得不等式 $\|W_{ci}\| \leq W_{Mi}$ 成立；另外，假设评价网络激励函数 $\sigma_i(Z_i)$ 、逼近误差 $\varepsilon_i(Z_i)$ 以及它们的梯度项 $\nabla \sigma_i(Z_i)$ 和 $\nabla \varepsilon_i(Z_i)$ 在紧集 Ω_{Z_i} 内都是有界信号，满足 $\|\sigma_i(Z_i)\| \leq \sigma_{Mi}$ ， $\|\varepsilon_i(Z_i)\| \leq \varepsilon_{Mi}$ ， $\|\nabla \sigma_i(Z_i)\| \leq b_{\sigma_i}$ 以及 $\|\nabla \varepsilon_i(Z_i)\| \leq b_{\varepsilon_i}$ ，其中 σ_{Mi} 、 ε_{Mi} 、 b_{σ_i} 和 b_{ε_i} 都是正常数。此外，假设存在一个正常数 δ_{Mi} ，使得残余误差信号 δ_{HJBi} 满足不等式关系 $\|\delta_{HJBi}\| \leq \delta_{Mi}$ 。

基于以上分析，给出如下主要定理。

定理 6.1: 考虑输入饱和约束条件下的不确定非线性多智能体系统(6.1)，设计分布式前馈自适应

跟踪控制输入为式(6.15)、式(6.25)和式(6.35)，神经网络权值自适应调节律为式(6.16)、式(6.26)和式(6.36)，并设计辅助系统如式(6.29)所示；设计分布式反馈最优控制输入如式(6.52)所示，评价网络权值更新律设计为式(6.55)；在假设 6.1-假设 6.4 成立的前提下，通过选择设计参数能够保证闭环系统中所有跟随者与领导者之间的一致性协同跟踪误差信号 $z_{i,1}$ 、神经网络参数估计误差 $\tilde{\theta}_{i,q}$ 以及评价网络权值估计误差信号 $\tilde{W}_{ci}$ 都是最终一致有界的。

证明：选择如下 Lyapunov 函数

$$V_{HJB} = V + \sum_{i=1}^N \left[\frac{1}{2} \tilde{W}_{ci}^T \alpha_i^{-1} \tilde{W}_{ci} + J_{si}(Z_i) \right] \quad (6.57)$$

通过对 V_{HJB} 求导，可得

$$\dot{V}_{HJB} = \dot{V} + \sum_{i=1}^N \left[\tilde{W}_{ci}^T \alpha_i^{-1} \dot{\tilde{W}}_{ci} + (\nabla J_{si}(Z_i))^T \dot{Z}_i \right] \quad (6.58)$$

将式(6.38)代入整理，式(6.58)可重写为

$$\begin{aligned} \dot{V}_{HJB} \leq & \sum_{i=1}^N \left\{ -k_i \|Z_i\|^2 - \frac{1}{2} r_i \|\tilde{\theta}_i\|^2 + \frac{1}{2} r_i' \|\theta_i\|^2 + \beta_i \right. \\ & \left. + Z_i^T (\bar{H}_i(Z_i) + G_i(X_i)U_i^*) + \tilde{W}_{ci}^T \alpha_i^{-1} \dot{\tilde{W}}_{ci} + (\nabla J_{si}(Z_i))^T \dot{Z}_i \right\} \end{aligned} \quad (6.59)$$

考虑 $\tilde{W}_{ci}^T \alpha_i^{-1} \dot{\tilde{W}}_{ci}$ 并将式(6.56)代入，化简整理可得

$$\begin{aligned} \tilde{W}_{ci}^T \alpha_i^{-1} \dot{\tilde{W}}_{ci} = & -\tilde{W}_{ci}^T \phi_i \phi_i^T \tilde{W}_{ci} - \tilde{W}_{ci}^T \frac{\phi_i \delta_{HJB_i}}{m_{si}^2} + \frac{1}{4} \tilde{W}_{ci}^T \frac{\phi_i}{m_{si}^2} \tilde{W}_{ci}^T M_{li} \tilde{W}_{ci} \\ & - \sum_{j \in \mathbb{N}_i} \left(\frac{1}{2} \tilde{W}_{ci}^T \frac{\phi_i}{m_{si}^2} W_{cj}^T M_{2j} \tilde{W}_{cj} - \frac{1}{4} \tilde{W}_{ci}^T \frac{\phi_i}{m_{si}^2} \tilde{W}_{cj}^T M_{2j} \tilde{W}_{cj} \right) \\ & - \tilde{W}_{ci}^T \left[\frac{1}{4} \frac{\phi_i}{m_{si}^2} \hat{W}_{ci}^T M_{li} \hat{W}_{ci} - \sum_{j \in \mathbb{N}_i} \frac{1}{4} \frac{\phi_i}{m_{si}^2} \hat{W}_{cj}^T M_{2j} \hat{W}_{cj} - (F_{2i} \hat{W}_{ci} - F_{li} \phi_i^T \hat{W}_{ci}) \right] \\ & - \frac{1}{2} \tilde{W}_{ci}^T \nabla \sigma_i(Z_i) G_i(X_i) R_{ii}^{-1} G_i^T(X_i) \nabla J_{si}(Z_i) \end{aligned} \quad (6.60)$$

考虑关系式 $\tilde{W}_{ci} = W_{ci} - \hat{W}_{ci}$ ，将估计权值 $\hat{W}_{ci}$ 和 $\hat{W}_{cj}$ 替换掉，经化简整理，式(6.60)可重新表示为

$$\begin{aligned} \tilde{W}_{ci}^T \alpha_i^{-1} \dot{\tilde{W}}_{ci} = & -\tilde{W}_{ci}^T \phi_i \phi_i^T \tilde{W}_{ci} - \tilde{W}_{ci}^T \frac{\phi_i \delta_{HJB_i}}{m_{si}^2} - \frac{1}{4} \tilde{W}_{ci}^T \frac{\phi_i}{m_{si}^2} W_{ci}^T M_{li} W_{ci} \\ & + \frac{1}{2} \tilde{W}_{ci}^T \frac{\phi_i}{m_{si}^2} W_{ci}^T M_{li} \tilde{W}_{ci} - \sum_{j \in \mathbb{N}_i} \frac{1}{4} \tilde{W}_{ci}^T \frac{\phi_i}{m_{si}^2} W_{cj}^T M_{2j} W_{cj} \\ & + \tilde{W}_{ci}^T (F_{2i} \hat{W}_{ci} - F_{li} \phi_i^T \hat{W}_{ci}) \\ & - \frac{1}{2} \tilde{W}_{ci}^T \nabla \sigma_i(Z_i) G_i(X_i) R_{ii}^{-1} G_i^T(X_i) \nabla J_{si}(Z_i) \end{aligned} \quad (6.61)$$

注意到下列等式成立

$$\tilde{W}_{ci}^T (F_{2i} \hat{W}_{ci} - F_{li} \phi_i^T \hat{W}_{ci}) = \tilde{W}_{ci}^T F_{2i} W_{ci} - \tilde{W}_{ci}^T F_{2i} \tilde{W}_{ci} - \tilde{W}_{ci}^T F_{li} \phi_i^T W_{ci} + \tilde{W}_{ci}^T F_{li} \phi_i^T \tilde{W}_{ci} \quad (6.62)$$

通过定义变量 $Y_i = [\phi_i^T \tilde{W}_{ci}, \tilde{W}_{ci}^T]^T$ ，将式(6.62)代入，式(6.61)可重新整理为如下形式

$$\tilde{W}_{ci}^T \alpha_i^{-1} \dot{\tilde{W}}_{ci} = -Y_i^T K_i Y_i + Y_i^T E_i - \frac{1}{2} \tilde{W}_{ci}^T \nabla \sigma_i(Z_i) G_i(X_i) R_{ii}^{-1} G_i^T(X_i) \nabla J_{si}(Z_i) \quad (6.63)$$

其中，

$$K_i = \begin{bmatrix} I & -\frac{1}{2}F_{li}^T \\ -\frac{1}{2}F_{li} & F_{2i} - \frac{1}{2}\frac{\phi_i}{m_{si}^2}W_{ci}^T M_{li} \end{bmatrix}, \quad E_i = \begin{bmatrix} -\frac{\delta_{HJB_i}}{m_{si}} \\ \left(F_{2i} - F_{li}\phi_i^T - \frac{1}{4}\frac{\phi_i}{m_{si}^2}W_{ci}^T M_{li} \right)W_{ci} - \sum_{j \in N_i} \frac{1}{4}\frac{\phi_i}{m_{si}^2}W_{cj}^T M_{2j}W_{cj} \end{bmatrix}.$$

由式(6.63)可以看出, 如果设计调节参数 F_{li} 和 F_{2i} 使得矩阵 $K_i > 0$, 则式(6.63)可变换为

$$\begin{aligned} \dot{V}_{HJB} \leq & \sum_{i=1}^N \left\{ -k_i \|Z_i\|^2 - \frac{1}{2}r_i \|\tilde{\theta}_i\|^2 + \frac{1}{2}r_i' \|\theta_i\|^2 + \beta_{li} \right. \\ & + Z_i^T (\bar{H}_i(Z_i) + G_i(X_i)U_i^*) - \lambda_{\min}(K_i) \|Y_i\|^2 + \|E_i\| \|Y_i\| \\ & \left. - \frac{1}{2}\tilde{W}_{ci}^T \nabla \sigma_i(Z_i) G_i(X_i) R_{ii}^{-1} G_i^T(X_i) \nabla J_{si}(Z_i) + (\nabla J_{si}(Z_i))^T \dot{Z}_i \right\} \end{aligned} \quad (6.64)$$

其中, $\lambda_{\min}(K_i)$ 表示矩阵 K_i 的最小特征值。

进一步, 假设在分布式最优控制输入 U_i^* 作用下闭环系统是有界的, 且满足关系 $\|\bar{H}_i(Z_i) + G_i(X_i)U_i^*\| \leq c_i \sqrt{\|Z_i\|}$, 其中, $c_i > 0$ 为常数。根据 Young 不等式, 可得

$$Z_i^T (\bar{H}_i(Z_i) + G_i(X_i)U_i^*) \leq \frac{1}{2\zeta_i^2} \|Z_i\|^2 + \frac{\zeta_i^2 c_i^2}{2} \|Z_i\| \quad (6.65)$$

其中, $\zeta_i > 0$ 为设计参数。

将不等式(6.65)代入式(6.64), 整理可得

$$\begin{aligned} \dot{V}_{HJB} \leq & \sum_{i=1}^N \left\{ -\zeta_i \|Z_i\|^2 + \frac{b_i^2 c_i^2}{2} \|Z_i\| - \frac{1}{2}r_i \|\tilde{\theta}_i\|^2 + \lambda_i - \lambda_{\min}(K_i) \|Y_i\|^2 + \|E_i\| \|Y_i\| \right. \\ & \left. - \frac{1}{2}\tilde{W}_{ci}^T \nabla \sigma_i(Z_i) G_i(X_i) R_{ii}^{-1} G_i^T(X_i) \nabla J_{si}(Z_i) + (\nabla J_{si}(Z_i))^T (\bar{H}_i(Z_i) + G_i(X_i)\hat{U}_i) \right\} \end{aligned} \quad (6.66)$$

其中, $\zeta_i = k_i - \frac{1}{2\zeta_i^2}$ 以及 $\lambda_i = \frac{1}{2}r_i' \|\theta_i\|^2 + \beta_{li}$ 。

根据式(6.48)和式(6.52)给出的 U_i^* 和 $\hat{U}_i$ 的表达式, 可以得到如下关系:

$$U_i^* - \hat{U}_i = -\frac{1}{2}R_{ii}^{-1}G_i^T(X_i) \left((\nabla \sigma_i(Z_i))^T \tilde{W}_{ci} + \nabla \varepsilon_i(Z_i) \right) \quad (6.67)$$

考虑式(6.67), 式(6.66)可变换为

$$\begin{aligned} \dot{V}_{HJB} \leq & \sum_{i=1}^N \left\{ -\zeta_i \|Z_i\|^2 + \frac{b_i^2 c_i^2}{2} \|Z_i\| - \frac{1}{2}r_i \|\tilde{\theta}_i\|^2 + \lambda_i - \lambda_{\min}(K_i) \|Y_i\|^2 + \|E_i\| \|Y_i\| \right. \\ & \left. + \frac{1}{2}(\nabla J_{si}(Z_i))^T G_i(X_i) R_{ii}^{-1} G_i^T(X_i) \nabla \varepsilon_i(Z_i) + (\nabla J_{si}(Z_i))^T (\bar{H}_i(Z_i) + G_i(X_i)U_i^*) \right\} \end{aligned} \quad (6.68)$$

这里考虑假设 6.1 易得不等式 $\|G_i(X_i)R_{ii}^{-1}G_i^T(X_i)\| \leq \kappa_i$ 成立, 其中, $\kappa_i > 0$ 为常数。进一步, 基于假设 6.3, 式(6.68)可化简为如下形式:

$$\begin{aligned} \dot{V}_{HJB} \leq & \sum_{i=1}^N \left\{ -\zeta_i \|Z_i\|^2 + \frac{b_i^2 c_i^2}{2} \|Z_i\| - \frac{1}{2}r_i \|\tilde{\theta}_i\|^2 + \lambda_i - \lambda_{\min}(K_i) \|Y_i\|^2 + \|E_i\| \|Y_i\| \right. \\ & \left. - \lambda_{\min}(\Lambda_i(Z_i)) \|\nabla J_{si}(Z_i)\|^2 + \frac{1}{2}\kappa_i b_{ei} \|\nabla J_{si}(Z_i)\| \right\} \end{aligned} \quad (6.69)$$

其中, $\lambda_{\min}(\Lambda_i(Z_i))$ 表示矩阵 $\Lambda_i(Z_i)$ 的最小特征值。

观察式(6.69), 为了保证闭环系统的稳定性, 需要选择参数, 保证 $k_i > \frac{1}{2\zeta_i^2}$ 。将式(6.69)整理为完全平方形式, 可得

$$\begin{aligned} \dot{V}_{HJB} \leq \sum_{i=1}^N \left\{ -\zeta_i \left(\|Z_i\| - \frac{b_i^2 c_i^2}{4} \right)^2 - \frac{1}{2} r_i \|\tilde{\theta}_i\|^2 - \lambda_{\min}(\mathbf{K}_i) \left(\|Y_i\| - \frac{\|E_i\|}{2\lambda_{\min}(\mathbf{K}_i)} \right)^2 \right. \\ \left. - \lambda_{\min}(\Lambda_i(Z_i)) \left(\|\nabla J_{si}(Z_i)\| - \frac{\kappa_i b_{e_i}}{4\lambda_{\min}(\Lambda_i(Z_i))} \right)^2 + v_i \right\} \end{aligned} \quad (6.70)$$

其中, $v_i = \frac{b_i^4 c_i^4}{16\zeta_i} + \frac{\|E_i\|^2}{4\lambda_{\min}(\mathbf{K}_i)} + \frac{\kappa_i^2 b_{e_i}^2}{16\lambda_{\min}(\Lambda_i(Z_i))} + \lambda_i$ 。

从式(6.70)可以得出这样的结论: 只要下列不等式关系成立, 就可以保证 $\dot{V}_{HJB} < 0$

$$\|Z_i\| \geq \sqrt{\frac{v_i}{\zeta_i} + \frac{b_i^2 c_i^2}{4\zeta_i}} \quad (6.71)$$

或

$$\|\tilde{\theta}_i\| \geq \sqrt{\frac{2v_i}{r_i}} \quad (6.72)$$

或

$$\|Y_i\| \geq \sqrt{\frac{v_i}{\lambda_{\min}(\mathbf{K}_i)}} + \frac{\|E_i\|}{2\lambda_{\min}(\mathbf{K}_i)} \quad (6.73)$$

或

$$\|\nabla J_{si}(Z_i)\| \geq \sqrt{\frac{v_i}{\lambda_{\min}(\Lambda_i(Z_i))}} + \frac{\kappa_i b_{e_i}}{4\lambda_{\min}(\Lambda_i(Z_i))} \quad (6.74)$$

综上所述, 基于 Lyapunov 稳定性定理可知, 在提出的分布式自适应最优控制器作用下, 闭环系统所有信号是有界的; 且所有跟随者均能够一致跟随领导者信号。

注释 6.3: 从定理 6.1 可知, 闭环系统信号 $\bar{z}_{i,q}$, $i=1, \dots, N$ 是有界的。另外, 基于文献[176]分析, 补偿信号 $\zeta_{i,q}$ 也是有界的。从定义式 $\bar{z}_{i,q} = z_{i,q} - \zeta_{i,q}$ 可得, 协同一致性跟踪误差 $z_{i,q}$ 也是有界的。

6.6 多导弹协同拦截制导应用

本节将建立多导弹协同拦截机动目标的数学模型, 并通过一定的分析构建多弹协同拦截非线性系统, 将协同拦截制导问题转化为典型的多智能体协同控制问题。

考虑 N 枚导弹协同拦截一个机动目标的情形, 在二维平面上, 其协同拦截制导示意图如图 6.2 所示。图中, $M_1, M_2, \dots, M_N$ 分别表示 N 枚导弹, T 表示机动目标; $V_i, \alpha_i, \theta_i, i=1, \dots, N$ 分别表示第 i 枚导弹的飞行速度、航迹角和视线角; V_t, β 分别表示目标的飞行速度和航迹角; 此外, r_i 为第 i 枚导弹与目标在视线方向的相对距离; u_i 为导弹垂直于速度方向的控制输入, v_t 表示目标垂直于速度方向的控制输入。本章假设所有导弹与目标的飞行速度均为常值, 且各导弹之间主要依靠通讯拓扑网络进行通信。也就是说, 第 i 枚导弹只能与它邻域内的导弹进行通信。




图 6.2 多弹协同拦截制导示意图

由图 6.2 可以得出，多导弹协同拦截机动目标的相对运动学关系为：

$$\begin{aligned}\dot{r}_i &= V_T \cos(\beta - \theta_i) - V_i \cos(\alpha_i - \theta_i) \\ \dot{\theta}_i &= (V_T \sin(\beta - \theta_i) - V_i \sin(\alpha_i - \theta_i)) / r_i \\ \dot{\alpha}_i &= u_i / V_i \\ \dot{\beta} &= v_T / V_T\end{aligned}\quad (6.75)$$

类似地，基于平行导引原则^[156]，只要保证第 i 枚导弹的视线角速率 $\dot{\theta}_i$ 趋于零，即视线角保持恒定，且导弹与目标的相对速率 $\dot{r}_i$ 小于零，就可以保证导弹最终击中目标。为此，定义系统状态变量为 $x_{i,1} = \theta_i, x_{i,2} = \dot{\theta}_i$ ，则多导弹协同拦截机动目标的非线性系统可描述为

$$\begin{aligned}\dot{x}_{i,1} &= x_{i,2} \\ \dot{x}_{i,2} &= -\frac{2\dot{r}_i}{r_i} x_{i,2} - \frac{\cos(\alpha_i - \theta_i)}{r_i} u_i + \frac{\cos(\beta - \theta_i)}{r_i} v_T\end{aligned}\quad (6.76)$$

基于式(6.76)，给出如下假设条件：

假设 6.5： 机动目标加速度指令 v_T 是有界的，即存在一个正常数 $v_{\max}$ ，使得不等式 $|v_T| \leq v_{\max}$ ；同时机动目标的飞行速度 V_T 也是有界信号，满足 $|V_T| \leq V_{T\max}$ ，其中， $V_{T\max}$ 为正常数。

另外，不妨假设导弹与目标的自动驾驶仪均为一阶动态系统，具体表示为

第 i 枚导弹质心运动方程：

$$\begin{aligned}\dot{x}_{Mi} &= V_i \cos \alpha_i \\ \dot{y}_{Mi} &= V_i \sin \alpha_i \\ \dot{\alpha}_i &= a_i / V_i \\ a_i &= (u_i - \dot{a}_i) / \tau_{Mi}\end{aligned}\quad (6.77)$$

其中， (x_{Mi}, y_{Mi}) 表示导弹的位置坐标信息， a_i 表示导弹侧向加速度， τ_{Mi} 为第 i 枚导弹的自动驾驶仪时间常数。

目标质心运动方程：

$$\begin{aligned}
\dot{x}_T &= V_T \cos \beta \\
\dot{y}_T &= V_T \sin \beta \\
\dot{\beta} &= a_T / V_T \\
a_T &= (v_T - a_r) / \tau_T
\end{aligned} \tag{6.78}$$

其中, (x_T, y_T) 表示机动目标位置坐标信息, a_T 为目标侧向加速度, τ_T 表示目标自动驾驶仪时间常数。

基于上述分析, 可给出导弹能够成功拦截机动目标的必要条件为:

$$\dot{\theta}_i \rightarrow 0, \dot{r}_i < 0 \tag{6.79}$$

在多导弹协同拦截制导过程中, 不仅仅要求导弹能够成功拦截机动目标; 同时还必须要求多导弹之间能够通过数据共享、战术协同的方式实现协同攻击的目的, 保证拦截效果, 提高拦截概率。通常情况下, 协同制导包括两种方式: 显式协同制导和隐式协同制导。显式协同制导要求所有导弹能够同时击中目标, 是协同制导中最常见的制导方式。它通常通过直接控制各导弹与目标之间的剩余之间达到同时攻击的目的。但这种协同制导方式对剩余时间的估计将直接影响协同制导精度。尤其在面对复杂环境下拦截高速大机动目标时, 由于目标的机动信息一般难以获得, 使得剩余时间估计困难, 从而可能导致协同制导任务失败。另一种协同制导方式为隐式协同制导; 它一般要求各导弹的某些变量达成一致, 如碰撞角协同、视线角协同以及终端速度协同等, 从而使得协同制导效能达到最大而不要求同时攻击目标。

本章采用的协同制导方式便是隐式协同制导, 要求各枚导弹拦截机动目标时能够保持相同的碰撞角, 从而保证拦截效果。根据文献[177]分析, 定义各导弹拦截机动目标时的碰撞角为

$$\eta_i = \alpha_i - \beta \tag{6.80}$$

如果保证视线角速率 $\dot{\theta}_i = 0$, 即视线角 θ_i 保持不变, 那么碰撞角可描述为

$$\eta_i = \alpha_i - \beta = \theta_i - \arcsin(V_i^{-1} V_T \sin(\theta_i - \beta)) - \beta \tag{6.81}$$

从式(6.81)可以看出, 如果假设所有导弹的速度相同, 则只要保证所有导弹的视线角 θ_i 达成一致, 就可以实现碰撞角协同的目的。

如果定义系统(6.76)的输出为 $y_i = x_{i,1}$, 那么多导弹之间的协同制导问题就可以描述成多导弹协同拦截非线性系统(6.76)的一致性控制问题。本节的主要目的就是通过设计导弹的控制输入 u_i 保证系统输出 $y_i = x_{i,1}$ 能够一致收敛于领弹参考信号 $r(t)$ 。

基于以上分析, 可以得出这样的结论: 本章多弹协同拦截制导主要实现以下两个目标:

- 1) 保证所有导弹最终能够击中目标, i.e., $\dot{\theta}_i \rightarrow 0$ 且 $\dot{r}_i < 0$;
- 2) 保证所有导弹的碰撞角 η_i 达到一致, i.e., $\lim_{t \rightarrow \infty} |\eta_i - \eta_j| \rightarrow 0$;

此外, 从式(6.76)可以看出, 当 $|\alpha_i - \theta_i| = \pi/2, |\beta - \theta_i| = \pi/2$ 时, 系统(6.76)是不可控的。因此, 可以归纳出多弹协同拦截制导律的可行域为

$$\Omega = \{x_i : |\alpha_i - \theta_i| \neq \pi/2, |\beta - \theta_i| \neq \pi/2, r_i \neq 0, \dot{r}_i < 0\} \tag{6.82}$$

注释 6.4: 本章采用领弹-从弹协同模式；通常情况下，这种协同制导模式分为两个阶段：在第一阶段，所有从弹试图实现碰撞角一致收敛于领弹的碰撞角信息，从而以相同的碰撞角跟随领弹逼近目标，这一阶段属于多导弹协同阶段；在第二阶段，当所有导弹逼近目标，即制导最后时刻，多导弹协同过程结束；各导弹将采用各自的制导律（如 PN 制导）拦截目标。由于第二阶段相比于第一阶段所需时间可以忽略。可以认为各导弹的碰撞角在击中目标时仍然相同，保持一致。

另外，在协同制导过程中，为方便起见，作出如下假设：

假设 6.6: 在多弹协同制导过程中，各导弹不存在误打、误撞的情形；同时也不考虑机动目标使用诱饵弹迷惑导弹，导致脱靶的情形。

在下一节中，我们将通过本节建立的多弹协同拦截非线性系统，验证本章提出的分布式自适应最优控制方法的有效性。

6.7 仿真验证

本节考虑 2 枚从弹协同拦截 1 个机动目标的情形。首先假设在末制导阶段所有从弹的飞行速度均保持不变且相同，即 $V_i = 600 \text{ m/s}$, $i = 1, 2$ ；机动目标的飞行速度假设为 $V_T = 400 \text{ m/s}$ ；导弹和目标的自动驾驶仪时间常数均选取为 $\tau_{M_i} = \tau_T = 0.1$ ；各导弹之间的通信拓扑结构假设为如图 6.3 所示：




图 6.3 各导弹通信拓扑图

其中，0 表示领弹，1 和 2 分别表示两枚从弹。

从图 6.3 容易得到，该通信拓扑结构下，邻接矩阵为 $\mathcal{A} = \begin{bmatrix} 0 & 0 \\ 1 & 0 \end{bmatrix}$ ，入度矩阵为 $\mathcal{D} = \text{diag}[0, 1]$ ，与领弹的连接矩阵为 $\mathcal{B} = \text{diag}[1, 0]$ 。

假设 2 枚从弹的初始航迹角分别为 $\alpha_1 = \pi/6 \text{ rad}$ 和 $\alpha_2 = \pi/3 \text{ rad}$ ，目标的初始航迹角为 $\beta = \pi/6 \text{ rad}$ ；从弹初始坐标位置分别假设为 $(x_{M1}, y_{M1}) = (500, 0)$ 和 $(x_{M2}, y_{M2}) = (0, 500)$ ，目标初始位置坐标为 $(x_T, y_T) = (2500, 0)$ ；为方便分析，领弹输出参考信号假设为 $\theta_0 = 0$ ；各从弹输入饱和和约束假设为 $|u_i| \leq 500 \text{ m/s}^2$ 。另外，控制器参数选择如下：

在前馈控制输入中，神经网络激励函数选取为 $S_{i,1}(Z_{i,1d}) = [\tanh(0.1x_{i,1d}), \tanh(x_{i,1d}), \tanh(0.5x_{i,1d})]^T$ 和 $S_{i,2}(Z_{i,2d}) = [\tanh(x_{i,1d}), \tanh(2x_{i,2d}), \tanh(x_{i,1d}x_{i,2d}), \tanh(5x_{i,1d}^2), \tanh(0.1x_{i,2d}^2)]^T$ ，初始取值 $\hat{\theta}_{i,1}(0)$ 和 $\hat{\theta}_{i,2}(0)$ 均设为零向量；其他设计参数选择如下： $k_{11} = 2, k_{12} = 0.01, \gamma_{11} = 10, \gamma_{12} = 10, \eta_{11} = 0.01, \eta_{12} = 0.2$ ， $k_{21} = 2.5, k_{22} = 0.9, \gamma_{21} = 2, \gamma_{22} = 0.2, \eta_{21} = 10, \eta_{22} = 0.01$ 。

在分布式反馈控制输入中，选择评价网络激励函数为 $\sigma_i(Z_i) = [\bar{z}_{1,1}^2, \bar{z}_{1,1}\bar{z}_{1,2}, \bar{z}_{1,2}^2, \bar{z}_{1,1}^2\bar{z}_{1,2}, \bar{z}_{1,1}\bar{z}_{1,2}^2]^T$ ，评价网络初始权值 $\hat{W}_{ci}(0)$ 选取为零向量；此外，选择 $Q_i(Z_i) = \bar{z}_{i,1}^2 + \bar{z}_{i,2}^2$, $R_{11} = R_{22} = 10I$ ， $R_{21} = 100I$ ；

设计参数设选取为 $F_{11} = 100 \cdot [1, 1, 1, 1]^T$, $F_{21} = 3I$, $F_{12} = 240 \cdot [1, 1, 1, 1]^T$, $F_{22} = 5I$, 其中, I 表示相应维数的单位矩阵; 评价网络学习率选取为 $\alpha_1 = \alpha_2 = 0.5$; Lyapunov 函数 $J_{si}(Z_i)$ 可选取为 $J_{si}(Z_i) = 0.5(\bar{z}_{i,1}^2 + \bar{z}_{i,2}^2)$ 。

在后面的仿真分析中, 我们考虑目标在两种不同机动形式下, 验证分布式自适应最优拦截制导方案的有效性。

情形 1: 目标不机动, i.e., $a_t = 0$ 。

仿真结果如图 6.4-图 6.8 所示。从图 6.4 可以看出, 两枚导弹通过协同制导方式实现了碰撞角的一致, 最终依次击中目标, 而不是同时击中目标, 这正是本章所提的隐式协同制导问题。可以看出两枚导弹在制导大部分时间段处于协同阶段, 试图保证碰撞角达成一致; 而在制导最后阶段, 协同拦截制导模式将变成了一对一拦截制导模式, 分别进行两次拦截。第一次由导弹 1 进行拦截, 而第二次由导弹 2 进行拦截。从图 6.5 可以看出各导弹的视线角速率和相对速率均满足拦截机动目标的必要条件 $\dot{\theta}_i \rightarrow 0$, $\dot{r}_i < 0$, 满足拦截条件, 可以保证所有导弹最终都能成功拦截目标。图 6.6 给出了导弹视线角和碰撞角响应曲线。从中可以清楚地看出各导弹视线角和碰撞角最终实现一致。图 6.7 给出了两枚导弹各自的侧向加速度曲线。可以发现导弹 1 控制输入并没有出现输入饱和现象。而导弹 2 的控制输入出现了饱和现象, 但在设计的辅助系统的作用下最终被限制在饱和约束范围内, 避免了因过载饱和而导致目标脱靶等现象。图 6.8 给出了自适应参数变化曲线, 验证了自适应估计误差信号 $\|\tilde{\theta}\|$ 的有界性。




图 6.4(a) 导弹-目标拦截轨迹




图 6.4(b) 导弹-目标相对距离

图 6.4 多弹协同拦截制导轨迹和相对距离 (目标不机动)




图 6.5(a) 导弹视线角速率




图 6.5(b) 导弹-目标相对速率

图 6.5 各导弹视线角速率和相对速率 (目标不机动)




图 6.6(a) 导弹视线角




图 6.6(b) 导弹碰撞角

图 6.6 各导弹视线角和碰撞角（目标不机动）




图 6.7(a) 导弹 1 的侧向加速度





图 6.7(b) 导弹 2 的侧向加速度

图 6.7 各导弹侧向加速度（目标不机动）


 图 6.8 自适应参数 $\hat{\theta}_{i,2}$ （目标不机动）

值得注意的是，在图 6.4(a)中出现的两次拦截过程可能不会同时出现。因为在实际拦截制导过程中，最终的目的就是成功拦截目标。如果在第一次拦截中，导弹 1 已经成功拦截目标，那么该协同制导过程就已经结束了，便不会出现第二次拦截。但如果在第一次拦截过程中，由于目标的机动或者其他未知因素导致导弹 1 没有完全摧毁目标，甚至让目标逃脱，那么第二次拦截便会继续进行，完成此次拦截任务。

情形 2: 目标机动为 $2g$ ，i.e., $a_T = 2g$, $g = 9.8\text{m/s}^2$ 。

在这种情形下，假设目标机动为 $a_T = 2g$ 。在其他仿真参数不变的情况下，仿真结果如图 6.9-图 6.13 所示：




图 6.9(a) 导弹-目标拦截轨迹




图 6.9(b) 导弹-目标相对距离

图 6.9 多弹协同拦截制导轨迹和相对距离（目标常值机动）

可以看到两枚导弹在拦截制导第一阶段，即导弹接近目标的过程中，能够实现视线角和碰撞角的一致，从而达到了协同的目的。而在第二阶段，即拦截制导末端，各导弹均能保证各自视线角速率和相对速率满足拦截制导的必要条件 $\dot{\theta}_i \rightarrow 0, \dot{r}_i < 0$ ，从而保证各枚导弹均能够最终成功拦截目标。基于此种考虑，可以认为各枚导弹最终能够在本章提出的分布式自适应最优拦截制导律作用下实现协同拦截的目的。




图 6.10(a) 导弹视线角速率




图 6.10(b) 导弹-目标相对速率

图 6.10 各导弹视线角速率和相对速率（目标常值机动）




图 6.11(a) 导弹视线角




图 6.11(b) 导弹碰撞角

图 6.11 各导弹视线角和碰撞角（目标常值机动）

然而与情形 1 不同的是，图 6.11(b)中所有导弹的碰撞角最终收敛于一个时变信号，而不是常值。这主要是由于目标的机动导致目标航迹角 β 不断变化，从而使得碰撞角 η_i 不断变化。另外与情形 1 类似，导弹 1 的控制输入没出现饱和现象，但导弹 2 的控制输入却出现了饱和现象。这主要是因为拦截制导初始时刻，由于导弹 2 与目标的相对距离大于导弹 1 与目标的相对距

离，而且它们的初始航迹角不同。导弹 2 需要调整自己的飞行轨迹保证自己的视线角与导弹 1 视线角达成一致，而由于导弹 2 不在导弹 1 的邻域内，导致导弹 1 不会收到导弹 2 的相关信息，也不会参照导弹 2 的飞行状态去调整自己的飞行轨迹。





图 6.12(a) 导弹 1 的侧向加速度

图 6.12(b) 导弹 2 的侧向加速度

图 6.12 各导弹侧向加速度（目标常值机动）


 图 6.13 自适应参数 $\hat{\theta}_{i,2}$ （目标常值机动）

综上所述，通过在目标不同机动形式下的仿真验证，表明本章提出的分布式自适应最优控制方案能够保证所有导弹以相同的碰撞角协同拦截机动目标，实现协同制导任务；同时还可以有效补偿输入饱和造成的影响。

6.8 本章小结

本章主要从多导弹协同拦截机动目标这一工程问题出发，研究了具有严格反馈形式的非线性多智能体系统的分布式最优控制问题。将 ADP 技术和指令滤波 Backstepping 控制方法相结合，解决了严格反馈非线性多智能体系统的自适应最优控制问题。首先利用指令滤波 Backstepping 控制方法，设计分布式前馈控制输入，将原系统的分布式跟踪控制问题转化为等效局部协同跟踪误差动态系统的分布式最优调节控制问题；并通过设计辅助系统有效解决了输入饱和问题。随后利用 ADP 技术，构建评价网络在线逼近耦合 HJB 方程的解，保证分布式自适应最优控制输入的实现。理论上保证了闭环系统的稳定性以及协同跟踪误差信号的最终一致有界性。通过数值仿真，验证了本章所提方案的有效性。然而需要指出的是，本章并没有充分考虑协同制导过程中可能出现的各弹在击中目标之前相互碰撞以及通信拓扑网络发生故障等特殊情况，而这些情况在实际工程中是不能忽略的。因此，在后续研究中将着重解决此类问题。

第七章 基于事件触发机制的多弹分布式最优协同拦截制导

7.1 引言

在前面第六章中, 面对高速、智能、大机动特性等先进飞行器的威胁与挑战, 为了弥补传统制导方式的不足, 将 ADP 技术应用于多导弹协同制导问题, 提出了分布式自适应最优协同制导方案; 不仅有效提高了导弹拦截概率, 保证拦截制导效果; 同时还可以实现了闭环系统性能的最优化; 但在前面的理论研究中主要关注了闭环系统的稳定性, 而忽略了控制器对通信资源和计算资源的消耗。特别是面对复杂多智能体系统, 可能会由于宽带和通道的限制导致通信阻塞, 从而使各智能体之间的通信拓扑遭到破坏, 因此在设计控制器时如何最大限度避免不必要的资源浪费具有很重要意义。

传统控制方法大多基于时间触发机制, 即控制器主要基于采样时间周期性地更新, 保证闭环系统的稳定性。当前后两次采样信号中, 如果它们的误差在可接受范围内, 那么控制器是没有必要进行更新的, 这样就不可避免地造成了计算资源的浪费。为了有效降低通信资源和控制器计算资源的浪费, 本章提出基于事件触发机制的分布式自适应最优控制方案。在事件触发机制中, 只有当连续两次采样信号误差超出一定范围才会触发控制器的更新过程。而在其他时间内控制器将保持原有的策略, 从而大大降低了控制器的更新次数, 节约了计算资源, 同时还能够保证闭环系统的稳定性; 基于以上分析, 本章提出的基于事件触发机制的分布式自适应最优制导方案会对未来发展自主智能的协同制导系统提供理论依据。

7.2 问题描述

考虑一类由 N 个跟随者和一个领导者组成的仿射非线性多智能体系统

$$\dot{x}_i(t) = f_i(x_i(t)) + g_i(x_i(t))u_i(t) \quad (7.1)$$

其中, $x_i(t) \in \mathbb{R}^n$ 表示第 i 个智能体的状态, $u_i(t) \in \mathbb{R}^m$ 为控制输入向量; $f_i(x_i) \in \mathbb{R}^n$ 和 $g_i(x_i) \in \mathbb{R}^{n \times m}$ 均为连续可微的非线性函数, 且满足 $f_i(0) = 0$; 此外, 假设 $f_i(x_i) + g_i(x_i)u_i(t)$ 在包含原点的局部范围内 Lipschitz 连续且假设系统(7.1)可控。

领导者动态系统假设为如下形式:

$$\dot{x}_0(t) = f_0(x_0(t)) \quad (7.2)$$

其中, $x_0(t) \in \mathbb{R}^n$ 表示领导者状态向量, $f_0(x_0(t))$ 为已知的非线性函数。

基于图论相关知识, 定义第 i 个智能体的局部邻域一致性误差为

$$e_i = \sum_{j \in \mathcal{N}_i} a_{ij}(x_i - x_j) + b_i(x_i - x_0) \quad (7.3)$$

通过对式(7.3)求导, 可以得到局部邻域一致性误差动态方程为

$$\dot{e}_i = f_{ei}(t) + (b_i + d_i)g_i(x_i)u_i(t) - \sum_{j \in \mathbb{N}_i} a_{ij}g_j(x_j)u_j(t) \quad (7.4)$$

其中, $f_{ei}(t) = (b_i + d_i)f_i(x_i) - \sum_{j \in \mathbb{N}_i} a_{ij}f_j(x_j) - b_i\dot{x}_0$ 。

本章的主要目的就是通过设计分布式控制输入 $u_i(e_i)$, 保证所有跟随者信号能够一致收敛于领导者参考信号; 同时保证下列局部合作性能指标函数最小:

$$\begin{aligned} J_i(e_i) &= \int_0^\infty r_i(e_i(\tau), u_i(\tau)) d\tau \\ &= \int_0^\infty \left(Q_i(e_i(\tau)) + u_i^T R_{ii} u_i + \sum_{j \in \mathbb{N}_i} u_j^T R_{ij} u_j \right) d\tau \end{aligned} \quad (7.5)$$

其中, $Q_i(e_i) = e_i^T Q_i e_i$, $Q_i \in \mathbb{R}^{n \times n}$ 表示半正定矩阵; $R_{ii} = r_{ii} r_{ii}^T \in \mathbb{R}^{m \times m} > 0$ 为对称正定矩阵, r_{ii} 为矩阵 R_{ii} 分解后的下三角矩阵; $R_{ij} \in \mathbb{R}^{m \times m} \geq 0$ 表示对称半正定矩阵。

基于局部合作性能指标函数(7.5), 定义第 i 个智能体的哈密顿函数为

$$\begin{aligned} H_i(e_i, u_i, \nabla J_i(e_i)) &= Q_i(e_i) + u_i^T R_{ii} u_i + \sum_{j \in \mathbb{N}_i} u_j^T R_{ij} u_j \\ &\quad + (\nabla J_i(e_i))^T \left(f_{ei}(t) + (b_i + d_i)g_i(x_i)u_i - \sum_{j \in \mathbb{N}_i} a_{ij}g_j(x_j)u_j \right) \end{aligned} \quad (7.6)$$

其中, $\nabla J_i(e_i)$ 表示 $J_i(e_i)$ 对变量 e_i 的偏导数, i.e., $\nabla J_i(e_i) = \partial J_i(e_i) / \partial e_i$ 。

基于 Bellman 最优性原理, 合作型最优代价函数 $J_i^*(e_i)$ 满足下列 HJB 方程:

$$\min_{u_i} H_i(e_i, u_i, \nabla J_i^*(e_i)) = 0 \quad (7.7)$$

不妨假设方程(7.7)的解存在且唯一。那么根据最优解存在的必要条件 $\partial H_i(\cdot) / \partial u_i = 0$, 可得分布式最优控制律为

$$u_i^*(e_i) = -\frac{1}{2}(b_i + d_i)R_{ii}^{-1}g_i^T(x_i)\nabla J_i^*(e_i) \quad (7.8)$$

将式(7.8)代入 HJB 方程(7.7), 可得相应的耦合 HJB 方程为

$$\begin{aligned} H_i(e_i, u_i^*, \nabla J_i^*(e_i)) &= Q_i(e_i) + (\nabla J_i^*(e_i))^T f_{ei}(t) - \frac{1}{4}(\nabla J_i^*(e_i))^T \bar{g}_i \nabla J_i^*(e_i) \\ &\quad + \frac{1}{4} \sum_{j \in \mathbb{N}_i} (\nabla J_j^*(e_j))^T \bar{g}_{-i} \nabla J_j^*(e_j) + \frac{1}{2} \sum_{j \in \mathbb{N}_i} a_{ij} (\nabla J_i^*(e_i))^T C_j \nabla J_j^*(e_j) = 0 \end{aligned} \quad (7.9)$$

其中, $J_i^*(0) = 0$, $\bar{g}_i = (b_i + d_i)^2 g_i(x_i) R_{ii}^{-1} g_i^T(x_i)$, $\bar{g}_{-i} = (b_j + d_j)^2 g_j(x_j) R_{jj}^{-1} R_{ij} g_j^T(x_j)$, $C_j = (b_j + d_j) g_j(x_j) R_{jj}^{-1} g_j^T(x_j)$ 。

针对推导出的分布式最优控制律(7.8), 需要说明一下两点: 1) 合作型最优代价函数 $J_i^*(e_i)$ 的获得需要求解耦合 HJB 方程(7.9)。但该 HJB 方程求解十分困难, 一般很难获得其解析解形式。2) 该分布式最优控制律属于传统的时间触发形式, 它会造成不必要的通信资源和计算资源的浪费。

基于以上分析, 本章将通过引入事件触发机制设计基于事件触发的分布式最优控制律, 并设计自适应触发条件保证闭环系统的稳定性。

7.3 事件触发分布式最优控制律设计

首先, 定义一组单调递增的触发序列 $\{t_{k_i}\}_{k_i=0}^\infty$, 其中, $t_{k_i}, k_i \in \mathbb{N}$ 表示事件触发时刻。定义第 i

个智能体在第 t_{k_i} 时刻触发时的状态为 $x_i(t_{k_i}) = x_i^{k_i}$ ；于是第 t_{k_i} 触发时刻的状态 $x_i(t_{k_i})$ 与当前状态 $x_i(t)$ 之间的事件触发误差为

$$s_i^{k_i}(t) = x_i^{k_i} - x_i(t), \quad \forall t \in [t_{k_i}, t_{k_{i+1}}) \quad (7.10)$$

需要指出的是，在事件触发时刻 $t = t_{k_i}$ ，触发误差 $s_i^{k_i}(t) = 0$ 。只有当触发误差 $s_i^{k_i}(t)$ 超出预设的触发条件阈值时该事件才会被触发；控制器也将根据触发时刻采样状态进行更新；与此同时，触发误差 $s_i^{k_i}(t)$ 重新归零。而在事件未触发之前，控制器将一直保持原来的状态。一般情况下，事件触发条件的设定与触发误差 $s_i^{k_i}(t)$ 和系统状态有关。

基于局部邻域一致性误差定义式(7.3)，定义事件触发机制下的局部邻域一致性误差为

$$e_i^{k_i} = \sum_{j \in \mathbb{N}_i} a_{ij}(x_i^{k_i} - x_j^{k_j}) + b_i(x_i^{k_i} - x_0), \quad \forall t \in [t_{k_i}, t_{k_{i+1}}) \quad (7.11)$$

因此可设计事件触发的分布式最优控制律为

$$\mu_i^*(e_i^{k_i}) = -\frac{1}{2}(b_i + d_i)R_{ii}^{-1}g_i^T(x_i^{k_i})\nabla J_i^*(e_i^{k_i}), \quad \forall t \in [t_{k_i}, t_{k_{i+1}}) \quad (7.12)$$

其中， $\nabla J_i^*(e_i^{k_i}) = \partial J_i^*(e_i)/\partial e_i|_{e_i=e_i^{k_i}}$ 。

基于式(7.11)，定义分布式事件触发误差为 $z_i^{k_i}(t) = e_i^{k_i} - e_i, \forall t \in [t_{k_i}, t_{k_{i+1}})$ 。可以得到如下关系式：

$$z_i^{k_i}(t) = \sum_{j \in \mathbb{N}_i} a_{ij}(s_i^{k_i}(t) - s_j^{k_j}(t)) + b_i s_i^{k_i}(t) \quad (7.13)$$

注释 7.1：基于式(7.10)和式(7.13)，可以得到全局分布式触发误差 $z^{k_i}(t)$ 和误差信号 $s^{k_i}(t)$ 满足关系 $z^{k_i}(t) = ((L + \mathcal{B}) \otimes I_N) s^{k_i}(t)$ ，其中， $z^{k_i}(t) = [(z_1^{k_i}(t))^T, \dots, (z_N^{k_i}(t))^T]^T$ ， $s^{k_i}(t) = [(s_1^{k_i}(t))^T, \dots, (s_N^{k_i}(t))^T]^T$ ，“ $\otimes$ ”表示 Kronecker 积运算。从中可以得出这样的结论：如果一个非线性函数有界且它的界值可表示为 $s_i^{k_i}(t)$ 的函数，那么该函数界值一定也可以表示为 $z_i^{k_i}(t)$ 的函数。

在设计自适应事件触发条件之前，首先作如下假设：

假设 7.1^[107]：分布式最优控制律 $u_i^*(e_i)$ 是 Lipschitz 连续的，满足条件 $\|u_i^*(e_i) - \mu_i^*(e_i^{k_i})\| \leq \mathcal{L}_{u_i} \|z_i^{k_i}(t)\|$ ，其中， $\mathcal{L}_{u_i}$ 为正常数。

为了保证在事件触发机制下闭环系统的稳定性，设计自适应事件触发条件并给出如下定理：

定理 7.1：考虑局部邻域一致性误差动态系统(7.4)以及局部合作性能指标函数(7.5)，如果设计自适应事件触发条件为

$$\|z_i^{k_i}(t)\|^2 \leq z_{\pi} = \frac{(1 - \eta_{i,1})\lambda_{\min}(Q_i)\|e_i\|^2 + \|r_{ii}^T \mu_i^*(e_i^{k_i})\|}{\mathcal{L}_{u_i}^2 \|R_{ii}\|} \quad (7.14)$$

其中， z_{π} 表示触发阈值， $\eta_{i,1} \in (0, 1)$ 为设计参数， $\lambda_{\min}(Q_i)$ 表示矩阵 Q_i 的最小特征值。则在事件触发的分布式最优控制律(7.12)作用下闭环系统能够保证渐近稳定。

证明：选择 Lyapunov 函数为 $L_{li}(t) = J_i^*(e_i)$ 。对其求导，并将式(7.4)代入，可得

$$\dot{L}_{li}(t) = (\nabla J_i^*(e_i))^T \left(f_{e_i}(t) + (b_i + d_i)g_i(x_i)\mu_i^*(e_i^{k_i}) - \sum_{j \in \mathbb{N}_i} a_{ij}g_j(x_j)u_j^* \right) \quad (7.15)$$

观察式(7.8)，如下等式关系成立：

$$(b_i + d_i)(\nabla J_i^*(e_i))^T g_i(x_i) = -2u_i^{*T}(e_i)R_{ii} \quad (7.16)$$

基于 HJB 方程(7.9), 可知

$$(\nabla J_i^*(e_i))^T \left(f_{ei}(t) - \sum_{j \in N_i} a_{ij} g_j(x_j) u_j^* \right) = -Q_i(e_i) + u_i^{*T} R_{ii} u_i^* - \sum_{j \in N_i} a_{ij} u_j^{*T} R_{ij} u_j^* \quad (7.17)$$

将式(7.16)和式(7.17)代入式(7.15), 整理可得

$$\begin{aligned} \dot{L}_{ii}(t) &= -Q_i(e_i) + u_i^{*T} R_{ii} u_i^* - 2u_i^{*T}(e_i)R_{ii}\mu_i^*(e_i^{k_i}) - \sum_{j \in N_i} a_{ij} u_j^{*T} R_{ij} u_j^* \\ &= -Q_i(e_i) + \|r_{ii}^T [u_i^*(e_i) - \mu_i^*(e_i^{k_i})]\|^2 - \|r_{ii}^T \mu_i^*(e_i^{k_i})\|^2 - \sum_{j \in N_i} a_{ij} u_j^{*T} R_{ij} u_j^* \end{aligned} \quad (7.18)$$

基于假设 7.1, 同时应用 Young 不等式关系, 式(7.18)可变换为

$$\dot{L}_{ii}(t) \leq -\lambda_{\min}(Q_i) \|e_i\|^2 + \mathcal{L}_{u_i}^2 \|R_{ii}\| \|z_i^{k_i}(t)\|^2 - \|r_{ii}^T \mu_i^*(e_i^{k_i})\|^2 \quad (7.19)$$

从式(7.19)中可以看出, 只要自适应触发条件(7.14)成立, 则对于 $\forall e_i \neq 0$, 式(7.19)可进一步化简为 $\dot{L}_{ii}(t) \leq -\eta_{i,1}^2 \lambda_{\min}(Q_i) \|e_i\|^2 < 0$ 。基于 Lyapunov 稳定性定理, 闭环系统是渐近稳定的。

注释 7.2: 基于定理 7.1 可以看出, 事件触发时刻 t_{k_i} 可以通过自适应事件触发条件(7.14)得到。但我们要通过调节参数 $\eta_{i,1}$ 保证事件触发最小驻留时间 $(\Delta t_{k_i})_{\min}$ (注: $\Delta t_{k_i} = t_{k_i+1} - t_{k_i}, k_i \in \mathbb{N}$) 不等式零。一旦出现 $(\Delta t_{k_i})_{\min} = 0$, 就会发生芝诺现象。

7.4 事件触发分布式最优控制律实现

为方便后续设计, 首先给出如下假设条件。

假设 7.2 ^[101]: 针对局部邻域误差动态系统(7.4)以及局部合作性能指标函数(7.5), 在事件触发分布式最优控制律(7.12)作用下, 存在一个有效的连续可微径向无界 Lyapunov 函数 $J_{si}(e_i)$, 使得不等式 $\dot{J}_{si}(e_i) = (\nabla J_{si}(e_i))^T \left(f_{ei}(t) + g_i(x_i) \mu_i^*(e_i^{k_i}) - \sum_{j \in N_i} a_{ij} g_j(x_j) u_j^* \right) < 0$ 成立, 其中, $\nabla J_{si}(e_i)$ 为 $J_{si}(e_i)$ 对变量 e_i 的偏导数。那么也一定存在一个正定矩阵 $\Lambda_i(e_i)$ 使得下列不等式成立:

$$(\nabla J_{si}(e_i))^T \left(f_{ei}(t) + g_i(x_i) \mu_i^*(e_i^{k_i}) - \sum_{j \in N_i} a_{ij} g_j(x_j) u_j^* \right) \leq \lambda_{\min}(\Lambda_i(e_i)) \|\nabla J_{si}(e_i)\|^2 \quad (7.20)$$

利用神经网络对连续非线性函数的逼近能力, 构建评价网络在线逼近合作型最优代价函数 $J_i^*(e_i)$, 具体表示为

$$J_i^*(e_i) = W_{ci}^T \sigma_i(e_i) + \varepsilon_i(e_i) \quad (7.21)$$

其中, $W_{ci} \in \mathbb{R}^L$ 表示评价网络理想权值, $\sigma_i(e_i) \in \mathbb{R}^L$ 为所选择的激励函数, $\varepsilon_i(e_i)$ 表示逼近误差。通过对式(7.21)求偏导数, 可得

$$\nabla J_i^*(e_i) = (\nabla \sigma_i(e_i))^T W_{ci} + \nabla \varepsilon_i(e_i) \quad (7.22)$$

其中, $\nabla \sigma_i(e_i)$ 表示 $\sigma_i(e_i)$ 对变量 e_i 的偏导数。

将式(7.22)代入式(7.14), 事件触发分布式最优控制律可表示为

$$\mu_i^*(e_i^{k_i}) = -\frac{1}{2} (b_i + d_i) R_{ii}^{-1} g_i^T(x_i^{k_i}) \left((\nabla \sigma_i(e_i^{k_i}))^T W_{ci} + \nabla \varepsilon_i(e_i^{k_i}) \right) \quad (7.23)$$

相应的事件触发 HJB 方程变为

$$H_i(e_i, W_{ci}, \mu_i^*(e_i^{k_i})) = r_i(e_i, \mu_i^*(e_i^{k_i})) + W_{ci}^T \nabla \sigma_i(e_i) \left(f_{ei}(t) + g_i(x_i) \mu_i^*(e_i^{k_i}) - \sum_{j \in \mathbb{N}_i} a_{ij} g_j(x_j) u_j^* \right) \stackrel{\Delta}{=} \delta_{HJB_i} \quad (7.24)$$

其中, 由逼近误差和事件触发误差共同造成的残余误差项为

$$\delta_{HJB_i} = -(\nabla \varepsilon_i(e_i^{k_i}))^T \left(f_{ei}(t) + g_i(x_i) \mu_i^*(e_i^{k_i}) - \sum_{j \in \mathbb{N}_i} a_{ij} g_j(x_j) u_j^* \right) \quad (7.25)$$

考虑到评价网络理想权值向量一般情况下是未知的, 为了实现事件触发分布式最优控制律, 采用评价网络输出信号估计最优代价函数, 具体可表示为

$$\hat{J}_i(e_i) = \hat{W}_{ci}^T \sigma_i(e_i) \quad (7.26)$$

其中, $\hat{W}_{ci}$ 为理想权值 W_{ci} 的估计值。

类似地, 我们有

$$\nabla \hat{J}_i(e_i) = (\nabla \sigma_i(e_i))^T \hat{W}_{ci} \quad (7.27)$$

通过将式(7.27)代入, 可以得到估计的事件驱动分布式最优控制律为

$$\hat{\mu}_i(e_i^{k_i}) = -\frac{1}{2}(b_i + d_i) R_{ii}^{-1} g_i^T(x_i^{k_i}) (\nabla \sigma_i(e_i^{k_i}))^T \hat{W}_{ci} \quad (7.28)$$

估计的事件触发哈密顿函数可表示为

$$H_i(e_i, \hat{W}_{ci}, \hat{\mu}_i(e_i^{k_i})) = r_i(e_i, \hat{\mu}_i(e_i^{k_i})) + \hat{W}_{ci}^T \nabla \sigma_i(e_i) \left(f_{ei}(t) + g_i(x_i) \hat{\mu}_i(e_i^{k_i}) - \sum_{j \in \mathbb{N}_i} a_{ij} g_j(x_j) \hat{u}_j \right) \stackrel{\Delta}{=} e_{ci} \quad (7.29)$$

考虑到 $H_i(e_i, u_i^*, \nabla J_i^*(e_i)) = 0$, 需要通过调整估计权值 $\hat{W}_{ci}$ 使得 $\hat{W}_{ci} \rightarrow W_{ci}$, 从而保证 $H_i(e_i, \hat{W}_{ci}, \hat{\mu}_i(e_i^{k_i})) \rightarrow 0$ 。换言之, 需要设计评价网络权值更新律 $\dot{\hat{W}}_{ci}$ 最小化如下目标函数:

$$E_{ci} = \frac{1}{2} e_{ci}^T e_{ci} \quad (7.30)$$

在假设 7.2 基础上, 基于梯度下降法, 评价网络权值更新律 $\dot{\hat{W}}_{ci}$ 设计为

$$\dot{\hat{W}}_{ci} = -\frac{\alpha_i \phi_i}{m_{si}^2} e_{ci} + \frac{\alpha_i}{2} (b_i + d_i) \nabla \sigma_i(e_i^{k_i}) g_i(x_i^{k_i}) R_{ii}^{-1} g_i^T(x_i^{k_i}) \nabla J_{si}(e_i) \quad (7.31)$$

其中, $\phi_i = \nabla \sigma_i(e_i) \left(f_{ei}(t) + (b_i + d_i) g_i(x_i) \hat{\mu}_i(e_i^{k_i}) - \sum_{j \in \mathbb{N}_i} a_{ij} (g_j(x_j) \hat{u}_j) \right) \in \mathbb{R}^L$, $\alpha_i > 0$ 表示评价网络学习率, $m_{si} = 1 + \phi_i^T \phi_i$ 。

通过定义评价网络权值估计误差 $\tilde{W}_{ci} = W_{ci} - \hat{W}_{ci}$, 结合式(7.24)、式(7.29)和式(7.31), 可得评价网络权值估计误差动态为

$$\dot{\tilde{W}}_{ci} = -\alpha_i \phi_i \phi_i^T \tilde{W}_{ci} + \alpha_i \frac{\phi_i}{m_{si}} \delta_{HJB_i} - \frac{\alpha_i}{2} (b_i + d_i) \nabla \sigma_i(e_i^{k_i}) g_i(x_i^{k_i}) R_{ii}^{-1} g_i^T(x_i^{k_i}) \nabla J_{si}(e_i) \quad (7.32)$$

其中, $\phi_i = \phi_i / m_{si} \in \mathbb{R}^L$ 。

基于上述分析, 可知该事件驱动的闭环系统表现出脉冲动力系统的特性, 即在 $t \in [t_k, t_{k+1})$, $k_i \in \mathbb{N}$ 表现出连续系统特性, 而在 $t = t_{k_i+1}$, $k_i \in \mathbb{N}$ 时刻却表现出离散系统特性。如果定义增广状态为 $\Psi_i = [e_i^T, e_i^{k_i T}, \tilde{W}_{ci}^T]^T$ 。那么在 $t \in [t_{k_i}, t_{k_i+1})$, $k_i \in \mathbb{N}$ 时刻的连续系统可描述为

$$\dot{\Psi}_i = \begin{bmatrix} \Gamma_i(\Psi_i) \\ 0 \\ \Theta_i(\Psi_i) \end{bmatrix}, \quad t \in [t_{k_i}, t_{k_i+1}), k_i \in \mathbb{N} \quad (7.33)$$

其中,

$$\begin{aligned} \Gamma_i(\Psi_i) &= f_{ci}(t) + g_i(x_i) \hat{\mu}_i(e_i^{k_i}) - \sum_{j \in \mathbb{N}_i} a_{ij} g_j(x_j) \hat{u}_j \\ \Theta_i(\Psi_i) &= -\alpha_i \varphi_i \varphi_i^T \tilde{W}_{ci} + \alpha_i \frac{\varphi_i}{m_{si}} \delta_{HJBi} - \frac{\alpha_i}{2} (b_i + d_i) \nabla \sigma_i(e_i^{k_i}) g_i(x_i^{k_i}) R_{ii}^{-1} g_i(x_i) \nabla J_{si}(e_i). \end{aligned}$$

在 $t = t_{k_i+1}, k_i \in \mathbb{N}$ 时刻的离散系统则描述为

$$\Psi_i(t) = \Psi_i(t^-) + \begin{bmatrix} 0 \\ e_i^{k_i} - e_i \\ 0 \end{bmatrix}, \quad t = t_{k_i+1}, k_i \in \mathbb{N} \quad (7.34)$$

其中, $\Psi_i(t^-) = \lim_{\zeta \rightarrow 0} \Psi_i(t - \zeta), \zeta \in (0, t_{k_i+1} - t_{k_i})$ 。

综上所述,本章提出的基于事件触发机制的分布式最优控制律能够通过构建评价网络结构,在线执行。为了更加清楚地展现本章提出的事件触发分布式最优控制方案,给出了所提控制方案的控制结构示意图,如下图 7.1 所示:




图 7.1 事件触发分布式最优控制结构图

7.5 稳定性分析

本节将分析该事件触发条件下闭环系统的稳定性。在此之前,针对非线性函数 $g_i(x_i)$ 以及评价网络,分别给出下列假设条件:

假设 7.3 ^[108]: 针对第 i 个智能体,非线性函数 $g_i(x_i)$ 是有界的且局部 Lipschitz 连续,即存在正常数 g_{Mi} 和 L_{gi} ,使得不等式 $\|g_i(x_i)\| \leq g_{Mi}$ 和 $\|g_i(x_i) - g_i(x_i^{k_i})\| \leq L_{gi} \|z_i^{k_i}(t)\|$ 成立。

假设 7.4 ^[106]: 针对第 i 个智能体,评价网络理想权值向量 W_{ci} 有界,满足 $\|W_{ci}\| \leq W_{Mi}$,其中, W_{Mi}

为正常数；假设激励函数 $\sigma_i(e_i)$ 、逼近误差 $\varepsilon_i(e_i)$ 以及它们的偏导数 $\nabla \sigma_i(e_i)$ 和 $\varepsilon_i(e_i)$ 在紧集 Ω_{e_i} 内均有界，即存在正常数 $\sigma_{Mi}, \varepsilon_{Mi}, b_{\sigma_i}$ 和 b_{ε_i} ，使得不等式 $\|\sigma_i(e_i)\| \leq \sigma_{Mi}$ ， $\|\varepsilon_i(e_i)\| \leq \varepsilon_{Mi}$ ， $\|\nabla \sigma_i(e_i)\| \leq b_{\sigma_i}$ 以及 $\|\nabla \varepsilon_i(e_i)\| \leq b_{\varepsilon_i}$ 成立；残余误差项满足 $\|\delta_{HJBi}\| \leq \delta_{Mi}$ ，其中， $\delta_{Mi} > 0$ 表示常数；进一步假设 $\nabla \sigma_i(e_i)$ 是 Lipschitz 局部连续的，满足条件 $\|\nabla \sigma_i(e_i) - \nabla \sigma_i(e_i^{k_i})\| \leq \mathcal{L}_{\sigma_i} \|z_i^{k_i}(t)\|$ ，其中， $\mathcal{L}_{\sigma_i}$ 为正常数。

下面给出本章主要定理，保证在评价网络结构下闭环系统的稳定性。

定理 7.2: 考虑第 i 个智能体的局部邻域误差动态系统(7.4)以及给定的合作型性能指标函数(7.5)。在假设 7.1-假设 7.4 成立的前提下，设计事件驱动分布式最优控制律为(7.22)，评价网络权值更新律为(7.31)；进一步假设第 i 个智能体的邻域智能体均处于稳定状态；那么设计如下自适应事件触发条件：

$$\|z_i^{k_i}(t)\|^2 \leq \bar{z}_{Ti} = \frac{(1 - \eta_{i,2}^2) e_i^T Q_i e_i + \|r_{ii}^T \hat{\mu}_i(e_i^{k_i})\|^2}{2(b_i + d_i)^2 \lambda_{\mathcal{L}_i} \|R_{ii}\| \|\hat{W}_{ci}\|} \quad (7.35)$$

其中， $\bar{z}_{Ti}$ 表示事件触发阈值， $\eta_{i,2} \in (0, 1)$ 为设计参数， $\lambda_{\mathcal{L}_i} = g_{Mi}^2 \mathcal{L}_{\sigma_i}^2 + \mathcal{L}_{g_i}^2 b_{\sigma_i}^2$ 将在后续证明中给出。则可保证闭环系统最终一致有界稳定，并且评价网络权值估计误差 $\tilde{W}_{ci}$ 最终一致有界。

证明：选择 Lyapunov 函数为

$$L_{2i}(t) = L_{21i}(t) + L_{22i}(t) + L_{23i}(t) + L_{24i}(t) \quad (7.36)$$

其中， $L_{21i}(t) = J_i^*(e_i)$ ， $L_{22i}(t) = J_i^*(e_i^{k_i})$ ， $L_{23i}(t) = \frac{1}{2} \tilde{W}_{ci}^T \tilde{W}_{ci}$ 以及 $L_{24i}(t) = \alpha_i J_{si}(e_i)$ 。

考虑到事件触发机制的引入使得闭环系统分成了连续动力系统和离散动力系统两部分，下面将分别讨论其稳定性。

情形 1: 在 $t \in [t_{k_i}, t_{k_i+1})$ ， $k_i \in \mathbb{N}$ 时刻，事件没有被触发，此时有 $\dot{L}_{22i}(t) = 0$ 。

通过对 $L_{21i}(t)$ 求导，有

$$\dot{L}_{21i}(t) = (\nabla J_i^*(e_i))^T \left(f_{ei}(t) + g_i(x_i) \hat{\mu}_i(e_i^{k_i}) - \sum_{j \in \mathbb{N}_i} a_{ij} g_j(x_j) \hat{u}_j \right) \quad (7.37)$$

结合式(7.8)和式(7.9)，式(7.37)可变换为

$$\begin{aligned} \dot{L}_{21i}(t) = & -Q_i(e_i) + u_i^{*T} R_{ii} u_i^* - \sum_{j \in \mathbb{N}_i} a_{ij} u_j^{*T} R_{ij} u_j^* + \sum_{j \in \mathbb{N}_i} a_{ij} (\nabla J_i^*(e_i))^T g_j(x_j) u_j^* \\ & - 2u_i^{*T} R_{ii} \hat{\mu}_i(e_i^{k_i}) - \sum_{j \in \mathbb{N}_i} a_{ij} (\nabla J_i^*(e_i))^T g_j(x_j) \hat{u}_j \end{aligned} \quad (7.38)$$

将式(7.38)整理为完全平方形式，可以得到

$$\begin{aligned} \dot{L}_{21i}(t) = & -Q_i(e_i) + \|r_{ii}^T [u_i^* - \hat{\mu}_i(e_i^{k_i})]\|^2 - \|r_{ii}^T \hat{\mu}_i(e_i^{k_i})\|^2 - \sum_{j \in \mathbb{N}_i} a_{ij} u_j^{*T} R_{ij} u_j^* \\ & + \sum_{j \in \mathbb{N}_i} a_{ij} (\nabla J_i^*(e_i))^T g_j(x_j) (u_j^* - \hat{u}_j) \end{aligned} \quad (7.39)$$

如果假设第 i 个智能体的邻域智能体都是稳定的，并进一步考虑假设 7.3 和假设 7.4 易得，非线性项 $\sum_{j \in \mathbb{N}_i} a_{ij} (\nabla J_i^*(e_i))^T g_j(x_j) (u_j^* - \hat{u}_j)$ 是有界的，即满足 $\left\| \sum_{j \in \mathbb{N}_i} a_{ij} (\nabla J_i^*(e_i))^T g_j(x_j) (u_j^* - \hat{u}_j) \right\| \leq \varpi_{li}$ ，其中， $\varpi_{li} > 0$ 为常数。

于是式(7.39)可重新表示为

$$\dot{L}_{21i}(t) \leq -e_i^T Q_i e_i + \|R_{ii}\| \|u_i^* - \hat{\mu}_i(e_i^{k_i})\|^2 - \|r_{ii}^T \hat{\mu}(e_i^{k_i})\|^2 + \varpi_{1i} \quad (7.40)$$

基于事件触发分布式最优控制律(7.28), 可得

$$\begin{aligned} u_i^* - \hat{\mu}_i(e_i^{k_i}) = & -\frac{1}{2}(b_i + d_i)R_{ii}^{-1} \left[g_i^T(x_i)(\nabla \sigma_i(e_i))^T - g_i^T(x_i^{k_i})(\nabla \sigma_i(e_i^{k_i}))^T \right] \hat{W}_{ci} \\ & - \frac{1}{2}(b_i + d_i)R_{ii}^{-1} \left[g_i^T(x_i) \left((\nabla \sigma_i(e_i))^T \tilde{W}_{ci} + \nabla \varepsilon_i(e_i) \right) \right] \end{aligned} \quad (7.41)$$

基于 Young 不等式, 式(7.41)可变换为

$$\begin{aligned} \|u_i^* - \hat{\mu}_i(e_i^{k_i})\|^2 \leq & (b_i + d_i)^2 \|R_{ii}^{-1}\|^2 \left\{ \left\| \left[g_i^T(x_i)(\nabla \sigma_i(e_i))^T - g_i^T(x_i^{k_i})(\nabla \sigma_i(e_i^{k_i}))^T \right] \hat{W}_{ci} \right\|^2 \right. \\ & \left. + \left\| g_i^T(x_i) \left((\nabla \sigma_i(e_i))^T \tilde{W}_{ci} + \nabla \varepsilon_i(e_i) \right) \right\|^2 \right\} \end{aligned} \quad (7.42)$$

考虑假设 7.3 和假设 7.4, 下列不等式关系成立:

$$\begin{aligned} & \|g_i^T(x_i)(\nabla \sigma_i(e_i))^T - g_i^T(x_i^{k_i})(\nabla \sigma_i(e_i^{k_i}))^T\|^2 \\ = & \|g_i^T(x_i)(\nabla \sigma_i(e_i) - \nabla \sigma_i(e_i^{k_i}))^T - (g_i(x_i) - g_i(x_i^{k_i}))^T (\nabla \sigma_i(e_i^{k_i}))^T\|^2 \\ \leq & 2\|g_i^T(x_i)(\nabla \sigma_i(e_i) - \nabla \sigma_i(e_i^{k_i}))^T\|^2 + 2\|(g_i(x_i) - g_i(x_i^{k_i}))^T (\nabla \sigma_i(e_i^{k_i}))^T\|^2 \\ \leq & 2\lambda_{Li} \|z_i^{k_i}(t)\|^2 \end{aligned} \quad (7.43)$$

将式(7.42)和式(7.43)代入, 式(7.40)可进一步表示为

$$\begin{aligned} \dot{L}_{21i}(t) \leq & -e_i^T Q_i e_i - \|r_{ii}^T \hat{\mu}_i(e_i^{k_i})\|^2 + 2(b_i + d_i)^2 \lambda_{Li} \|R_{ii}^{-1}\|^2 \|\hat{W}_{ci}\|^2 \|z_i^{k_i}(t)\|^2 \\ & + (b_i + d_i)^2 g_{Mi}^2 b_{\sigma_i}^2 \|R_{ii}^{-1}\|^2 \|\tilde{W}_{ci}\|^2 + (b_i + d_i)^2 g_{Mi}^2 b_{\sigma_i}^2 \|R_{ii}^{-1}\| + \varpi_{1i} \end{aligned} \quad (7.44)$$

接下来, 对 $L_{23i}(t)$ 求导, 可得

$$\dot{L}_{23i}(t) = -\alpha_i \tilde{W}_{ci}^T \varphi_i \varphi_i^T \tilde{W}_{ci} + \alpha_i \tilde{W}_{ci}^T \frac{\varphi_i}{m_{si}} \delta_{HJBi} - \frac{\alpha_i}{2} (b_i + d_i) \tilde{W}_{ci}^T \nabla \sigma_i(e_i^{k_i}) g_i(x_i^{k_i}) R_{ii}^{-1} g_i^T(x_i) \nabla J_{si}(e_i) \quad (7.45)$$

考虑到 $m_{si} \geq 1$, 并再次利用 Young 不等式, 得

$$\tilde{W}_{ci}^T \frac{\varphi_i}{m_{si}} \delta_{HJBi} \leq \frac{1}{2\gamma_i^2} \|\tilde{W}_{ci}\|^2 + \frac{\gamma_i^2}{2} \alpha_i^2 \delta_{Mi}^2 \quad (7.46)$$

其中, $\gamma_i > 0$ 为需要设计的正常数。

将式(7.46)代入, 化简整理可得

$$\begin{aligned} \dot{L}_{23i}(t) \leq & -(\alpha_i - \frac{1}{2\gamma_i^2}) \lambda_{\min}(\varphi_i \varphi_i^T) \|\tilde{W}_{ci}\|^2 + \frac{\gamma_i^2}{2} \alpha_i^2 \delta_{Mi}^2 - \alpha_i (\nabla J_{si}(e_i))^T g_i(x_i) (\mu_i^*(e_i^{k_i}) - \hat{\mu}_i(e_i^{k_i})) \\ & - \frac{\alpha_i}{2} (b_i + d_i) (\nabla J_{si}(e_i))^T g_i(x_i) R_{ii}^{-1} g_i^T(x_i^{k_i}) \nabla \varepsilon_i(e_i^{k_i}) \end{aligned} \quad (7.47)$$

其中, $\lambda_{\min}(\varphi_i \varphi_i^T)$ 表示矩阵 $\varphi_i \varphi_i^T$ 的最小特征值。

对 $L_{24i}(t)$ 求导, 可得

$$\dot{L}_{24i}(t) = \alpha_i (\nabla J_{si}(e_i))^T \left(f_{ci}(t) + g_i(x_i) \hat{\mu}_i(e_i^{k_i}) - \sum_{j \in \mathbb{N}_{\bar{N}_i}} a_{ij} g_j(x_j) \hat{u}_j \right) \quad (7.48)$$

将式(7.44)、式(7.47)和式(7.48)代入, 可得 Lyapunov 函数 $L_{2i}(t)$ 的导数为

$$\begin{aligned}
 \dot{L}_{2i}(t) \leq & -e_i^T Q_i e_i - \|r_{ii}^T \hat{\mu}_i(e_i^{k_i})\|^2 + 2(b_i + d_i)^2 \lambda_{\varepsilon i} \|R_{ii}^{-1}\| \|\hat{W}_{ci}\|^2 \|z_i^{k_i}(t)\|^2 \\
 & - \left[\left(\alpha_i - \frac{1}{2\gamma_i^2} \right) \lambda_{\min}(\varphi_i \varphi_i^T) - (b_i + d_i)^2 g_{Mi}^2 b_{\sigma_i}^2 \|R_{ii}^{-1}\| \right] \|\tilde{W}_{ci}\|^2 \\
 & + (b_i + d_i)^2 g_{Mi}^2 b_{\sigma_i}^2 \|R_{ii}^{-1}\| + \varpi_{li} + \frac{\gamma_i^2}{2} \alpha_i^2 \delta_{Mi}^2 \\
 & + \alpha_i (\nabla J_{si}(e_i))^T \left(f_{ei}(t) + g_i(x_i) \mu_i^*(e_i^{k_i}) - \sum_{j \in \mathbb{N}_i} a_{ij} g_j(x_j) u_j^* \right) \\
 & + \sum_{j \in \mathbb{N}_i} a_{ij} (\nabla J_{sj}(e_j))^T g_j(x_j) (u_j^* - \hat{u}_j) \\
 & - \frac{\alpha_i}{2} (b_i + d_i) (\nabla J_{si}(e_i))^T g_i(x_i) R_{ii}^{-1} g_i^T(x_i^{k_i}) \nabla \varepsilon_i(e_i^{k_i})
 \end{aligned} \tag{7.49}$$

与前面所述一样, 如果假设邻域智能体是稳定的, 则非线性项 $\sum_{j \in \mathbb{N}_i} a_{ij} (\nabla J_{sj}(e_j))^T g_j(x_j) (u_j^* - \hat{u}_j)$ 可以认为是有界的, 且满足 $\left\| \sum_{j \in \mathbb{N}_i} a_{ij} (\nabla J_{sj}(e_j))^T g_j(x_j) (u_j^* - \hat{u}_j) \right\| \leq \varpi_{2i}$, 其中, $\varpi_{2i} > 0$ 为正常数。

基于假设 7.2-假设 7.4, 对式(7.49)化简整理, 可得

$$\begin{aligned}
 \dot{L}_{2i}(t) \leq & -e_i^T Q_i e_i - \|r_{ii}^T \hat{\mu}_i(e_i^{k_i})\|^2 + 2(b_i + d_i)^2 \lambda_{\varepsilon i} \|R_{ii}^{-1}\| \|\hat{W}_{ci}\|^2 \|z_i^{k_i}(t)\|^2 \\
 & - \left[\left(\alpha_i - \frac{1}{2\gamma_i^2} \right) \lambda_{\min}(\varphi_i \varphi_i^T) - (b_i + d_i)^2 g_{Mi}^2 b_{\sigma_i}^2 \|R_{ii}^{-1}\| \right] \|\tilde{W}_{ci}\|^2 \\
 & - \alpha_i \lambda_{\min}(\Lambda_i(e_i)) \left[\|\nabla J_{si}(e_i)\| - \frac{(b_i + d_i) \kappa_{2i}}{4 \lambda_{\min}(\Lambda_i(e_i))} \right]^2 + \Xi_i
 \end{aligned} \tag{7.50}$$

其中, $\Xi_i = (b_i + d_i)^2 \kappa_{2i} + \varpi_{li} + \varpi_{2i} + \frac{\gamma_i^2}{2} \alpha_i^2 \delta_{Mi}^2 + \frac{\alpha_i (b_i + d_i)^2 \kappa_{2i}^2}{16 \lambda_{\min}(\Lambda_i(e_i))}$, $\kappa_{2i} = g_{Mi}^2 b_{\sigma_i}^2 \|R_{ii}^{-1}\|$ 。

观察式(7.50), 为保证闭环系统的稳定性可通过选择设计参数, 保证下列不等式成立:

$$\left(\alpha_i - \frac{1}{2\gamma_i^2} \right) \lambda_{\min}(\varphi_i \varphi_i^T) - (b_i + d_i)^2 g_{Mi}^2 b_{\sigma_i}^2 \|R_{ii}^{-1}\| > 0$$

在此基础上, 如果设计自适应事件触发条件如式(7.35)所示, 并且使得评价网络权值估计误差信号 $\tilde{W}_{ci}$ 满足如下不等式关系:

$$\|\tilde{W}_{ci}\| \geq \sqrt{\frac{\Xi_i}{\left(\alpha_i - \frac{1}{2\gamma_i^2} \right) \lambda_{\min}(\varphi_i \varphi_i^T) - (b_i + d_i)^2 g_{Mi}^2 b_{\sigma_i}^2 \|R_{ii}^{-1}\|}} \tag{7.51}$$

那么可以保证, 对于 $\forall e_i \neq 0$, 有 $\dot{L}_{2i}(t) \leq -\eta_{i,2}^2 e_i^T Q_i e_i < 0$ 。根据 Lyapunov 稳定性定理可知, 在 $t \in [t_{k_i}, t_{k_i+1})$, $k_i \in \mathbb{N}$ 时间段内, 闭环系统的最终一致有界稳定性得以保证。

情形 2: 在任意的 $t = t_{k_i+1}$ 时刻, 事件被触发。

在这种情况下, 闭环系统表现出离散动力学特性。考虑 Lyapunov 函数的差分方程, 具体表示为

$$\begin{aligned}
 \Delta L_{2i}(t_{k_i}) &= L_{2i}(e_i^{k_i+1}) - L_{2i}(e_i(t^-)) \\
 &= \Delta L_{21i}(t_{k_i}) + \Delta L_{22i}(t_{k_i}) + \Delta L_{23i}(t_{k_i}) + \Delta L_{24i}(t_{k_i})
 \end{aligned} \tag{7.52}$$

其中, $e_i(t^-) = \lim_{\varsigma \rightarrow 0} e_i(t_{k_i+1} - \varsigma)$, $\varsigma \in (0, t_{k_i+1} - t_{k_i})$, $\Delta L_{21i}(t_{k_i}) = J_i^*(e_i^{k_i+1}) - J_i^*(e_i(t^-))$, $\Delta L_{22i}(t_{k_i}) = J_i^*(e_i^{k_i+1}) - J_i^*(e_i^{k_i})$,

$$\Delta L_{23i}(t_{k_i}) = \frac{1}{2} [\tilde{W}_{ci}^T(e_i^{k_i+1}) \tilde{W}_{ci}(e_i^{k_i+1}) - \tilde{W}_{ci}^T(e_i(t^-)) \tilde{W}_{ci}(e_i(t^-))], \quad \Delta L_{24i}(t_{k_i}) = J_{si}^*(e_i^{k_i+1}) - J_{si}^*(e_i(t^-)).$$

基于不等式(7.35)、式(7.51)和式(7.52)可知, 在时间 $t \in [t_{k_i}, t_{k_i+1})$ 内, 有 $\dot{L}_{2i}(t) < 0$ 。进一步考虑到局部误差动态系统中状态变量以及合作型代价函数均为连续信号, 可以得到 $L_{2i}(e_i^{k_i+1}) < L_{2i}(e_i(t^-))$ 。换言之, 在这种情况下, 下列不等式均成立:

$$\Delta L_{21i}(t_{k_i}) = J_i^*(e_i^{k_i+1}) - J_i^*(e_i(t^-)) \leq 0 \quad (7.53)$$

$$\Delta L_{23i}(t_{k_i}) = \frac{1}{2} [\tilde{W}_{ci}^T(e_i^{k_i+1}) \tilde{W}_{ci}(e_i^{k_i+1}) - \tilde{W}_{ci}^T(e_i(t^-)) \tilde{W}_{ci}(e_i(t^-))] \leq 0 \quad (7.54)$$

$$\Delta L_{24i}(t_{k_i}) = J_{si}^*(e_i^{k_i+1}) - J_{si}^*(e_i(t^-)) \leq 0 \quad (7.55)$$

结合式(7.53)-式(7.55), 可以得到如下不等式关系:

$$\Delta L_{2i}(t_{k_i}) \leq \Delta L_{22i}(t_{k_i}) = J_i^*(e_i^{k_i+1}) - J_i^*(e_i^{k_i}) \leq -\kappa(\|s_i^{k_i+1}(t_{k_i})\|) \quad (7.56)$$

其中, $\kappa(\cdot)$ 属于 κ 类函数^[166]以及 $h_i^{k_i+1}(t_{k_i}) = e_i^{k_i+1} - e_i^{k_i}$ 。这样就可以保证在任意的 $t = t_{k_i+1}$ 时刻, $\Delta L_{2i}(t_{k_i}) < 0$ 。

结合上述两种情形可以得出, 只要设计自适应触发条件如式(7.35)所示, 且评价网络权值估计误差信号 $\tilde{W}_{ci}$ 满足不等式(7.51), 就可以保证事件触发机制下的闭环系统的稳定性以及闭环系统信号的最终一致有界性。

注释 7.3: 值得注意的是, 式(7.14)中给出的自适应之间触发条件和式(7.35)中给出的触发条件略有不同。事实上, 可以把式(7.35)给出的触发条件看作是式(7.14)的估计形式。在评价网络学习过程中, 事件触发分布式自适应最优控制律在自适应事件触发条件(7.35)作用下更新控制策略; 同时保证评价网络估计权值估计误差 $\tilde{W}_{ci}$ 有界。当评价网络学习过程结束, 在自适应事件触发条件(7.14)作用下, 将学习得到的分布式最优控制律将作用于原系统, 实现非线性多智能系统的分布式自适应最优控制。从式(7.14)和式(7.35)可以看出, 设计参数 $\eta_{i,1}$ 和 $\eta_{i,2}$ 的选择将直接导致不同的事件触发条件, 从而影响控制器的采样频率。一旦控制器采样频率改变, 则势必会影响控制精度。在实际工程中面对具体的控制对象时, 往往需要通过调节参数 $\eta_{i,1}$ 和 $\eta_{i,2}$ 来权衡控制精度和控制器计算量之间的问题。

7.6 最小驻留时间分析

本节将通过对最小驻留时间的分析, 确保闭环系统在学习过程中不会出现芝诺行为。针对连续非线性多智能体系统, 在事件触发分布式自适应最优控制律作用下, 定义最小驻留时间为

$$(\Delta t_{k_i})_{\min} = \min_{j \in \mathbb{N}} \{t_{k_i+1} - t_{k_i}\} \quad (7.57)$$

接着给出如下定理, 从理论上保证最小驻留时间有下界且下界值为非零正常数。

定理 7.3: 考虑局部误差动态系统(7.4), 在事件驱动分布式自适应最优控制律(7.22)以及自适应事件触发条件(7.35)作用下, 最小驻留时间 $(\Delta t_{k_i})_{\min}$ 是有下界的且满足不等式

$$(\Delta t_{k_i})_{\min} \geq \frac{1}{\ell_{1i}} \ln(1 + \bar{h}_i) > 0 \quad (7.58)$$

其中, ℓ_{1i} 和 $\bar{h}_i$ 均为正常数。

证明: 在事件触发分布式最优协同控制律(7.22)作用下, 第 i 个智能体的局部协同误差闭环系统可表述为

$$\dot{e}_i = f_{ei}(t) - \frac{1}{2}(b_i + d_i)^2 g_i(x_i) R_{ii}^{-1} g_i^T(x_i) (\nabla \sigma_i(e_i^{k_i}))^T \hat{W}_{ci} - \sum_{j \in \mathbb{N}_i} a_{ij} g_j(x_j) \hat{u}_j \quad (7.59)$$

考虑到非线性函数 $f_{ei}(t)$ 是局部 Lipschitz 连续的, 有 $\|f_{ei}(t)\| \leq \ell_{1i} \|e_i\|$, 其中, ℓ_{1i} 为正常数。另外, 基于定理 7.2, 可以得到评价网络估计权值 $\hat{W}_{ci}$ 是有界的, i.e., $\|\hat{W}_{ci}\| \leq \lambda_{\hat{W}_{ci}}$, 其中, $\lambda_{\hat{W}_{ci}}$ 为正常数。进一步可以确定非线性项 $\sum_{j \in \mathbb{N}_i} a_{ij} g_j(x_j) \hat{u}_j$ 也是有界的, 即存在一个正常数 ϖ_{3i} , 使得不等式

$$\left\| \sum_{j \in \mathbb{N}_i} a_{ij} g_j(x_j) \hat{u}_j \right\| \leq \varpi_{3i} \text{ 成立。}$$

基于上述分析, 式(7.59)可变换为如下形式:

$$\|\dot{e}_i\| \leq \ell_{1i} \|e_i\| + \ell_{2i} \quad (7.60)$$

其中, $\ell_{2i} = \frac{1}{2}(b_i + d_i)^2 g_{Mi}^2 \sigma_{Mi} \lambda_{\hat{W}_{ci}} \|R_{ii}^{-1}\| + \varpi_{3i}$ 。

在 $t \in [t_{k_i}, t_{k_i+1})$, $k_i \in \mathbb{N}$ 时刻内, 对分布式事件触发误差信号 $z_i^{k_i}(t)$ 求导, 可得 $\dot{z}_i^{k_i}(t) = -\dot{e}_i$ 。考虑式(7.60), 下列不等式成立:

$\|\dot{z}_i^{k_i}(t)\| \leq \ell_{1i} \|z_i^{k_i}(t)\| + \ell_{1i} \|e_i^{k_i}\| + \ell_{2i}$, $\forall t \in [t_{k_i}, t_{k_i+1})$ (7.61) 应用比较原理^[166], 并考虑到初始条件 $z_i^{k_i}(0) = e_i^{k_i}(0) - e_i(0) = 0$, 可以得到下列不等式:

$$\|z_i^{k_i}(t)\| \leq \frac{\ell_{1i} \|e_i^{k_i}\| + \ell_{2i}}{\ell_{1i}} \left[e^{\ell_{1i}(t-t_{k_i})} - 1 \right] \quad \forall t \in [t_{k_i}, t_{k_i+1}) \quad (7.62)$$

由(7.62)易得

$$t_{k_i+1} - t_{k_i} \geq \frac{1}{\ell_{1i}} \ln(1 + \bar{h}_i^{k_i}) > 0 \quad (7.63)$$

其中, $\bar{h}_i^{k_i} = \frac{\ell_{1i} \|z_i^{k_i}(t_{k_i+1})\|}{\ell_{1i} \|e_i^{k_i}\| + \ell_{2i}} > 0$ 以及 $z_i^{k_i}(t_{k_i+1}) = e_i^{k_i} - e_i(t_{k_i+1})$ 。

如果把变量 $\bar{h}_i^{k_i}$, $k_i \in \mathbb{N}$ 表示为 $\bar{h}_i = \min_{k \in \mathbb{N}} \bar{h}_i^{k_i}$, 那么可以看到最小驻留时间 $(\Delta t_{k_i})_{\min}$ 满足不等式(7.58)。定理证毕。

7.7 仿真验证

为了验证所提方案的有效性, 本节将上述理论应用于多导弹协同拦截制导问题中, 提出基于事件触发机制的多弹分布式最优协同拦截制导方案, 实现多弹同时拦截机动目标的任务。本节首先建立多导弹协同拦截机动目标的非线性系统, 然后通过数值仿真方式, 验证本方案的有效性。

7.7.1 多弹协同拦截制导应用

基于第六章建立的多导弹协同拦截制导运动学方程, 本节采用显示协同制导方式, 实现所

有导弹同时攻击目标的任务。为此, 本节将剩余距离作为协同变量, 通过控制各枚导弹与目标的剩余距离 $r_1, \dots, r_N$, 使它们同时趋于零; 从而保证所有导弹同时击中目标。

选择状态变量为 $x_i = [x_{i1}, x_{i2}]^T = [r_i, \dot{r}_i]^T$, 经变换可得, 多导弹协同拦截制导系统可表述为如式(7.1)所示非线性多智能体系统, 具体表示为

$$\dot{x}_i = f_i(x_i) + g_i(x_i)u_i + d_i \quad (7.64)$$

其中, $f_i(x_i) = \begin{pmatrix} x_{i2} \\ \dot{x}_{i2} \end{pmatrix}$, $g_i(x_i) = \begin{pmatrix} 0 \\ \sin(\alpha_i - \theta_i) \end{pmatrix}$; 非线性项 $d_i = \begin{pmatrix} 0 \\ -\sin(\beta - \theta_i)v \end{pmatrix}$ 表示由目标机动造成的干扰。

基于式(7.64), 多导弹协同制导问题就可以转化为非线性多智能体系统的协同控制问题。我们的主要目的就是通过设计事件触发的分布式自适应最优控制律, 保证系统(7.64)中状态变量 x_i 一致收敛于零, 从而实现多弹协同制导任务。

为简单起见, 对拦截制导系统作如下假设:

假设 7.5: 目标控制输入指令是有界的, 即存在一个正常数 ζ_v , 满足 $|v| \leq \zeta_v$ 。

假设 7.6: 多枚导弹在协同拦截制导过程中, 相互之间不存在碰撞问题。

基于以上分析, 可以得出本节多弹协同制导需要完成以下三个目标:

- 1) 保证所有导弹都能够击中目标, i.e., $r_i \rightarrow 0$;
- 2) 保证导弹与目标之间的剩余距离达成一致, i.e., $\lim_{t \rightarrow \infty} |r_i - r_j| \rightarrow 0$;
- 3) 保证导弹与目标之间的相对速率达成一致, i.e., $\lim_{t \rightarrow \infty} |\dot{r}_i - \dot{r}_j| \rightarrow 0$;

基于多弹协同拦截制导系统(7.64)以及导弹-目标相对运动关系可以看出, 当弹-目相对距离 $r_i \rightarrow 0$ 时, 非线性函数 $f_i(x_i) \rightarrow \infty$ 。此时拦截制导系统已被破坏, 设计的多弹协同制导律已不再适用。事实上在实际工程应用中, 由于导弹导引头的物理限制等因素, 一般情况下存在一个可接受的最小脱靶距离 ε_0 , 当 $r_i \leq \varepsilon_0$ 时, 制导过程结束, 此后完全依靠导弹自身惯性实现最后的拦截。另外, 与第六章类似, 事件触发分布式最优协同拦截制导方案的可行域为

$$\Omega = \{x_i : |\alpha_i - \theta_i| \neq 0, |\beta - \theta_i| \neq 0, r_i \neq 0, \dot{r}_i < 0\} \quad (7.65)$$

7.7.2 数值仿真

在本节中, 假设由 2 枚从弹和 1 枚领弹组成的多导弹系统协同拦截机动目标; 它们之间的通信拓扑结构如图 7.2 所示。




图 7.2 事件触发机制下多弹通信拓扑图

其中, 0 代表领弹, 1 和 2 分别表示 2 枚从弹。

在该通信拓扑结构下, 易得邻接矩阵为 $\mathcal{A} = \begin{bmatrix} 0 & 0 \\ 1 & 0 \end{bmatrix}$, 入度矩阵为 $\mathcal{D} = \text{diag}[0, 1]$, 与领弹的连接矩阵为 $\mathcal{B} = \text{diag}[1, 0]$ 。

假设在末制导阶段,所有导弹的飞行速度恒定且相等,即 $V_i = 600 \text{ m/s}$;目标飞行速度为常值 $V_T = 400 \text{ m/s}$;导弹与目标的自动驾驶仪时间常数假设为 $\tau_{Mi} = \tau_T = 0.1$ 。

接下来将针对不同目标机动形式,进行仿真验证。

情形 1: 目标阶跃机动, i.e., $a_T = 3g \text{ m/s}^2$

在这种情况下,假设目标机动为 $a_T = 3g \text{ m/s}^2$,其中, $g = 9.8 \text{ m/s}^2$;导弹与目标的初始航迹角假设为 $\alpha_0 = 45^\circ, \alpha_1 = 45^\circ, \alpha_2 = 45^\circ$ 以及 $\beta = 80^\circ$;领弹初始坐标位置设定为 $(0, 0)$,2枚从弹初始位置坐标分别为 $(200, 0)$ 和 $(400, 0)$;目标初始位置坐标假设为 $(1000, 1000)$ 。不妨假设领弹采用比例导引方法,导引律设计为 $u_0 = N\dot{r}_0\dot{\theta}_0$,其中,参数 $N = 5$,从而保证领弹能够成功拦截机动目标。如此,由领弹提供的参考信号 $x_0 = [r_0, \dot{r}_0]^T$ 即可用于本章所提事件触发分布式最优协同拦截制导方案中。

在基于事件触发机制的分布式自适应最优协同制导方案中,选择评价网络激励函数为 $\sigma_i(e_i) = [e_{i1}^2, e_{i1}e_{i2}, e_{i2}^2, e_{i1}^2e_{i2}, e_{i1}e_{i2}^2]^T$,初始权值向量为 $\hat{W}_{c1}(0) = [2, 2, 2, 2, 2]^T$ 和 $\hat{W}_{c2}(0) = [20, 20, 20, 20, 20]^T$;采样时间设定为 0.05 s 。针对从弹 1,选择 $Q_1(e_1) = e_1^T e_1, R_{11} = 1, R_{12} = 1$;学习率为 $\alpha_1 = 0.8$;设计参数选择为 $\eta_{1,2} = 0.5$ 和 $\lambda_{c1} = 150$;Lyapunov 函数选取为 $J_{s1}(e_1) = 0.5e_1^T e_1$ 。针对从弹 2,选择 $Q_2(e_2) = 20e_2^T e_2, R_{22} = 120, R_{21} = 1$;学习率设定为 $\alpha_2 = 0.004$;设计参数为 $\eta_{2,2} = 0.5$ 和 $\lambda_{c2} = 80$; $J_{s2}(e_2) = 0.001e_2^T e_2$ 。为保证评价网络在学习过程中信号持续激励,在制导过程中需要在制导律 $\mu_i(e_i^{k_i})$ 中加入一个较小的有界探索信号 $n_i(t) = 0.1\sin^5(t)\cos(t) + 0.5\sin^5(2t)\cos(0.2t)$ 。

仿真结果如图 7.3-图 7.6 所示。图 7.3(a)给出了所有导弹拦截机动目标的轨迹,从中可以看到,在不同初始位置发射的各枚导弹,由于它们与目标的相对距离不同,为了保证同时拦截,从弹 1 和从弹 2 需要通过“绕路”与领弹达成一致,从而保证领弹和从弹同时击中目标。图 7.3(b)刻画了 2 枚从弹在协同拦截过程中所需要的侧向加速度。




图 7.3(a) 导弹-目标拦截轨迹




图 7.3(b) 导弹侧向加速度

图 7.3 事件触发机制下多弹协同拦截轨迹和侧向加速度 (目标阶跃机动)

图 7.4(a)表明所有从弹和领弹与机动目标的相对距离逐渐减小,并同时到达容许脱靶量范围内,具体脱靶量以及拦截时间可见下表 7.1。从表 7.1 中可以清楚地看到,在容许脱靶量范围内,各枚导弹同时拦截机动目标的最大时间误差为 0.03 s ,能够保证同时攻击。图 7.4(b)给出了相对速率的响应曲线,从中可以看出各枚导弹的相对速率从不同初始条件下最终达成一致,从而完

成了本章协同制导中要求的三个目标。




图 7.4(a) 相对距离




图 7.4(b) 相对速率

图 7.4 事件触发机制下相对距离和相对速率（目标阶跃机动）




图 7.5(a) 事件触发条件




图 7.5(b) 评价网络权值范数

图 7.5 事件触发条件和评价网络权值范数（目标阶跃机动）




图 7.6 事件触发时刻（目标阶跃机动）

图 7.5(a)给出了 2 枚从弹各自的事件触发条件曲线，可以看出通过各自参数的调节，使得各枚导弹的事件触发条件不同。为了说明评价网络权值更新律的收敛性，给出了图 7.5(b)，评价网络权值在经过一段时间的学习后能够收敛于理想权值，从而保证闭环系统的稳定性。另外，图 7.6 描述了事件触发时刻，从中可以直观地得出本文分析的芝诺行为不会发生。

表 7.1 目标阶跃机动下的制导性能

	脱靶量(m)	拦截时间(s)
领弹	0.64	5.93
从弹 1	0.68	5.93
从弹 2	0.07	5.90

情形 2: 正弦机动, i.e., $a_T = 100 \sin(2t) \text{ m/s}^2$

这种情况下, 假设目标按正弦形式机动, 即 $a_T = 100 \sin(2t) \text{ m/s}^2$ 。选择导弹的初始航迹角为 $\alpha_0 = 45^\circ, \alpha_1 = 45^\circ, \alpha_2 = 135^\circ$, 领弹初始坐标位置为 $(0, 0)$, 从弹 1 和从弹 2 的初始位置坐标分别为 $(100, 0)$ 和 $(800, 0)$; 目标初始位置坐标假设为 $(500, 500)$; 此时选择领弹的制导增益为 $N = 15$ 。

评价网络激励函数和初始权值向量与情形 1 相同, 其他设计参数选取如下: 针对从弹 1, 选取 $Q_1(e_1) = e_1^T e_1, R_{11} = 1, R_{12} = 20$, 评价网络学习率为 $\alpha_1 = 0.5, \eta_{1,2} = 0.5, \lambda_{e1} = 50$; 考虑从弹 2, 选取 $Q_2(e_2) = e_2^T e_2, R_{22} = 100, R_{21} = 1, \alpha_2 = 0.04, \eta_{2,2} = 0.4, \lambda_{e2} = 0.6$ 。

仿真结果如图 7.7-图 7.9 所示。图 7.7(a)给出了在目标正弦机动情形下, 各枚导弹协同拦截目标的轨迹, 尽管目标以正弦机动形式逃逸, 在本章所提出的事件触发机制下的分布式最优协同制导律作用下, 能够保证所有拦截弹通过信息共享同时击中目标, 实现协同攻击的任务。图 7.7(b)给出了 2 枚从弹的侧向加速度响应曲线, 可以看到由于本章没有考虑输入饱和问题, 导弹所需控制输入幅值较大。图 7.8 给出了各导弹与目标的相对距离变化曲线和相对速率变化曲线, 表明协同拦截制导系统的状态向量均趋于一致, 实现了同时拦截目的; 具体制导性能可参考下表 7.2, 从中可以得出, 领弹和从弹能够以较小的脱靶量同时拦截机动目标, 实现协同拦截的目的。自适应事件触发条件变化曲线如图 7.9(a)所示; 图 7.9(b)表明在设计的权值更新律作用下, 评价网络权值最后收敛于理想值, 能够实现最优协同拦截。




图 7.7(a) 导弹-目标拦截轨迹

图 7.7(b) 导弹侧向加速度

图 7.7 事件触发机制下多弹协同拦截轨迹和侧向加速度 (目标正弦机动)




图 7.8(a) 相对距离

图 7.8(b) 相对速率

图 7.8 事件触发机制下相对距离以及相对速率 (目标正弦机动)




图 7.9(a) 事件触发条件




图 7.9(b) 评价网络权值范数

图 7.9 事件触发机制条件和评价网络权值范数（目标正弦机动）

表 7.2 目标正弦机动下的制导性能

	脱靶量(m)	拦截时间(s)
领弹	0.10	2.98
从弹 1	0.09	2.98
从弹 2	0.60	2.98

综上所述，可以得出这样的结论：在提出的基于事件触发机制的分布式自适应最优协同控制方案下，所有从弹能够一致跟随领弹在容许脱靶量范围内同时拦截机动目标，并且能够保证闭环系统所有信号的有界性。

7.8 本章小结

本章从多弹协同拦截机动目标的应用背景出发，研究在事件触发机制下的非线性多智能体系统的分布式自适应最优协同控制问题。首先通过设计自适应事件触发条件，保证了在事件触发分布式最优控制律作用下闭环系统的渐近稳定性。为了求解耦合 HJB 方程，构建了评价网络，设计了基于时间触发机制的评价网络权值更新律，保证了事件触发分布式最优控制律能够在线运行。利用 Lyapunov 稳定性定理，证明了闭环系统的稳定性。仿真验证了导弹能够在容许脱靶量范围内同时拦截目标，实现协同攻击的目的。然而需要指出的是，本章对评价网络权值更新律的设计仍然基于时间触发机制；同时也没有考虑输入饱和问题。因此进一步考虑输入饱和和约束，并同时设计基于事件触发机制的评价网络权值更新律不仅更加符合工程要求，也可以更大程度上节约计算资源。

第八章 总结与展望

8.1 主要工作总结

本文主要以导弹拦截制导为应用背景,将拦截制导问题描述为非线性系统的最优控制问题;在最优控制以及微分对策理论框架下,利用自适应动态规划(ADP)技术,主要针对拦截制导系统存在的内部扰动、外界干扰、输入饱和、输出约束、有限时域制导等一系列问题展开研究,提出了基于 ADP 技术的自适应最优拦截制导方案;提高了制导系统在复杂动态环境下的鲁棒性和可靠性;本文研究成果也进一步拓宽了 ADP 技术的应用范围,丰富和发展了 ADP 理论体系。本文主要研究工作为:

(1) 考虑拦截制导系统存在内部扰动、外界干扰等不确定项影响的情况,提出了基于微分对策的鲁棒自适应最优制导方案。设计了改进型微分对策控制策略,保证了闭环系统在干扰影响下的渐近稳定性和最优性;利用 ADP 技术构建了评价网络结构,在线执行微分对策控制策略,保证闭环系统的稳定性。

(2) 考虑拦截制导系统要求终端状态约束等特性以及过载饱和风险对系统的影响,提出了输入饱和条件下的基于微分对策的有限时域自适应最优拦截制导方案。构建时变评价网络结构在线逼近时变最优代价函数,满足终端约束条件,避免过载饱和风险。最后从理论上详细分析了闭环系统的稳定性并给出仿真验证结果。

(3) 考虑拦截制导系统存在输入饱和、输出约束等问题,提出了多约束条件下基于微分对策的自适应最优拦截制导方案。构建“前馈+反馈”控制结构,先后设计了前馈控制输入和反馈自适应最优控制输入,保证了闭环系统的稳定性和预定性能指标函数的最小化。

(4) 考虑 ADP 技术在高维非线性拦截制导系统中可能面临的计算复杂度问题,提出了基于 ADP 技术的自适应预测最优拦截制导方案。将 ADP 技术与连续时间预测控制方法相结合,构建“离线-在线”控制模式,有效降低 ADP 技术的计算复杂度,提高了控制器的鲁棒性。

(5) 针对多弹协同拦截机动目标的情形,提出了基于 ADP 技术的多弹自适应最优协同拦截制导方案。采用“领弹-从弹”协同模式,结合指令滤波 Backstepping 控制方法和 ADP 技术,提出了“前馈+反馈”控制结构,保证了协同变量的一致收敛性和闭环系统的稳定性。

(6) 考虑多弹协同拦截制导过程中计算和通信资源的节约问题以及各弹之间由于通信信道阻塞造成的脱靶现象,提出了基于事件触发机制的多弹分布式自适应最优协同拦截制导方案,将事件触发机制引入分布式最优控制律的设计中,有效节约了拦截制导系统的计算和通信资源,设计了自适应事件触发条件,保证闭环系统的渐近稳定性。

总之,本文主要是针对导弹拦截制导问题,为使其能够在复杂环境下能够根据外界环境的

变化以及系统自身的特性,具有轨迹自适应调整能力,从而自主应对突发情况,本文利用 ADP 技术,发展了一套基于 ADP 技术的自适应最优制导方案;该方案融合了自适应控制、最优控制、智能控制以及强化学习等方法,是一种新型的智能优化制导方案,对未来智能制导技术的发展具有重要的理论意义和潜在的应用前景。

然而,在复杂多变的战场环境中,拦截制导系统无疑会同时存在多源干扰(电磁干扰、噪声干扰、诱饵干扰、外界环境干扰等)、制导时间、过载饱和以及多约束等不同程度限制条件的影响,这对拦截制导系统的鲁棒性、自适应性、快速性以及计算能力等均提出更高的要求。因此,基于上述研究基础,进一步深入系统地发展易于工程实现的智能自主拦截制导律,对未来智能制导系统的发展具有重要的参考价值。

8.2 后续工作展望

本文将 ADP 技术应用于导弹拦截制导问题,提出了在线自适应最优拦截制导方案,并结合拦截制导系统的特点,进行了较为深入的研究,取得了一些初步的研究成果。然而,ADP 技术作为一种新型近似优化方法,对其理论的研究尚不完善,还需要进一步深入研究。另外,对基于 ADP 技术的拦截制导问题的研究才刚刚起步,还有很多值得深入探索研究的问题,主要包括:

(1) 针对现有 ADP 算法计算复杂度高、计算量较大等问题,提出一种能够克服上述缺点的新型 ADP 算法,将有助于完善 ADP 理论体系;并对 ADP 技术大量应用于实际系统具有重要的推动作用。

(2) 考虑拦截制导系统的复杂性以及战场环境的多变性,研究一种基于离线训练和在线学习相结合的自学习最优控制模式,不仅能够降低控制器的计算复杂度,而且还能自适应动态环境变化,提高拦截制导系统的鲁棒性和稳定性;从而对未来智能作战系统的开发具有重要的参考价值。

(3) 实际拦截制导系统中,可能存在多种不同形式的动态约束问题,而本文考虑的多约束条件均为形式较为简单的常值约束,有一定的局限性。因此考虑更加符合实际情况的复杂多约束条件,研究基于 ADP 技术的自适应最优制导问题还需要进一步深入分析。

(4) 考虑多弹协同制导过程中,通信拓扑网络发生变化、甚至故障等不利情况,研究变拓扑网络结构下基于 ADP 技术的多弹分布式自适应最优协同制导,将进一步完善 ADP 技术在协同制导中的应用;

(5) 在多弹协同制导过程中,如何保证各枚导弹在攻击机动目标之前不会发生误打、误撞等问题,将对协同制导方案的工程应用具有十分重要的意义。但现如今对该课题的研究成果并不多见。如何利用 ADP 技术,在考虑上述问题的前提下,研究多弹分布式自适应最优制导是一个值得深入探索的课题。

参考文献

- [1] 刁兆师. 导弹精确高效末制导与控制若干关键技术研究, [博士学位论文]. 北京: 北京理工大学, 2015.
- [2] 李运迁. 大气层内拦截弹制导控制及一体化研究, [博士学位论文]. 哈尔滨: 哈尔滨工业大学, 2011.
- [3] 孙传鹏. 基于博弈论的拦截制导问题研究, [硕士学位论文]. 哈尔滨: 哈尔滨工业大学, 2014.
- [4] 张友安, 黄诒, 王丽英. 约束条件下的末制导律研究进展. 海军航空工程学院学报, 2013, (06): 581-586.
- [5] 谭拂晓, 刘德荣, 关新平, et al. 基于微分对策理论的非线性控制回顾与展望. 自动化学报, 2014, 40(01): 1-15.
- [6] 张化光, 张欣, 罗艳红, et al. 自适应动态规划综述. 自动化学报, 2013, (04): 303-311.
- [7] 刘德荣, 李宏亮, 王鼎. 基于数据的自学习优化控制: 研究进展与展望. 自动化学报, 2013, 39(11): 1858-1870.
- [8] D. Wang, H. B. He, D. R. Liu. Adaptive critic nonlinear robust control: A survey. IEEE Transactions on Cybernetics, 2017, 47(10): 3429-3451.
- [9] B. Kiumarsi, K. G. Vamvoudakis, H. Modares, et al. Optimal and autonomous control using reinforcement learning: A survey. IEEE Transactions on Neural Networks and Learning Systems, 2018, 29(6): 2042-2062.
- [10] P. Werbos. Beyond regression : new tools for prediction and analysis in the behavioral sciences, [PhD thesis], Massachusetts: Harvard University, 1974.
- [11] D. V. Prokhorov, D. C. Wunsch. Adaptive critic designs. IEEE Transactions on Neural Networks, 1997, 8(5): 997-1007.
- [12] R. Padhi, N. Unnikrishnan, X. Wang, et al. A single network adaptive critic (SNAC) architecture for optimal control synthesis for a class of nonlinear systems. Neural Networks, 2006, 19(10): 1648-1660.
- [13] Y. H. Luo, Q. Y. Sun, H. G. Zhang, et al. Adaptive critic design-based robust neural network control for nonlinear distributed parameter systems with unknown dynamics. Neurocomputing, 2015, 148: 200-208.
- [14] Y. Wang, B. O'donoghue, S. Boyd. Approximate dynamic programming via iterated Bellman

- inequalities. *International Journal of Robust and Nonlinear Control*, 2015, 25(10): 1472-1496.
- [15] 魏庆来. 基于近似动态规划的非线性系统最优控制研究, [博士学位论文]. 沈阳: 东北大学, 2009.
- [16] L. Buşoniu, B. De Schutter, R. Babuška. Approximate dynamic programming and reinforcement learning, *Interactive collaborative information systems*: Springer, 2010: 3-44.
- [17] D. P. Bertsekas, J. N. Tsitsiklis. Neuro-dynamic programming: an overview. *Proceedings of the 34th IEEE Conference on Decision and Control*, New Orleans, LA : IEEE, 1995: 560-564.
- [18] L. M. Zhu, H. Modares, G. O. Peen, et al. Adaptive suboptimal output-feedback control for linear systems using integral reinforcement learning. *IEEE Transactions on Control Systems Technology*, 2015, 23(1): 264-273.
- [19] Bhasin S. Reinforcement learning and optimal control methods for uncertain nonlinear systems, [PhD thesis]. Gainesville: University of Florida, 2011.
- [20] B. Luo, H. N. Wu, T. W. Huang, et al. Reinforcement learning solution for HJB equation arising in constrained optimal control problem. *Neural Networks*, 2015, 71: 150-158.
- [21] D. Vrabie, K. G. Vamvoudakis, F. L. Lewis. *Optimal Adaptive Control and Differential Games by Reinforcement Learning Principles*. London: IET, 2013.
- [22] H. G. Zhang, D. R. Liu, Y. H. Luo, et al. *Adaptive Dynamic Programming for Control: Algorithms and Stability*. New York Dordrecht: Springer Science & Business Media, 2012.
- [23] F. L. Lewis, D. R. Liu. *Reinforcement Learning and Approximate Dynamic Programming for Feedback Control*. Piscataway: IEEE Press Computational Intelligence, 2013.
- [24] D. R. Liu, Q. L. Wei, D. Wang, et al. *Adaptive Dynamic Programming with Applications in Optimal Control*. Switzerland: Springer, 2017.
- [25] S. G. Khan, G. Herrmann, F. L. Lewis, et al. Reinforcement learning and optimal adaptive control: An overview and implementation examples. *Annual Reviews in Control*, 2012, 36(1): 42-59.
- [26] 赵冬斌, 刘德荣, 易建强. 基于自适应动态规划的城市交通信号优化控制方法综述. *自动化学报*, 2009, (06): 676-681.
- [27] Z. P. Jiang, Y. Jiang. Robust adaptive dynamic programming for linear and nonlinear systems: An overview. *European Journal of Control*, 2013, 19(5): 417-425.
- [28] D. Vrabie, O. Pastravanu, M. Abu-Khalaf, et al. Adaptive optimal control for continuous-time linear systems based on policy iteration. *Automatica*, 2009, 45(2): 477-484.
- [29] D. Vrabie, F. L. Lewis. Neural network approach to continuous-time direct adaptive optimal control for partially unknown nonlinear systems. *Neural Networks*, 2009, 22(3): 237-46.

- [30] K. G. Vamvoudakis, F. L. Lewis Online actor-critic algorithm to solve the continuous-time infinite horizon optimal control problem. *Automatica*, 2010, 46(5): 878-888.
- [31] 崔黎黎. 基于神经网络的近似动态规划理论及其应用研究, [博士学位论文]. 沈阳: 东北大学, 2011.
- [32] 张欣. 基于神经网络的非仿射非线性系统近似最优控制研究, [博士学位论文]. 沈阳: 东北大学, 2012.
- [33] 宋睿卓. 基于自适应动态规划的几类非线性时滞系统最优化控制方法研究, [博士学位论文]. 沈阳: 东北大学, 2011.
- [34] 曹宁. 基于自适应动态规划的一类非线性奇异摄动系统次优控制研究, [博士学位论文]. 沈阳: 东北大学, 2009.
- [35] D. Wang, D. R. Liu, H. L. Li, et al. Neural-network-based robust optimal control design for a class of uncertain nonlinear systems via adaptive dynamic programming. *Information Sciences*, 2014, 282(0): 167-179.
- [36] D. Wang, D. R. Liu, C. X. Mu, et al. Neural network learning and robust stabilization of nonlinear systems with dynamic uncertainties. *IEEE Transactions on Neural Networks and Learning Systems*, 2018, 29(4): 1342-1351.
- [37] D. Wang, C. X. Mu. Adaptive-critic-based robust trajectory tracking of uncertain dynamics and its application to a spring-mass-damper system. *IEEE Transactions on Industrial Electronics*, 2018, 65(1): 654-663.
- [38] C. X. Mu, D. Wang. Neural-network-based adaptive guaranteed cost control of nonlinear dynamical systems with matched uncertainties. *Neurocomputing*, 2017, 245: 46-54.
- [39] Q. L. Wei, D. R. Liu, Q. Lin. Discrete-time local value iteration adaptive dynamic programming: Admissibility and termination analysis. *IEEE Transactions on Neural Networks and Learning Systems*, 2017, 28(11): 2490-2502.
- [40] Q. L. Wei, D. R. Liu, F. L. Lewis, et al. Mixed iterative adaptive dynamic programming for optimal battery energy control in smart residential microgrids. *IEEE Transactions on Industrial Electronics*, 2017, 64(5): 4110-4120.
- [41] Q. L. Wei, D. R. Liu. Data-driven neuro-optimal temperature control of water-gas shift reaction using stable iterative adaptive dynamic programming. *IEEE Transactions on Industrial Electronics*, 2014, 61(11): 6399-6408.
- [42] Q. L. Wei, D. R. Liu, Q. Lin. Value iteration adaptive dynamic programming for optimal control of discrete-time nonlinear systems. *IEEE Transactions on Cybernetics*, 2016, 46(3): 840-853.

- [43] Q. L. Wei, D. R. Liu. Adaptive dynamic programming for optimal tracking control of unknown nonlinear systems with application to coal gasification. *IEEE Transactions on Automation Science and Engineering*, 2014, 11(4): 1020-1036.
- [44] Y. Jiang, Z. P. Jiang. Robust approximate dynamic programming and global stabilization with nonlinear dynamic uncertainties. *Proceedings of 50th IEEE Conference on Decision and Control and European Control Conference, Orlando, FL, USA : IEEE*, 2011: 115-120.
- [45] Y. Jiang, Z. P. Jiang. Robust adaptive dynamic programming and feedback stabilization of nonlinear systems. *IEEE Transactions on Neural Networks and Learning Systems*, 2014, 25(5): 882-93.
- [46] W. N. Gao, Z. P. Jiang, K. Ozbay. Data-driven adaptive optimal control of connected vehicles. *IEEE Transactions on Intelligent Transportation Systems*, 2017, 18(5): 1122-1133.
- [47] T. Bian, Z. P. Jiang. Value iteration and adaptive dynamic programming for data-driven adaptive optimal control design. *Automatica*, 2016, 71: 348-360.
- [48] W. N. Gao, Z. P. Jiang. Learning-based adaptive optimal tracking control of strict-feedback nonlinear systems. *IEEE Transactions on Neural Networks and Learning Systems*, 2018, 29(6): 2614-2624.
- [49] K. K. Sun, Y. M. Li, S. C. Tong. Fuzzy adaptive output feedback optimal control design for strict-feedback nonlinear systems. *IEEE Transactions on Systems Man Cybernetics-Systems*, 2017, 47(1): 33-44.
- [50] K. K. Sun, S. Sui, S. C. Tong. Optimal adaptive fuzzy FTC design for strict-feedback nonlinear uncertain systems with actuator faults. *Fuzzy Sets and Systems*, 2017, 316: 20-34.
- [51] Y. M. Li, K. K. Sun, S. C. Tong. Observer-based adaptive fuzzy fault-tolerant optimal control for SISO nonlinear systems. *IEEE Transactions on Cybernetics*, 2018, 49(2): 649-661.
- [52] K. K. Sun, S. Sui, S. C. Tong. Fuzzy adaptive decentralized optimal control for strict feedback nonlinear large-scale systems. *IEEE Transactions on Cybernetics* 2018, 48(4): 1326-1339.
- [53] S. C. Tong, K. K. Sun, S. Sui. Observer-based adaptive fuzzy decentralized optimal control design for strict-feedback nonlinear large-scale systems. *IEEE Transactions on Fuzzy Systems*, 2018, 26(2): 569-584.
- [54] D. Wang, D. R. Liu, Q. C. Zhang, et al. Data-based adaptive critic designs for nonlinear robust optimal control with uncertain dynamics. *IEEE Transactions on Systems, Man, and Cybernetics: Systems*, 2016, 46(11): 1544-1555.
- [55] D. R. Liu, D. Wang, F. Y. Wang, et al. Neural-network-based online HJB solution for optimal

- robust guaranteed cost control of continuous-time uncertain nonlinear systems. IEEE Transactions on Cybernetics, 2014, 44(12): 2834-2847.
- [56] 屈秋霞, 罗艳红, 张化光. 针对时变轨迹的非线性仿射系统的鲁棒近似最优跟踪控制. 控制理论与应用, 2016, 33(1): 77-84.
- [57] X. Yang, H. B. He, X. N. Zhong. Adaptive dynamic programming for robust regulation and its application to power systems. IEEE Transactions on Industrial Electronics, 2018, 65(7): 5722-5732.
- [58] X. Yang, H. B. He. Self-learning robust optimal control for continuous-time nonlinear systems with mismatched disturbances. Neural Networks, 2018, 99: 19-30.
- [59] Q. Y. Fan, G. H. Yang. Adaptive actor-critic design-based integral sliding-mode control for partially unknown nonlinear systems with input disturbances. IEEE Transactions on Neural Networks and Learning Systems, 2016, 27(1): 165-177.
- [60] H. G. Zhang, Q. X. Qu, G. Y. Xiao, et al. Optimal guaranteed cost sliding mode control for constrained-input nonlinear systems with matched and unmatched disturbances. IEEE Transactions on Neural Networks and Learning Systems, 2018, 29(6): 2112-2126.
- [61] R. Z. Song, F. L. Lewis, Q. L. Wei, et al. Off-policy actor-critic structure for optimal control of unknown systems with disturbances. IEEE Transactions on Cybernetics, 2016, 46(5): 1041-1050.
- [62] S. Bhasin, R. Kamalapurkar, M. Johnson, et al. A novel actor-critic-identifier architecture for approximate optimal control of uncertain nonlinear systems. Automatica, 2013, 49(1): 82-92.
- [63] D. R. Liu, Y. Z. Huang, D. Wang, et al. Neural-network-observer-based optimal control for unknown nonlinear systems using adaptive dynamic programming. International Journal of Control, 2013, 86(9): 1554-1566.
- [64] Y. F. Lv, J. Na, Q. M. Yang, et al. Online adaptive optimal control for continuous-time nonlinear systems with completely unknown dynamics. International Journal of Control, 2016, 89(1): 99-112.
- [65] B. Luo, H. N. Wu, T. W. Huang, et al. Data-based approximate policy iteration for affine nonlinear continuous-time optimal control design. Automatica, 2014, 50(12): 3281-3290.
- [66] X. Yang, D. R. Liu, B. Luo, et al. Data-based robust adaptive control for a class of unknown nonlinear constrained-input systems via integral reinforcement learning. Information Sciences, 2016, 369: 731-747.
- [67] F. Y. Wang, N. Jin, D. R. Liu, et al. Adaptive dynamic programming for finite-horizon optimal

- control of discrete-time nonlinear systems with ε -error bound. IEEE Transactions on Neural Networks, 2011, 22(1): 24-36.
- [68] D. Wang, D. R. Liu, Q. L. Wei. Finite-horizon neuro-optimal tracking control for a class of discrete-time nonlinear systems using adaptive dynamic programming approach. Neurocomputing, 2012, 78(1): 14-22.
- [69] A. Heydari, S. N. Balakrishnan. Finite-horizon control-constrained nonlinear optimal control using single network adaptive critics. IEEE Transactions on Neural Networks and Learning Systems, 2013, 24(1): 145-157.
- [70] Q. M. Zhao. Finite-horizon optimal control of linear and a class of nonlinear systems, [PhD thesis]. Rolla: Missouri University of Science and Technology, 2013.
- [71] H. Xu, Q. M. Zhao, T. Dierks, et al. Neural network-based finite-horizon approximately optimal control of uncertain affine nonlinear continuous-time systems. Proceedings of American Control Conference, Portland, Oregon, USA : IEEE, 2014: 1243-1248.
- [72] H. Xu. Finite-horizon near optimal design of nonlinear two-player zero-sum game in presence of completely unknown dynamics. Journal of Control, Automation and Electrical Systems, 2015, 26(4): 361-370.
- [73] H. Xu, S. Jagannathan. Neural network-based finite horizon stochastic optimal control design for nonlinear networked control systems. IEEE Transactions on Neural Networks and Learning Systems, 2015, 26(3): 472-485.
- [74] H. Xu, Q. M. Zhao, S. Jagannathan. Finite-horizon near-optimal output feedback neural network control of quantized nonlinear discrete-time systems with input constraint. IEEE Transactions on Neural Networks and Learning Systems, 2015, 26(8): 1776-88.
- [75] H. M. Guzey, H. Xu, J. Sarangapani. Neural network-based finite horizon optimal adaptive consensus control of mobile robot formations. Optimal Control Applications and Methods, 2015, 37(5): 1014-1034.
- [76] H. G. Zhang, X. H. Cui, Y. H. Luo, et al. Finite-horizon H_∞ tracking control for unknown nonlinear systems with saturating actuators. IEEE Transactions on Neural Networks and Learning Systems, 2018, 29(4): 1200-1212.
- [77] H. N. Wu, M. M. Li, L. Guo. Finite-horizon approximate optimal guaranteed cost control of uncertain nonlinear systems with application to mars entry guidance. IEEE Transactions on Neural Networks and Learning Systems, 2015, 26(7): 1456-1467.
- [78] M. Abu-Khalaf, F. L. Lewis. Nearly optimal control laws for nonlinear systems with saturating

- p>actuators using a neural network HJB approach.
- Automatica*
- , 2005, 41(5): 779-791.
- [79] M. Abu-Khalaf, F. L. Lewis, H. Jie. Neurodynamic programming and zero-sum games for constrained control systems. *IEEE Transactions on Neural Networks*, 2008, 19(7): 1243-1252.
 - [80] H. G. Zhang, Y. H. Luo, D. R. Liu. Neural-network-based near-optimal control for a class of discrete-time affine nonlinear systems with control constraints. *IEEE Transactions on Neural Networks*, 2009, 20(9): 1490-1503.
 - [81] X. Yang, D. R. Liu, Y. Z. Huang. Neural-network-based online optimal control for uncertain non-linear continuous-time systems with control constraints. *IET Control Theory and Applications*, 2013, 7(17): 2037-2047.
 - [82] X. Yang, D. R. Liu, D. Wang. Reinforcement learning for adaptive optimal control of unknown continuous-time nonlinear systems with input constraints. *International Journal of Control*, 2014, 87(3): 553-566.
 - [83] H. Modares, F. L. Lewis. Optimal tracking control of nonlinear partially-unknown constrained input systems using integral reinforcement learning. *Automatica*, 2014, 50(7): 1780-1792.
 - [84] H. Modares, F. L. Lewis, M. B. Naghibi-Sistani. Integral reinforcement learning and experience replay for adaptive optimal control of partially-unknown constrained-input continuous-time systems. *Automatica*, 2014, 50(1): 193-202.
 - [85] D. R. Liu, X. Yang, D. Wang, et al. Reinforcement-learning-based robust controller design for continuous-time uncertain nonlinear systems subject to input constraints. *IEEE Transactions on Cybernetics*, 2015, 45(7): 1372-85.
 - [86] K. G. Vamvoudakis, M. F. Miranda, J. P. Hespanha. Asymptotically stable adaptive-optimal control algorithm with saturating actuators and relaxed persistence of excitation. *IEEE Transactions on Neural Networks and Learning Systems*, 2016, 27(11): 2386-2398.
 - [87] Q. Y. Fan, G. H. Yang. Nearly optimal sliding mode fault-tolerant control for affine nonlinear systems with state constraints. *Neurocomputing*, 2016, 216: 78-88.
 - [88] Q. Y. Fan, G. H. Yang. Adaptive nearly optimal control for a class of continuous-time nonaffine nonlinear systems with inequality constraints. *ISA Transactions*, 2017, 66: 122-133.
 - [89] Q. Y. Fan, G. H. Yang, D. Ye. Quantization-based adaptive actor-critic tracking control with tracking error constraints. *IEEE Transactions on Neural Networks and Learning Systems*, 2018, 29(4): 970-980.
 - [90] H. G. Zhang, Q. L. Wei, D. R. Liu. An iterative adaptive dynamic programming method for solving a class of nonlinear zero-sum differential games. *Automatica*, 2011, 47(1): 207-214.

- [91] H. G. Zhang, L. L. Cui, Y. H. Luo. Near-optimal control for nonzero-sum differential games of continuous-time nonlinear systems using single-network ADP. IEEE Transactions on Cybernetics, 2013, 43(1): 206-216.
- [92] K. G. Vamvoudakis, F. L. Lewis. Online solution of nonlinear two-player zero-sum games using synchronous policy iteration. International Journal of Robust and Nonlinear Control, 2012, 22(13): 1460-1483.
- [93] H. Modares, F. L. Lewis, M. B. N Sistani. Online solution of nonquadratic two-player zero-sum games arising in the H_∞ control of constrained input systems. International Journal of Adaptive Control and Signal Processing, 2014, 28(3-5): 232-254.
- [94] D. B. Zhao, Q. C. Zhang, D. Wang, et al. Experience replay for optimal control of nonzero-sum game systems with unknown dynamics. IEEE Transactions on Cybernetics, 2016, 46(3): 854-865.
- [95] H. Jiang, H. G. Zhang, G. Y. Xiao, et al. Data-based approximate optimal control for nonzero-sum games of multi-player systems using adaptive dynamic programming. Neurocomputing, 2018, 275: 192-199.
- [96] Q. C. Zhang, D. B. Zhao. Data-based reinforcement learning for nonzero-sum games with unknown drift dynamics. IEEE Transactions on Cybernetics, 2018, DOI: 10.1109/TCYB.2018.2830820.
- [97] H. Jiang, H. G. Zhang, Y. H. Luo, et al. H_∞ control with constrained input for completely unknown nonlinear systems using data-driven reinforcement learning method. Neurocomputing, 2017, 237: 226-234.
- [98] R. Z. Song, F. L. Lewis, Q. L. Wei. Off-policy integral reinforcement learning method to solve nonlinear continuous-time multiplayer nonzero-sum games. IEEE Transactions on Neural Networks and Learning Systems, 2017, 28(3): 704-713.
- [99] Y. H. Zhu, D. B. Zhao, X. Yang, et al. Policy iteration for H_∞ optimal control of polynomial nonlinear systems via sum of squares programming. IEEE Transactions on Cybernetics, 2018, 48(2): 500-509.
- [100] D. Wang, C. X. Mu, Q. C. Zhang, et al. Event-based input-constrained nonlinear H_∞ state feedback with adaptive critic and neural implementation. Neurocomputing, 2016, 214: 848-856.
- [101] D. Wang, H. B. He, D. R. Liu. Improving the critic learning for event-based nonlinear H_∞ control design. IEEE Transactions on Cybernetics, 2017, 47(10): 3417-3428.
- [102] Q. C. Zhang, D. B. Zhao, Y. H. Zhu. Event-triggered H_∞ control for continuous-time nonlinear

- system via concurrent learning. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2017, 47(7): 1071-1081.
- [103] D. Wang, C. X. Mu, X. Yang, et al. Event-based constrained robust control of affine systems incorporating an adaptive critic mechanism. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2017, 47(7): 1602-1612.
- [104] D. Wang, D. R. Liu. Learning and guaranteed cost control with event-based adaptive critic implementation. IEEE Transactions on Neural Networks and Learning Systems, 2018, 29(12): 6004-6014.
- [105] D. Wang, C. X. Mu, D. R. Liu, et al. On mixed data and event driven design for adaptive-critic-based nonlinear H_∞ control. IEEE Transactions on Neural Networks and Learning Systems, 2018, 29(4): 993-1005.
- [106] X. Yang, H. B. He. Adaptive critic designs for event-triggered robust control of nonlinear systems with unknown dynamics. IEEE Transactions on Cybernetics, 2018, DOI: 10.1109/TCYB.2018.2823199.
- [107] X. Yang, H. B. He, Q. L. Wei. An adaptive critic approach to event-triggered robust control of nonlinear systems with unmatched uncertainties. International Journal of Robust and Nonlinear Control, 2018, DOI:10.1002/rnc.4096.
- [108] Q. C. Zhang, D. B. Zhao, D. Wang. Event-based robust control for uncertain nonlinear systems using adaptive dynamic programming. IEEE Transactions on Neural Networks and Learning Systems, 2018, 29(1): 37-50.
- [109] L. Dong, X. N. Zhong, C. Y. Sun, et al. Adaptive event-triggered control based on heuristic dynamic programming for nonlinear discrete-time systems. IEEE Transactions on Neural Networks and Learning Systems, 2017, 28(7): 1594-1605.
- [110] L. Dong, X. N. Zhong, C. Y. Sun, et al. Event-triggered adaptive dynamic programming for continuous-time systems with control constraints. IEEE Transactions on Neural Networks and Learning Systems, 2017, 28(8): 1941-1952.
- [111] 董璐. 基于事件触发自适应动态规划的最优控制方法研究, [博士学位论文]. 南京: 东南大学, 2017.
- [112] K. G. Vamvoudakis, A. Mojoodi, H. Ferraz. Event-triggered optimal tracking control of nonlinear systems. International Journal of Robust and Nonlinear Control, 2017, 27(4): 598-619.
- [113] V. Narayanan, S. Jagannathan. Event-triggered distributed control of nonlinear interconnected

- systems using online reinforcement learning with exploration. IEEE Transactions on Cybernetics, 2018, 48(9): 2510-2519.
- [114] V. Narayanan, S. Jagannathan. Event-triggered distributed approximate optimal state and output control of affine nonlinear interconnected systems. IEEE Transactions on Neural Networks and Learning Systems, 2018, 29(7): 2846-2856.
- [115] V. Narayanan, S. Jagannathan. Distributed event-sampled approximate optimal control of interconnected affine nonlinear continuous-time systems. Proceedings of American Control Conference (ACC), Boston, MA, USA: IEEE, 2016: 3044-3049.
- [116] K. G. Vamvoudakis, F. L. Lewis, G. R. Hudas. Multi-agent differential graphical games: Online adaptive learning solution for synchronization with optimality. Automatica, 2012, 48(8): 1598-1611.
- [117] M. I. Abouheaf, F. L. Lewis, K. G. Vamvoudakis, et al. Multi-agent discrete-time graphical games and reinforcement learning solutions. Automatica, 2014, 50(12): 3038-3053.
- [118] Q. L. Wei, D. R. Liu, F. L. Lewis. Optimal distributed synchronization control for continuous-time heterogeneous multi-agent differential graphical games. Information Sciences, 2015, 317: 96-113.
- [119] Q. L. Wei, D. R. Liu, G. Shi, et al. Multibattery optimal coordination control for home energy management systems via distributed iterative adaptive dynamic programming. IEEE Transactions on Industrial Electronics, 2015, 62(7): 4203-4214.
- [120] H. G. Zhang, J. L. Zhang, G. H. Yang, et al. Leader-based optimal coordination control for the consensus problem of multiagent differential games via fuzzy adaptive dynamic programming. IEEE Transactions on Fuzzy Systems, 2015, 23(1): 152-163.
- [121] Q. Jiao, H. Modares, S. Y. Xu, et al. Multi-agent zero-sum differential graphical games for disturbance rejection in distributed control. Automatica, 2016, 69: 24-34.
- [122] N. T. Luy. Distributed cooperative H_∞ optimal tracking control of MIMO nonlinear multi-agent systems in strict-feedback form via adaptive dynamic programming. International Journal of Control, 2017, 91(4): 952-968.
- [123] N. T. Luy. Adaptive dynamic programming-based design of integrated neural network structure for cooperative control of multiple MIMO nonlinear systems. Neurocomputing, 2017, 237: 12-24.
- [124] N. T. Luy. Distributed optimal integrated tracking control for separate kinematic and dynamic uncertain non-holonomic mobile mechanical multi-agent systems. IET Control Theory and

- Applications, 2017, 11(18): 3249-3260.
- [125] N. T. Luy. Distributed optimal control for nonholonomic systems with input constraints and uncertain interconnections. *Nonlinear Dynamics*, 2018, DOI: 10.1007/s11071-018-4228-8.
- [126] G. X. Wen, C. L. P. Chen, J. Feng, et al. Optimized multi-agent formation control based on an identifier-actor-critic reinforcement learning algorithm. *IEEE Transactions on Fuzzy Systems*, 2018, 26(5): 2719-2731.
- [127] H. G. Zhang, H. Jiang, Y. H. Luo, et al. Data-driven optimal consensus control for discrete-time multi-agent systems with unknown dynamics using reinforcement learning method. *IEEE Transactions on Industrial Electronics*, 2017, 64(5): 4091-4100.
- [128] J. L. Zhang, H. G. Zhang, T. Feng. Distributed optimal consensus control for nonlinear multiagent system with unknown dynamic. *IEEE Transactions on Neural Networks and Learning Systems*, 2018, 29(8): 3339-3348.
- [129] 杨永亮. 无模型自适应动态规划及其在多智能体协同控制中的应用, [博士学位论文]. 北京: 北京科技大学, 2018
- [130] G. K. Venayagamoorthy, R. G. Harley, D. C. Wunsch. Dual heuristic programming excitation neurocontrol for generators in a multimachine power system. *IEEE Transactions on Industry Applications*, 2003, 39(2): 382-394.
- [131] P. J. Wook, R. G. Harley, G. K. Venayagamoorthy. Adaptive-critic-based optimal neurocontrol for synchronous generators in a power system using MLP/RBF neural networks. *IEEE Transactions on Industry Applications*, 2003, 39(5): 1529-1540.
- [132] Q. L. Wei, D. R. Liu, G. Shi. A novel dual iterative Q-learning method for optimal battery management in smart residential environments. *IEEE Transactions on Industrial Electronics*, 2015, 62(4): 2509-2518.
- [133] D. Ernst, M. Glavic, F. Capitanescu, et al. Reinforcement learning versus model predictive control: A comparison on a power system problem. *IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics)*, 2009, 39(2): 517-529.
- [134] S. N. Balakrishnan, V. Biega. Adaptive-critic-based neural networks for aircraft optimal control. *Journal of Guidance, Control, and Dynamics*, 1996, 19(4): 893-898.
- [135] R. Enns, J. Si. Apache helicopter stabilization using neural dynamic programming. *Journal of Guidance Control and Dynamics*, 2002, 25(1): 19-25.
- [136] R. Enns, S. Jennie. Helicopter trimming and tracking control using direct neural dynamic programming. *IEEE Transactions on Neural Networks*, 2003, 14(4): 929-939.

- [137] S. Ferrari, R. F. Stengel. Online adaptive critic flight control. *Journal of Guidance, Control, and Dynamics*, 2004, 27(5): 777-786.
- [138] J. Valasek, J. Doebbler, M. D. Tandale, et al. Improved adaptive-reinforcement learning control for morphing unmanned air vehicles. *IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics)*, 2008, 38(4): 1014-1020.
- [139] E. Stingu, F. L. Lewis. An approximate dynamic programming based controller for an underactuated 6DOF quadrotor. *Proceedings of IEEE Symposium on Adaptive Dynamic Programming And Reinforcement Learning (ADPRL)*, Paris, France: IEEE, 2011: 271-278.
- [140] D. Nodland, H. Zargarzadeh, S. Jagannathan. Neural network-based optimal adaptive output feedback control of a helicopter UAV. *IEEE Transactions on Neural Networks and Learning Systems*, 2013, 24(7): 1061-1073.
- [141] Y. Zhou, E. J. V. Kampen, Q. P. Chu. Nonlinear adaptive flight control using incremental approximate dynamic programming and output feedback. *Journal of Guidance, Control, and Dynamics*, 2016, 40(2): 493-500.
- [142] C. X. Mu, Z. Ni, C. Y. Sun, et al. Air-breathing hypersonic vehicle tracking control based on adaptive dynamic programming. *IEEE Transactions on Neural Networks and Learning Systems*, 2017, 28(3): 584-598.
- [143] J. Dalton, S. N. Balakrishnan. A neighboring optimal adaptive critic for missile guidance. *Mathematical and Computer Modelling*, 1996, 23(1): 175-188.
- [144] D. P. Bertsekas, M. L. Homer, D. A. Logan, et al. Missile defense and interceptor allocation by neuro-dynamic programming. *IEEE Transactions on Systems, Man, and Cybernetics - Part A: Systems and Humans*, 2000, 30(1): 42-51.
- [145] D. Han, S. N. Balakrishnan. State-constrained agile missile control with adaptive-critic-based neural networks. *IEEE Transactions on Control Systems Technology*, 2002, 10(4): 481-489.
- [146] C. K. Lin. Adaptive critic autopilot design of Bank-to-turn missiles using fuzzy basis function networks. *IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics)*, 2005, 35(2): 197-207.
- [147] B. Gaudet, R. Furfaro. Missile homing-phase guidance law design using reinforcement learning. *Proceedings of AIAA Guidance, Navigation, and Control Conference*, Minneapolis, Minnesota: AIAA, 2012: P. 4470.
- [148] Q. L. Wei, R. Z. Song, P. F. Yan. Data-driven zero-sum neuro-optimal control for a class of continuous-time unknown nonlinear systems with disturbance using ADP. *IEEE Transactions on*

- Neural Networks and Learning Systems, 2016, 27(2): 444-58.
- [149] Y. Fu, T. Y. Chai. Online solution of two-player zero-sum games for continuous-time nonlinear systems with completely unknown dynamics. IEEE Transactions on Neural Networks and Learning Systems, 2016, 27(12): 2577-2587.
- [150] N. T. Luy. Robust adaptive dynamic programming based online tracking control algorithm for real wheeled mobile robot with omni-directional vision system. Transactions of the Institute of Measurement and Control, 2016, 39(6): 832-847.
- [151] Y. Fu, J. Fu, T. Y. Chai. Robust adaptive dynamic programming of two-player zero-sum games for continuous-time linear systems. IEEE Transactions on Neural Networks and Learning Systems, 2015, 26(12): 3314-3319.
- [152] F. L. Lewis, D. Vrabie, V. L. Syrmos. Optimal Control. Hoboken, New Jersey: Wiley & Sons, 2012: 1045-1206.
- [153] Schaft A.J.V.D. L_2 -gain analysis of nonlinear systems and nonlinear state-feedback H_∞ control. IEEE Transactions on Automatic Control, 1992, 37(6): 770-784.
- [154] T. Dierks, S. Jagannathan. Optimal control of affine nonlinear continuous-time systems. Proceedings of American Control Conference (ACC), Baltimore, MD, USA: IEEE, 2010: 1568-1573.
- [155] F. L. Lewis, A. Yesildirak, S. Jagannathan. Neural Network Control of Robot Manipulators and Nonlinear Systems. Philadelphia PA: Taylor & Francis, Inc., 1999: 161–211.
- [156] R. Bardhan, D. Ghose. Nonlinear differential games-based impact-angle-constrained guidance law. Journal of Guidance, Control, and Dynamics, 2015, 38(3): 384-402.
- [157] 周慧波. 基于有限时间和滑模理论的导引律及多导弹协同制导研究, [博士学位论文]. 哈尔滨: 哈尔滨工业大学, 2015.
- [158] H. Zargarzadeh, T. Dierks, S. Jagannathan. Adaptive neural network-based optimal control of nonlinear continuous-time systems in strict-feedback form. International Journal of Adaptive Control and Signal Processing, 2014, 28(3-5): 305–324.
- [159] H. Zargarzadeh, T. Dierks, S. Jagannathan. Optimal control of nonlinear continuous-time systems in strict-feedback form. IEEE Transactions on Neural Networks and Learning Systems, 2015, 26(10): 2535-2549.
- [160] H. Zargarzadeh, T. Dierks, S. Jagannathan.. State and output feedback-based adaptive optimal control of nonlinear continuous-time systems in strict feedback form. Proceedings of American Control Conference (ACC), Montréal, Canada: IEEE, 2012: 6412-6417.

- [161] M. Chen, G. Tao, B. Jiang. Dynamic surface control using neural networks for a class of uncertain nonlinear systems with input saturation. *IEEE Transactions on Neural Networks and Learning Systems*, 2015, 26(9): 2086-2097.
- [162] P. Lu. Optimal predictive control of continuous nonlinear systems. *International Journal of Control*, 1995, 62(3): 633-649.
- [163] W. H. Chen, D. J. Ballance, P. J. Gawthrop. Optimal control of nonlinear systems: a predictive control approach. *Automatica*, 2003, 39(4): 633-641.
- [164] B. Panchal, J. P. Kolhe, S. E. Talole. Robust predictive control of a class of nonlinear systems. *Journal of Guidance, Control, and Dynamics*, 2014, 37(5): 1437-1445.
- [165] Y. Y. Zhang, S. Li, X. Y. Jiang. Near-optimal control without solving HJB equations and its applications. *IEEE Transactions on Industrial Electronics*, 2018, 65(9): 7173-7184.
- [166] H. K. Khalil. *Nonlinear Systems (Third Edition)*. Upper Saddle River, NJ, USA: Prentice-Hall, 2002.
- [167] I. S. Jeon, J. I. Lee, M. J. Tahk. Homing guidance law for cooperative attack of multiple missiles. *Journal of Guidance, Control, and Dynamics*, 2010, 33(1): 275-280.
- [168] 彭琛, 刘星, 吴森堂, et al. 多弹分布式协同末制导时间一致性研究. *控制与决策*, 2010, 25(10): 1557-1561.
- [169] J. L. Zhou, J. Y. Yang. Distributed guidance law design for cooperative simultaneous attacks with multiple missiles. *Journal of Guidance, Control, and Dynamics*, 2016, 39(10): 2439-2447.
- [170] 赵启伦, 陈建, 董希旺, et al. 拦截高超声速目标的异类导弹协同制导律. *航空学报*, 2016, (03): 936-948.
- [171] J. L. Zhou, Y. Z. Lü, Z. K. Li, et al. Cooperative guidance law design for simultaneous attack with multiple missiles against a maneuvering target. *Journal of Systems Science and Complexity*, 2018, 31(1): 287-301.
- [172] B. Zhu, A. H. B. Zaini, L. H. Xie. Distributed guidance for interception by using multiple rotary-wing unmanned aerial vehicles. *IEEE Transactions on Industrial Electronics*, 2017, 64(7): 5648-5656.
- [173] Q. K. Shen, P. Shi. Distributed command filtered backstepping consensus tracking control of nonlinear multiple-agent systems in strict-feedback form. *Automatica*, 2015, 53: 120-124.
- [174] M. Shahvali, J. Askari. Cooperative adaptive neural partial tracking errors constrained control for nonlinear multi-agent systems. *International Journal of Adaptive Control and Signal Processing*, 2016, 30(7): 1019-1042.

- [175] Z. C. Cao, Q. Xiao, R. Huang, et al. Robust neuro-optimal control of underactuated snake robots with experience replay. *IEEE Transactions on Neural Networks and Learning Systems*, 2018, 29(1): 208-217.
- [176] W. J. Dong, J. A. Farrell, M. M. Polycarpou, et al. Command filtered adaptive backstepping. *IEEE Transactions on Control Systems Technology*, 2012, 20(3): 566-580.
- [177] X. Y. Wang, S. H. Li, J. Lam. Distributed active anti-disturbance output consensus algorithms for higher-order multi-agent systems with mismatched disturbances. *Automatica*, 2016, 74 (Supplement C): 30-37.

致 谢

四年的博士求学生涯即将在此画上休止符，望着窗外星光零落的夜空，往事历历在目，如海潮般向我涌来。四年来，有多少个苦心钻研、废寝忘食的日夜，又有多少次峰回路转、柳暗花明的喜悦，此刻，都已成为我人生中美好的回忆和宝贵的财富。值此论文完成之际，我要向所有帮助过、关心过我的老师，同学及家人表达最真诚的感谢与最美好的祝福。

首先，我要感谢我的恩师刘春生教授。我今天取得的所有成绩都离不开刘老师的亲切关怀和悉心指导。从我论文的选题到后续的研究以及论文的撰写等过程中，无不倾注着刘老师的心血。古人云“温而厉，威而不猛，恭而安”，这就是刘老师的真实写照。在科研中，刘老师以她渊博的知识储备和严谨的治学态度，让我在一次次的徘徊与惆怅中看到了希望，找到了信心，在帮助我攻坚克难的同时，也培养了我戒骄戒躁，勤劳踏实的科研态度；生活中，刘老师更以她慈母般的关怀与无微不至的呵护让我这位远离家乡的学子感受到了来自家的温暖，而这份成长与感动将会化作我今后人生中最美好的回忆。在这里，谨向刘春生老师表达我最衷心的感谢和诚挚的敬意。

其次，感谢 418 实验室的兄弟姐妹们：段丹丹、魏阿龙、单一、李蔚蓝、戴姣、陈燕妮、吴翔、马诚诚、姚家桢、邹怡茹、袁斐然、严鹏等。忘不了与你们争论一个定理面红耳赤最后豁然开朗相视而笑的欣慰；忘不了与他们一起登高远眺指点江山激扬文字，畅谈人生理想的豪情；忘不了与他们在校“优秀研究生实验室”评比过程中群策群力，团结一心最终获得这一荣誉时的喜悦……，四年来，是他们用自己特有的年轻活力与无限热情感染着我，让我时刻保持奋斗的激情。

特别要感谢我的家人，是你们的包容和理解，让我在生活中少了一份担心，在工作中多了一份欣慰，让我在四年博士生涯中，能够心无旁骛、全心全意地投入科研工作中；是你们的支持与鼓励，陪伴我走过了这一人生重要阶段，你们的殷切期望就是我不断前进的动力和源泉。

最后，由衷地感谢所有参与该论文审阅和答辩的专家学者，你们的宝贵意见和建议将为我今后的研究工作指明方向。

孙景亮

2019 年 03 月

在学期间的研究成果及发表的学术论文

攻读博士学位期间发表（录用）期刊论文情况

1. Jingliang Sun, Chunsheng Liu. Distributed fuzzy adaptive backstepping optimal control for nonlinear multi-missile guidance systems with input saturation. *IEEE Transactions on Fuzzy Systems*, 2019, 27(3): 447-461. (SCI, 中科院一区, IF: 8.415, 长文, TOP 期刊)
2. Jingliang Sun, Chunsheng Liu. Distributed zero-sum differential game for multi-agent systems in strict-feedback form with input saturation and output constraint. *Neural Networks*, 2018, 106: 8-19. (SCI, 中科院二区, IF: 7.197, TOP 期刊)
3. Jingliang Sun, Chunsheng Liu. Disturbance observer-based robust missile autopilot design with full-state constraints via adaptive dynamic programming. *Journal of the Franklin Institute*, 2018, 355(5): 2344-2368. (SCI, 中科院二区, IF: 3.576, TOP 期刊)
4. Jingliang Sun, Chunsheng Liu. Backstepping-based adaptive dynamic programming for missile-target guidance systems with state and input constraints. *Journal of the Franklin Institute*, 2018, 355(17): 8412-8440. (SCI, 中科院二区, IF: 3.576, TOP 期刊)
5. Jingliang Sun, Chunsheng Liu. Backstepping-based adaptive predictive optimal control of nonlinear systems with application to missile-target engagement. *ISA Transactions*, 2018, 83: 42-52. (SCI, 中科院二区, IF: 3.370)
6. Jingliang Sun, Chunsheng Liu, Xia Zhao. Backstepping-based zero-sum differential games for missile-target interception systems with input and output constraints. *IET Control Theory and Applications*, 2018, 12(2): 243-253. (SCI, 中科院三区, IF: 3.296)
7. Jingliang Sun, Chunsheng Liu. Finite-horizon differential games for missile-target interception system using adaptive dynamic programming with input constraints. *International Journal of Systems Science*, 2018, 49(2): 264-283. (SCI, 中科院三区, IF: 2.185)
8. Jingliang Sun, Chunsheng Liu. Decentralized zero-sum differential game for a class of large-scale interconnected systems via adaptive dynamic programming. *International Journal of Control*, DOI: 10.1080/00207179.2018.1466059. (SCI, 中科院三区, IF: 2.101)
9. Jingliang Sun, Chunsheng Liu. Adaptive dynamic surface-based differential games for a class of pure-feedback nonlinear systems with output constraints. *International Journal of Control*, DOI: 10.1080/00207179.2018.1503724. (SCI, 中科院三区, IF: 2.101)
10. Jingliang Sun, Chunsheng Liu, Nian Liu. Data-driven adaptive critic approach for nonlinear

- optimal control via least square support vector machine. *Asian Journal of Control*, 2018, 20(1): 104-114. (SCI, 中科院三区, IF: 1.528)
11. Jingliang Sun, Chunsheng Liu, Qing Ye. Robust differential game guidance laws design for uncertain interceptor-target engagement via adaptive dynamic programming. *International Journal of Control*, 2017, 90(5): 990-1004. (SCI, 中科院三区, IF: 2.101)
12. Jingliang Sun, Chunsheng Liu. Optimal obstacle avoidance via distributed consensus algorithms with communication delay. *Journal of Systems Engineering and Electronics*, 2016, 27(6): 1272-1282. (SCI, 中科院四区, IF: 0.572)
13. Qing Ye, Chunsheng Liu, Jingliang Sun. A backstepping-based guidance law for an exoatmospheric missile. *IEEE Transactions on Aerospace and Electronic Systems*, DOI: 10.1109/TAES.2018.2852419 (SCI, 中科院三区, IF: 2.063)
14. Jiao Dai, Chunsheng Liu, Jingliang Sun. Adaptive optimal fault-tolerant control scheme for a class of strict-feedback nonlinear systems. *Transactions of the Institute of Measurement and Control*, DOI: 10.1177/0142331218786529. (SCI, 中科院四区, IF: 1.579)
15. 孙景亮, 刘春生. 基于自适应动态规划的导弹制导律研究综述. *自动化学报*, 2017, 43(7): 1101-1113. (重要核心期刊, EI)
16. Jingliang Sun, Chunsheng Liu, Nian Liu. Policy iteration based optimal control for partially unknown nonlinear systems via semi-parametric regression model. *International Journal of Machine Learning and Computing*, 2016, 6(3):172-178. (EI)
17. 孙景亮, 刘春生, 史浩明. 基于动态势场法的最优一致性避障算法研究. *飞行力学*, 2015, 33(4): 376-380. (核心期刊)
18. 陈燕妮, 刘春生, 孙景亮. 基于自适应优化的有限时间微分对策制导律. *控制理论与应用*. (已录用, 重要核心期刊, EI)
19. 吴翔, 刘春生, 孙景亮. 基于 ADP 的导引控制一体化全状态受限反演控制. *信息与控制*, 2018. (已录用, 核心期刊)
20. 戴姣, 刘春生, 孙景亮. 基于自适应动态规划的一类非线性系统的容错控制器设计. *电光与控制*, 2018, 25(10): 84-88. (核心期刊)
21. 魏阿龙, 刘春生, 孙景亮. 不确定非线性多智能体系统的最优协同控制. *电光与控制*, 2018, 25(9): 12-16,48. (核心期刊)
22. 刘念, 刘春生, 孙景亮. 自适应动态规划算法在飞行器追逃中的应用. *飞行力学*, 2016, 34(6): 45-48+62. (核心期刊)

攻读博士学位期间发表（录用）会议论文情况

1. Jingliang Sun, Chunsheng Liu. Distributed zero-sum differential game for multi-agent nonlinear system via adaptive dynamic programming, 37th Chinese Control Conference (CCC), July 25-27, 2018: 2770-2775, Wuhan, China. (EI 检索)
2. Jingliang Sun, Chunsheng Liu. Adaptive neural control with prescribed performance for strict-feedback systems with input saturation, IEEE Chinese Guidance, Navigation and Control Conference (CGNCC), Aug. 10-12, 2018, Xiamen, China. (EI 检索)
3. Jingliang Sun, Chunsheng Liu, Jiao Dai. Robust optimal control for missile-target guidance systems via adaptive dynamic programming, 2018 Chinese Automation Congress (CAC), Nov. 30-Dec. 2, 2018: 836-841, Xi'an, China. (EI 检索)
4. Jingliang Sun, Chunsheng Liu. Zero-sum differential games for nonlinear systems using adaptive dynamic programming with input constraint. 36th Chinese Control Conference (CCC), July 26-28, 2017: 2501-2506, Dalian, China. (EI 检索)
5. Jingliang Sun, Chunsheng Liu, Along Wei. Robust zero-sum differential game for uncertain nonlinear systems via adaptive dynamic programming. IEEE Chinese Guidance, Navigation and Control Conference (CGNCC), Aug. 12-14, 2016: 1387-1392, Nanjing, China, 2016. (EI 检索)
6. Jingliang Sun, Chunsheng Liu, Ke Lu, Haoming Shi. Optimal robust control for attitude of quad-rotor aircraft based on SDRE. 34th Chinese Control Conference (CCC), July 28-30, 2015: 2333-2337, Hangzhou, China. (EI 检索)
7. Yanni Chen, Chunsheng Liu, Jingliang Sun. Finite-time differential game for nonlinear systems using adaptive dynamic programming. IEEE Chinese Guidance, Navigation and Control Conference (CGNCC), Aug. 10-12, 2018, Xiamen, China. (EI 检索)
8. Jiao Dai, Chunsheng Liu, Jingliang Sun. Distributed differential game for nonlinear multiagent systems with unknown actuator faults and disturbance, 2018 Chinese Automation Congress (CAC), Nov. 30-Dec. 2, 2018: 847-852, Xi'an, China. (EI 检索)

已投稿期刊论文情况

1. Jingliang Sun, Chunsheng Liu. Distributed adaotive optimal control of strict-feedback nonlinear systems with application to multi-missile cooperative guidance. International Journal of Robust and Nonlinear Control. (稿件号: RNC-19-0204, 二审, SCI 检索)
2. Jingliang Sun, Chunsheng Liu. Event-driven distributed adaptive optimal design for nonlinear

multi-missile guidance systems under directed topology. IEEE Transactions on Neural Networks and Learning Systems. (稿件号: TNNLS-2018-P-9821, 审稿中, SCI 检索)

3. Jingliang Sun, Chunsheng Liu. Adaptive optimal backstepping control for uncertain nonlinear guidance systems subject to input constraints. ISA Transactions. (稿件号: ISATRANS-D-19-00232, 审稿中, SCI 检索)

攻读博士学位期间申请发明专利情况

1. 孙景亮, 刘春生, 魏阿龙. 一种基于数据驱动单网络结构的最优控制方法. 发明专利, 专利号: ZL201511025977.X, 授权日期: 2018.05.08
2. 孙景亮, 刘春生, 单一, 魏阿龙. 一种基于自适应动态规划的输入受限微分对策制导方法. 发明专利, 专利号: ZL201710089678.5, 授权日期: 2019.02.12
3. 魏阿龙, 刘春生, 孙景亮. 一种基于在线数据的同步策略更新最优控制方法. 发明专利, 专利公开: CN108181816A
4. 单一, 刘春生, 孙景亮, 李蔚蓝. 基于视觉的旋翼无人机稳定跟踪目标的控制系统及方法. 发明专利, 专利公开号: CN106774436A
5. 戴姣, 刘春生, 孙景亮. 一种基于自适应动态规划的分布式最优协同容错控制方法. 发明专利, 专利公开号: CN108828949A.
6. 单一, 刘春生, 李蔚蓝, 孙景亮. 一种旋翼无人机在移动目标上自主着陆的控制方法. 发明专利, 专利公开号: CN107515622A
7. 单一, 刘春生, 李蔚蓝, 孙景亮. 基于视觉的旋翼无人机稳定跟踪目标的控制系统. 实用新型专利, 授权号: CN206532142U.

攻读博士学位期间参加科研项目情况

1. 国家自然科学基金项目: “无尾飞翼布局飞行器的操纵面故障强化学习最优自适应补偿控制研究”, 项目编号: 61473147, 主要研究人员。
2. 江苏省普通高校学术学位研究生科研创新计划项目: “基于微分对策的鲁棒自适应动态规划拦截制导研究”, 项目编号: KYLX16_0376, 项目负责人。
3. 南京航空航天大学博士学位论文创新与创优基金: “基于微分对策的自适应动态规划制导及多弹协同拦截方法研究”, 项目编号: BCXJ16-02, 项目负责人。
4. 江西省教育厅科技项目: “基于 DSP 的四旋翼飞行器视觉导航避障系统研究”, 项目编号: GJJ151290, 主要研究人员 (排名第二)。
5. 江西省教育厅科技项目: “基于视觉辅助技术的无人机自主着陆系统研究”, 项目编号:

GJJ151286, 主要研究人员 (排名第二)。